

Martes 21 de Abril de 2026

1. Anteproxecto

1.1. Título

Interpretabilidade e explicabilidade mediante técnicas de Aprendizaxe Profundo de caixa branca aplicadas ó análise de imaxe

1.2. Breve descripción

Na actualidade, as Redes de Neuronas Artificiais demostraron unha efectividade excelente nunha gran cantidade de tarefas. Con todo os modelos actuais funcionan como unha caixa negra polo que en xeral non é posible interpretar os mecanismos cos que resolven os problemas plantexados. Esta limitación cara a interpretabilidade e explicabilidade dos sistemas vólvese crítica en sistemas de alto risco como o diagnóstico clínico, a xestión do emprego ou o deseño de componentes de seguridade, xa que restrinxe o seu uso no marco legal da Unión Europea.

Nos derradeiros anos diferentes liñas de investigación procuraron solventar estes problemas. No ámbito do procesamento da imaxe xurdiron diferentes liñas de investigación, entre elas as chamadas de Caixa Blanca que teñen como obxectivo ser interpretables por deseño. Neste marco xurde CRATE, que asemellándose á ben coñecida arquitectura Transformer e a través da optimización desenrolada aprende representacións dispersas e o máis representativas posible. Como CRATE foi deseñada dende primeiros principios cada compoñente ten un rol interpretable e por tanto o sistema (e as súas decisións). É por isto que a interpretabilidade do modelo deriva na súa explicabilidade.

Malia parecer prometedor, o seu rendemento atópase por debaixo do estado da arte ou de outros modelos baseados en Transformer e o seu uso estivo limitado a tarefas e dominios xerais polo que a súa aplicación en contextos específicos non foi explorada dabondo.

Neste traballo centrámonos en explorar estas técnicas novidasas, tentando aportar cambios que permitan mellorar o rendemento e explorar a súa posible aplicación en ámbitos concretos da Visión por Computadora como a imaxe médica.

1.3. Obxectivos concretos

(i) Exploración dos principios e fundamentos de Aprendizaxe Profundo de Caixa Branca mediante experimentación con modelos CRATE e variantes. (ii) Avalación das capacidades de interpretabilidade e explicabilidade dos sistemas resultantes. (iii) Aplicación dos modelos a contextos de análise de imaxe médica. (iv) Proposta de melloras no rendemento e eficiencia dos modelos, mediante a profundización nos principios e fundamentos de Aprendizaxe Profundo de Caixa Branca.

1.4. Método de traballo

O método que se abordará para a realización deste proxecto comezará cun estudo exhaustivo da bibliografía e das tecnoloxías a empregar (así como do código dispoñible) e virá seguido de varios procesos. Análise das alegacións en materia de interpretabilidade e explicabilidade e definición de experimentos axeitados para a súa avaliación aplicada. Análise dos fundamentos matemáticos implicados na derivación de sistemas de caixa branca baseados en primeiros principios. Desenvolvemento de melloras fundamentadas nestes principios matemáticos, ou derivados deles, que permitan abordar ou resolver as limitacións observadas experimentalmente nos sistemas de base. E experimentación incremental coas melloras nos termos previamente descritos. Debido á natureza do proxecto, utilizarase unha metodoloxía Iterativa Incremental na que a partir de modelos base e experimentos co seu correspondente análise, propónse melloras de acordo o observado.

1.5. Fases principais

As principais fases do traballo foron: (i) Estudio dos fundamentos das técnicas de Aprendizaxe Profundo Caixa Branca e a súa aplicación á análise médica. (ii) Desenvolvemento dun prototipado base de acordo ás implementacións de referencia. (iii) Desenvolvemento dun marco experimental e avaliacións. (iv) Desenvolvemento incremental de melloras e propostas dende a xustificación teórica, a correspondente implementación até a súa correspondente avaliación experimental. (v) Análise dos resultados obtidos. (vi) Redacción de informes semanais e memoria.

1.6. Material e medios necesarios

Ordenador portátil para o desenvolvemento do código e GPU do Varpa Group. A Librerías PyTorch e einops para desenvolvemento de modelos e

Numpy e Matplotlib para os gráficos. Datasets públicos tanto de imaxe xeral como de imaxe médica. O material bibliográfico e o código de referencia.