

Martes 21 de Abril de 2026

1. Anteproxecto

1.1. Título

Interpretabilidade e explicabilidade mediante técnicas de Aprendizaxe Profundo de caixa branca aplicadas ó análise de imaxe

1.2. Breve descripción

Na actualidade, as Redes de Neuronas Artificiais demostraron unha efectividade excelente nunha gran cantidade de tarefas. Con todo os modelos actuais funcionan como unha caixa negra polo que en xeral non é posible interpretalos mecanismos cos que resolven os problemas plantexados. Esta limitación cara a interpretabilidade e explicabilidade dos sistemas vólvese crítica en sistemas de alto risco como o diagnóstico clínico, a xestión do emprego ou o deseño de componentes de seguridade, xa que restrinxe o seu uso no marco legal da Unión Europea.

Nos derradeiros anos diferentes liñas de investigación procuraron solventar estes problemas. No ámbito do procesamento da imaxe xurdiron diferentes liñas de investigación, entre elas as chamadas de Caixa Blanca que teñen como obxectivo ser interpretables por deseño. Neste marco xurde CRATE, que asemellándose á ben coñecida arquitectura Transformer e a través da optimización desenrolada aprende representacións dispersas e o máis representativas posible. Como CRATE foi deseñada dende primeiros principios cada compoñente ten un rol interpretable e por tanto o sistema (e as súas decisións). É por isto que a interpretabilidade do modelo deriva na súa explicabilidade.

Malia parecer prometedor, o seu rendemento atópase por debaixo do estado do arte ou de outros modelos baseados en Transformer e o seu uso estivo limitado a tarefas e dominios xenerais polo que a súa aplicación en contextos específicos non foi explorada dabondo.

Neste traballo centrámonos en explorar estas técnicas novidasas, tentando aportar cambios que permitan mellorar o rendemento e explorar a súa posible aplicación en ámbitos concretos da Visión por Computadora como a imaxe médica.

1.3. Obxectivos concretos

- Exploración e experimentación dos fundamentos e principios do Aprendizaxe Profundo Caixa Blanca e da súa posible aplicación á imaxe médica dende o punto de vista de sistemas interpretables e explicables.
- Busca de mellorar o rendemento e eficiencia destes sistemas aproveitando a anterior exploración.

1.4. Método de traballo

Debido á natureza investigadora e exploratoria deste traballo, existen limitacións en canto á posible planificación, debido á incerteza asociada ós resultados dos experimentos. Isto motiva a metodoloxía Iterativa Incremental na que a partir de modelos base e experimentos co seu correspondente análise, propónse melloras de acordo o observado.

1.5. Fases principais

As principais fases do traballo foron:

- Estudio dos fundamentos das técnicas de Aprendizaxe Profundo Caixa Blanca e a súa aplicación á análise médica.
- Desenvolvemento dun prototipado base de acordo ás implementacións de referencia.
- Desenvolvemento dun marco experimental e avaliacións.
- Desenvolvemento incremental de melloras ca súa correspondente avaliación experimental.
- Análise dos resultados obtidos.
- Redacción de informes semanais e memoria.

1.6. Material e medios necesarios

Ordenador portatil para o desenvolvemento do código e GPU do Varpa Group. A Librerías PyTorch e einops para desenvolvemento de modelos e Numpy e Matplotlib para os gráficos. Datasets públicos tanto de imaxe xeral como de imaxe médica. O material bibliográfico e o código de referencia.