



Anteproxecto TFG

GRAO EN INTELIXENCIA ARTIFICIAL

Datos da/o estudante*:

Nome e apelidos	José Romero Conde
DNI	35630098Q
Enderezo electrónico	j.rconde@udc.es
Teléfono	658755850

Título (galego)*: Interpretabilidade e explicabilidade mediante técnicas de Aprendizaxe Profundo de caixa branca aplicadas ó análise de imaxe.

Título (castelán)*: Interpretabilidad y explicabilidad mediante técnicas de Aprendizaje Profundo de caja blanca aplicadas al análisis de imagen.

Título (inglés)*: Interpretability and explicability through white-box Deep Learning techniques applied to image analysis.

Tipo de proxecto*: De desenvolvemento en investigación

Modalidade de proxecto*: Traballo a proposta do alumno

Dirección:

Máximo dúas persoas da FIC. Permítese unha terceira persoa só no caso de pertencer a outra organización (que hai que especificar):

— Titor(a) da FIC*: Rouco Maseda, José (jose.rouco@udc.es)

— Titor(a) da FIC: Novo Buján, Jorge (j.novo@udc.es)

— Director(a) externo/a:
Organización:

Breve descrición*:

Na actualidade, as Redes de Neuronas Artificiais demostraron unha efectividade excelente nunha gran cantidade de tarefas. Con todo os modelos actuais funcionan como unha caixa negra polo que



en xeral non é posible interpretar os mecanismos cos que resolven os problemas plantexados. Esta limitación cara a interpretabilidade e explicabilidade dos sistemas vólvese crítica en sistemas de alto risco como o diagnóstico clínico, a xestión do emprego ou o deseño de componentes de seguridade, xa que restrinxe o seu uso no marco legal da Unión Europea.

Nos derradeiros anos diferentes liñas de investigación procuraron solventar estes problemas. No ámbito do procesamento da imaxe xurdiron diferentes liñas de investigación, entre elas as chamadas de Caixa Blanca que teñen como obxectivo ser interpretables por deseño. Neste marco xurde CRATE, que asemellándose á ben coñecida arquitectura Transformer e a través da optimización desenrolada aprende representacións dispersas e omáis representativas posible. Como CRATE foi deseñada dende primeiros principios cada compoñente ten un rol interpretable e por tanto o sistema (e as súas decisións). É por isto que a interpretabilidade do modelo deriva na súa explicabilidade. Malia parecer prometedor, o seu rendemento atópase por debaixo do estado do arte ou de outros modelos baseados en Transformer e o seu uso estivo limitado a tarefas e dominios xenerais polo que a súa aplicación en contextos específicos non foi explorada dabondo.

Neste traballo centrámonos en explorar estas técnicas novidosas, tentando aportar cambios que permitan mellorar o rendemento e explorar a súa posible aplicación en ámbitos concretos da Visión por Computadora como a imaxe médica.

Obxectivos concretos*:

Exploración e experimentación dos fundamentos e principios do Aprendizaxe Profundo Caixa Blanca e da súa posible aplicación á imaxe médica dende o punto de vista de sistemas interpretables e explicables.

Busca de mellorar o rendemento e eficiencia destes sistemas aproveitando a anterior exploración.

Método de traballo*:



Debido á natureza investigadora e exploratoria deste traballo, existen limitacións en canto á posible planificación, debido á incerteza asociada ós resultados dos experimentos. Isto motiva a metodoloxía Iterativa Incremental na que a partir de modelos base e experimentos co seu correspondente análise, propónse melloras de acordo o observado.

Fases principais do traballo*:

As principais fases do traballo foron: (i) Estudio dos fundamentos das técnicas de Aprendizaxe Profundo Caixa Blanca e a súa aplicación á análise médica. (ii) Desenvolvemento dun prototipado base de acordo ás implementacións de referencia. (iii) Desenvolvemento dun marco experimental e avaliacións. (iv) Desenvolvemento incremental de melloras ca súa correspondente avaliación experimental. (v) Análise dos resultados obtidos. (vi) Redacción de informes semanais e memoria.

Material, medios e recursos necesarios*:

Ordenador portátil para o desenvolvemento do código e GPU do Varpa Group. A Librarías PyTorch e einops para desenvolvemento de modelos e Numpy e Matplotlib para os gráficos. Datasets públicos tanto de imaxe xeral como de imaxe médica. O material bibliográfico e o código de referencia.

Propiedade intelectual do traballo*:

O Regulamento dos Traballos de Fin de Grao da Facultade de Informática da Coruña (aprobado pola Xunta de Centro o 18 de xullo de 2022) establece na sección 4, en relación aos dereitos derivados da propiedade intelectual dos traballos, o seguinte:

4.1. No caso dos traballos desenvolvidos en colaboración cunha entidade externa, a titularidade dos dereitos de propiedade e explotación dos resultados, se for o caso, rexerase polo establecido na relación contractual entre



a/o estudante e a entidade externa. Neste caso, quen exerza a dirección académica non será titular dos dereitos de propiedade intelectual, salvo que se establecer doutra maneira nun documento asinado pola/o estudante, o profesorado encargado da dirección e un/ha representante da entidade externa.

4.2. No caso dos traballos desenvolvidos no ámbito do centro, a titularidade dos dereitos de propiedade intelectual, se for o caso, corresponderá á/ao estudante segundo queda recollido no apartado h) do artigo 8 do Real Decreto 1791/2010 do 30 de decembro, salvo que se establecer doutra maneira no anteproxecto asinado pola/o estudante e o profesorado encargado da dirección do TFG.

Os resultados xerados durante a realización do TFG poderán ser utilizados para a docencia na UDC, sempre con autorización e mención explícita de quen ostente a súa autoría.

Indique a continuación se o traballo se realiza en colaboración cunha entidade externa ou no ámbito do centro, e neste último caso, o acordo sobre os dereitos derivados da propiedade intelectual do traballo.

O traballo realízase en colaboración cunha entidade externa: No

Nome da empresa:

Se o traballo non se realiza en colaboración cunha entidade externa, indique se os dereitos derivados da propiedade intelectual son compartidos entre a/o estudante e as/os directores: Sí

Asinado:

Estudiante

Titoras/es e Directoras/es