

Luns 13 de Abril de 2026

WB, E/I, DL, CV:

interpretabilidad y explicabilidad mediante técnicas de aprendizaje profundo de caja blanca aplicadas a análisis de imagen

1. Propuesta anteproxecto

1.1. Titulo

...

Fases:

- estudio de los fundamentos de las técnicas WB y su aplicación al análisis de imagen.
- desarrollo de un prototipo base de acuerdo a las implementaciones de referencia
- desarrollo de marco experimental y evaluaciones
- desarrollo incremental de mejoras con su correspondiente evaluación experimental
- análisis resultados
- escritura/redacción de informes y memoria

1.2. Breve descripción

Este traballo xurde no berce dun momento de desenvolvemento teórico guiado pola experimentación e o empiricismo, planteándose como oposición. As Redes de Neuronas Artificiais que están a sufrir un esplendor en aplicacións carecen dun marco teórico para entendelas tanto os profesionais informáticos como o resto que traballen con elas. Por eso apostamos pola proposta de Yi Ma que a través duns principios claramente caracterizados (compresión a través de representacións que conserven a máxima información intra clase e a máxima discriminación entre case) deriváanse unha familia de Redes Neuronalas sobre as que se planea este traballo.

limitacion

Quien es

vago

1.3. Obxectivos concretos

Estudar como as *cabezas de atención semánticas* poden apoiar a interpretabilidade no diagnóstico no dominio médico e como pequenos cambios na rede, xurdidos da súa formulación, poden afectar ó rendemento da mesma.

1.4. Método de traballo

A metodoloxía é de tipo iterativo incremental.

Objetivos:

- explorar y experimentar DL whitebox
- explorar su aplicación en imagen medica
- realizar evaluaciones en cuanto a interpretabilidad y explicabilidad

1.5. Fases principais

metodología:

Debido a la naturaleza investigadora y exploratoria de este trabajo, suponen ciertas limitaciones en cuanto a la planificación debido a la incertidumbre asociada a los resultados de los experimentos. Esto motiva la metodología I.I.,. EXPLICAR METODOLOGIA II

1. Lectura bibliográfica

2. Acomodación do código para experimentos futuros e planteamento da tarefa inicial (predicción binaria de vaso).

3. Planteamento de propostas e experimentación.

- en la actualidad las MN han demostrado una efectividad excelente en una gran cantidad de tareas. sin embargo los modelos actuales funcionan como un caja negra por lo que en general no es posible interpretar los mecanismos con los que se resuelven los problemas planteados. Esto limita la interpretabilidad (RF) e explicabilidad (decir porque a la solución; mediante un diseño del sistema)

- estas limitaciones se vuelven criticas en sistemas de alto riesgo como diagnóstico clínico.

- en los últimos años diferentes lines de investigación intentaron solucionar estos problemas. Una de ellas se basa en crear sistemas neuronales llamados white box, pretenden: ... (El lector no tiene ni idea) *interpretables*, las partes tienen un rol, lo que facilitaría derivar explicaciones de porque se toma una decisión. Interpretabilidad → explicabilidad

- (hasta que punto se ha explorado), si bien esto parece prometedor, su rendimiento aun se encuentra por debajo del SOTA y su uso ha estado limitado a tareas iniciales generalistas.


- en este trabajo nos centramos (como objetivo) explorar estas técnicas novedosas para intentar aportar mejoras que permitan mejorar su rendimiento y explorar su posible aplicación en ámbitos concretos de CV como imagen medica

1.6. Material e medios necesarios

- GPU de varpa con Python 3.8.10 e rsync instalados.
- Ordenador portátil

2. Que é o master?

3. Como son os parches da rede preentrenada do Yi Ma?



4. Experimentos con moitas épocas [en curso]

Lancei os nove experimentos correspondentes ás combinacións de usar ou non as seguintes perdas:

- $\|A\|_1 + \|b\|_1$, a chamo L1
- $\|x - A'Ax\|_{fro}$, a chamo reconstruccion
- $\|AA' - I\|_{fro}$, a chamo ortogonal

Por tanto son 8 (2^3) experimentos a 200000 épocas.

De momento a que mellor foi (que para min foi mal) é: sen L1, con reconstruccion e con ortogonal. As figuras de abaixo teñen ganacia de 5.

