

Facultade de Informática
UNIVERSIDADE DA CORUÑA

TRABALLO FIN DE GRAO
GRAO EN INTELIXENCIA ARTIFICIAL

Interpretabilidade e explicabilidade mediante técnicas de Aprendizaxe Profundo de Caixa Blanca aplicadas ó análise de imaxe

Estudante: José Romero Conde

Dirección: José Rouco Maseda

Jorge Novo Buján

A Coruña, agosto de 2026.

Á miña avoa

Agradecementos

Quero agradecer este traballo a blablabla

Resumo

Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

Abstract

Hello, here is some text without a meaning. This text should show what a printed text will look like at this place. If you read this text, you will get no information. Really? Is there no information? Is there a difference between this text and some nonsense like “Huardest gefburn”? Kjift – not at all! A blind text like this gives you information about the selected font, how the letters are written and an impression of the look. This text should contain all letters of the alphabet and it should be written in of the original language. There is no need for special content, but the length of words should match the language.

Palabras chave:

- First itemtext
- Second itemtext
- Last itemtext
- First itemtext
- Second itemtext
- Last itemtext
- First itemtext

Keywords:

- First itemtext
- Second itemtext
- Last itemtext
- First itemtext
- Second itemtext
- Last itemtext
- First itemtext

Índice Xeral

1 Introdución **1**

1.1 Contexto xeral . . . 1

1.2 Revisión pormenorizada SOTA e traballos relacionados . . . 2

1.2.1 Optimización non convexa sen restriccións . . . 2

1.2.2 ISTA . . . 3

1.2.3 Interpretabilidade no sota, *como?* . . . 4

1.2.4 Explicabilidade no sota, *por que?* . . . 5

1.2.5 MCR^2 e ReduNet - Redes Caixa Blanca . . . 6

1.2.6 ViT . . . 8

1.2.7 Aprendizaxe de diccionarios . . . 8

1.2.8 Aprendizaxe desenrolado . . . 9

1.2.9 CRATE . . . 9

1.2.10 Conxuntos de datos . . . 11

1.3 Métricas . . . 12

1.4 Discusión . . . 12

1.4.1 Elementos diferenciais . . . 12

1.4.2 Oportunidades . . . 12

1.4.3 Contribucións . . . 12

2 Metodoloxía e planificación **13**

2.1 Método de traballo . . . 13

2.2 Recursos . . . 13

2.2.1 Humanos . . . 13

2.2.2 De *Software* . . . 14

2.2.3 De *Hardware* . . . 16

2.3 Planificación . . . 16

3 Traballo proposto **18**
3.1 Segundo orden . . . 18
3.1.1 Aproximación da inversa mediante suma de matrices . . . 18
3.1.2 Nova arquitectura . . . 19
3.1.3 Cruce . . . 19
3.2 Visualizacións dos mapas de atención . . . 21
3.2.1 Motivación . . . 21
3.2.2 Procedemento . . . 22
3.2.3 Extensión para resolución . . . 22
3.2.4 Extensión ó segundo orde . . . 22
3.3 Recuperación de parches representativos . . . 23
3.3.1 Procedemento . . . 23
3.4 Compartir U e D . . . 24
3.5 Combinación de achegas . . . 25
3.6 Tarefas de adestramento . . . 25
3.7 Hipóteses . . . 27

4 Resultados **29**
4.1 Imagenet . . . 29
4.1.1 Búsqueda de arquitecturas . . . 31
4.1.2 Cruce de arquitecturas . . . 32
4.1.3 Explicabilidade dos mapas de atención . . . 32
4.1.4 Explicabilidade das dimensións . . . 36
4.2 DRIVE . . . 36
4.2.1 Búsqueda de arquitecturas . . . 38
4.2.2 Explicabilidade dos mapas de atención . . . 40
4.2.3 Explicabilidade das dimensións . . . 40
4.2.4 Búsqueda de hiperparámetros . . . 40
4.3 RFMiD . . . 41
4.3.1 Búsqueda de arquitecturas . . . 41
4.3.2 Explicabilidade dos mapas de atención . . . 42
4.3.3 Explicabilidade das dimensións . . . 43
4.4 Discusións . . . 43

5 Conclusións **49**
5.1 TFG en sí . . . 49
5.2 Resultados . . . 49
5.3 Traballo futuro . . . 50

A Material adicional **52**

Relación de Acrónimos **54**

Glosario **55**

Bibliografía **56**

Índice de Figuras

1.1 Comparación entre A.A. e A.P.. Figura de autoría propia. 2
1.2 Ilustración da influencia da eleción da tasa de aprendizaxe. Figura de autoría propia. 3
1.3 Funcións de activación. Figura de autoría propia. 4
1.4 Métodos de explicabilidade. Subfiguras extraídas de [14] e [15]. 6
1.5 Iteración dos pasos do MCR^2. Figura de autoría propia. 8
1.6 Arquitectura do ViT. Figura de autoría propia. 9
1.7 Decorrupción con A.D.. Subfiguras extraídas de [23]. 10
1.8 Mostras dos conxuntos de datos. Imaxes extraídas de [25], [26] e [27]. 11

2.1 Esquema das reunións. Figura de autoría propia. 14
2.2 Mapa de cor Pink. Figura extraída de [30]. 16
2.3 Esquema do uso do servidor. Figura de autoría propia. 16

3.1 Comparativa entre a atención do modelo CRATE orixinal e a proposta. Figura de autoría propia. 20
3.2 Paso do procedemento de recuperación de palabras representativas dos dicionarios. Figura de autoría propia. 24
3.3 Comparativa entre a proxeción lineal do modelo CRATE orixinal e a proposta. Figura de autoría propia. 26
3.4 Mostras de supervision para o conxunto de datos DRIVE. Figura de autoría propia. 28

4.1 Adestramento de diferentes arquitecturas sobre Imagenet. Figura de autoría propopia. 30
4.2 Métricas de MCR^2 e dispersión de diferentes arquitecturas sobre Imagenet. Figura de autoría propopia. 30

4.3 Visualización dos mapas de atención sobre imaxes de vacas. Figura de autoría propia. 33
4.4 Visualización dos mapas de atención sobre imaxes de insectos. Figura de autoría propia. 34
4.5 Mosaico con parches asociados a todas as dimensións de todas as cabezas dunha Rede adestrada en Imagenet. Figura de autoría propia. 37
4.6 Adestramento de diferentes arquitecturas sobre DRIVE. Figura de autoría propia. 38
4.7 Adestramento da arquitectura orixinal e a proposta sobre DRIVE. Figura de autoría propia. 38
4.8 Métricas de MCR^2 e dispersión de diferentes arquitecturas sobre DRIVE. Figura de autoría propia. 39
4.9 Comparativa da segmentación das variantes orixinal e combo. Figura de autoría propia. 39
4.10 Visualización dos mapas de atención sobre DRIVE. Figura de autoría propia. . 44
4.11 Escola de parches asociados ás dimensións dunha Rede adestrada con DRIVE. Figura de autoría propia. 45
4.12 Comparativa do adestramento dalgunhas arquitecturas sobre RFMiD. Figura de autoría propia. 46
4.13 Métricas de MCR^2 e dispersión de diferentes arquitecturas sobre RFMiD. Figura de autoría propopia. 46
4.14 Visualización dos mapas de atención sobre RFMiD. Figura de autoría propia. . 47
4.15 Escola de parches asociados ás dimensións dunha Rede adestrada con RFMiD. Figura de autoría propia. 48

Índice de Táboas

3.1 Combinacións das diferentes achegas. 26

4.1 Resultados do cruce de ordes mostrando o rendemento no conxunto de proba cas métricas Precisión a un e a cinco (ver Sección 1.3). Pódese apreciar que cambiar de orde ofrece uns resultados moi malos. 32

4.2 AUC no conxunto de proba para unha escolma de arquitecturas. Nótese que se ben para a mesma tasa de aprendizaxe θ a variante de segundo orde ten moito peor rendemento, o feito de que con unha tasa de aprendizaxe máis pequena rinda mellor (acompañada do comportamento de adestramento inestable apreciable na Figura 4.12) suxire que con tasas de adestramento máis baixas podería rendir aínda mellor. Por outra banda ca evidencia presente non pódese inferir moito do impacto de compartir en canto a rendemento. 42

<
CONTEXTO:

Sé concreto e conciso, fala en positivo, verbos directos, define termos obxectivamente, identifica datos relevantes, obxectivos, solucións parciais, limitacións, avances, e fia os argumentos. Sobre isto, usa o estilo que queiras:

1. A aprendizaxe automática é .... Pretende resolver datos->función.
2. Dificultade. Identifica problema. Datos multimodais, sinais (datos sen información explícita), aplicacións onde a distribución é multidimensional ou complexa. Exixe sistemas avanzados.
3. Os primeiros sistemas de AA son sistemas de regresión simple, tícamente lineais ou con poucos graos de non linealidade, ou xestión básica de ruido e outliers.
4. Identifica limitación: Os sistemas clasicos requiren intervención humana para identificar a información relevante, e disminución factores de variación. A AA clásica abórdase mediante multiples fases previas de procesamento de datos e extracción manual de caracteristicas, deseñadas a man. O obxectivo simflificar favpres de variación, reducir ruido, extraer información relevante, onde as relacións funcionais sexan mais simples ou evidentes de identificar de forma automatica.
5. As RNA (define, inspiración biolóxica), pretenden escalar a aprendizaxe. Os primeiros modelos tiñan problemas de aprendizaxe de múltiples capas. Coas técnicas de AP solventouse, permitindo aprender simultaneamente as fases de procesado, extracción de características, inferencia e toma de decisións de forma continua. A figura 1.1.
6. A contrapartida é que os sistemas son mais complexos: 1) necesidade de gran cantidade da datos etiquetados, 2) os sistemas son complexos, de caixa negra. De forma que xa non é viable interpretar o proceso (interpretabilidade), nin coñecer os motivos polos que o sistema ofrece as saidas estatísticamente correctas dacordo aos datos dispoñibles (explicabilidade).
7. Isto motiva a investigación en técnicas de AP interpretables e explicables, que é o foco deste proxecto.

>

Capítulo 1

Introdución

PRIMER capítulo da memoria

1.1 Contexto xeral

[NOTA: non darlle mais voltas a introducion de momento] dato irrelevante

No contexto das sociedades da información que levamos vivindo como mínimo dende a revolución industrial, é cada vez máis evidente (aserción dogmática) a importancia ~~do~~ (da) Aprendizaxe Automático (A.A.). Esta disciplina trata de *aprender* funcións (de calquera propósito) en base a unha experiencia ~~o~~ (ou) un conxunto de datos (de calquera orixe). ~~O~~ (A) A.A. gozou dun esplendor tanto no desenvolvemento teórico [1] como nas aplicacións (e.g. xogar as damas [2], recoñecer a fala [3] . . .) durante a segunda metade do pasado século. <aparte> <seguido>

Hoxe, na tercera década do século XXI atopamos que a natureza dos datos trocou, onde denantes unha representación natural dos datos era útil (vaguedad) e con garantías de éxito, agora con datos multimodais, que xurden da interacción social é máis difícil. (vaguedad) En particular os dominios das nosas (indefinición) funcións poden ser espazos moi complexos (vaguedad) e os datos de entrada poden precisar un preprocesado particular. (indefinición) Se antes a disciplina de Procesamento de Señais Dixitais (P.S.D.) ofrecía unha serie de métodos de preprocesado (Filtrado de Kalman, Transformada de Ondas Discreta...), agora ~~o~~ (a) Aprendizaxe de Representacións (A.R.) ofrece unha serie de métodos para *aprender* o preprocesado axeitado para a combinación de tarefa e conxunto de datos. É por isto que recentemente estase a ver un crecemento moi acelerado ~~no~~ (na) Aprendizaxe Profundo (~~o~~ (a) A.P.), unha subdisciplina ~~do~~ (da) A.A. que ten como *slogan*: "Máis grande é mellor" (indefinición, cliché terminador) [4, 5] e prentende solventar o problema ~~do~~ (da) A.R. a través dunha sucesión de operadores non lineais coñecidos como Rede de Neuronas Artificiais (R.N.A.), ver Figura 1.1 para máis detalles.

Pola súa banda as compoñentes das R.N.A. actuais non gozan (non seguitur) da mesma xustificación teórica que acostumaban antaño outros algoritmos de A.A., como a Regresión Lineal ou as Máquinas de ~~Soporte Vectorial~~ (Vectores Soporte) [1]. Por tanto vivimos nun momento no que as R.N.A. reinan

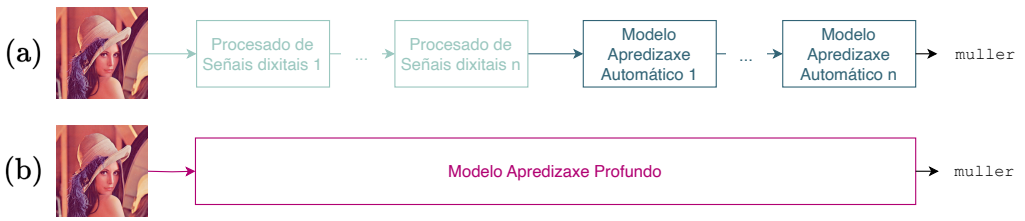


Figura 1.1: Diferenzas no procedemento enxeñeril entre ~~o~~ A.A. clásico ~~a~~ e ~~o~~ A.P. cun exemplo de clasificación de imaxe. (a) No enfoque clásico, a entrada (neste caso os *píxels* das imaxes) ~~debía ser preprocesada~~ son procesadas con un ou máis métodos de P.S.D. co fin de extraer características (bordes, esquinas, patróns predefinidos . . .) que logo o(s) algoritmo(s) de aprendizaxe usará(n) para predecir a saída. (b) Na aproximación moderna, un modelo de A.P. é quen de extraer por si só as características que vai precisar para predecir a saída. Deste xeito o modelo de A.P. cumple o rol de extracción de características e de discriminación sobre elas. Figura de autoría propia.

o mundo das aplicacións pero parcial, foso y mota sen que exista unha teoría conclusiva que as avale, ou cando menos de momento. Esta situación motivou o desenvolvemento dun marco para comprender as R.N.A., primeiro dende o punto de vista do algoritmo, é dicir interpretabilidade dos seus procesos de aprendizaxe e inferencia, para finalmente poder entender as decisións que toma de xeito individual e ofrecer unha xustificación a devandita resposta, é dicir, explicabilidade [6].

[NOTA: hai que motivar a necesidade de explicabilidade e interpretabilidade. e.g. confianza dos médicos, aiact. aqui hay motivos [7]]

<Antes do SOTA, penso que é necesario introducir conceptos e motivación xeral>

~~1.2 Revisión pormenorizada SOTA e traballos relacionados~~

~~O traballo neste TFG móntase sobre a arquitectura CRATE (ver 1.2.9, páxina 9). Para poder exponer tanto a devandita arquitectura como as nosas aportacións, é necesaria a revisión duns conceptos previos.~~

<no caso de poñelo, non vai aquí, porque fai perder o foco con detalles irrelevantes para dar contexto e motivación a este nivel de introducción>

1.2.1 Optimización non convexa sen restriccións

A

[NOTA: falar da influencia do learning rate nos tambaleos do adestramento da Rede (para a sección 4.3.1)]

[NOTA: falar da Figura 1.2]

[NOTA: falar de que en todo o traballo usamos AdamW [8] e que ten weigth decay. tal cosa é importante]

[NOTA: nalgún lugar ten que dicirse que as funcións de pérdida de a rede normal e a de segundo orde non son igual de difíciles, en particular a de segundo orde é máis difil porque como cada parámetro esta sometido a máis operación realemente ten máis restriccións. o cal nun problema sinxelo com drive axuda á converxencia pero en problemas complexos como RFMiD a dificulta.]

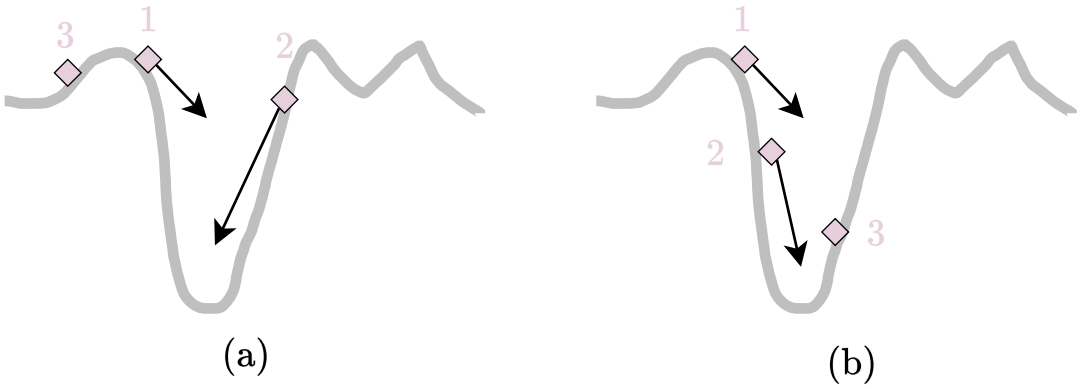


Figura 1.2: Ilustración da influencia da eleción da tasa de aprendizaxe. Repórtase un un punto incicial (1) co seu gradiente negativo (dirección de máximo descenso), e as dúas iteracións seguintes. En (a) empregouse unha tasa de aprendizaxe grande que supón trucar de "parede" en cal de avanzar nunha dirección. En (b) utilizouse unha tasa de aprendizaxe máis baixa o que permite seguir na mesma rexión polo menos ata que se está suficientemente preto do mínimo. Figura de autoría propia.

[NOTA: falar da relación converxencia - dimensión VC (para a sección 4.1.1) (ou non?)]

<non vai aquí, ainda>

1.2.2 ISTA

B

[NOTA: ser é correcto o que digo pero paréme irrelevante. o que é relevante do ISTA é dicir que é unha implementación de aprendizaxe de diccionarios, que parécese a un MLP e que funciona baixo o principio de Unroll learning. todo isto é interesante dicilo poruque logo o ISTA vai ser o MLP de crate.]

Un algoritmo clásico do A.A. é a Regresión Lineal, co que Carl F. Gauss empezou a teorizar e ofrecer garantías sobre o seu modelo

$$X\beta = Y + \epsilon$$

onde $\epsilon \sim \mathcal{N}(\mu, \sigma^2)$ nos albores do século XIX, chegando á coñecida forma cerrada

$$\hat{\beta} = (X^{'}X)^{-1}X^{'}Y.$$

A primeira regularización do modelo para facelo máis robusto chegou con ideas orixais no campo de resolución de problemas mal planteados, Andrey Tikhonov introduce a penalización segundo a norma $\mathcal{L}_2$ dos parámetros β, o cal é equivalente a asumir unha distribución

Gausiana en β. O estimador ten a forma cerrada

$$\hat{\beta} = (X^{'}X + \lambda I)^{-1}X^{'}Y$$

onde λ controla a estructura do conxunto de funcións [1]. Se ben esta regularización segue a usarse hoxe en día porque devandita asunción pode ser moi natural, dende o 1996 considérase o Lasso [9], que penaliza a norma $\mathcal{L}_1$ (equivalente a asumir unha distribución Laplaciana nos parámetros) e sen ter forma cerrada ofrece un estimador con ceros, é dicir o proceso de optimización de Lasso supón unha selección de características.

Como en moitos problemas de optimización de interese científico e comercial a resolución deste problema convexo por medio de métodos de punto interior pode ser infactible [10], o algoritmo Ista atopa unha solución ó Lasso a través da iteración:

$$\beta_{t+1} = \sigma_\epsilon(\beta t - \lambda X^{'}(X\beta - Y))$$

onde σ_ϵ é a función de umbral suave (ver figura 1.3)

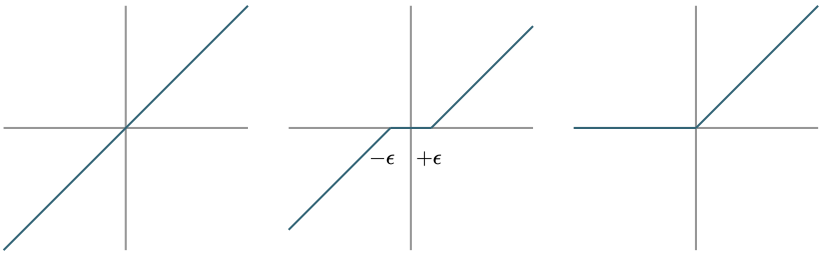


Figura 1.3: Funcións de activación usadas no traballo. (*esquerda*) Función identidade (*centro*) Función de umbral suave $\sigma_\epsilon(\cdot)$, parametrizada por ϵ (*dereita*) Función ReLU, nótese que a función $\sigma_\epsilon(x)$ é indentica (no dominio $\mathbb{R}^+$) a ReLU$(x - \epsilon)$. Figura de autoría propia.

1.2

~~1.2.3~~ Interpretabilidade ~~no sota, *como?*~~ e explicabilidade

Un modelo de A.A. pode ofrecer claridade sobre o seu compartamento respondendo a duas grandes preguntas: *Como* toma decisións? e *Porque* tomou unha decisión particular? Os campos de Interpretabilidade e Explicabilidade tratan de ou ben dar respostas a estas preguntas, respectivamente.

1.2.1. Motiivación
< Entornos de IA críticos, toma de decisións de gran impacto, confiabilidade, IA act, etc. >

<intentaría, antes de intentar aportar unha interpretación-sumaria-intuitiva, aportar unha defición>

1.2.2. Intelixencia Artificial Interpretable

Pola sua banda, a Intelixencia Artificial Interpretable (I.A.I) crea modelos que responden á pregunta '*Como* toma decisións?' de forma intrínseca. Consideremos Regresión Lineal, aínda que é un modelo ben Interpretable en xeral, se hai moitas variables regresoras, pode non selo tanto. Nese caso podemos preferir un axuste os datos que asegure que moitos $\beta_i = 0$, desta forma á hora de interpretar ó modelo podemos aforrarnos toda o análise relativo a esas variables. Esa foi a idea de Lasso [9], que instanciouse máis tarde como un operador iterativo

<intentaría redactar exemplos, sen entrar en detalles, e con orientación didáctica. Por exemplo (como inspiración):

"Algúns exemplos típicos de modelos considerados interpretables incluen regresións lineais simples, árbores de decisión, ou sistemas de emarellamento de patróns (pattern matching). Con todo, a interpretabilidade destes modelos depende en gran medida da comprensión por parte do usuario do espazo sobre o que se traballa. É dicir, para que estes modelos sexan interpretables é preciso comprender o que significan os eixos do espazo sobre o que se fai a regresión de datos, o significado das dimensións e valores sobre as que se toman decisións, e os conceptos asociados aos prototipos sobre os que se fai matching.

>

(ver 1.2.2) e finalmente nunha R.N.A. [11, 12]. Neste caso caso cada capa da Rede lava a cabo unha iteración do algoritmo (ver 1.2.8).

A bondade da I.A.I recae en que ~~aqueles~~ (deseñadores, exeñeiros) que creen ~~un~~ modelo o entenden (ou poden chegar a entendelo), e por tanto ~~o~~ poden ~~reparar~~ se o considerasen. Desgraciadamente, tanto no caso da regresión lineal dispersa ou os árboles de decisión, buques insignida da I.A.I ~~os modelos son simples.~~ En xeral a búsqueda de interpretabilidade ~~nun sistema~~ conleva un decaemento no seu rendemento xeral [13]. ~~Por outra banda, a interpretabilidade conleva unha netural explicabilidade.~~

[NOTA: motivar máis a necesidade de interpretabilidade zicais]

É por todo isto que estamos nun momento de necesidade de modelos de A.A. interpretables de alto rendemento, que permitan resolver as tarefas complexas.

[NOTA: falar (zicais despois) de que neste caso (crate) 'symbolic knowledge injection and extraction', hai extración no sentido de que dicimos o sematica da cabeza pero non hai inxección]

1.2.4 ~~Explicabilidade no sota, *por que?*~~

Intelixencia Artificial Explicable (I.A.X)

falar da fidelidad 'the fidelity of an explanation determines the precision with which the model behavior is elucidated'

[NOTA: temos como recurso [13]]

gustaríame falar mal de LIME [14] por ser unha falsedade e unha xustificación dun modelo 'distinto'.

distinción entre local e global: explicar (modelo como un todo / modelo real VS decisións particulares modelo local), por exemplos e situar o noso traballo

tipos de aplicabilidad (o noso metodo realmente só vale para transformers) pero lime vale para todo

tipo: visualización VS feature attribution

problemas:

- Falta de métricas cuantitativas: como comparar variacións, no noso caso aplica
- escalabilidade: falar de local é caro, global as veces precisa moitos locales. no noso caso o caro é a resolución. ...desplegar
- vinculación da explicación ca acción

[NOTA: —]

A Intelixencia Artificial Explicable (I.A.X) ofrece mecanismos que incorpóranse sobre modelos (xa adestrados) para explicar o razoamento detrás das decisións do algoritmo. Estes poden clasificarse según locais ou globais segundo se para ofrecer a xustificación usa o modelo

<Dedicaría a un párrafo (oun a cada) a estas categorizacións, explicando o que implica con algún exemplo. Dedicalle varias frases explicación intuitiva conceptual de alto nivel. Pero concluiría conque estas categorizacións, si ben permiten organizar o estado da arte, non destacan os mecanismos subxacentes á estructura das explicacións en sí. De feito, o resto do texto non fai uso destes conceptos. Isto parece máis relevante. ¿En qué consiste a explicación e qué explica?

como un todo ou só unha parte del; e segundo se poden aplicarse a calqueira algoritmo ou precisa que este sexa parte dunha familia (e.g. sobre un modelo da familia ViT, ben poden usarase métodos de explicación xerais ou métodos exclusivos dos ViT).

<Intenta explicar primeiro a idea abstracta, xeral, antes do mecanismo que usa para conseguilo.>

Un exemplo de método explicable é LIME [14], ~~que~~ para ofrecer unha xustificación de porque un modelo deu unha saída cunha certa entrada, ~~far~~ a partir de inferencias con entrdas similares e aproxima localmente a función de decisión. Pode ofrecer explicacións relativamente útiles ~~(ver Figura 1.4a)~~ pero fundamentase na localidade, e usa un modelo auxiliar.

<concretar>

. Por exemplo, na Figura X, ilústraste un caso onde LIME pretende aportar unha explicación de por qué o sistema decidiu que a imaxe correspondía a un husky, destacando que o sistema tomou a decisión ... <explicar concepto de clever hans>

do espazo de entradas

isto é relevante por¿

<
1. Intentar definir o concepto
2. Proporcionar intuición
3. Enunciar exemplos de métodos (referencias)
4. Identificar limitacións e dicutir o que implica
>

Outra familia de métodos ~~son~~ comprenden: GradCAM (para C.N.N.), ReciproCAM ou CAM guiado por atención (para ViT). Estes usan parte da información da pasada *forward* ou *backwards* e adoitan conseguir <evitar termos vagos> bos resultados en canto a respostar a pregunta 'Que porcion da imaxe correspóndese cunha certa clase?'. Non obstante presenta o defecto de que non pode manipularse conceptos semanticos máis pequenos ca clase e ademáis o uso dun método deste tipo adoita ser <concretar / explicar> algo relativamente sofisticado con moitos elementos novos.

<Discutir implicacións. Citar/discutir figura de exemplo para ilustrar>

<Pódese clarificar. Ao igual que coa interpretabilidade, hai que facer un "reframing", identificando conceptos e introducindo pistas sobre os puntos onde CRATE e a proposta vai aportar aspectos diferencias, sen concretar ainda a solución máis que conceptualmente a motivación>

Por tanto, precisamos algoritmos de explicabilidade que sexan de aplicación ou ben xeral ou ben cara os modelos usados agora (e.g. C.N.N., ViT ...), que exploten o modelo como un todo (non como LIME) dun xeito transparente (non como GradCAM) e idealmente que nos permitan manipular conceptos semánticos máis finos.

<IMPORTANTE. As figuras hai que presentalas e citalas sempre no texto. Citar unha figura non sustitue a súa explicación conceptual no texto sobre o que representa e implica. Hai que integrala no relato.>



(a) a) LIME pode sinalar as rexións que fan tomar a decisión de se a imaxe é un *husky* ou non, neste caso vemos que o modelo di que é un husky pola neve e non polo animal en sí. Polo tanto grazas á explicabilidade podemos identificar mostras nas que o modelo da a solución correcta pero por motivos equivocados. Figura extraída de [14].



(b) b) ReciproCAM sinala a influencia dunha rexión con respecto a clase, neste caso a clase é elefante. Figura extraída de [15]

Figura 1.4: Exemplos de métodos de explicabilidade con aplicación a imaxes.

~~1.2.5 MCR^2 e ReduNet - Redes Caixa Blanca~~

[NOTA: darlle unha volta a esta sección, o tema e presentar o obxectivo MCR^2 disperso para motivar a crate e as nosas derivacións e xa]

1.3. Nova sección propia sobre redes neuronais.
Obxectivo:
- Introducir redes neuronais desde os seus fundamentos neurofisiolóxicos
--> Modelo de neurona. Exemplo perceptrón multicapa -> Posibles interpretacións: pattern matching, Proxeción de espazos
--> Cortex visual, Sparse coding. Exemplo Redes convolucionais -> Interpretación:
--> Autoencoders -> Transformadas, PCA, compresión. Aprendizaxe de diccionarios, ISTA
--> Redes residuais -> Intepretación: aprendizaxe desenrolado
--> Modelos de atención e transformers. VIT -> Interpretación: Memorias asociativas, circuitos lóxicos. Qué son os tokens e qué representan?
--> Discusión sobre interpretabilidade de redes neuronais e deseño ad hoc de arquitecturas. Mesmo si os mecanismos son interpretables, é necesario 1) coñecer o que representan os patróns, 2) poder interpretar mecanisticamente o algoritmo e procedemento de procesamento. Motiva as seguintes seccións.

Na primeira metade da pasada década viuse o esplendor dun tipo de R.N.A. nas que o operador principal é a convolución dun filtro ou *kernel* aprendible coa imaxe (ou ca saída doutra convolución), estas Redes chámanse Rede de Neuronas Artificiais Convolucionais (*Convolutional Neural Network*) (C.N.N.). Se ben son algo explicables [16, 17], a pregunta 'Que esta a facer esta compoñente da C.N.N.?' en xeral só pode responderse *a posteriori*. Isto motivou ó grupo do profesor Yi Ma o desenvolvemento dunha C.N.N. como instancia do MCR^2 [18], creando así unha Rede Caixa Blanca **[NOTA: acronimo? mellor en inglés?]**.

A Maximal Coding Rate Reduction (MCR^2) é unha función obxectivo de A.R. que intenta cumplir cos seguintes obxectivos na representación no espacio de características:

[NOTA: estas tres características sacoas de o artigo de CRATE pero quito a de 'consistent' porque penso que non ven ó caso, no libro de 2022 fala doutras tres características, pero estas parécenme máis entendibles]

1.4. Nova sección sobre propiedades das representacións
Obxectivo: Resumir e explicar as propiedades desexables das representacións e a súa utilidade en termos de explicabilidade e interpretabilidade.
-> Subseccións de compresión / low dim, Linealidade/space density e dispersión /independencia.
-> Subsección de MCR^2

- *Comprimidas:* sendo uniformemente distribuídas segundo algunhas estruturas de baixa dimensión[1] estándar que se axustan á baixa dimensionalidade intrínseca dos datos, co fin de asegurar unha codificación compacta dos datos.
- *Lineais:* as estruturas de baixa dimensión teñen unha xeometría (a anacos) lineal, co fin de facilitar a interpolación e a extrapolación no espazo de representación.
- *Dispersas:* as estruturas de baixa dimensión correspondentes a diferentes partes da distribución dos datos son estatísticamente incoherentes ou xeometricamente ortogonais, e tamén aliñadas cos eixes, co fin de asegurar unha codificación máis compacta e facilitar o procesamento posterior.

Formalmente defínese como a maximización da seguinte función:

$$\Delta R(Z|U_{[K]}) = R(Z) - R^c(Z|U_{[K]})$$

onde

$$R(Z) \doteq \frac{1}{2}\text{logdet}(I + Z^{'}Z)$$

e

$$R^c(Z|U) \doteq \sum_k R(U_k^{'}Z)$$

[NOTA: —]

en [19] dicen que as redes (Transformadores) caixas brancas son as que diséñanse '*con a estuctura dos datos de entrada en mente, representando un maridaxe entre a aproximación clásica a A.R. e o novo A.P.*'

[1] Como unhas gausianas

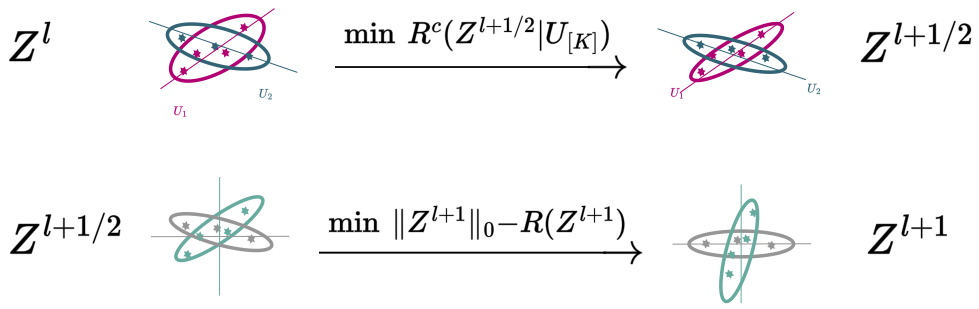


Figura 1.5: Iteración dos pasos do MCR[2]. O primeiro paso *comprime* o espacio segundo modelos locais de gausiana parametrizados por $U_i \in U_{[K]}$. Isto é: asigna cada token a un espacio (En realidade a asignación é suave no sentido de que cada token exprésase como $z_i = \alpha_i U_{[K]}$, onde $\alpha_{i,j}$ é a influencia do espazo U_j no token z_i.) e reduce o volumen que ocupan os tokens de cada espacio. O segundo paso realiza dúas accións simultaneamente: expande o volumen que ocupan todos os tokens (de todos os espacios) e rota os exes de xeito que coincidan cas coordenadas, facendo así unha representación dispersa. Figura de autoría propia.

1.2.6 ViT

integrado en 1.3

A arquitectura ViT (do inglés *Vision in Transformer*)[20] é unha instanciación do xa coñecido Transformer [21] aplicado á vision. No seu dominio orixinal, o procesamento da linguaxe natural, o Transformer demostrou moi bo rendemento, xogando un papel moi importante na burbulla económica da IA que estamos a vivir. En particular o ViT demostrou que a convolución, a compoñente fundamental das C.N.N. xa non era necesaria[2] marcando así un hito na historia do A.P.. Na Figura 1.6 ilústrase a arquitectura a nivel conceptual para un problema de clasificación.

1.2.7 Aprendizaxe de diccionarios

integrado en 1.3

O aprendizaxe de diccionarios é o problema de representar o vector $X \in \mathbb{R}^n$, como unha combinación $\beta \in \mathbb{R}^d$ de *palabras dun diccionario* $D \in \mathbb{R}^{n,d}$ de forma que preténdese minimizar

$$\|X - D\beta\|_p$$

para algún p. Este problema correspóndese cun cambio de base (e.g. Transformada de Fourier, PCA ...) no que pasamos da representación orixinal (valores RGB dos píxeles) a unha máis interesante ou representativa. Sobre este problema adoitanse engadir restricción adicionais, por exemplo que as columnas de D sexan ortonormais, isto é $D^{'}D = I$, e ten a implicación de que as *palabras* do *diccionario* sexan incoherentes entre sí (pola natureza dos respectivos problemas, tanto a Transformada de Fourier como PCA teñen esta propiedade). Outra restric-

[2]Cando menos para clasificación de imaxe de dominio xeral[22]

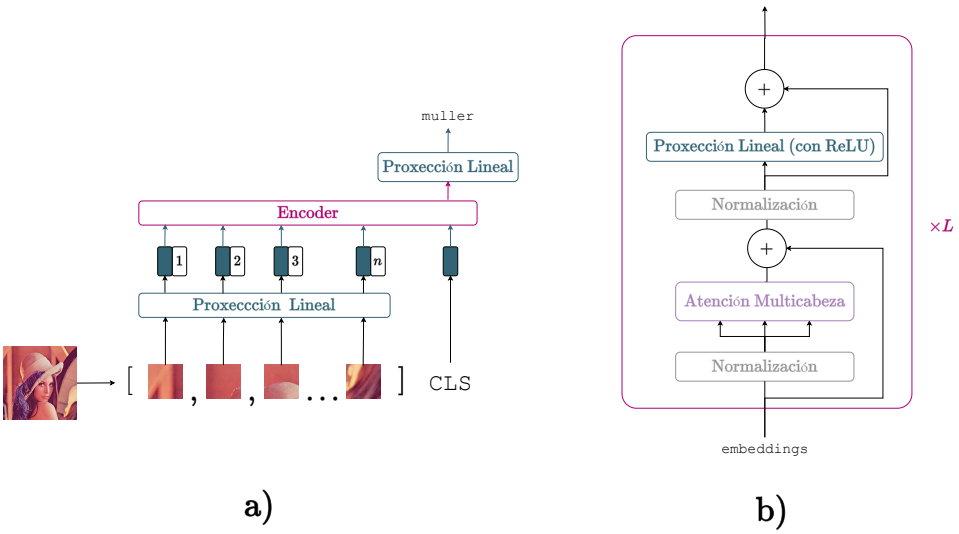


Figura 1.6: Arquitectura do ViT [20]. a) Para ser procesadas, as imaxes son recortadas en parches. Estes son proxectados ó espacio de `embeddings` e concatenados cun vector posicional (representado na Figura como un núnmero) antes de entrar no Encoder. Xunto cos parches tamén é entrada do Encoder un vector aprendible asociado á `clase`. b) O encoder consta de dos grandes bloques residuais precedidos de normalización, o primeiro é a Atención Multicabeza [21] e o segundo un M.L.P.. Figura de autoría propia.

ción é penalizar o número de *palabras* cas que un pode expresarse é dicir $\|\beta\|_0$, de xeito que este novo problema sería:

$$\min \|X - D\beta\|_p + \|\beta\|_0$$

para algún p. A esta formulación coñécese como Aprendizaxe de Diccionarios Dispersa, e ten moitas propiedades interesantes [6], por exemplo a *decorrupción* de imaxes (ver Figura 1.7).

1.2.8 Aprendizaxe desenrolado

Integrado en 1.3

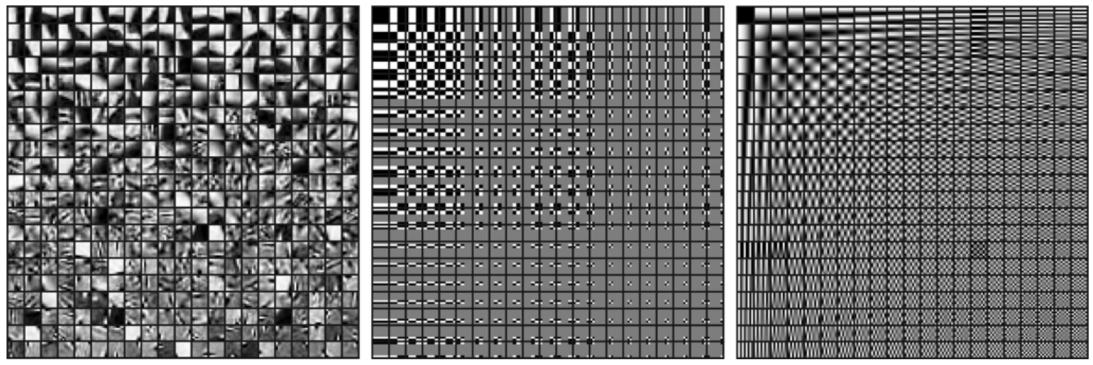
[NOTA: recurso : [24], acronimo: Aprendizaxe Desenrolado (A.D.). esencialmente: cada capa modela Z^l co seu modelo correspondente (conxunto de bases). conseguindo, a través delas o obxectivo global. esta seccion é para introducir o crate, cousas que saianse deso sobran]

1.5 Nova sección sobre redes de caixa branca
Concepto: Interpretabilidade da arquitectura, derivandoa desde first principles
Motivación: En lugar de RNA con arquitectura ad hoc, darlle sentido as eleccions
-> Subsección redunet -> Resnet como algorimo desenrolado
-> Subsección CRATE -> Derivación de transformers

1.2.9 CRATE

Unha alternativa a ViT onde cada capa é interpretable **[NOTA: explicar máis, pero só o necesario.]**

[NOTA: polo menos hai que facela conexión entre o obxectivo de maximización e a arquitectura. tamen hai que facer paralelismo co vit clásico (o mssa é o mhsa,



(a)



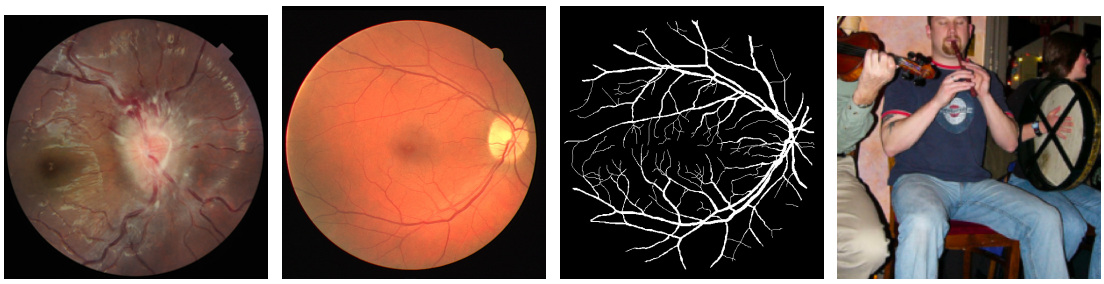
(b)

Figura 1.7: Exemplo de *decorrupción* con Aprendizaxe de Diccionarios. (a) Móstranse tres dicionarios, o primeiro adestrado segundo o algoritmo KSV e un conxunto de datos de caras, o segundo e o terceiro son bases de Haar e da Transformada de coseno discreta, respectivamente. (b) Unha imaxe con ruído, e o resultado de reexpresar devandita imaxe como unha combinación de palabras dos tres anteriores dicionarios. Obsérvase que o mellor resultado acádase co diccionario aprendido. Figuras extraídas de [23].

o ista é o mlp . . .). tamén tense que presentar as formulas que logo vanse usar na seccion 3.1.1. quizais algún diagrama? igual cun recorte do diagrama 3.1 e engadirlle o mlp/ista chega?. falando do MCR2 e Sparsity hai que dicir, "como verase na seccion 3.2, istos principios suporan propiedades emerxentes como a asignación sematica ás cabezas de atencion". ainda que xa faramos dos vit hai que facer explicito o uso to token cls no crate porque logo vaise usar enton non pode aparecer da nada, ou que o lector teña que deducir que simplemente iportase do vit.]

En otro capítulo (3 o 4)

1.2.10 Conxuntos de datos



(a) (b) (c) (d)

Figura 1.8: Mostras dos conxuntos de datos. (a) Imaxe de fondo de retina con edema de disco óptico, pertencente ó conxunto de datos RFMiD. (b-c) Imaxe de fondo de retina e a súa correspondente máscara binaria anotada, pertencentes ó conxunto de datos DRIVE (d) Imaxe de mostra do conxunto de datos ImageNet

- **RFMiD 2.0 (2023).** [25] Recolle mostras de enfermidades raras con imaxes de alta resolución. Además de a etiqueta 'san', inclue 48 condicións entre as que se atopan as patoloxías vasculares (e.g. oclusións de veas e arterias, retinopatía hipertensiva, retinopatía hemorráxica, vasos tortuosos ...), diabéticas (e.g. retinopatía diabética, edema macular, manchas algodonosas, microaneurismas ...), dexenerativas ou relacionadas ca idade (e.g. dexeneración macular asociada ca idade, drusas, retinite pigmentaria, miopía ...), trastornos do nervio óptico (e.g. escavación do nervio óptico, edema do disco óptico, palidez do disco óptico, hialose asteroide ...), alteracións estructurais da retina (e.g. desprazamento da retina, burato retiniano, rotura retiniana ...), congénitas (e.g. coloboma, pregamentos coroideos, hipertensión intracranial idiopática ...) ...Polo que é de gran utilidade para o diagnóstico e caracterización destas patoloxías dado o seu nivel de precisión cas etiquetas.
- **DRIVE (2004).** [26] Deseñado para segmentación de vasos sanguíneos, inclue 40 imaxes cas súas máscaras binarias anotadas manualmente por expertos (ver Figura 1.8 (b-c)).

- **ImageNet (2009).** [27] Nace ante a necesidade dun gran conxunto de datos de imaxe natural e foi plantexado como unha xerarquía de xeito que o concepto de *clase* é multinivel, porque se ben hai animais e artefactos, ambos divídense en subcategorías recursivamente ate chegar ó nivel do individuo. É dicir, preséntase o 'labrador alemán' non como un elemento illado pero como parte dos 'cans' e estes á súa vez de 'carnívoros', 'placentarios'... Polo seu gran tamaño é variedade tivo un impacto notable no desenvolvemento do A.P. es as R.N.A..

Capítulo 3

1.3 Métricas

No presente traballo fase uso das seguintes métricas:

- **Precisión:** **[NOTA: explicar tamén acc@5]**
- **AUC-ROC:** **[NOTA: explicar]**
- **Dice:** **[NOTA: explicar]**

Completar en base ao contexto e introducción anterior, a modo de resumen de ideas principais, identificación de oportunidades e formalizacion de proposta, antes de enumerar contribucións

1.4 Discusión

1.4.1 Elementos diferenciais

[NOTA: crate nunca usouse con datasets de ollos]

1.4.2 Oportunidades

[NOTA: experimentar coa interpretabilidade / explicabilidade en datasets que o precisen pola AI Act blablabla]

1.4.3 Contribucións

[NOTA: ??]

Capítulo 2

Metodoloxía e planificación

O que queira peixes que molle o cu [28]

Neste capítulo descríbese cómo se traballou así como os recursos involucrados e a planificación do traballo.

2.1 Método de traballo

Dada a natureza exploratoria do proxecto, adoptouse un modelo de desenvolvementto iterativo e incremental. Este enfoque permite introducir novos avances de forma progresiva en cada iteración, mediante o desenvolvemento e avalación dos aportes de cada incremento para o avance do proxecto. Isto permiet reaccionar de forma áxil mediante a planificación progresiva de novas funcionalidades e experimentacións adicionais, axustadas a cada estadío no desenvolvemento e resultados da investigación.

Os primeiros esforzos adicaronse á compresión do material. Unha vez a compresión foi sufiente para empezar as iteracións semanais~~, estas consistían en sucesións de reunión (ver 2.1) e traballo individual.~~ O traballo individual do alumno ó longo das semanas comprendía:

O avance das iteracións foi controlada mediante reunións, que seguen o equema representado na figura 2.1, de forma que en función dos resultados parciais, se prioriza o foco do seguinte incremento.

- **Programación:** de experimentos (isto é: adestramento de R.N.A.) e de visualizacións para poder analizar distintos aspectos das Redes adestradas.
- **Análise de resultados:** para interpretar as visualizacións e formular afirmacións ou preguntas dependendo do entendemento. En ambos casos era moi útil porque se formulaba unha afirmación, ó presentarlla ós titores ou ben comprendía porque tiña razón ou porque non a tiña; e se formulaba unha pregunta aprendía da súa resposta.
- **Lectura bibliográfica:** de temas que non plantexáronse ó principio pero foron importantes para respostar ás preguntas que xurdían e en xeral comprender profundamente o tema a tratar, segundo íase presentando de forma distinta ó longo das semanas.

2.2 Recursos

2.2.1 Humanos

Este traballo foi supervisado por tres tutores [1] que tiveron o rol directivo en canto ás ideas, respostaron a pregunta 'Qué se fai?' e en canto o método, 'Cómo se fai?'. O alumno tivo de

[1] Un dos cales mudou de universidade durante o traballo e por tanto non figura na portada.

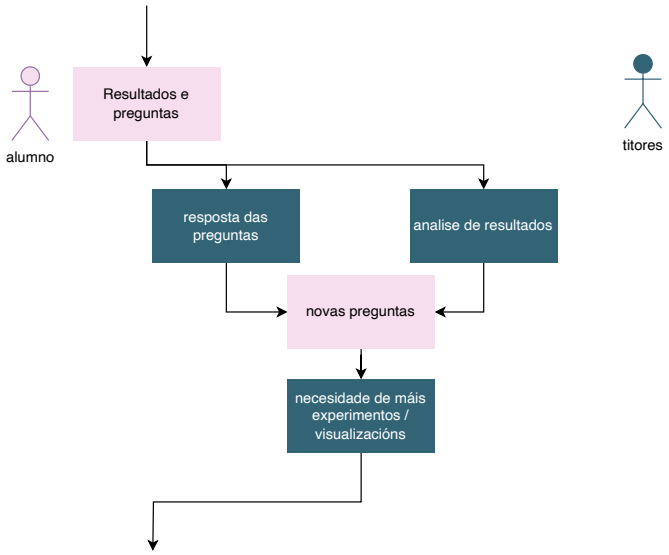


Figura 2.1: Esquema do contido das reunións semanais entre o alumno e os titores. Figura de autoría propia.

entrada un natural papel subordinado é dicir, leu e programou o que se lle mandou. Co paso das semanas, o coñecemento e intuición que desenvolveu o alumno sobre o tema permitiulle do mesmo modo propoñer ideas e métodos, dotando ós tutores dun rol máis alto nivel.

A primeira achega dos tutores foi o punteiro á bibliografía e código necesarios para a compresión do tema. Devandita tarefa mantivo ocupado ó alumno en soidade os primeiros meses e cando este acadou un nivel de compresión sufiente comenzaron as reunións semanais. ~~Estas seguían o esquema da Figura 2.1~~

2.2.2 De *Software*

A continuación listanse os recursos *Software* empregados no traballo con importancia descendente. Nótese que todo o *Software* é código aberto e nalgúns casos código libre.

- **Python:** [2] a linguaxe por defecto para escribir os programas do traballo. Funcionalmente é conector das librerías mencionadas xa que se ben por si só Python non é tan útil para a práctica de A.P., funciona como un fabuloso pegamento.
- **PyTorch:** [3] a libraría por defecto de A.P. hoxe en día que permitiunos facer modificacións, inspeccións e adestramentos sobre a R.N.A., o cal corresponde co *grosso* do traballo.

[2] Python Software Foundation License Version 2 (PSF-2.0)
[3] BSD 3-Clause License

- **einops:** [4] é un paquete adicado á manipulación axil a nivel de código de tensores. Como a disciplina de A.P. esencialmente baséase neso, o paquete axilizou o desenvolvemento á vez que fixo o código máis lexible é fácil de manter ou asegurar a súa correctitude.
- **draw.io (diagrams.net):** [5] a éxpresión gráfica é moi importante á hora de comunicar conceptos complexos, polo que nos informes semanais e no presente documento os esquemas e diagramas realizáronse con este conveniente programa de escritorio.
- **Matplotlib:** [6] a libraría por defecto para as gráficas e figuras xeradas de xeito programático con Python.
- **NumPy:** [7] é a libraría que da soporte ós tipos de dato de Matplotlib polo que fai de punto en común entre o código experimental desenvolto en PyTorch / einops e o código de figuras desenvolto en Matplotlib.
- **Bash:** [8] cando o programa (ou *script*) ía ser sufientemente pequeno, o alumno considerou á linguaxe Bash moito máis elegante e apropiada. Notar que estrictamente estrictamente non fixo falta sair de Python e por tanto a decisión ten unha compoñente de gusto persoal.
- **rsync:** [8] para ambos sentidos da sincronización retratada na Figura 2.3 foi de gran utilidade este programa GNU.
- **Vim:** [9] para a edición de arquivos de texto. En particular, a codificación de programas, a escritura da memoria ou a esporádica modificación dalgún arquivo de configuración.
- **tmux:** [10] é un multiplexor de terminais, é dicir permite acceder a múltiples sesións de terminal simultaneamente nunha única xanela. É útil para executar máis dun programa de liña de comandos ó mesmo, en particular, Vim para a edición de aquivos e Python para a execución dos mesmos.
- **latexmk:** [11] para a compilación da memoria, segundo as recomendacións do equipo de desenvolvemento da plantilla da memoria da FIC [29].

Merécese unha mención o mapa de cor `pink` (ver Figura 2.2) do paquete Matplotlib que foi usado nas visualizacións de atención (ver Sección 3.2) polo seu gran rango de luminosidade (L^*) [30] e o seu parecido co rosa institucional da UDC.

[4] MIT License
[5] Apache License 2.0
[6] Matplotlib License (BSD-style license based on the PSF License)
[7] BSD 3-Clause License
[8] GNU General Public License Version 3 (GPL-3.0-or-later)
[9] Vim License
[10] ISC License
[11] GNU General Public License Version 2 or later (GPL-2.0-or-later)



Figura 2.2: Mapa de cor Pink. Figura extraída de [30].

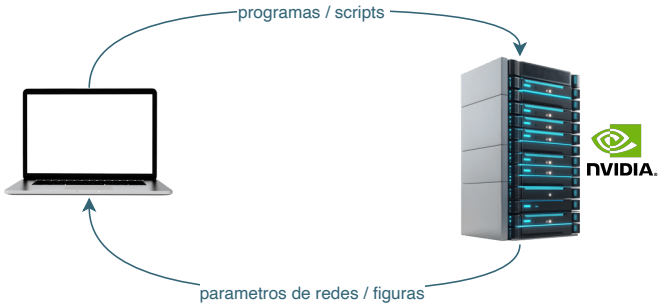


Figura 2.3: As comunicacións entre o portatil do alumno e o servidor seguen un bucle de sicronización. Figura de autoría propia.

2.2.3 De *Hardware*

Fíxose uso d~~o~~[a] portatil do alumno para o desenvolvemento do código así como dun servidor cedido polo Grupo VARPA que conta cunha gráfica NVIDIA RTX A6000 ó que o alumno podía conectarse de xeito remoto. Ó desenvolver os programas ~~no seu~~ [na súa] portatil, o alumno debía sincronizarse co servidor para que o segundo tivese o código do primeiro, e o primeiro os artefactos do segundo (ver Figura 2.3).

2.2.4. De datos
-> Lista de datasets

2.3 Planificación

As fases do traballo foron: <incluir temporización aproximada en esforzo (horas)>

- Presentación, por parte dos titores, do marco xeral do traballo así como punteiros a recursos bibliográficos e de código.
- Lectura bibliográfica e comprensión do código de referencia.
- Comezo das interacións segundo o esquema da Figura 2.1.
- Nova tarefa: segmentar con venas usando CRATE e máis o conxunto de datos DRIVE (ver 1.8). Ali consideramos o sistema de supervisión (convolucionar a imaxe con gaussianas con desviacións típicas $\sigma_i = 2^i \times 0.5 \qquad \forall i \in \{0 \dots n\}$ pero finalmente usamos a version naive)
- Proposición do segundo orden, motivada teoricamente e a nivel experimental ~~[NOTA: en retrospectiva ambas motivacións orixinais eran cuestionables]~~. A cal, pola

sua parte motivou tanto o cambio de tarefa (predicción de ollo san - non san no conxunto de datos RFMiD) como a consideración de uso de Linformer ~~[NOTA: que quedou en nada].~~ Además considerouse o cruce (adestrar cun orde e facer inferencia con outro), que cualitativa e cuantitativamente demostrou non funcionar para Imagenet.

- Proposición de compartir U e D.
- Investigación dos parches da capa lineal de entrada ó transformer, co obxectivo de invertila red ~~[NOTA: non fun capaz de invertila, principalmente por descoñecemento e complexidade].~~ Probouse a adestrar primeiro esa capa, a regulalizala con distintas penalizacións e varias (bastantes) combinacións (primeiro adestrar so a primeira capa con e sin regularizacions e logo conxelala, adestrar con regularizacions . . .)
- Comparativa en Imagenet da nosa red (ambas proposicións) ca de referencia
- Estas tarefas víronse asociadas á programación de *scripts* de visualización e redación de memorias semanais, de xeito totalmente paralelo.
- Redacción da memoria.

<incluir un diagrama de Gantt>

2.4. Estimación de custos

2.5 Seguemento e desvios.

Capítulo 3

Traballo proposto

O presente traballo é de carácter teórico e experimental. Neste capítulo presentaranse as propostas téoricas así como as posibilidades de comparación e análise dos experimentos que expondranse no próximo capítulo. Deste xeito a práctica experimental, ver o Capítulo 4 (e as consecuentes conclusións, ver Capítulo 5) baséase nas achegas teóricas a continuación presentadas.

Sección de visión xeral, onde se introducen de forma xeral, intuitiva, abstracta, todos os apectos detallados a continuación

<Faltaría motivar e proporcionar contexto:
1. Detalle concreto da derivación de CRATE
2. Oportunidade
3. Proposta
4. Derivación
5. Implicacións e analise
>

3.1 Segundo orden

Segundo a presentación do modelo CRATE **[NOTA: falta por presentar]** (ver Sección 1.2.9), considérase agora a derivación de outro modelo estilo ViT (ver Sección 1.2.6) a partires da mesma premisa de maximizar o *Sparse Coding Rate*.

3.1.1 Aproximación da inversa mediante suma de matrices

O operador MSSA do CRATE é unha implementación de un ascenso de gradiente sobre $R^c(Z|U_{[K]})$, é dicir queremos:

$$\nabla R^c(Z|U_{[K]}) = \sum_k U_k(U_k' Z)(I + (U_k Z)'(U_k Z))^{-1}$$

onde ...

(ver Sección 1.2.9). Se Z son os tokens que estanse a procesar, esta operación intuitivamente corresponde con movelos (é dicir, cambiar a súa representación) cara un espazo onde os tokens máis parecidos[1] segundo un criterio k o sexan máis, simultaneamente para os K criterios. Devandita operación conlevaría K inversas o cal é computacionalmente complexo. Eiquí nace un dilema: Computar o que dí o principio, obtendo os resultados que tense en mente ou pola contra aproximar para facer a tarefa factible? Os autores optaron por aproximar as

[1] Neste caso o criterio de similaridade k-ésimo é o producto interno usual no espazo definido pola transformación liñeal U_k. É dicir, sim $(z_i, z_j) = (U_k z_i)'(U_k z_j)$

inversas segundo a expansión de primer orden das series de Neumann [31], o cal resultaría no exposto CRATE 1.2.9. En particular a expresión quedaría

$$\nabla R^c(Z|U_{[K]}) \approx \sum_k U_k(U_k'Z)(I - (U_kZ)'(U_kZ)) \tag{1}$$

Neste traballo preguntámonos: Qué pasaría se a aproximación fora máis precisa? Se a aproximación orixinal derivou nunha R.N.A., Qué R.N.A. resultaría de ter aproximado máis fino? A continuación presentamos a nosa derivación. Collendo adicionalmente o segundo termo da expansión de Neumann, quedaría o seguinte operador que asemella unha versión *de segundo orde* [32, 33] :

$$\nabla R^c(Z|U_{[K]}) \approx \sum_k U_k(U_k'Z)(I - (U_kZ)'(U_kZ) + ((U_kZ)'(U_kZ))^2) \tag{2}$$

[NOTA: engadir un pouco de explicación para que se entenda como se pasa de unha cousa á seguinte. OU NON?]

3.1.2 Nova arquitectura

Pódese apreciar que a aproximación proposta é unha reinterpretación do rol de cada parámetro da Rede, influindo así nas operacións nas que compromételese tanto na inferencia (fluxo de entrada á saída) como no adestramento (fluxo de saída a entrada).

[NOTA: dicir que ó facer backprop hai que guardar o doble de memoria e por tanto: co mesmo *hardware* as épocas duran máis. É unha desvantaxe do modelo]

[NOTA: Referenciar a Figura 3.1]

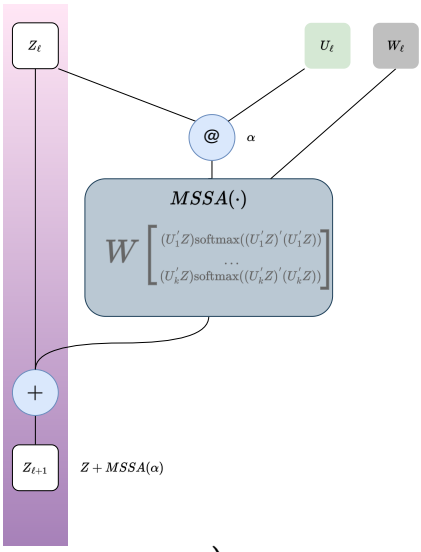
[NOTA: dicir algo de que usa o mesmo número de parametros pero ten máis información de gradiente]

Leváronse a cabo experimentos probando devandita arquitectura con todolos conxuntos de datos expostos na Sección 1.2.10 e os seus resultados exponse nas Seccións 4.1.1, 4.2.1 e 4.3.1.

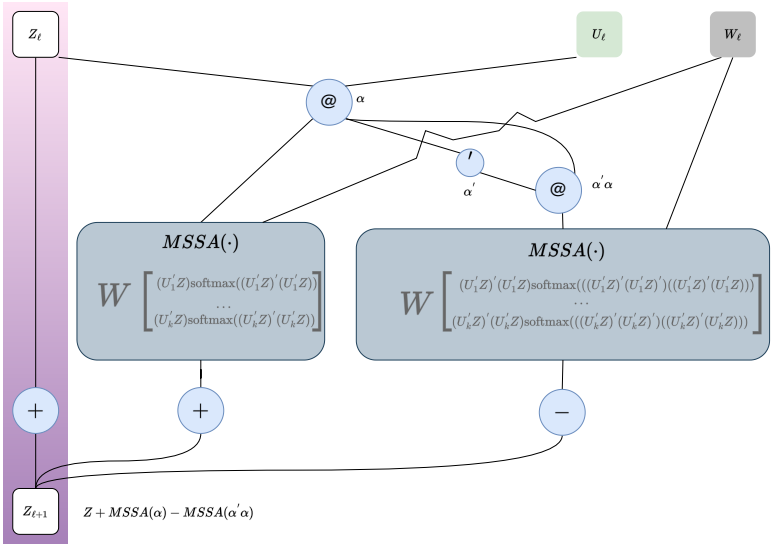
3.1.3 Cruce

Polas deseables propiedades desta nova arquitectura e o feito de que use os mesmos parámetros que a orixinal, xurde de forma natural a pregunta: Como comportaríase a unha Rede adestrada nun réxime de primeiro orden de ser usada en inferencia como se fora de primeiro segundo orde? E viceversa?

Como a versión de segundo orden pódese interpretar como a rede orixinal (unha cabeza de atención por bloque) con unha correción explicita no obxectivo de MCR^2 Disperso (en forma



a)



b)

Figura 3.1: a) A atención multicabeza do CRATE orixinal. Mostráse o fluxo residual da atención en púrpura [21, 34]. O símbolos @ e + denotan multiplicación e suma matricial respectivamente. b) A atención multicabeza proposta. O símbolos $'$ e − denotan trasposta e resta respectivamente o. **[NOTA: Explicar máis supoño pero non sei o que]**. Pódese apreciar que aínda que a arquitectura proposta realiza máis computo, non está máis parametrizada. Para máis detalles sobre a arquitectura orixinal e a súa derivación consultar [31]. Figura de autoría propia.

de outra cabeza) podería ser o caso que adestrar en, digamos, modo primeiro orde e facer inferencia en modo segundo orde, obteñamos unha correción *gratis* sen precisar un adestramento máis custoso. Tamén podería ser o caso que de adestrar en segundo orden e facer inferencia como primeiro orden (pensemos nun contexto en tempo real no que a velocidade é crítica) obteñamos a velocidade do primeiro orden ca precisión da segunda.

Leváronse a cabo experimentos probando ambas combinacións de cruce co conxunto de datos ImageNet e exponse os seus resultados na Sección 4.1.2.

3.2 Visualizacións dos mapas de atención

3.2.1 Motivación

Se ben todolos Transformadores (en xeral, e todolos ViT en particular) teñen relacións de *atención*, e pode dicirse que dous *tokens atendense moito ou pouco*. Polo xeral estas relacións non reflictense de forma intuitiva nas relacións que podemos facer os humanos, é decir, os humanos podemos relacionar a condición de hipertensión nun ollo con rexións de venas moi tortuosas ou podemos relacionar a raza dun can coa forma das súas orellas. Nesta "problemática" ou discrepancia entre a nosa intuición e as R.N.A. nace DINO [35], que a traveso dun réxime de adestramento sofisticado, non trivial e non totalmente comprensible (parcialmente arbitrario) consegue unhas relacións de atención que sí correspóndese coa intuición humana. En particular as relacións de atención das visualizacións do artigo realízanse entre cada token e o token `[CLS]`[2].

Resultado do diseño baseado no principio de MCR[2] disperso, o modelo CRATE (ver Sección 1.2.9) é quen de producir semellantes visualizacións as do DINO, quizáis un pouco peores [19], pero claramente superiores en ambos casos a un ViT convencional con adestramento convencional. A diferencia entre as solucións que ofrecen DINO e CRATE reside en que entre un ViT e DINO cambia totalmente o procedimento de adestramento e mesmo as funcións de pérdidas usadas, mentres que entre un ViT e CRATE cambia lixeiramente a arquitectura, pero conservando todas as compoñentes e o adestramento.

A continuación descríbese como poder *visualizar* estas relacións de atención, que teñen como fin demostrar ó lector que efectivamente o funcionamento interno de CRATE correspóndese polo menos parcialmente ca intuición humana, exemplos de devanditas visualizacións presentaranse e discutiranse nas Seccións 4.1.3, 4.2.2 e 4.3.2.

[2]Segundo o artigo fundacional dos ViT [20] o token `[CLS]` identifica a clase, nos problemas de clasificación. En particular nun contexto de diagnóstico de patoloxías a patoloxía é a clase.

3.2.2 Procedemento

A visualización da Rede supón, para cabeza ver canto *atende* o token `[CLS]` ós tokens asociados cunha imaxe. Desta forma se nunha cabeza de atención dunha Rede adestrada a predecir presenza de patoloxía en imaxes de fondo de retina, hai moita relación entre os tokens correspondentes a unhas rexións da retina e o token `[CLS]`, entón probablemente exista unha relación entre esas rexións e o estado de saúde dese ollo.

Como a atención nos ViT é un fenómeno relativo, é decir, unha cabeza pode atender moito a case todos os tokens e outra case nada á maioria; para a correcta visualización deste fenómeno é preciso unha normalización. Como xa existe unha `softmax` na atención (que subordina o comportamento xa que influe no adestramento) parece natural expresar a "relación coa clase" no modelo CRATE do token z_i na capa ℓ na cabeza j (ver Figura 3.1) como a saída da `softmax` indexada no token `[CLS]`, é dicir sólo interésanos as relacións que ten un token co token `[CLS]` normalizado con canto relacionánse os demáis tokens co token `[CLS]`. Formalmente:

$$\texttt{relacion_clase}(z_i|U_j^\ell) = \frac{e^{\langle U_j^{\ell\prime} z_i, U_j^{\ell\prime} z_{[\text{CLS}]}\rangle}}{\sum_{i=1}^{N} e^{\langle U_j^{\ell\prime} z_i, U_j^{\ell\prime} z_{[\text{CLS}]}\rangle}}$$

Onde U_j^ℓ é a parametrización da j-ésima cabeza de atención da ℓ-ésima capa do Transformador. Así una vez calculados devanditos valores podemos simplemente asignar un cor a cada nivel de relación, onde (no caso dos diagramas deste traballo) máis relación é rosa mentras que menos é branco (para unha referencia no mapa de cor ver a Figura 2.2).

3.2.3 Extensión para resolución

A desvantaxe do método é que é moi *grano grueso* posto que só temos un valor por token. Para solventar eso **[NOTA: falar do de facer stride para ter máis resolución]**

3.2.4 Extensión ó segundo orde

Baseándonos na técnica de visualización dos mapas de activación dos autores de CRATE [19, 31] **[NOTA: explicar que fan? esencialmente indexan o que vai á dereita da W na cabeza polo token CLS, non sei se enténdese]**, extendemos a visualización ó novo modelo do seguinte xeito.

- Como pódese apreciar na Figura 3.1, todas as operación que relizanse en CRATE, tamén ocurren na novo modelo, por tanto igualmente pódese extrer os mapas de atención que xa tiñamos antes do mesmo xeito.

- Como as novas operacións (a nova canbeza) son análogas ás existentes (subtituindo α por $\alpha^{'}\alpha$), pódese

[NOTA: seguir falando] [NOTA: falar de que a nova representación intermedia é máis *suave*]

3.3 Recuperación de parches representativos

Xa que o MLP de CRATE implementa un aprendixaze de diccionarios (ver Seccións 1.2.2, 1.2.7 e 1.2.9) é de especial interese a visualización das *palabras* que compoñen o diccionario.

3.3.1 Procedemento

Para as visualizacións das palabras dunha Rede do vindeiro capítulo, neste traballo optamos polo seguinte procedemento en dous pasos:

1. Dada unha capa (normalmente a penúltima) collíase a salida intermedia do modelo de xeito que, para cada token obtíñase un vector (ver Figura 3.2). Esto facíase para todas as imaxes do conxunto de datos e para cada cabeza.

2. Unha vez temos para cada token de cada imaxe unha representación vectorial onde cada entrada deses vectores correspóndese cunha palabra, podemos preguntarnos: Cales son os parches que teñen a entrada i-ésima con máis valor absoluto? Eses seran os parches máis representativos de cada palabra e unha escolma deles dará dun vistazo unha idea do que supon esa palabra en términos visuais. Por tanto por cada entrada do vector calculamos mediante unha ordenación simple cales son os k vectores con devandita entrada de maior magnitude, para cada cabeza.

3. Finalmente, xa cos índices das imaxes (por exemplo: para a entrada corresponde ca decimoquinta palabra, os dous parches máis representativos son o segundo parche da quincuaxésima cuarta imaxe e o vixéximo parche da septuaxésima decimo terceira imaxe) escolmamos devanditos parches (os píxeles deles) e os arranxamos todos nun diagrama como o mosaico da Figura 4.5 onde cada gran columna é unha cabeza, dentro destas cada fila é unha palabra e dentro destas a columna i-ésima correspóndese co i-ésimo parche máis representativo. Unha vez este mosaico estaba preparado, procedíase a unha fase de inspeción manual para identificar palabras de interes.

En realidade, como o paso un podría tardar ate varias horas para o conxunto de datos completo de ImageNet, e xerar como resultado unha tremenda colección de tensores, neste traballo optouse pola realización simultanea dos pasos 1 e 2, é dicir, ir ordenando a medida que facíase a escolma.

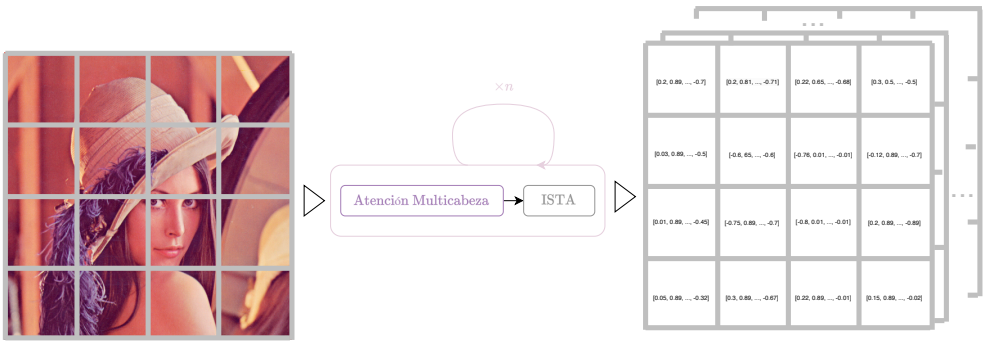


Figura 3.2: Representación intermedia que úsase para comparar os parches dos tokens. Na figura pódese observar que o parche correspondente á cara de Lenna é o que ten o valor absoluto máis grande na primeira entrada da primeira cabeza e por tanto neste caso poderíamos pensar que a primeira palabra desta cabeza ten o significado de "cara". En realidade as interprestacións semánticas das palabras dunha Rede adoitan ser menos evidentes, isto foi naturalmente un exemplo artificial. Figura de autoría propia.

3.4 Compartir U e D

Segundo as ideas do A.D. (ver Sección 1.2.8) nas que adscríbese o modelo CRATE, neste traballo preguntámonos: Se cada capa supón un proceso iterativo sobre o obxectivo MCR^2 disperso (ver Sección 1.2.5), Por que deben ser distintos os tensores U e D[3]? No modelo orixinal son distintos para cada capa ℓ, o que resulta en que a idea que os autores queren reflexar de "Optimizar os subespacios e o diccionarios o traveso das capas"[31] póñase en contradicción co mesmo deseño do modelo. Así, se compartísemos sendos tensores estaríamos comprobando realmente ate que punto ocurre o que os autores de CRATE pensan que ocurre.

Na Figura 3.3 pódese comparar a diferencia entre o modelo orixinal (á esquerda) e a versión na que comparténse ambos tensores, pódese apreciar que o segundo é un modelos máis lixeiro posto que conta con moitos menos parámetros. A lixereza pode ser unha vantaxe posto que as inferencias poden ser máis rápidas e de seguro o modelo ocupa menos en disco. Pola contra, no adestramento as derivadas da Propagación cara atrás [36] serían igualmente pesadas co respecto o modelo orixinal. Tamén existen beneficios no adestramento, no modelo orixinal a capa ℓ actualiza U_ℓ e D_ℓ cos seus correspondentes tensores $\frac{\partial \mathcal{L}}{\partial U_\ell}$ e $\frac{\partial \mathcal{L}}{\partial D_\ell}$, e así ocurre cas n capas; pola contra no modelo proposto a capa ℓ actualízase cos n tensores $\{\frac{\partial \mathcal{L}}{\partial U_i}\}^n$ e $\{\frac{\partial \mathcal{L}}{\partial D_i}\}^n$ polo que recibe máis información da supervisión. Esta información, no caso de non ser contradictoria[4], pódese esperar que axude á converxencia do adestramento.

Como temos intuición sobre o significado de tanto U coma D (ver Sección 1.2.9), punto intermedios moi interesante entre compartir ambos tensores ou non compartir ningún pode

[3]Respectivamente, os subespacios ortogonais e os diccionarios.
[4]Será permanentemente contradictoria no caso no que realmente precisese un modelo máis grande.

ser só compartir un deles:

- Só compartir U supondría optimizar ó traveso das capas uns espacios (que tenderan a ortogonais) que actuen sobre as mesmas rexións da imaxe, aínda que estas rexións podan rexpresarse.
- Só compartir D supondría manter fixas as palabras cas que pode representarse un token ó longo das capas, mentres que os tokens cos que se relacione ou agrupe sexan distintos.

[NOTA: dicir algo estilo que esta explicación non é moi boa pero porque todo esto é moi abstracto e é millor mirar os resultados]

Paga a pena notar, cara os resultados que exporanse no vindeiro Capítulo, que os modelos que compartan D, ó ter menos palabras en total, necesariamente evaluaranse como menos dispersos. É dicir, no modelo orixinal un token pode expresarse con d palabras na primeira capa, con outras d na segunda... e así cas n capas. O certo e que nos modelos de A.P. existe unha tendencia á abstracción cara as capas máis profundas[37], por tanto esperaríamos que: (i) as palabras das capas máis profundas sexan máis abstractas (ii) as palabras que reduzcan ó máximo o erro de representación nunha capa, dado un nivel de abstracción distinto, deben ser tamén distintas (iii) as palabras que permitan unha representación moi dispersa deben ser moi axeitadas, de non selo a representación preferirá usar máis palabras para reducir o erro de representación e por tanto reducindo tamén o nivel de dispersión. É por isto que dous modelos, un que comparta D e outro que non, van ter necesariamente niveis de dispersión distintos.

3.5 Combinación de achegas

Na Sección 3.1.2 expúsose unha nova arquitectura (a saber, a aproximación de segundo orde), e na Sección 3.4 outras tres (a saber, compartir U, compartir D e a combinación, é dicir compartir ambas). Naturalmente cabe preguntarse, Cómo resultarían as combinacións? A priori como cada unha das achegas por separado é fundamentada nos mesmos principios nos que derivouse o modelo CRATE orixinal (a saber o MCR^2 disperso), parece natural que todas as 2^3 posibles combinacións destes tres elementos respeten igualmente estos principios. Desta forma, como reflíctese na Táboa 3.1, neste traballo consideraremos a cobinación de todas as achegas por separado como a proposta combo, consideraremos nalgúns casos algunhas propostas derivadas e compararemolas co modelo orixinal.

3.6 Tarefas de adestramento

Sobre os conxuntos de datos expostos na Sección 1.2.10 realizáronse experimentos sobre as seguintes tarefas:

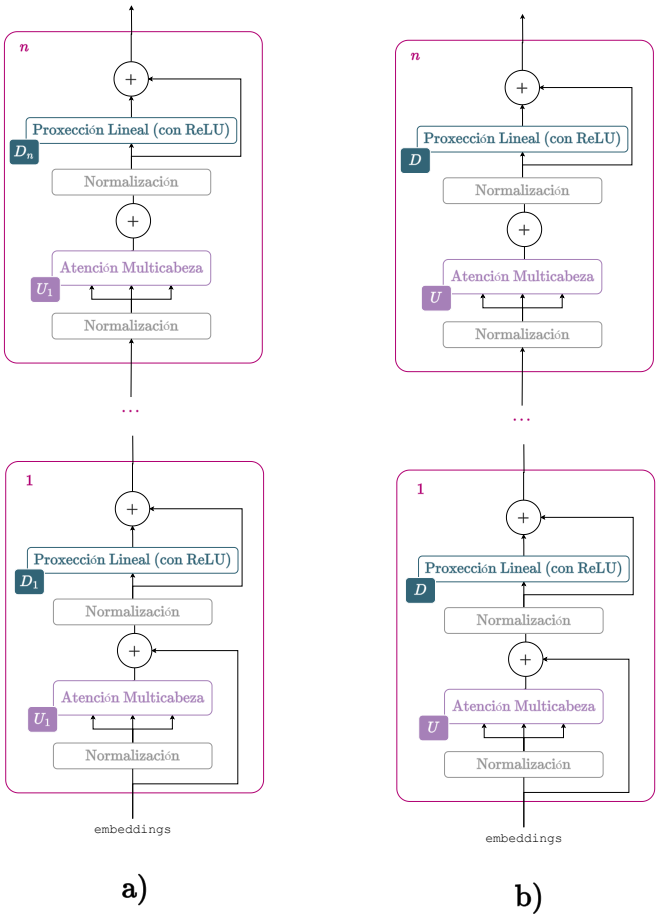


Figura 3.3: a) Rede orixinal onde cada capa ℓ ten os seús tensores U_ℓ e D_ℓ; para a atención multicabeza e o MLP, respectivamente. b) Proposta de compartir devanditos tensores ó traveso das capas. Figura de autoría propia.

	$U_{\text{comp.}}$		Non $U_{\text{comp.}}$	
	$D_{\text{comp.}}$	Non $D_{\text{comp.}}$	$D_{\text{comp.}}$	Non $D_{\text{comp.}}$
1^{eiro} orde	derivada	derivada	derivada	orixinal
2^{ndo} orde	combo	derivada	derivada	derivada

Táboa 3.1: Combinacións das diferentes achegas.

- Clasificación binaria sobre DRIVE, para a detección de vasos sanguíneos, ver Figura 3.4. A tarefa non elixiuse nin por complexa, ou interesante de ser resolta pero precisamente polo contrario, por ser simple, case trivial **[NOTA: se ben a tarefa si me parece trivial, o certo é que non acadamos resultados tan bos xd, a ver como digo isto mellor]**, as representacións internas deberían ser intuitivas.

- Clasificación binaria sobre RFMiD (ver Sección 1.2.10) onde todas as enfermidades aglutinábanse nunha única clase. Neste problema máis complexo esperaríamos que as representacións internas, e en xeral a explicabilidade asociada ás inferencias aporte luz sobre a condición do paciente. Neste caso o problema sí ten (ou pode ter) un interese real doble: por unha banda é interesante un modelo que axude ó ollo clínico do persoal sanitario tomando a decisión de enfermo ou non, pero además (e de xeito máis noble neste traballo **[NOTA: igual vou un pouco de flipao con isto que acabo de dicir?]**) habería unha xustificación a devandita decisión a traveso da técnica de explicabilidade de Visualización de Mapas de Atención, exposta na Sección 3.2.

- Clasificación multiclase en ImageNet (ver Sección 1.2.10). Pola variabilidade das mostras neste conxunto e súa xeralidade, as representacións que se aprendan deberían ser suficientemente xerais como para poder ter algún tipo de interese para imaxes arbitrarias (sempre que non se afasten moito de as grandes categorías xerais de animais e artefactos humáns).

Sobre devanditas tarefas puideronse comparar distintas posibilidades de adestramento e estudalas traveso de técnicas de explicabilidade que descríbense nas seccións deseguido. Estas comparacións e ablacións recollense nos experimentos expostos no Capítulo 4

3.7 Hipóteses

Con todo o exposto neste cápitulo, nacen as seguintes preguntas:

- Qué diferencias de rendemento poderanse observar ca nova variantes propostas da arquitectura CRATE?

- Como CRATE deseñouse co obxectivo de Dispersión e Minimización do Coding Rate (ver Sección 1.2.9), Qué suporá as novas variantes co respecto a este obxectivo? É dicir, Cómo rendiran nestras métricas?

- Cómo resultará o cruce de arquitecturas, segundo a definición da Sección 3.1.3, de primeiro orde a segundo? E de segundo a primeiro?

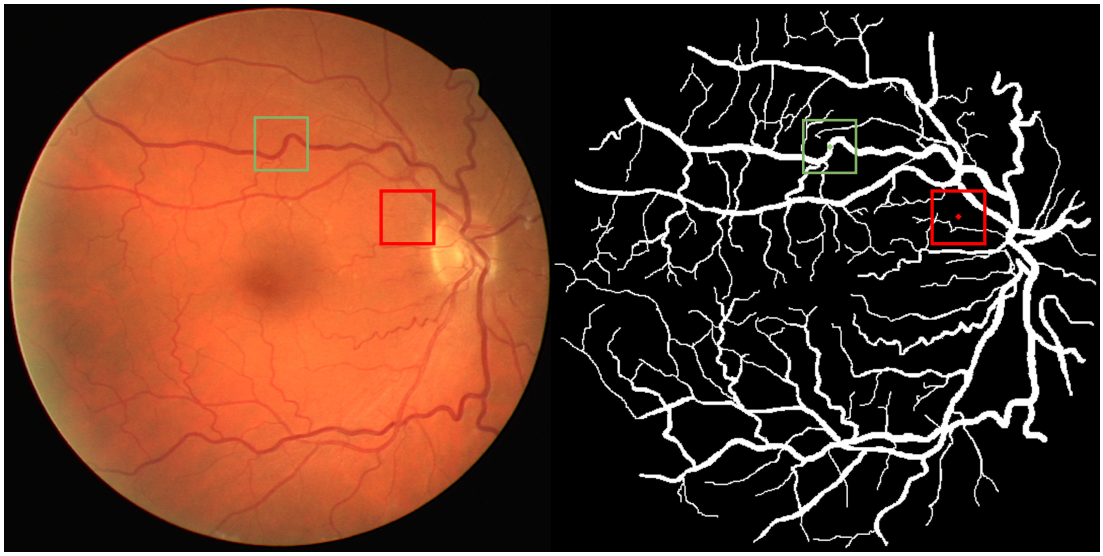


Figura 3.4: M
ostras de supervision para o conxunto de datos DRIVE.Mostras de supervision para o conxunto de datos DRIVE. As imaxes divídense en parches de 105 píxeles (a súa vez estos parches divídense en 7×7 tokens de 15 píxeles, ver Sección 1.2.6), cuxa etiqueta é 1 se o píxel central é vena e 0 se non o é. Devandita información extraese da máscara xa presente no conxunto de datos, ver a Sección1.2.10. Figura de autoría propia.

- Qué diferencias poderánse observar entre as visualizacións dos mapas de atención ó traveso dos ordes e dos modelos que comparten ou non U e D?
- Qué información poden desvelar da diagnose de patoloxías relacionadas ca retina as visualizacións dos mapas de atención?
- Qué diferencias poderánse observar entre a recuperación de parches representativos ó traveso dos ordes e dos modelos que comparten ou non U e D?

No vindeiro cápitulo, a traveso da experimentación cas tarefas propostas na Sección 3.6 tratarase de dar resposta a estas preguntas.

Capítulo 4

Resultados

Neste capítulo realiazaranse experimentos para comprobar técnicas de interpretabilidade e explicabilidade así como as Hipóteses expostas na Sección 3.7 sobre os conxuntos de datos descritos na sección 1.2.10 e cas tarefas de adestramento expostas na Sección 3.6. Deste xeito na Seccións 4.1, 4.2 e 4.3 discutiremos os resultados sobre Imagenet, DRIVE e RFMiD respectivamente. A separación en conxuntos de datos da exposición dos resultados resulta en que cos distintos conxuntos de datos a Rede sométese a distintas tarefas, en distintas condicións con distintos hiperparámetros. Como un predicado sobre o rendemento dun modelo pode ser certo para unha tarefa e conxunto de datos determinado pero non para outro, o estudar os resultados por conxuntos-tarefas semellaba o máis correcto.

Faltaría unha sección que permita ver o equeme e organización xeral da experimentación, a modo de índice e introducción.

4.1 Imagenet

Sobre o conxunto de datos Imagenet, por ser o máis custoso non se puido facer moita proba[1], non obstante fixemos tres adestramentos relativamente longos probando as variantes: (i) Modelo CRATE orixinal, (ii) Modelo CRATE segundo orde e (iii) Modelo CRATE segundo orde con U e D compartidos. **[NOTA: decir: O lector podería botar en falta a alternativa primeiro orde compartido U e D, pero non deu tempo?]**

Por ser Imagenet un conxunto de datos tan diverso, a explicabilidade e volvése tamén máis complexa. Se ben a variedade e cantidade de clases permitenos obter visualizacións dos mapas de atención máis ou menos interesantes de calqueira obxecto natural.

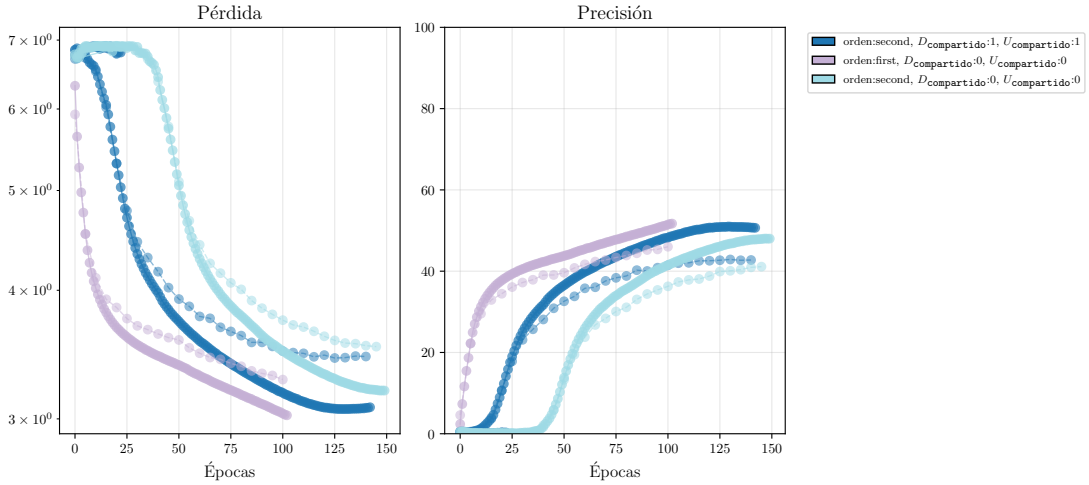


Figura 4.1: En liña continua os valores de Perda e Precisión respectivamente sobre o conxunto de adestramento o traveso das Épocas, en liña discontinua sobre o conxunto de validación. Pódese observar que a configuración base, é dicir, a rosa e a que acada mellores resultados aínda que ás outras dúas deuselles máis épocas. Figura de autoría propopia.

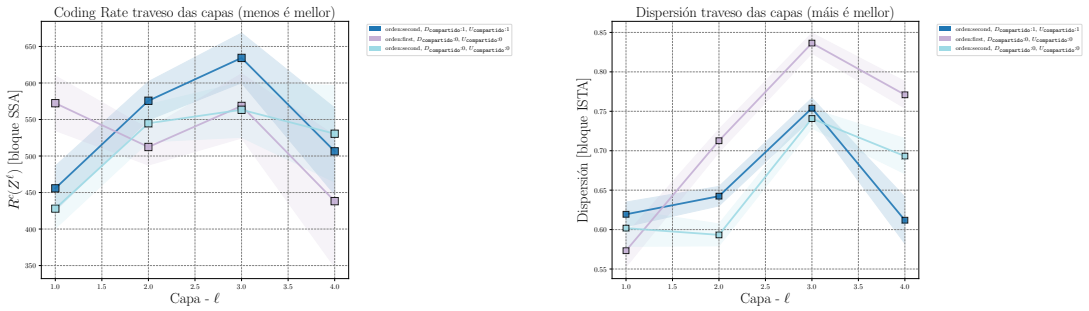


Figura 4.2: Métricas de MCR^2 e dispersión de diferentes arquitecturas sobre Imagenet. Apréciase que o modelo orixinal ofrece mellores resultados en ambas métricas e ademáis ten mellores métricas segundo o índice da capa é máis alto (salvo o último), o cal é unha propiedade desexada de CRATE, non obtida neste experimento nas variantes de segundo orde. Figura de autoría propopia.

4.1.1 Búsqueda de arquitecturas

En canto á metrica Precisión a que mellor resultou no noso experimento dende logo foi o modelo orixinal, como pódese ver na Figura 4.1, **[NOTA: é dicir, nestas condicións as nosas proposicións son peores]**. En canto a MCR^2 e Dispersión tamén é mellor o modelo orixinal, como pódese ver na Figura 4.2 pero eso é pouca sorpresa xa os mesmos autores de CRATE (ver Sección 1.2.9) observaron que ó traveso **das épocas e capas** mellorábanse ambas métricas, e aquí con "épocas" quérese dicir proximidade de converxencia ou definitiva cercanía de $\hat{\theta}$ a θ [1] (ver Sección 1.2.1), e como nas variantes de segundo orde queda aínda moito (ou cando menos quédalles máis que ó modelo primeiro orde) é esperable que teñan peores valores en MCR^2 e Dispersión. Tamén é, por tanto, razonable a observación de que aparte de o modelo primeiro orde ten *menos* Coding Rate ca as outras variantes, tamén ten menos a traveso das capas (exceptuando a última), propiedade que sabemos por [31] que debería observarse nos modelos CRATE ben adestrados. O mesmo é certo para a Dispersión. Paga a pena notar os seguintes aspectos sobre o experimento:

- Os experimentos realiazáronse con exactamente os hiperparámetros especificados na publicación do modelo orixinal [31], é de esperar que as distintas variacións dun modelo precisen diferentes configuración para: (i) asegurar a converxencia a un mínimo suficientemente baixo (ii) unha converxencia con velocidade parecida; é dicir, se o noso modelo non converxera ou converxera moito máis lento **podería deberse exclusivamente á escolma de hiperparámetros** tales como a tasa de aprendizaxe, o tamaño de *batch*, o número de épocas, o momentum, o optimizador e a súa configuración ... En definitiva, habería que realizar unha busqueda en cuadrícula ou aleatoria [38] antes de afirmar categoricamente nada. Tal búsqueda non realiazouse por custe computacional e queda para traballo futuro.

- Obsérvase que as tres alternativas aprenden e continuan a facelo, de seguro continuarían algunhas épocas máis antes de converxer finalmente. Cantas épocas máis? Cal sería o estado final das alternativas unha vez que todas converxeron? Son preguntas importantes que precisan de máis exploración que, de novo, por custo computacional non puideron respostarse.

- **[NOTA: dicir algo estilo: os adestramentos cortaronse a man para ser relativamente comparables pero deberían adestrar moitas mais épocas]**

As redes usadas contaban con 6 cabezas ó traveso de 4 capas.

[1] Os autores do modelo orixinal no seu equipo contaban con 16 GPUs A100 de 40GB, o cal é un equipo 32 veces máis caro que o dispoñible para este traballo, unha GPU A6000 de tamén 48GB pero máis lenta. Ilustrativamente, a época a eles duraballe 240 segundos [31] mentras que a nos cerca das 3 horas.

adestrado (↓) / inferencia (→)	primeiro orde		segundo orde	
	acc@1	acc@5	acc@1	acc@5
primeiro orde	0.5260	0.7645	0.0010	0.0052
segundo orde	0.0010	0.0055	0.4721	0.7160

Táboa 4.1: Resultados do cruce de ordes mostrando o rendemento no conxunto de proba cas métricas Precisión a un e a cinco (ver Sección 1.3). Pódese apreciar que cambiar de orde ofrece uns resultados moi malos.

4.1.2 Cruce de arquitecturas

Logo de ter adestrado nas mesmas condicións, tanto a versión orixinal de CRATE (*primeiro orde*) como a versión *segundo orde*, presentánse agora os resultados do cruce (ver Sección 3.1.3) na Táboa 4.1 onde pódese ver que ningunha forma de cruce de orde trae resultados positivos, é máis, en ambos casos son cercanos a un predictor aleatorio. En conclusión, ambas hipóteses plantexadas resultan ser falsas.

4.1.3 Explicabilidade dos mapas de atención

Como o conxunto de datos Imagenet é tan variado, diverso e exhaustivo [27], para un analásise cualitativo non superficial **[NOTA: dicir que neste traballo non fíxose analásise cuantitativo dos mapas de atención pero en [19] explícase como podería facerse.]** é preciso acotar a variabilidade das imaxes co fin de poder encontrar os mesmos patróns nas distintas imaxes e analizar como de distintas son as respostas da Rede. No obstante as conclusións extraídas poderían estar sesgadas ás imaxes escolmadas e non ser xeneralizables. Polo tanto neste traballa para analizar os mapas de atención dun xeito relativamente preciso pero non totalmente sesgado optouse por analizar sobre:

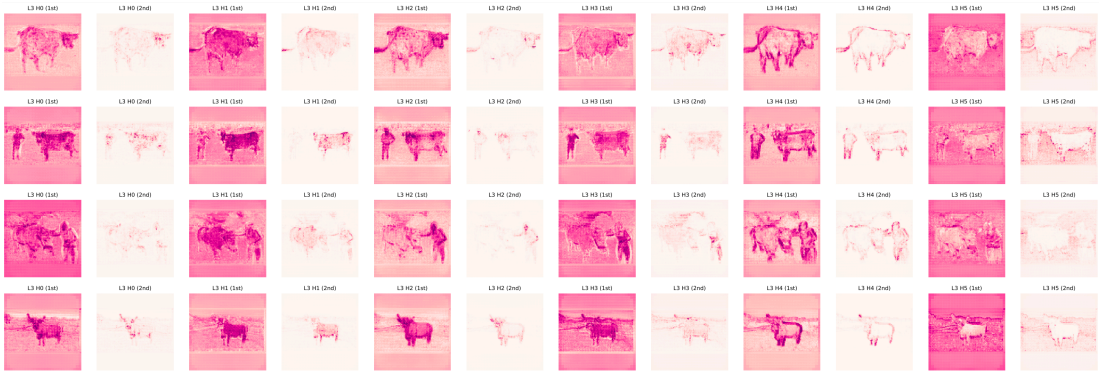
- Imaxes de vacas con humáns, extraídas do concurso Miss Vaca [39], presentes no problema de clasificación ca etiqueta `ox` no caso das vacas e baixo varias no caso dos humáns[2], dispoñibles na Figura 4.3.
- Imaxes de insectos entre os que atópanse mosquitos (presentes no problema de clasificación ó que foron adestradas as Redes baixo a etiqueta de `fly`) e velutinas (ausentes no conxunto de datos, pero que ofrecen a oportunidade de analizar a xeneralización da Rede sobre imaxes fóra do mesmo) dispoñibles na Figura 4.4.

[2]Se ben ningunha destas é clase, digamos, 'human', sí temos: '`ballplayer`', '`ballplayer, baseball player`', '`groom, bridegroom`', '`scuba diver`', '`academic gown, academic robe, judge's robe`' e '`military uniform`'... As cales van forzar á Rede a ter o concepto de humán.



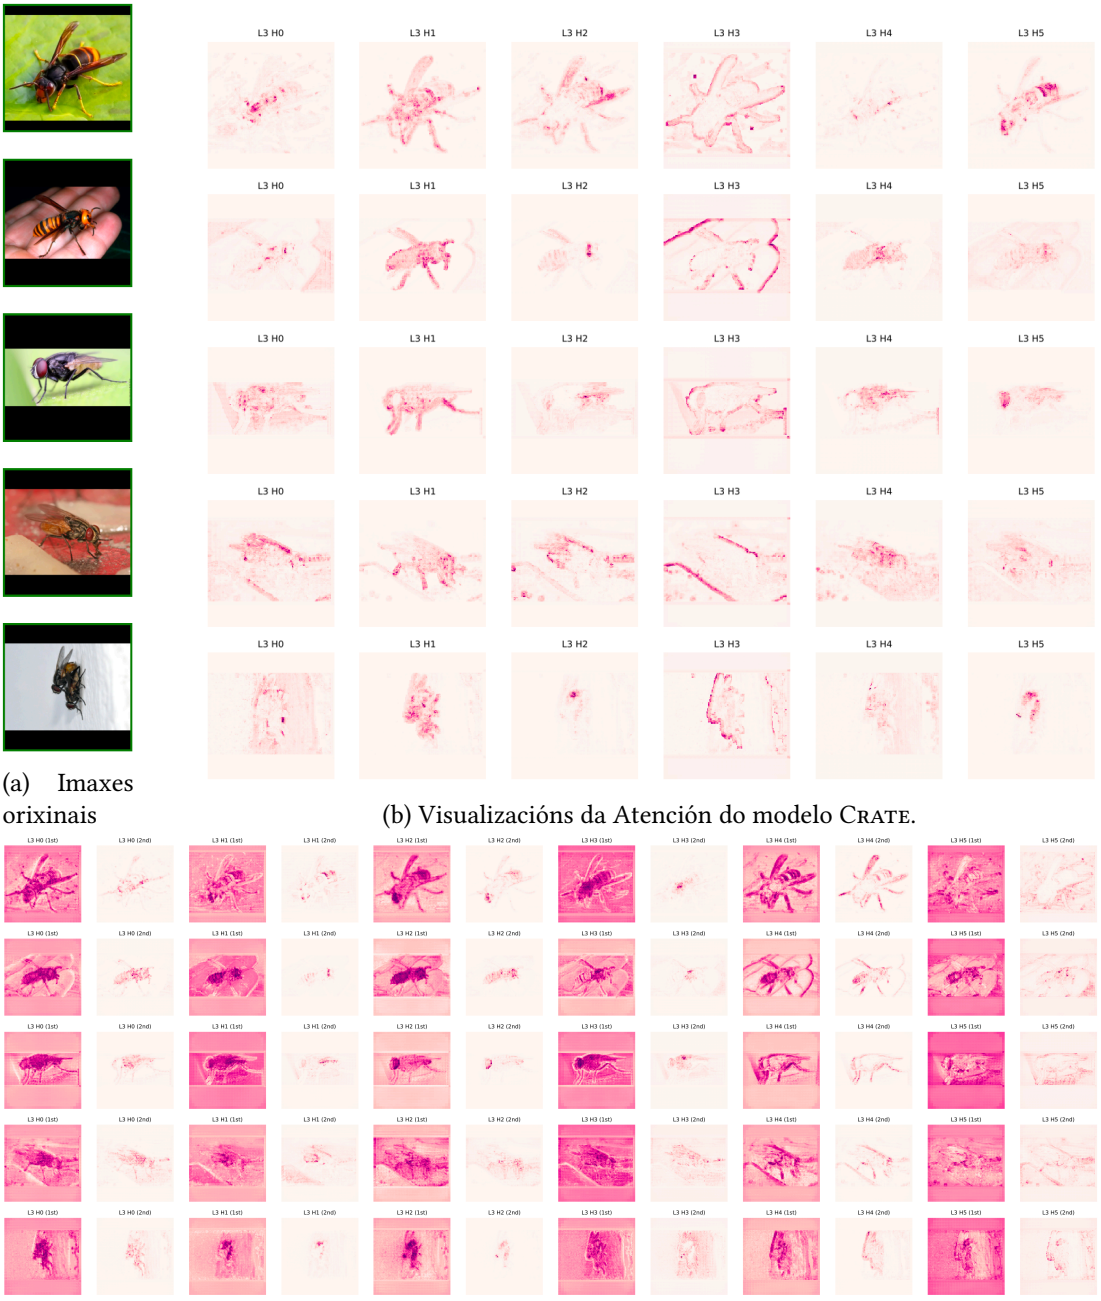
(a) Imaxes orixinais

(b) Visualizacións da Atención do modelo CRATE.



(c) Visualizacións da Atención da versión do modelo CRATE segundo orde.

Figura 4.3: Explicabilidade das variantes aportación combo e modelo orixinal con Visualizacións dos Mapas de Atención con imaxes de Miss Vaca [39]. Móstranse as 6 cabezas da última capa. Figura de autoría propia.



(a) Imaxes orixinais

(b) Visualizacións da Atención do modelo CRATE.

(c) Visualizacións da Atención da versión do modelo CRATE segundo orde.

Figura 4.4: Explicabilidade das variantes aportación combo e modelo orixinal con Visualizacións dos Mapas de Atención con imaxes de velutinas (as cales non estaban presentes no conxunto de datos de adestramento) e mosquitos. Móstranse as 6 cabezas da última capa. Figura de autoría propia.

Nas visualizacións apreciáse como as diferentes cabezas atenden a conceptos semánticamente distintos, propiedade resultado da ortogonalidade dos distintos espazos $U_{[K]}$, ver Sección 1.2.9. En particular obsérvanse os seguintes conceptos:

- **O fondo:** presente no modelo CRATE na cuarta cabeza (H3) e na variante de segundo orde na sexta cabeza (H5), tanto para imaxes de vacas como de insectos. Esta cabezas *atenden* ás rexións que non son parte do protagonista. Desta forma, caracterizando ó fondo como algo illado a Rede pode non ter problemas en identificar o obxecto independentemente do fondo. Pola contra se unha rexión de fondo e *atendida* por outras cabezas poderíamos identificar un caso de memorización (e.g. dí que é unha vaca porque está sobre a herba e as vacas adoitan estar sobre a herba, non porque identifique a vaca en sí mesma).

- **As cabezas:** presente no modelo CRATE na derradeira cabeza (H5) e na variante se segundo orde na terceira cabeza (H2), tanto para imaxes de vacas como para de insectos. Estas cabezas *atenden* ás cabezas en si mesmas e en menor medida a outras rexións de grande importancia como o cu ou a cola, pero non atenden en xeral ó corpo dos animais. Notar que en ambas Redes existe unha confusión ca derradeira imaxe de moscas (que aparecen dúas en realidade, unha sobre outra), xa que atendén só a cabeza dunha mosca; do mesmo xeito tamén existe confusión nas imaxes de vacas que teñen humáns xa que as Redes teñen dificultades para *atender* á vez a ambas cabezas.

- **O corpo:** presente no modelo CRATE na primeira e quinta cabezas (H0 e H4) para imaxes de vacas e na segunda, quinta e sextas (H1, H4 e H5) para imaxes de insectos. Na variante se segundo orde na segunda e cuarta cabezas (H1 e H3) para imaxes de vacas e na primeira e cuarta (H0 e H3) para imaxes de insectos. Aquí son precisas dúas cabezas xa que (polo xeral) unha atende á xeralidade da superficie do corpo e a outra a matices (que normalmente a outra cabeza non atendeu) e complementan a descrición. É precisamente nestos casos das cabezas "que atenden a matices" onde observar á representación intermedia da variante de segundo orde (é dicir a cabeza á esquerda de cada dúas) é especialmente nutritivo para o análise xa que o seu suavizado (ver Sección 3.2.4) permite entender a relación global con devandita cabeza e o animal.

- **As pernas:** presente no modelo CRATE na terceira cabeza (H2) para imaxes de vacas e na segunda (H1) para imaxes de insectos. Na variante de segundo orde na quinta cabeza (H4) tanto para imaxes de vacas como de insectos. Aquí observarmos unha cousa moi interesante: por unha banda o modelo orixinal comparte cabeza (a H1) para dous conceptos separables (corpo e pernas), mentras que na variante de segundo orde a cabeza que *atende* ás pernas faino independentemente do animal, o cal correspóndense

ca intuición e comunicación humana xa que usamos a palabras "pernas" ou "patas" para refererinos tanto ás das vacas como ás dos insectos. A priori semella máis interesante aglutinar conceptos relacionados abstractamente (pernas de vacas e insectos) que outros máis triviais (tratar ó corpo e ás pernas das vacas como unha soa cousa), perdendo expresividade.

4.1.4 Explicabilidade das dimensións

Como Imagenet é un conxunto de datos tan variado e diverso, as Redes que adestrénse con el teñen que estar preparadas para capturar ca súa representación todo tipo de imaxes naturais. Isto ten dúas implicacións importantes en canto á visualización de parches das dimensións (dispoñible na Figura 4.5):

- A Rede ten que ser quen de recoñecer todo tipo de texturas con todo tipo de cores. Isto implica que a Rede Deve levar a cabo moitas tarefas de P.S.D. e por tanto sería razonable que tivera dimensións asociada a conceptos tales como "segunda derivada orientada cara a dereita", "vermello", "primera derivada sobre fondo azul". É dicir, esperaríamos unha escolma de elementos de baixo nivel, de relativa fácil caracterización manual, necesarios para procesar calquera imaxe.

- As imaxes do conxunto de datos poden presentar o mesmo concepto a traveso de distintas aparencias. Poñamos por caso a clase "`rugby ball`", dependendo da escala da imaxe poderá ocupar maís ou menos tokens, que dende logo serán de cores variados, variada iluminación... en definitiva, se hai algunha dimensión asociada a devandita clase (sabemos que debe haber polo menos unha, pero probablemente sexan varias as asociadas) dificilmente poderíamos esperar similitude visual entre os parches representativos desta dimensión.

[NOTA: incluir recortes do mosaico e falar en particular deles (ou non?). todo esto pódese facer sobre unha única rede e logo falar de si hai diferencias ou non entre as redes (eu non atopo)]

4.2 DRIVE

Por ser DRIVE o escenario de adestramento máis económico fíxose unha búsqueda de arquitecturas exhaustiva probando todas as 2^3 ocións da Táboa 3.1, a cal examinaráse na Sección 4.2.1. Co respecto á explicabilidade, estudaranse os mapas de atención e as palabras do diccionario D nas Seccións 4.2.2 e 4.2.3 respectivamente.



Figura 4.5: Mosaico con parches asociados a todas as dimensións de todas as cabezas dunha Rede adestrada en Imagenet. Neste caso as 6 grandes columnas correspóndense cas 6 cabezas de atención nos que divídese a representación de z_i^ℓ, dentro de cada columna, cada unha das 64 filas é unha dimensión. Así os 15 parches de cada dimensión son precisamente os 15 parches de todo o conxunto de datos Imagenet con maior valor absoluto nesa dimensión, por orde de esquerda a dereita. Figura de autoría propia.

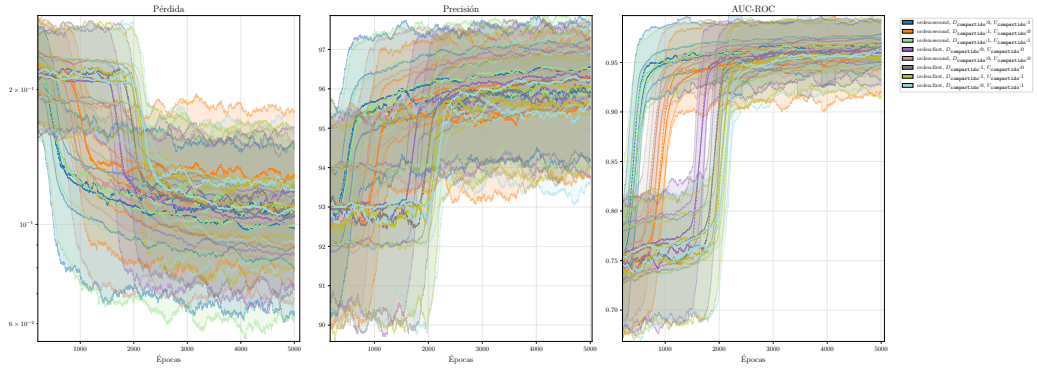


Figura 4.6: Comparativa entre as 2^3 combinacións dos atributos: segundo orde, compartir U e compartir D. Os valores foron suavizados cunha media deslizante e repórtase a desviación típica $\pm\sigma$. Obsérvase que se ben todas as variantes acadan valores similares de converxencia, a transición de fase ocurre a distintos tempos nas distintas arquitecturas, pero razonablemente pódense agrupar por grupos. O primeiro grupo (o da converxencia máis temprana) é o de segundo orde con U compartido, o segundo grupo é segundo orde sen compartir U e o derradeiro grupo é o das variantes de primeiro orde, encabezado polo baseline. Figura de autoría propia.

4.2.1 Búsqueda de arquitecturas

O resultado do adestramento das oito variantes pódese ver na Figura 4.6 onde vese que as distintas variantes, para esta tarefa e este conxunto de datos acadan (cas suficientes épocas, neste caso 5000) resultados semellantes [3]. En particular a comparativa un a un entre a proposta combo e a orixinal pódese ver na Figura 4.7, onde apréciase que a proposta ten unha converxencia máis veloz.

[3]Paga a pena notar que, se nos quedaramos na época 1500 todas as variantes de segundo orde terían converxido mentres que as de primeiro orde non, e poderíamos sacar conclusións erroneas. Por tanto é importante subliñar a importancia dos adestramentos longos para ofrecer conclusións asertivas, e por tanto as conclusións da Sección precedente son só preliminares.

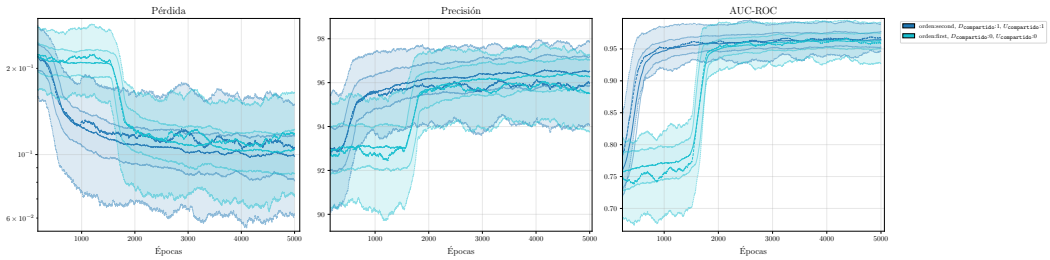


Figura 4.7: Comparativa entre a proposta combo e o CRATE orixinal. Malia a proposta comezar o réxime de converxencia final máis de 1000 épocas antes, eventualmente acadan resultados semellantes. Figura de autoría propia.

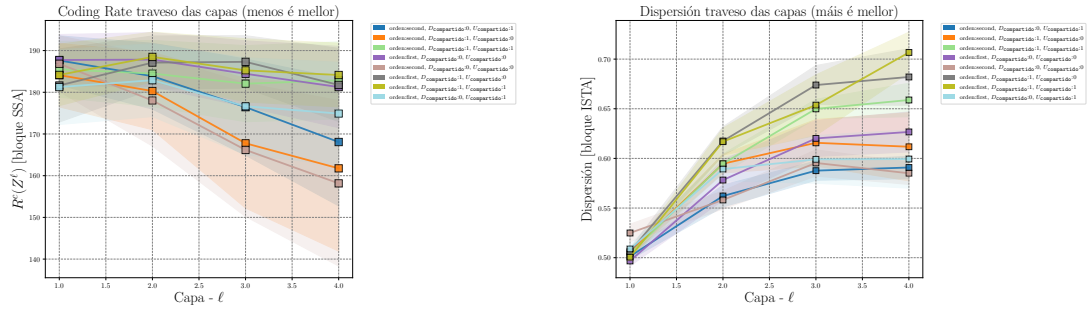


Figura 4.8: Comparativa dos obxectivos MCR^2 e Dispersión entre as variantes expostas na Táboa 3.1. Pódese observar que a variante combo é mellor que o modelo orixinal en ambas métricas. Pódese apreciar que as variantes con mellor Coding Rate (ambas segundo orde sen compartir U, sen compartir e compartindo D) teñen mala dispersión e viceversa. En xeral apréciase unha loita entre estas duas métricas onde as variantes que fano ben nunha fano mal na outra. Por outra banda sí observase en todas as variantes a propiedade de que ambas métricas son mellores ó traveso das capas, segundo o principio de A.D. apreciable na Figura 1.5. Figura de autoría propia.

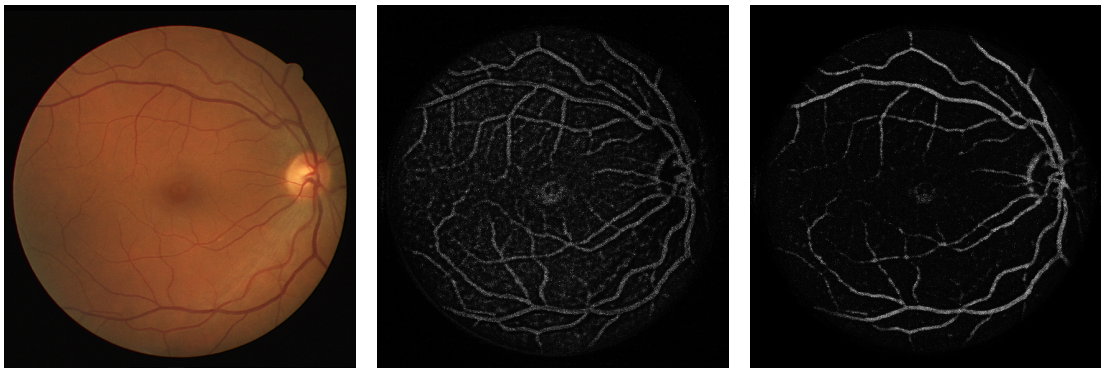


Figura 4.9: Comparativa da segmentación das variantes orixinal (centro, cun DICE de 0.23) e combo (dereita, cun DICE de 0.62) . A imaxe de entrada móstrase por referencia á esquerda. **[NOTA: decir que son unha merda. teño redes que segmentan mellor neste experimento e doutros: a que mellor segmenta deste experimento é primeiro orde que comparte U (a celeste nas gráficas) que ten malas metricas e é a última en converxer. podo pensar pq é esta a que mellor segmenta (actualmente non teño idea) ou calarme a boca]**. A métrica DICE descríbese na Sección 1.3. Figura de autoría propia.

Se ben todas estas propostas (incluído o modelo orixinal![31]) fixéronse tendo presentes os obxectivos de MCR^2 e Dispersión, unha pregunta natural é: Cómo reflictense as diferentes decisións arquitecturais nestos obxectivos? Como pódese ver na Figura 4.8, o certo é que (polo menos para as condicións deste experimento) non existen variantes que sexan as mellores en ambas métricas, posto que existe un balanceo entre ambos obxectivos e compiten entre eles [31]. Non obstante, sí é certo que a variante combo é mellor que a orixinal en ambas métricas. Cuantitativamente pódese apreciar que efectivamente a combo é mellor que a orixinal na segmentacións da Figura 4.9.

Todas as arquitecturas teñen catro capas e tres cabezas por capa.

4.2.2 Explicabilidade dos mapas de atención

Recordando a tarefa asociada con este conxunto de datos (ver Sección 3.6) e lembrando que o modelo CRATE segue os principios de separación por tokens do ViT (ver Sección 1.2.6) , un primeiro pensamento é que o modelo **atenderá** principalmente ó token central [4]. Por outra banda, segundo as ideas presentadas na Sección 1.1 tamén esperaríamos que as primeiras capas da Rede realice algunha tarefa de P.S.D. como deteción de bordes. Adicionalemente podería ser interesante atender ós tokens limítrofes de izquierda e dereita (posto que a maior parte de vasos son horizontais, na deteción de vaso no pixel central é máis interesante a esquerda e dereita que o arriba e abaixo) e finalmente unha comprensión global do parche. Pois todas estas cousas acharonse nos Mapas de Atención das Redes adestradas, por exemplo a da Figura 4.10 que en particular é o modelo orixinal de CRATE.

4.2.3 Explicabilidade das dimensións

Segundo a técnica desenvolvida na Sección 3.3.1 e como vese na Figura 4.11 a Rede aprende *palabras* útiles que permitiranlle sintetizar os elementos da imaxe dun xeito máis abastracto así como discriminar entre aquelas rexións que non teñen interese para a clasificación (pero si que teñen interese para a representación da Rede, porque só pode 'descartar' ou 'ignorar' aquelo que caracteriza).

4.2.4 Búsqueda de hiperparámetros

[NOTA: zicais eu pasaba de isto. aqui poderia falar dalgúns experimentos que fixen estilo grid serach para ver os millores hiperparámetros pero paréceme un pouco irrelevante]

[4] No caso de ter un numero de tokens $n = k^2$ onde k é impar, o cal foi o certo para o noso experimento.

4.3 RFMiD

[NOTA: actualmente (vernes 28 pola tarde) está acabando de executar a ultima rede do experimento (segundo que comparte e learning rate pequeno), asi que eventualmente haberá que recomputar todas as graficas nas que teña aparecido.]

O conxunto de datos RFMiD (ver Sección 1.2.10) e a súa tarefa asociada (ver Sección 3.6) supón moita complexidade para as Redes dun xeito moi distinto a Imagenet, aquí existe moita redundancia entre imaxes, o problema só ten dúas clases pero tamén o característico dun ollo patolóxico pode ser moito máis sutil. Aquí non vale inferencias basadas no cor xeral da imaxe ou na forma ou textura xeral, en RFMiD uns píxeles póden ser críticos. Además a motivación para adestrar Redes explicables e interpretables como as expostas neste traballo é de especial importancia neste conxunto de datos porque máis aló da etiqueta de "este fondo de retina posúe ou non unha patoloxía" as Redes **[NOTA: deberían]** brindar unha xustificación a devandita afirmación.

Levouse a cabo unha exploración dun subconxunto das arquitecturas da Taboa 3.1, en particular (i) Modelo CRATE orixinal (ii) Modelo CRATE compartindo U e D (iii) Modelo CRATE segundo orde (iv) Modelo CRATE segundo orde compartindo U e D (proposta combo). Durante o experimento observouse *tambaleos* na optimización das Redes de segundo orde (ver Sección 1.2.1) e decidiuse repetir o adestramento destas dúas Redes con unha tasa de aprendizaxe máis baixa **[NOTA: tasa de aprendizaxe acrónimo? (t.a.)]**. Polo que ós mencionados engadeselles (v) Modelo CRATE segundo orde con tasa de aprendizaxe máis baixa.(vi) Modelo CRATE segundo orde compartindo U e D (proposta combo) con tasa de aprendizaxe máis baixa.

Co fin de que as Redes pouderan adestrar efectivamente usáronse Transformadores CRATE de 12 capas e 6 cabezas.

4.3.1 Búsqueda de arquitecturas

[NOTA: Falar da Táboa 4.2, e das Figuras 4.12 e 4.13]

O proceso de adestramento e converxencia das seis Redes pódese apreciar na Figura 4.12 onde están dispoñibles os valores de Perdida, Precisión e AUC para o conxunto de adestramento e validación, adicionalmente o AUC para o conxunto de proba está dispoñible na Táboa 4.2. As métricas de Coding Rate e Dispersión por capas pódense atopar na Figura 4.13. Con devandito material apréciase o seguinte:

- As variantes de primeiro orde posúen moitas máis facilidades de adestramento neste problema cos hiperparámetros probados. Pola contra non pode dicirse que acadaran un estado de converxencia posto que a Pérdida en adestramento seguía baixando con velocidade, polo que a comparativa entre elas (a saber, modelo orixinal e compartir U e D)

	Primeiro Orde	Segundo Orde	
	$\theta = 5 \times 10^{-5}$	$\theta = 5 \times 10^{-5}$	$\theta = 1 \times 10^{-5}$
Sen compartir	**0.8776** (orixinal)	0.7431	0.7898
Compartindo	0.8768	0.7192	0.8055

Táboa 4.2: AUC no conxunto de proba para unha escolma de arquitecturas. Nótese que se ben para a mesma tasa de aprendizaxe θ a variante de segundo orde ten moito peor rendemento, o feito de que con unha tasa de aprendizaxe máis pequena rinda mellor (acompañada do comportamento de adestramento inestable apreciable na Figura 4.12) suxire que con tasas de adestramento máis baixas podería rendir aínda mellor. Por outra banda ca evidencia presente non pódese inferir moito do impacto de compartir en canto a rendemento.

aínda pode ser temprano para facela. Isto débese a que malia agora estar prácticamente empatadas nas métricas habituais, é certo que nos mapas de atención a variante que comparte é máis interpretable (ver Figura 4.14), pero tamén é certo que nas métricas especiais de Coding Rate e Dispersión, de momento a variante orixinal ten un mellor rendemento (ver Figura 4.13).

- As variantes de segundo orde se ben experimentan pouco aprendizaxe (ou un aprendizaxe marxinal), con unha tasa de aprendizaxe máis baixa sí poden aprender máis. O que resulta nas preguntas: Ata cando se pode baixar a tasa de aprendizaxe e seguir experimentando melloras no aprendizaxe? E, Nese punto, como rendirán as variantes de segundo orde?

- Se ben o modelo orixinal foi o que tivo o mellor rendimento, compartir U e D (o cal converteo nun modelo máis lixeiro xa que pasa de ocupar 30.7 MB con 8M parámetros a 25.1 MB con 6.5M de parámetros) empeora especialmente pouco o seu rendemento, a costa de volvelo moito máis interpretable, como sabemos por construcción e veremos na vindeira Sección na Figura 4.14.

4.3.2 Explicabilidade dos mapas de atención

[NOTA: falar da Figura 4.14]

Como os resultados da Búsqueda de arquitecturas exposta na Sección precedente deixaron de manifesto que as únicas variantes (que baixo as nosas condicións de adestramento) tiveron aprendido foron o modelo orixinal e a variante que comparte os tensores U e D procedemos á comparacion da explicabilidade de devanditas Redes á traveso da técnica exposta na Sección 3.2. A comparación levouse a cabo con catro imaxes do conxunto de proba que poden verse xunto cos mapas de atención asociados ás dúas últimas capas das dúas redes para cada

unha das catro imaxes na Figura 4.14. Da observación dos mapas pódese extraer as seguintes conclusións:

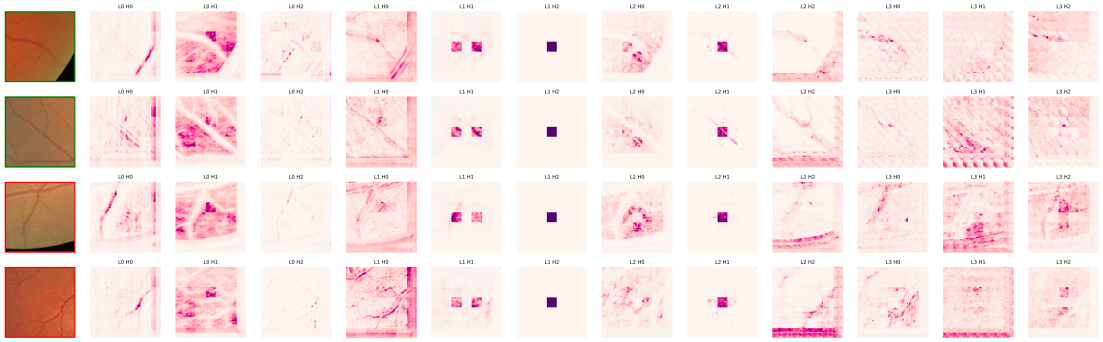
- As diferentes cabezas exhiben maior diversidade de conceptos ós que atende no caso da Rede que comparte U e D. Esta ofrece unha separación semántica semellante a que pódese atopar en Imagenet (ver Figura **??**), que foi precisamente o dominio no que os autores da Rede CRATE demostraron súa propiedade de "separación semántica". Pola contra se ben é certo que as diferentes cabezas da Rede orixinal non atenden exactamente ó mesmo, todas parecen repetir o patrón que (segundo a Rede) ten que ver ca patoloxía da imaxe. Ademáis pódese observar na Figura 4.12 que áinda que a Rede orixinal segue en réxime de aprendizaxe, pode decirse que está na fase de converxencia polo que esta diferencia observada é posible que mantéñase certa áinda con experimentos máis longos.
- A Rede que comparte por atender a cousas distintas non só acércase maís á alegación orixinal dos outores se non que é máis comprensiva ca imaxe. Mentras a Rede orixinal mantén unha hipótese firme ó traveso das cabezas a variante que comparte considera moitos aspectos diferentes da imaxe polo que, de estar errada é máis probable que atenda (por casualidade) a cousas interesantes; no caso da Rede orixinal aférrase a un pensamento e, de estar errada non ten máis que ofrecer.
- **[NOTA: seguir falando?]**

4.3.3 Explicabilidade das dimensións

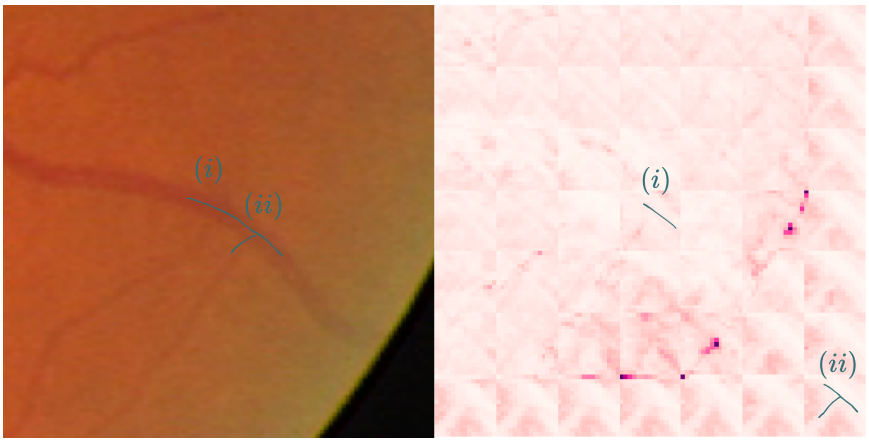
[NOTA: falar da Figura 4.15]

4.4 Discusións

- Introdución: limitacións e oportunidades.
- Desenvolvemento
- Conclusións



(a) Visualización das Atencións das tres cabezas (H$i, i \in \{0, 1, 2\}$) nas catro capas (L$i, i \in \{0, 1, 2, 3\}$) para catro parches, os dous de arriba de clase positiva e os dous de abaixo de clase negativa. Pódese ver que na primeira capa, a primeira e terceira cabezas (L0H0 e L0H2) implementan deteción de bordes ou alta resposta na primeira derivada da imaxe mentres que a segunda cabeza (L0H1) detecta os vasos en sí. Na segunda capa temos na primeira cabeza (L1H0) un detector de derivadas segundas estilo Laplaciano **[NOTA: Explicar na introdución os conceptos de derivada primeira e laplaciano?]** mentres que as outras dúas cabezas (L1H1 e L1H2) temos a atención adicada os tokens centrais, claves para esta tarefa en particular. Finalmente na derradeira capa, a que tomará a decisión final, obsérvase que en cada token **[NOTA: seguir falando]**.



(b) **[NOTA: non estou moi seguro desta explicación]** Zoom dun parche e a atención da segunda cabeza na derradeira capa. Pódese ver como cada token reflicte en si mesmo toda a situación de interese para a inferencia, neste caso a presenza dun vaso no centro do parche. Tamén pódese ver como os distintos tokens supoñen unha pequena translación na zona de interese, polo que o token central captura a escea (i) e outro a (ii).

Figura 4.10: Visualizacións das Atencións, en (a) pódese ver todas as atencións de todas as capas e para imaxes de clase positiva e negativa e en (b) un zoom para apreciar en detalle a resolución da atención. Figura de autoría propia.



(a) Esta palabra recolle venas marrones orientadas aproximadamente horizontalmente de cor marrón sobre fondo alaranxado escuro.



(b) Esta palabra recolle venas marrones orientadas aproximadamente horizontalmente de cor vermello sobre fondo alaranxado vibrante.



(c) Esta palabra recolle porcións do borde superior esquerdo do ollo (ver Figura 1.8).

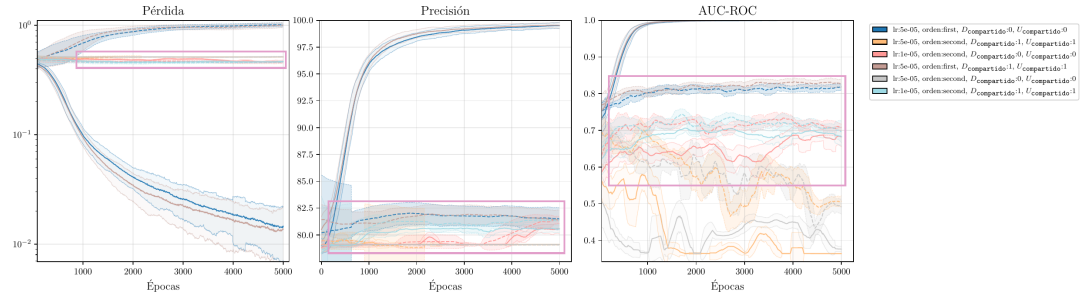


(d) Esta palabra recolle parches de cor vermello relativamente uniforme.

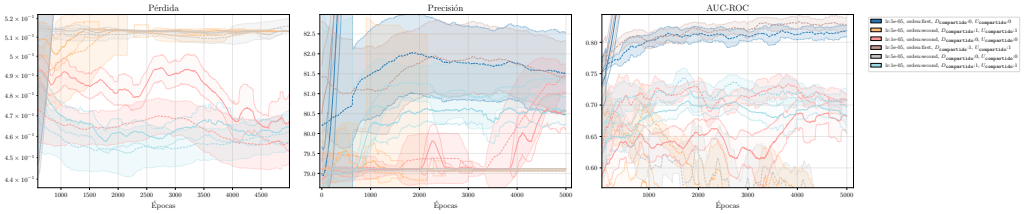


(e) Esta palabra recolle parches de cor amarelo relativamente uniforme. Correspóndense ca rexión do disco ótico (ver Figuras 1.8 e 3.4).

Figura 4.11: Escolma de parches representativos dalgunhas dimensions dunha Rede adestrada no conxunto de datos DRIVE ca tarefa especificada na Sección 3.6. As dimensións (a) e (b) recollen presenza de venas o cal é de moito interese para a tarefa de clasificación, a dimensión (c) recolle parches das rexións limítrofes co fondo da imaxe e as dimensións (d) e (e) recollen parches de cor 'lisos'. **[NOTA: falar máis ? mostrar un mosaico de todas as palabras como fixen con Imagenet?]**. Figura de autoría propia.



(a) Visión gobal do adestramento para RFMiD. Apréciase un veloz adestramento nas variantes orixinal e primeiro orde compartindo D e U. Non obstante sofren dun gran sobreaxuste, é dicir hai moita diferencia entre adestramento e validación (e os resultados de proba dispoñibles na Táboa 4.2). Pola contra contra todas as demáis variantes parecen ter un peor rendimento. Os rectángulos rosas sinalan a rexión ampliada na vindeira subfigura.



(b) Se ben as variantes segundo orde con tasa de aprendizaxe $\theta = 5 \times 10^{-5}$ ofrecen malos resultados dando moitos tumbos no proceso de aprendizaxe, as mesmas arquitecturas con unha tasa de aprendizaxe máis baixa, sí demostran aprender algo.

Figura 4.12: Comparativa do adestramento dalgunhas arquitecturas sobre RFMiD. Móstranse en liña continua os valores para o conxunto de adestramento e en liña discontinua para o conxunto de validación. Repórtanse valores para a Pérdida do modelo (esquerda), a Precisión (centro) e AUC (dereita). Figura de autoría propia.

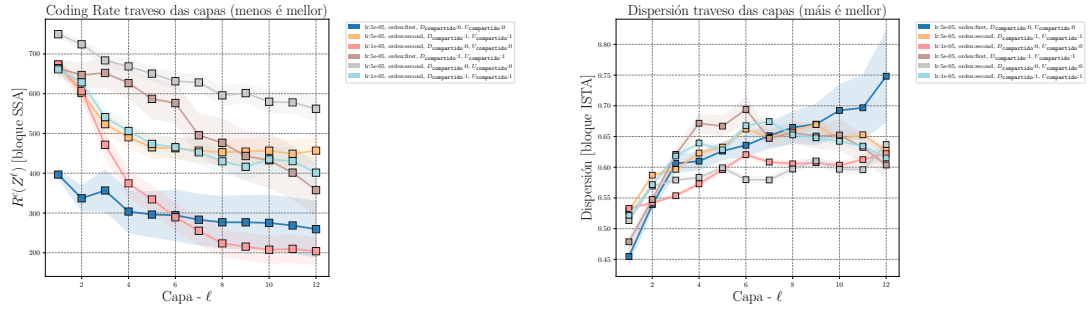
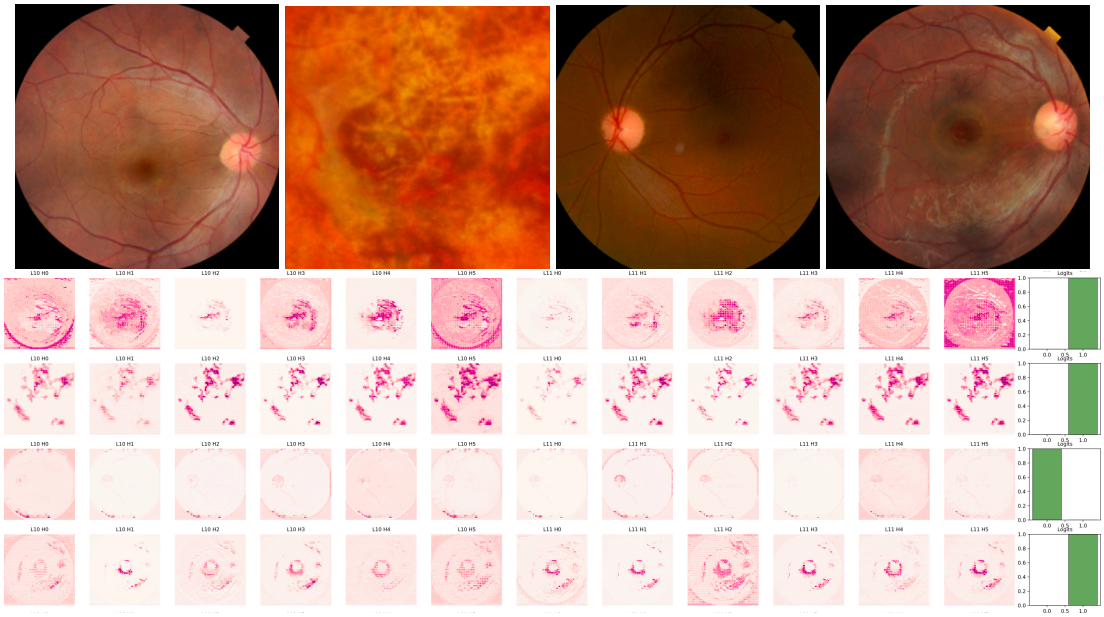
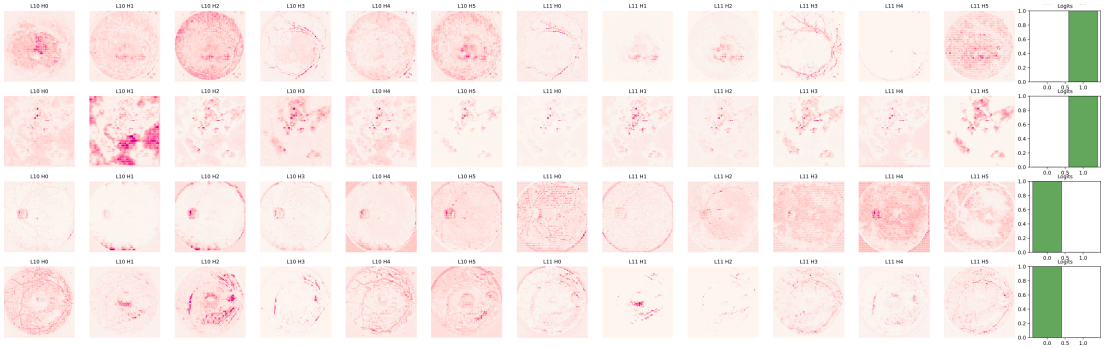


Figura 4.13: Métricas de MCR^2 e dispersión de diferentes arquitecturas sobre RFMiD. Figura de autoría propopia.

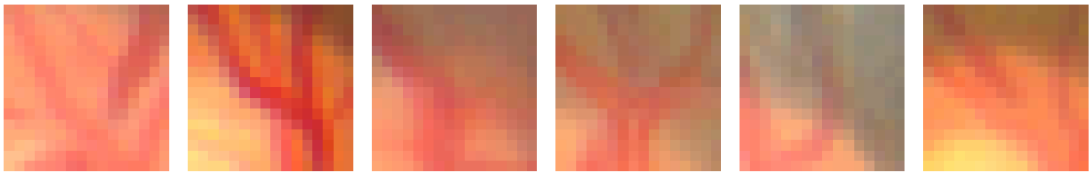


(a) Mapas de atención para as seis cabezas (H$i \in \{0, 1, 2, 3, 4, 5\}$) dúas últimas capas (L$i \in 10, 11$) do modelo CRATE orixinal. Obsérvase como a Rede ten unha *hipótese* de se a Rede ten patoloxía ou non e a manifesta matizando levemente algunhas rexións, pero as 12 cabezas mostradas veñen a atender relativamente ás mesmas rexións. O cal é relativamente bo se é o correcto pero no caso de non selo xa non aporta información real sobre o exemplo e só repetiría 12 veces o seu erro.



(b) Mapas de atención para as seis cabezas (H$i \in \{0, 1, 2, 3, 4, 5\}$) dúas últimas capas (L$i \in 10, 11$) do modelo CRATE con os tensores U e D compartidos a traveso das 12 capas. Apréciase duas cosas notables: (i) cada cabeza atende a cousas realmente distintas, pode ser que non todo teña que ver co que cree a Rede que é un sintóma patolóxico (non é malo) pero dende logo aténdese a todas as rexións cunha separación semántica semellante á atopada en Imagenet (ver Figura 4.3) (ii) unha cabeza dada ten unha relación coa mesma cabeza da seguinte capa, neste caso a cabeza L10Hj coa L11Hj. Esta relación se ben está claro que existe (o sabemos pola construcción da arquitectura) non é trivial e moitas veces incorpóranse rexións atendidas por outras cabezas.

Figura 4.14: Visualización dos mapas de atención sobre RFMiD. Arriba móstranse os catro ollos usados para realizar inferencia (os cales son patolóxicos todos) e en (a) e (b) compáranse os mapas de atención (para todas as cabezas das dúas últimas capas) da Red CRATE orixinal e a variante que comparte U e D respectivamente. Á dereita de cada fila móstrse a predicción de se é patolóxico (1) ou non (0). Malia neste exemplo acadar mellor resultado o modelo orixinal ($\frac{3}{4}$ contra $\frac{2}{4}$) as atencións do modelo que comparte tensores son máis variadas e suxerentes. Figura de autoría propia.



(a) Os parches desta palabra correspóndense con rexións de cruces ou solapamento de venas. A identificación destes constitue un paso importante no diagnóstico clínico.



(b) Esta palabra recolle parches dun cor verduzco que pode ser indicativo de imperfecións na captura de imaxes, en devandito caso a caracterización destos parches nunha palabra pode axudar ó modelo de clasificación a ser robusto ás imperfecións e centrarse na patoloxía. A propiedade de robustez sígese de que o MLP do ViT de CRATE implementa un aprendizaxe de diccionarios disperso [6] (ver Seccións 1.2.6, 1.2.7 e 1.2.9)

Figura 4.15: Mostras de *palabras* aprendidas no ISTA para o problema de clasificación binaria co conxunto de datos RFMiD (ver Figura 1.8) **[NOTA: as duas primeiras son de posemb7/2d3fb2]**

Capítulo 5

Conclusións

DERRADEIRO capítulo da memoria, onde se presentará a situación final do traballo, as leccións aprendidas, a relación coas competencias da titulación en xeral e a mención en particular, posibles liñas futuras,...

5.1 TFG en sí

Teño que dala sensación de que traballei dabondo

5.2 Resultados

- **[NOTA: o cruce non funciona en absoluto, polo menos en imagenet. o cal non era trivial en absoluto. e además pola teoría ate parecería o contrario.]**
- **[NOTA: crate nunca usouse para cousas medicas -> isto é a parte de INTERPRETABILIDADE do meu TFG. se non con DINO valdría]**
- **[NOTA: en canto a rendemento puro parece que a mellor variante é a orixinal. non obstante para estar seguros é preciso máis experimentación.]**
- **[NOTA: en canto a mapas de atención parece que en Imagenet a variante segundo orde aínda con peor rendemento ofrecía mellor separación semantica (falta probas cuantitativas).]**
- **[NOTA: en canto a palabras do dicionario non teño conclusión ningunha. :/]**
- **[NOTA: o segundo orde parece que precisa un lr máis baixo. ten sentido.]**
- **[NOTA: en xeral pouca conclusion-conclusion teño, penso que máis que conclusions o que teño son moitas más preguntas]**

5.3 Traballo futuro

Apéndices

Apéndice A

Material adicional

Exemplo de capítulo con formato de apéndice, onde se pode incluír material adicional que non teña cabida no corpo principal do documento, suxeito á limitación de 80 páxinas establecida no regulamento de TFGs.

Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Duis fringilla tristique

neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

Relación de Acrónimos

A.A. Aprendizaxe Automático. iv, 1–5

A.D. Aprendizaxe Desenrolado. iv, 9, 24, 39

A.P. Aprendizaxe Profundo. iv, 1, 2, 7, 8, 12, 14, 15, 25

A.R. Aprendizaxe de Representacións. 1, 7

C.N.N. Rede de Neuronas Artificiais Convolucionais (*Convolutional Neural Network*). 6–8

I.A.I Intelixencia Artificial Interpretable. 4, 5

I.A.X Intelixencia Artificial Explicable. 5

M.L.P. Perceptrón Multicapa (Multi-Layer Percetron). 9

MCR^2 Maximal Coding Rate Reduction. iv, v, 6–8, 19, 21, 24, 25, 30, 31, 39, 40, 46

P.S.D. Procesamento de Señais Dixitais. 1, 2, 36, 40

R.N.A. Rede de Neuronas Artificiais. 1, 2, 5, 7, 12–14, 19, 21

Glosario

explicabilidade Cualidade dun sistema de toma de decisións xunto con ferramentas auxiliares ou non de xustificar as súas decisións. Responde á pregunta: Porqué se tomou esta decisión?. iv, 2, 5, 6, 27, 29, 33, 34, 36, 42

interpretabilidade Cualidade intrínsica dun sistema de toma de decisións que permite coñecelo, de xeito que os seus compoñentes están xustificados e enténdese o seu rol. 2, 5, 29

token Vector que apréndese que forma parte da entrada e fluxo interno de modelos Transformadores.. 8, 11, 18, 21–25, 28, 36, 40, 44

Bibliografía

[1] V. N. Vapnik, *The nature of statistical learning theory*. Springer-Verlag New York, Inc., 1995.

[2] A. L. Samuel, "Some studies in machine learning using the game of checkers," *IBM Journal of Research and Development*, vol. 3, no. 3, pp. 210–229, July 1959.

[3] L. R. Rabiner, "A tutorial on hidden markov models and selected applications in speech recognition," *Proceedings of the IEEE*, vol. 77, no. 2, pp. 257–286, 1989.

[4] A. Krizhevsky, I. Sutskever, and G. E. Hinton, "Imagenet classification with deep convolutional neural networks," vol. 60, no. 6, p. 84–90, May 2017. [En liña]. Dispoñible en: http://dx.doi.org/10.1145/3065386

[5] K. Simonyan and A. Zisserman, "Very deep convolutional networks for large-scale image recognition," in *International Conference on Learning Representations*, 2015.

[6] J. Wright and Y. Ma, *High-Dimensional Data Analysis with Low-Dimensional Models: Principles, Computation, and Applications*. Cambridge University Press, January 2022. [En liña]. Dispoñible en: http://dx.doi.org/10.1017/9781108779302

[7] S. Verma, A. Lahiri, J. P. Dickerson, and S.-I. Lee, "Pitfalls of explainable ml: An industry perspective," 2021. [En liña]. Dispoñible en: https://arxiv.org/abs/2106.07758

[8] I. Loshchilov and F. Hutter, "Decoupled weight decay regularization," 2017. [En liña]. Dispoñible en: https://arxiv.org/abs/1711.05101

[9] R. Tibshirani, "Regression shrinkage and selection via the lasso," *Journal of the Royal Statistical Society: Series B (Methodological)*, vol. 58, no. 1, pp. 267–288, 01 1996. [En liña]. Dispoñible en: https://doi.org/10.1111/j.2517-6161.1996.tb02080.x

[10] A. Beck and M. Teboulle, "A fast iterative shrinkage-thresholding algorithm for linear inverse problems," *SIAM Journal on Imaging Sciences*, vol. 2, no. 1, pp. 183–202, 2009.

[11] K. Gregor and Y. LeCun, "Learning fast approximations of sparse coding," in *Proceedings of the 27th International Conference on International Conference on Machine Learning*, ser. ICML'10. Madison, WI, USA: Omnipress, 2010, p. 399–406.

[12] A. Szlam, K. Gregor, and Y. LeCun, "Fast approximations to structured sparse coding and applications to object classification," 2012. [En liña]. Dispoñible en: https://arxiv.org/abs/1202.6384

[13] M. Garouani, J. Mothe, A. Barhrhouj, and J. Aligon, "Investigating the duality of interpretability and explainability in machine learning," 2025. [En liña]. Dispoñible en: https://arxiv.org/abs/2503.21356

[14] M. T. Ribeiro, S. Singh, and C. Guestrin, ""why should i trust you?": Explaining the predictions of any classifier," 2016. [En liña]. Dispoñible en: https://arxiv.org/abs/1602.04938

[15] S.-Y. Byun and W. Lee, "Vit-reciprocam: Gradient and attention-free visual explanations for vision transformer," 2023. [En liña]. Dispoñible en: https://arxiv.org/abs/2310.02588

[16] M. D. Zeiler and R. Fergus, "Visualizing and understanding convolutional networks," 2013. [En liña]. Dispoñible en: https://arxiv.org/abs/1311.2901

[17] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra, "Grad-cam: Visual explanations from deep networks via gradient-based localization," 2016. [En liña]. Dispoñible en: https://arxiv.org/abs/1610.02391

[18] K. H. R. Chan, Y. Yu, C. You, H. Qi, J. Wright, and Y. Ma, "Redunet: A white-box deep network from the principle of maximizing rate reduction," 2021. [En liña]. Dispoñible en: https://arxiv.org/abs/2105.10446

[19] Y. Yu, T. Chu, S. Tong, Z. Wu, D. Pai, S. Buchanan, and Y. Ma, "Emergence of segmentation with minimalistic white-box transformers," 2023. [En liña]. Dispoñible en: https://arxiv.org/abs/2308.16271

[20] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, and N. Houlsby, "An image is worth 16x16 words: Transformers for image recognition at scale," 2020. [En liña]. Dispoñible en: https://arxiv.org/abs/2010.11929

[21] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, "Attention is all you need," 2017. [En liña]. Dispoñible en: https://arxiv.org/abs/1706.03762

[22] X. Chen, C.-J. Hsieh, and B. Gong, "When vision transformers outperform resnets without pre-training or strong data augmentations," 2021. [En liña]. Dispoñible en: https://arxiv.org/abs/2106.01548

[23] M. Aharon, M. Elad, and A. Bruckstein, "rmk-svd: An algorithm for designing overcomplete dictionaries for sparse representation," vol. 54, no. 11, p. 4311–4322, November 2006. [En liña]. Dispoñible en: http://dx.doi.org/10.1109/TSP.2006.881199

[24] V. Monga, Y. Li, and Y. C. Eldar, "Algorithm unrolling: Interpretable, efficient deep learning for signal and image processing," 2019. [En liña]. Dispoñible en: https://arxiv.org/abs/1912.10557

[25] S. Panchal, A. Naik, M. Kokare, S. Pachade, R. Naigaonkar, P. Phadnis, and A. Bhange, "Retinal fundus multi-disease image dataset (rfmid) 2.0: A dataset of frequently and rarely identified diseases," *Data*, vol. 8, no. 2, 2023. [En liña]. Dispoñible en: https://www.mdpi.com/2306-5729/8/2/29

[26] J. Staal, M. Abramoff, M. Niemeijer, M. Viergever, and B. van Ginneken, "Ridge-based vessel segmentation in color images of the retina," *IEEE Transactions on Medical Imaging*, vol. 23, no. 4, pp. 501–509, 2004.

[27] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and L. Fei-Fei, "Imagenet: A large-scale hierarchical image database," in *2009 IEEE conference on computer vision and pattern recognition*. IEEE, 2009, pp. 248–255.

[28] Instituto Cervantes. (2026) O que algo quere, algo lle custa. Centro Virtual Cervantes. [En liña]. Dispoñible en: https://cvc.cervantes.es/lengua/refranero/Ficha.aspx?Par=58652&Lng=2

[29] L. M. Castro, "modelo-tfg-fic: Modelo de memoria de tfg da facultade de informática (fic) da universidade da coruña," https://gitlab.com/lauramcastro/modelo-tfg-fic, 2020, gitLab repository, accessed 2026-06-14.

[30] Matplotlib Development Team, "Choosing colormaps in matplotlib," https://matplotlib.org/stable/users/explain/colors/colormaps.html, 2026, accessed: 2026-08-25.

[31] Y. Yu, S. Buchanan, D. Pai, T. Chu, Z. Wu, S. Tong, H. Bai, Y. Zhai, B. D. Haeffele, and Y. Ma, "White-box transformers via sparse rate reduction: Compression is all there is?" 2023. [En liña]. Dispoñible en: https://arxiv.org/abs/2311.13110

[32] Wikipedia, "Neumann series," https://en.wikipedia.org/wiki/Neumann_series, 2026. [En liña]. Dispoñible en: https://en.wikipedia.org/wiki/Neumann_series

[33] J. Nocedal and S. Wright, *Numerical optimization*, 2nd ed., ser. Springer series in operations research and financial engineering. New York, NY: Springer, 2006. [En liña]. Dispoñible en: http://gso.gbv.de/DB=2.1/CMD?ACT=SRCHA&SRT=YOP&IKT=1016&TRM=ppn+502988711&sourceid=fbw_bibsonomy

[34] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," 2015. [En liña]. Dispoñible en: https://arxiv.org/abs/1512.03385

[35] M. Caron, H. Touvron, I. Misra, H. Jégou, J. Mairal, P. Bojanowski, and A. Joulin, "Emerging properties in self-supervised vision transformers," 2021. [En liña]. Dispoñible en: https://arxiv.org/abs/2104.14294

[36] D. E. Rumelhart, G. E. Hinton, and R. J. Williams, "Learning representations by back-propagating errors," vol. 323, no. 6088, p. 533–536, October 1986. [En liña]. Dispoñible en: http://dx.doi.org/10.1038/323533a0

[37] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. MIT Press, 2016, http://www.deeplearningbook.org.

[38] J. Bergstra and Y. Bengio, "Random search for hyper-parameter optimization," *Journal of Machine Learning Research*, vol. 13, no. 10, pp. 281–305, 2012. [En liña]. Dispoñible en: http://jmlr.org/papers/v13/bergstra12a.html

[39] Wikipedia contributors, "Miss vaca," https://es.wikipedia.org/wiki/Miss_Vaca, 2026, Última edición: 30 de junio de 2026.