Facultade de Informática
UNIVERSIDADE DA CORUÑA

TRABALLO FIN DE GRAO
GRAO EN INTELIXENCIA ARTIFICIAL

Interpretabilidade e explicabilidade mediante técnicas de Aprendizaxe Profundo de Caixa Blanca aplicadas ó análise de imaxe

Estudante: José Romero Conde

Dirección: José Rouco Maseda

Jorge Novo Buján

A Coruña, novembro de 2026.

Á miña avoa

Agradecementos

Quero agradecer este traballo primeiro ós meus pais que tiveron moita paciencia e non os merezo e en segundo lugar ós meus amigos que me animaron e me escoitaron falar de cousas que non lles importaba.

Resumo

Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

Abstract

Hello, here is some text without a meaning. This text should show what a printed text will look like at this place. If you read this text, you will get no information. Really? Is there no information? Is there a difference between this text and some nonsense like “Huardest gefburn”? Kjift – not at all! A blind text like this gives you information about the selected font, how the letters are written and an impression of the look. This text should contain all letters of the alphabet and it should be written in of the original language. There is no need for special content, but the length of words should match the language.

Palabras chave:

- First itemtext
- Second itemtext
- Last itemtext
- First itemtext
- Second itemtext
- Last itemtext
- First itemtext

Keywords:

- First itemtext
- Second itemtext
- Last itemtext
- First itemtext
- Second itemtext
- Last itemtext
- First itemtext

Índice Xeral

1 Introdución **1**

1.1 Contexto xeral . . . 1
1.2 Interpretabilidade e Explicabilidade . . . 4
1.2.1 Motivación . . . 4
1.2.2 Intelixencia Artificial Interpretable . . . 4
1.2.3 Intelixencia Artificial Explicable . . . 5
1.3 Aprendizaxe Profundo . . . 8
1.3.1 Orixes liñeais . . . 8
1.3.2 Dispersión . . . 9
1.3.3 Compresión . . . 9
1.3.4 O rol da capa . . . 10
1.3.5 A Atención . . . 10
1.3.6 Discusión . . . 10
1.3.7 ISTA . . . 10
1.3.8 ViT . . . 11
1.3.9 Aprendizaxe desenrolado . . . 11
1.4 Representacións . . . 12
1.4.1 Aprendizaxe de diccionarios . . . 12
1.4.2 MCR^2 . . . 15
1.5 Redes Caixa Branca . . . 15
1.5.1 Motivación . . . 15
1.5.2 MCR^2 e ReduNet - Redes Caixa Blanca . . . 15
1.6 CRATE . . . 16
1.6.1 Diferenzas arquitecturais entre CRATE e ViT . . . 16
1.6.2 Principios teóricos **[NOTA: ou 'Relación con conceptos da teoría']** 18
1.7 Obxectivos e contribucións . . . 20
1.7.1 Elementos diferenciais . . . 20

1.7.2 Oportunidades . . . 20
1.7.3 Contribucións . . . 20
1.8 Organización da memoria . . . 21

2 Metodoloxía e planificación 22
2.1 Método de traballo . . . 22
2.2 Recursos . . . 23
2.2.1 Humanos . . . 23
2.2.2 De *Software* . . . 23
2.2.3 De *Datos* . . . 25
2.2.4 De *Hardware* . . . 26
2.3 Distribución temporal do traballo . . . 27
2.4 Estimación de custos . . . 28

3 Traballo proposto 29
3.1 Introdución . . . 29
3.2 Segundo orden . . . 30
3.2.1 Aproximación da inversa mediante suma de matrices . . . 30
3.2.2 Nova arquitectura . . . 31
3.2.3 Cruce . . . 34
3.3 Visualizacións dos mapas de atención . . . 35
3.3.1 Motivación . . . 35
3.3.2 Procedemento . . . 35
3.3.3 Extensión para resolución . . . 36
3.3.4 Extensión ó segundo orde . . . 37
3.4 Recuperación de parches representativos . . . 38
3.4.1 Procedemento . . . 38
3.5 Compartir U e D . . . 39
3.6 Combinación de achegas . . . 42
3.7 Métricas . . . 42
3.8 Tarefas de adestramento . . . 43
3.9 Preguntas . . . 44

4 Resultados 46
4.1 Introdución . . . 46
4.2 Imagenet . . . 47
4.2.1 Busca de arquitecturas . . . 48
4.2.2 Cruce de arquitecturas . . . 49

4.2.3 Explicabilidade dos mapas de atención . . . 49
4.2.4 Explicabilidade das dimensións . . . 53
4.3 DRIVE . . . 55
4.3.1 Busca de arquitecturas . . . 55
4.3.2 Explicabilidade dos mapas de atención . . . 57
4.3.3 Explicabilidade das dimensións . . . 58
4.4 RFMiD . . . 58
4.4.1 Busca de arquitecturas . . . 58
4.4.2 Explicabilidade dos mapas de atención . . . 60
4.4.3 Explicabilidade das dimensións . . . 61
4.5 Discusións . . . 62

5 Conclusións **69**
5.1 Valoración do TFG . . . 69
5.2 Resultados . . . 70
5.2.1 Variante Segundo Orde . . . 70
5.2.2 Cruce de ordes . . . 71
5.2.3 Variante que comparte . . . 72
5.2.4 CRATE en imaxen médica . . . 72
5.3 Limitacións . . . 73
5.4 Traballo futuro . . . 73

A Optimización non convexa sen restriccións **76**
A.1 Planteamento . . . 76
A.2 O efecto da tasa de aprendizaxe η . . . 77
A.3 Extensións sobre o descenso de gradiente . . . 77

Relación de Acrónimos **78**

Glosario **79**

Bibliografía **80**

Índice de Figuras

1.1 Comparación entre A.A. e o resto da Intelixencia Artificial. Figura de autoría propia. . . . 1
1.2 Comparación entre A.A. e A.P.. Figura de autoría propia. . . . 3
1.3 Métodos de explicabilidade. Subfiguras extraídas de [5] e [6]. . . . 6
1.4 Modelo de neurona. Figura de autoría propia. . . . 8
1.5 Arquitectura *Encoder-Decoder*. Figura de autoría propia. . . . 9
1.6 Proxeción ás bolas $\mathcal{L}_1$ e $\mathcal{L}_2$. Figura de autoría propia. . . . 12
1.7 Funcións de activación. Figura de autoría propia. . . . 12
1.8 Arquitectura do ViT. Figura de autoría propia. . . . 13
1.9 Decorrupción con A.D.. Subfiguras extraídas de [9]. . . . 14
1.10 Iteración dos pasos do MCR^2. Figura de autoría propia. . . . 18
1.11 Esquema da arquitectura de CRATE. Figura de autoría propia. . . . 18

2.1 Esquema das reunións. Figura de autoría propia. . . . 23
2.2 Mapa de cor Pink. Figura extraída de [31]. . . . 25
2.3 Mostras dos conxuntos de datos. Imaxes extraídas de [32], [33] e [34]. . . . 25
2.4 Esquema do uso do servidor. Figura de autoría propia. . . . 26
2.5 Diagrama de Gantt ilustrando as tarefas do traballo. Figura de autoría propia. 27

3.1 Comparativa entre a atención do modelo CRATE orixinal e a proposta. Figura de autoría propia. . . . 32
3.2 Pasos do procedemento de Mapas de Atención de alta resolución. Figura de autoría propia. . . . 36
3.3 Paso do procedemento de recuperación de palabras representativas dos dicionarios. Figura de autoría propia. . . . 39
3.4 Comparativa entre a proxeción lineal do modelo CRATE orixinal e a proposta. Figura de autoría propia. . . . 40

3.5 Mostras de supervision para o conxunto de datos DRIVE. Figura de autoría propia. . . . 44

4.1 Adestramento de diferentes arquitecturas sobre Imagenet. Figura de autoría propia. . . . 47
4.2 Métricas de MCR^2 e dispersión de diferentes arquitecturas sobre Imagenet. Figura de autoría propia. . . . 48
4.3 Visualización dos mapas de atención sobre imaxes de vacas. Figura de autoría propia. . . . 50
4.4 Visualización dos mapas de atención sobre imaxes de insectos. Figura de autoría propia. . . . 51
4.5 Mosaico con parches asociados a todas as dimensións de todas as cabezas dunha Rede adestrada en Imagenet. Figura de autoría propia. . . . 54
4.6 Adestramento de diferentes arquitecturas sobre DRIVE. Figura de autoría propia. 55
4.7 Adestramento da arquitectura orixinal e a proposta sobre DRIVE. Figura de autoría propia. . . . 56
4.8 Métricas de MCR^2 e dispersión de diferentes arquitecturas sobre DRIVE. Figura de autoría propia. . . . 56
4.9 Comparativa da segmentación das variantes orixinal e combo. Figura de autoría propia. . . . 57
4.10 Visualización dos mapas de atención sobre DRIVE. Figura de autoría propia. . . 63
4.11 Escolma de parches asociados ás dimensións dunha Rede adestrada con DRIVE. Figura de autoría propia. . . . 64
4.12 Comparativa do adestramento dalgunhas arquitecturas sobre RFMiD. Figura de autoría propia. . . . 65
4.13 Métricas de MCR^2 e dispersión de diferentes arquitecturas sobre RFMiD. Figura de autoría propia. . . . 65
4.14 Visualización dos mapas de atención sobre RFMiD. Figura de autoría propia. . . 66
4.15 Escolma de parches asociados ás dimensións dunha Rede adestrada con RFMiD. Figura de autoría propia. . . . 67
4.16 Mosaico con parches asociados a todas as dimensións de todas as cabezas das seis Redes adestradas en RFMiD. Figura de autoría propia. . . . 68

A.1 Ilustración da influencia da eleción da tasa de aprendizaxe. Figura de autoría propia. . . . 76

Índice de Táboas

3.1 Combinacións sometidas a experimentación. 42

4.1 Combinacións sometidas a experimentación. 46
4.2 Resultados do cruce de ordes para o conxunto de datos Imagenet. 49
4.3 AUC no conxunto de proba para unha escolma de arquitecturas para o conxunto de datos RFMiD. 59

Capítulo 1

Introdución

Todos os modelos están errados, pero algúns son útiles. [1]

Un modelo que acerta pero non sabe dicir por que acerta serve de pouco alí onde unha decisión errada ten consecuencias. Este capítulo parte do contexto actual da Aprendizaxe Automática (A.A.), a Aprendizaxe Profunda (A.P.) para entender porque a interpretabilidade e explicabilidade importan. Preséntanse propiedades que debería ter un bo modelo e introdúcese Crate como unha vía para obtelas por deseño. O capítulo remata cas oportunidades e contribucións deste traballo.

1.1 Contexto xeral

A Aprendizaxe Automática (A.A.) é tanto unha rama da Intelixencia Artificial, á que serve con técnicas e métodos como da Estatística, da que recibe garantías e principios teóricos. No contexto da Intelixencia Artificial, a A.A. permite a un sistema *aprender* a través de datos a comportase dun xeito específico, o cal non precisou unha programación explíta. En contraste

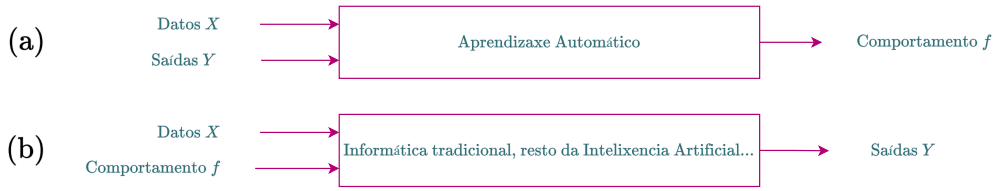

Figura 1.1: Comparación entre A.A. e o resto da Intelixencia Artificial. (a) Un sistema de A.A. recibe datos explicativos dalgún fenómeno ou mostra (X) e a etiqueta ou resposta esperada do sistema ante devanditos datos (Y), como resultado do proceso de adestramento obterase o comportamento f que poderase utilizar no futuro para a partires de novos datos X producir saídas axeitadas Y. (b) Un sistema informático xeral precisa do comportamento desexado de antemán, habitualmente especificado a traveso de código para, xunto con entradas X producir saídas Y. Figura de autoría propia.

con outras ramas da Intelixencia Artificial en particular (como os Sistemas Expertos ou Sistemas de Planificación) ou da Informática en xeral que son programadas para actuar dunha forma, a A.A. ten a vantaxe de *descubrir* a forma máis axeitada de comportarse, dados uns datos e as súas saídas, como ilústrase na Figura 1.1. Máis formalmente, considérase unha función $f : X \to Y$ non observada e unha mostra de N pares $\{x_i, y_i\}_{1 \leq i \leq N}$ observados, cos cales quérese estimar unha función $\hat{f}$ o máis pareceida a f. Algunhas tarefas típicas a aprender son a Clasificación, onde a saída asociada a un dato é a clase ou categoría, é dicir Y son o conxunto de clases (e.g. un sistema que clasifique correo en *spam*) ou a Regresión, onde a saída asociada a un dato pode ser calquera número, é dicir $Y \subset \mathbb{R}$ (e.g. un sistema de predicción metereolóxica onde a saída e a cantidade de precipitación do vindeiro día).

A natureza dos datos sobre os que un sistema de A.A. debe aprender poden ser moi complexos nos Sistemas de Interese científico e económico xa que estos poden ter unha alta dimensionalidade (e.g. no sistema metereolóxico serían todos os valores que se teñen en conta para facer a predicción), diferentes modalidades (e.g. as entradas dun sistema poden ser imaxes, audio, datos tabulares, ou varios destos xuntos) e en xeral relacións funcionais non liñais. Ademáis, na maioria dos contextos de interese os datos (e as saídas) poden vir acompañados de ruídos ou perturbacións de naturezas diversas. Isto supón a necesidade de achar principios e algoritmos complexos que poidan encontrar a razón funcional entre os datos e as saídas, solventando os problemas mencionados con éxito.

Nos albores da A.A., no século XIX, os algoritmos eran relativamente sinxelos e só podían achar relacións funcionais lineais e ser robustos a tipos de ruído moi concretos. O século XX viu o esplendor de desenvolvementos teóricos e prácticos, instanciados nunha chea de algoritmos, como os árbores de decisión, as máquinas de vectores de soporte, as cadenas de Markov, a regresión xeralizada... que permitiu solventar problemas moi diversos en natureza (recoñecemento da fala e da escrita, recomendacións de productos na *e-commerce*, xogo do xadrez...) con certa velocidade para conxuntos de datos de gran tamaño.

Non obstante, para que un sistema de A.A. aprendera con éxito a función deseada era precisa unha modelización axeitada do problema xeral, moitas veces divididos en subproblemas que á súa vez axudábanse de ferramentas do Procesamento de Señais Dixitais (P.S.D.) (e.g. Transformadas de Fourier ou *wavelet*). Así, un sistema completo de Intelixencia Artificial que usara A.A. precisaba que o enxeñeiro invesigara a natureza dos datos en relación ca saída e a traveso dese coñecemento de dominio fora unindo as pezas do *puzzle* xuntando diferentes ferramentas de P.S.D. e modelos de A.A. para obter o rendemento esperado, como móstrase na Figura 1.2

Por outra banda, inspirándose no cerebro animal, o ártifice da intelixencia, existe dende as últimas oito décadas un intento de modelar toda a relación funcional entre os datos de saída cunha única compoñentei complexa: a Rede de Neuronas Artificiais (R.N.A.). Certas Redes

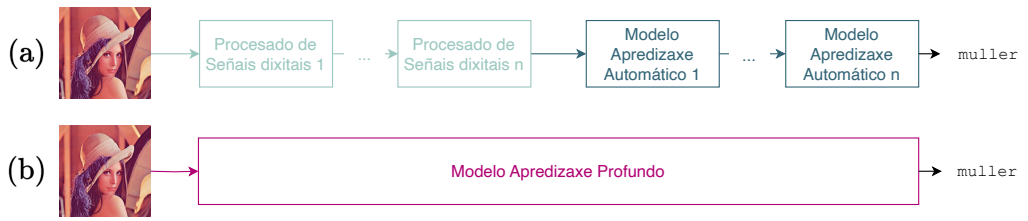

Figura 1.2: Diferenzas no procedemento enxeñeril entre o A.A. clásico e o A.P. cun exemplo de clasificación de imaxe. (a) No enfoque clásico, a entrada (neste caso os píxel das imaxes) debía ser preprocesada con un ou máis métodos de P.S.D. co fin de extraer características (bordes, esquinas, patróns predefinidos . . .) que logo o(s) algoritmo(s) de aprendizaxe usará(n) para predecir a saída. (b) Na aproximación moderna, un modelo de A.P. é quen de extraer por si só as características que vai precisar para predecir a saída. Deste xeito o modelo de A.P. cumple o rol de extracción de características e de discriminación sobre elas. Figura de autoría propia.

Neuronais primitivas pódese ver hoxe mesmo como modelos de A.A. ordinario, pero a finais do século XX e especialmente a partires da década do 2010 unha idea dotou ás R.N.A. de distinción e éxito sobre outros modelos: a composición de capas. Realmente unha única capa de Rede Neuronal non é cousa sustancialmente distinta de Regresión Lineal ou SVM, exemplos de algoritmos de A.A., pero mentres que estes precisaban de unha compoñente P.S.D. ou outro modelo A.A. se a relación funcional era complexa, as R.N.A. superaron esta dificultade a traveso da composición delas mesmas. A interacción entre as capas permitía unha sincronización total da información en inferencia e en adestramento: agora o adestramento dos modelo facíase unha única vez e xa quedaba aprendida a relación funcional. Se ben a corrente neuronal tivo varios nomes ó largo dos anos, na actualidade esta aproximación coñécese por Aprendizaxe Profunda (A.P.) por ser "profunda" a superposición de capas (en contraposición a "superficial"). A nivel do sistema completo, as diferencias entre a aproximación trandicional, misturando múltiples compoñentes de P.S.D. e A.A. e a aproximación neuronal onde hai unha única compoñente de A.P. pódense ver na Figura 1.2.

Polo exposto pode deducirse correctamente que o desenvolvemento de sistemas de Intelixencia Artificial baseados en A.P. é máis sinxelo de deseñar que aquelos baseados en A.A. puro, e así é. Nembargantes, os problemas do A.P. existen en outras vías non menos importantes, a saber (i) O custo computacional necesario para adestrar e usar o sistema (ii) A necesidade de moitas mostras etiquetadas para o correcto adestramento do sistema (iii) A falta de interpretabilidade e explicabilidade (para definicións máis detalladas ver a Sección 1.2) do sistema en xeral. Se ben o primeiro problema resolveuse co acelerado desenvolvemento tecnolóxico deste século, os outros dóus se cadra empeoraron [2]. E posto que a Intelixencia Artificial ten cada vez máis presencia nas nosas vidas xurde a necesidade de impoñer restricións sobre o desenvolvemento. Por exemplo, na Unión Europea os usos da Intelixencia Artificial considerados de *alto risco* (como a educación, o empleo a lexislación, a xustiza...)

deben ter mecanismos de explicabilidade[3].

Por ser a A.P. a rama máis fructífera da Intelixencia Artificial, vérsatil e se o problema é complexo, as veces a única capaz de resolvelo; precisamente a vertente da Intelixencia Artificial menos interpretable e explicable, nace a imperiosa necesidade de desenvolver modelos de A.P. interpretables e explicables. Deste xeito teríanse os beneficios (sinxeleza de deseño, capacidade resolutiva) perdendo os prexuizos, permitindo así unha Intelixencia Artificial útil é transparente.

1.2 Interpretabilidade e Explicabilidade

Un modelo de A.A. pode ofrecer claridade sobre o seu compartamento respondendo a duas grandes preguntas: *Como* toma decisións? e *Porque* tomou unha decisión particular? Os campos de Interpretabilidade e Explicabilidade tratan de ou ben dar respostas a estas preguntas, respectivamente. Na Sección 1.2.1 motivarase a importacia da cuestión, e nas Seccións 1.2.2 e 1.2.3 farase unha breve exposición dos conceptos de Intelixencia Artificial Interpretable (I.A.I) e Intelixencia Artificial Explicable (I.A.X) respectivamente.

1.2.1 Motivación

Dende un punto de vista utilitario pódense considerar ós modelos de A.A. (e por ende A.P.) como *caixas negras* que fan o seu traballo de transformar as entradas en saídas sen reparar no seu funcionamento interno ou porqué tomou unha decisión particular. Pero este punto de vista é problemático cando as consecuencias das decisións afectan dalgún xeito á vida das persoas. Isto é, se nun videoxogo, a Intelixencia Artificial que controla a un personaxe non xogable é defectuosa, no peor caso supondrá unha mala experiencia de xogo; porén se no ministerio unha Intelixencia Artificial que controla a quen se lle dan axudas é defectuosa, as consecuencias son moi graves. Por suposto, as consecuencias dunha Intelixencia Artificial defectuosa poden xogar ca vida e ca morte das persoas se trátase dun sistema de triaxe médico. Neses casos será necesario, *en xeral* entender que ten presente o sistema para tomar decisións e como manipula devandita información e *en particular* entender que se tivo en conta, e como, para cada decisión individual. Mesmo se o sistema non ten a última palabra estas cuestións son importantes porque se un profesional encóntrase asistido dun sistema de Intelixencia Artificial que non comprende como funciona, deixará de confiar nel.

1.2.2 Intelixencia Artificial Interpretable

A Intelixencia Artificial Interpretable (I.A.I) é aquela que posúe a propiedade de ser entendible, en particular dos procesos de manipulación dos datos de entrada que desembocan

nunha saída. Deste xeito a interpretabilidade dun sistema está ligada a habilidade dos desenvolvedores do mesmo para entendelo. Algúns exemplos de modelos de I.A.I son a regresión lineal simple, ás árbores de decisión ou os sistemas de emparellamento de patróns. Con todo a interpretabilidade non depende exclusivamente do modelo (no sentido de que si un modelo de Intelixencia Artificial é en xeral interpretable, un sistema que o use non ter por que selo) posto que depende do tamaño das entradas e da súa natureza. Por exemplo unha árbore de decisións con centos ou miles de follas (e por tanto centos ou miles de ramificacións) pode ser tan complicado de explicar que de feito sexa imposible ou non práctico. O mesmo ocúrrelle á regresión lineal ou as máquinas de vectores de soporte, se teñen centos de entradas pode ser inviabel facer unha explicación do rol que tivo cada unha delas na decisión final. Ademáis do problema da escala , un modelo a priori interpretable pode chegar a non selo se as súas entradas son o sufientemente *abstractas* como para non poder entenderse; e así por poucas que sexan tampouco sería interpretable o sistema.

A bondade da I.A.I reside en que crean un modelo (deseñadores, enxeñeiros) o entendan co fin de aplicar trazabilidade e depuración nos casos de mal funcionamento. Por iso tanto os modelos como as entradas e a natureza das mesmas deben ser sinxelas para que poda existir un entendemento axeitado, o cal habitualmente conleva no decaemento do rendemento do mesmo [4].

En xeral o entendemento do funcionamento dun sistema debería supoñer a comprensión das decisións particulares, é dicir a interpretabilidade conleva unha inherente explicabilidade. Por exemplo, se nun sistema de contratación dunha empresa mediante o análise de currículums adestrado con datos históricos da empresa descúbrese que hai unha ponderación negativa á pertenza dunha certa minoría, automáticamente saberíase que para cada candidato que pertenza a devandita minoría hai menos probabilidades de contratación.

Dúas vías caracterizan principalemente a interpretabilidade dun sistema: a capacidade para *introducir* coñecemento de alto nivel ou simbólico que se quere que o sistema teña presente e a capacidade para *extraelo*, é dicir dado un sistema adestrado, Que coñecemento en termos do dominio está a manipular á hora de tomar decisións? Neste traballo verase como no deseño dun modelo de A.P. poden introducirse certas nocións intuitivas que deberían cumplirse sempre, así como no sistema xa adestrado pódese extraer o *coñecemento* que adquiriu a traveso do proceso de adestramento cos datos.

1.2.3 Intelixencia Artificial Explicable

A Intelixencia Artificial Explicable (I.A.X) é aquela que está dotada de mecanismos, técnicas ou principios que permiten explicar o razoamento detrás das decisións do sistema. Ben puidendo ser estos mecanismos intrínsecos ó sistema (de forma que sempre estiveron presentes) ou ben poden ser técnicas que se lle engadan segundo sexa preciso a un sistema xa

(a) LIME pode sinalar as rexións que fan tomar a decisión de se a imaxe é un *husky* ou non, neste caso vemos que o modelo di que é un husky pola neve e non polo animal en sí. Polo tanto grazas á explicabilidade podemos identificar mostras nas que o modelo da a solución correcta pero por motivos equivocados. Figura extraída de [5].

(b) ReciproCAM sinala a influencia dunha rexión con respecto a clase, neste caso a clase é elefante. Figura extraída de [6]

Figura 1.3: Exemplos de métodos de explicabilidade con aplicación a imaxes. Subfiguras extraídas de [5] e [6].

adestrado, dotándoo así de explicabilidade. Estas técnicas poden clasificarse baixo diferentes taxonomías que se ben organizan o estado da arte, non destacan os mecanismos subxacentes á estructura das explicacións en sí, nembargantes para ubicar ó lector onde sitúase a explicabilidade neste traballo con respecto a outros discutiranse agora brevemente algúnhas delas.

As explicacións dun sistema poden ser *locais* ou *globais* segundo se para ofrecer a xustificación usase o modelo como un todo ou só unha parte del. Dito doutro xeito as explicacións locais explican unha predición concreta, e as globais explican o modelo no seu conxunto. Posto que as funcións de decisión f adoitan ser moi complexas e deben cubrir todo o espacio das entradas, as explicación locais á hora de explicar porque $y = f(x)$, optan por achar unha nova función $\hat{f}$ que aproxime f na contorna de x. Asemade o métodos de explicación temén poden dividirse en se poden aplicarse a *calqueira algoritmo* ou precisa que este sexa *parte dunha familia*. Posto que os métodos de explicación baséanse nos principios do modelo, se estos son xerais e comúns a todos os algoritmos de A.A. os métodos derivados poderanse aplicar para todos os modelos, porén se na construcción da explicación empréganse principios que só posúen un algoritmo ou unha familia deles, devandita explicación só será aplicable para os membros desta. Por exemplo, sobre un modelo da familia ViT (ver Sección 1.3.8), ben poden usarase métodos de explicación xerais ou métodos exclusivos dos ViT.

Porén, a explicabilidade dos modelos de aprendizaxe automático aínda presenta importantes desafíos. Entre eles destacan a falta dunha linguaxe común para representar as explicacións, a ausencia de métricas cuantitativas estandarizadas para avaliar a súa calidade e a dificultade de establecer procedementos de avaliación aplicables a diferentes contextos [7].

Posto que o problema específico deste traballo é o análise de imaxe, exporanse agora duás técnicas de explicación con aplicación ó noso problema.

A técnica LIME [5] é un intérprete da función f en termos máis sinxelos de xeito que sexa explicable . Para ofrecer unha xustificación de porque un modelo deu unha saída cunha certa entrada x, fai inferencias con N entradas similares $\{x_i\}_{1\leq i\leq N}$ e aproxima localmente a función de decisión. Ofrece explicacións en termos de como cambiou f segundo as variacións de x, e poden ser visualmente doadas de entender. Por exemplo na Figura 1.3a o método LIME sinalou os píxeles máis importantes para tomar a decisión '*husky*' e pódese ver que neste caso aínda que a decisión é correcta, o modelo esta baseandose no fondo nevado (porque no conxunto de adestramento había moitas mostras deste can con fondo nevado) polo que pode concluirse que o modelo memorizou esta casuistica (ter sempre un fondo nevado) pero non comprende o que é un *husky*.

Outra familia de métodos comprenden: GradCAM (para C.N.N.), ReciproCAM ou CAM guiado por atención (para ViT, ver Sección 1.3.8). A diferencia de LIME que podía ser usado para calquera modelo de A.A., estes estan deseñados ou ben para Rede de Neuronas Artificiais Convolucionais (*Convolutional Neural Network*) (C.N.N.) ou ben para ViTs (ver a Sección 1.3 para detalles sobre estes modelos), é dicir exemplos R.N.A.. Fan un uso técnico da información intermedia da Rede e a utilizan para resaltar que rexións da imaxe teñen que ver ca clase. Deste xeito, pódese adestrar unha Rede para solventar un problema de análise de imaxe e logo escoller un método axeitado para o tipo de Rede que se adestrou e usalo dun xeito relativamente "*plug-in*". Na Figura 1.3b pódese ver un exemplo de ReciproCAM [6] onde o método resalta as rexións que máis teñen que ver segundo o modelo ca clase "elefante". Aínda que podan parecer moi útiles, estos métodos presentan o defecto de que non poden manipular conceptos semanticos máis pequenos ca clase, por exemplo na Figura 1.3b sería interesante saber que tivo en conta o modelo para que este pense porque devandita rexión é un elefante: Fixouse nas orellas? Na trompa? Sabemos que sabe o que é un elfante pero non porque o sabe. Ademáis o uso de métodos deste tipo adoita ser algo relativamente sofisticado con moitos elementos novos.

Ademais, cómpre destacar que unha explicación non sempre resulta suficiente para permitir unha intervención sobre o comportamento do modelo. Moitas das técnicas actuais limítanse a explicar por que se produciu unha determinada predición, sen proporcionar recomendacións accionables que permitan corrixir os erros ou modificar o comportamento do sistema. Esta limitación constitúe un dos principais retos actuais da explicabilidade na contorna industrial [7].

Por tanto, precisamos algoritmos de explicabilidade que sexan de aplicación ou ben xeral ou ben cara os modelos usados agora (e.g. C.N.N., ViT ...), que exploten o modelo como un todo (non como LIME) dun xeito transparente (non como os métodos CAM) e idealmente que

nos permitan manipular conceptos semánticos máis finos sempre co fin de entender e correxir o modelo no caso de erro.

1.3 Aprendizaxe Profundo

Posto que o eido do traballo basease en varios principios técnicos desta corrente do A.A., farase agora unha explicación dalgúns conceptos relativos ó A.P. que serán de utilidade máis tarde.

1.3.1 Orixes liñeais

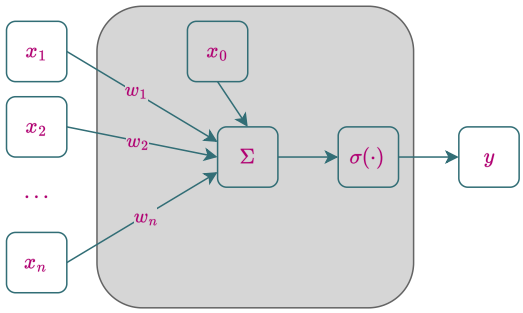

Figura 1.4: Modelo de neurona. As entradas $\{x_1, x_1, \ldots, x_n\}$ sufren unha combinación afín (isto é: $x_0 + \sum_{1=i}^{n} x_i w_i$) para posteriormente aplicarse unha función non lineal $\sigma(\cdot)$. Os números ou 'parámetros' $\{x_0, w_1, w_2, \ldots, w_n\}$ adoitan aprenderse mediante algún proceso mentras que a función $\sigma(\cdot)$ adoita ser fixa. Figura de autoría propia.

A correcte neuronal, que na actualidade manifféstase a traveso do A.P. a pesares de ter unha historia de máis de 70 anos, conservou o mesmo marco para entender os procesos máis elementais, a saber a *neurona*. Nos inicios (e aínda hoxe en ocasións) o modelo neuronal póde expresar como unha combinación afín das entradas ó que se lle aplica unha función no lineal $\sigma(\cdot)$, como pode verse na Figura 1.4. Estas neuronas (no seu momento chamadas 'perceptróns'), sobre a década dos 70 emperazon a superpoñerse ó largo e acho para formar os Perceptrón Multicapa (Multi-Layer Percetron) (M.L.P.), isto é sobre cada conxunto de entradas aplicábanse *varias neuronas distintas*, digamos m, prodicindo así as salidas $\{y_1, y_2, \ldots, y_m\}$ e sobre estas repetíase o proceso. Chegando a acadar aprendizaxe de funcións complexas con compoñentes elementais tan sinxelas como a neurona.

Os M.L.P. na actualidade son unha compoñente crucial de moitos sistemas de Intelixencia Artificial, e en particular da Atención (ver Sección 1.3.5) que ten un rol indiscutible nos grandes sistemas de Intelixencia Artificial de hoxe como os grandes modelos da linguaxe como ChatGPT. Intuitivamente, o funcionamento dos M.L.P. pode interpretarse como emparellamento de patróns onde unha neurona ou varias teñen un patrón asociado ou como proxec-

cións en espacios de xeito que a relación funcional complicada a estimar f, a traveso das capas vaise 'linealizando' para que a derradeira capa (composta por neuronas) sexa quen de separar o as entradas do xeito desexado.

1.3.2 Dispersión

Unha idea común na corriente neuronal da Intelixencia Artificial e do entendemento do cerebro humano e a 'dispersión', isto é: non todas as compoñentes (neuronas) teñen que activarse á vez. Es máis segundo o traballo fundacional de Barlow do 72 no campo da neurociencia [8], o número de neuronas activas debería ser o mínimo. En efecto agora sabemos que na primeira area cortical do cortex visual humano (V1) a activación de neuronas é moi dispersa no sentido de que algunhas poucas dispáranse intensamente e outras moitas non se disparan. Así a Intelixencia Artificial inspirouse deste principio de forma explicita e implícita.

No modelo neuronal C.N.N. (moi exitoso no campo de análise de imaxe), por deseño a maioría das conexións w_i da Figura 1.4 serían sempre 0, é dicir a arquitectura C.N.N. é por deseño dispersa. Por outra banda técnicas como a Codificación dispersa [9, 10] parten dunha Rede non dispersa e pero buscan explicitamente chegar a un certo nivel de dispersión. O *Dropout* [11] pola súa banda introduce dispersión arbitraria no adestramento da Rede ca premisa de que acelerará devandito proceso. Un exemplo detellado de representación dispersa pode atoparse na apartado 1.4.1 da Sección xeral sobre representacións.

1.3.3 Compresión

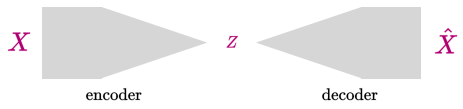

Figura 1.5: Arquitectura *Encoder-Decoder*. As entradas X comprímense no encoder ate chegar a unha representación Z de menor dimensión, esta é quen de reconstruir polo menos de xeito aproximado a X. Figura de autoría propia.

Se un sistema neuronal (natural ou artificial) é disperso e funciona correctamente, significa que as poucas neuronas que se activan representan de boa maneira a entrada do sistema. Esa propiedade de 'representar moito con pouco' non é exclusiva da dispersión e no eido da A.P. tamén pode chegarse grazas á comprensión ou cambio de base. Isto é, pasar da representación do espazo orixinal unha máis axeitada para os propósitos de regresión, clasificación, ...

Técnicas tradicionais de compresión comprenden as transformadas de Fourier e Karhunen–Loève (tamén coñecida como PCA) onde as bases do espazo dependen dun xeito lineal, coñecido e estudado das entradas. Na actualidade, no A.P. tamén úsanse os Autoencoders que como se mostra na Figura 1.5 comprenden de dúas partes que reducen as entradas X a unha

nova representación Z e a volven a aumentar cara o espazo orixinal (ou outro tamén grande) $\hat{X}$. Eixindo unha relación á parella X e $\hat{X}$, por exemplo que sexan iguais, pódense obter boas representacións *comprimidas* en Z.

1.3.4 O rol da capa

Nos modelos de A.P. vistos (M.L.P., C.N.N. e Autoencoders), o comportamento compréndense polo xeral ó nivel da R.N.A. como un todo, pero pode chegar a ser difícil interpretar o rol de cada capa individual que a compone. Enteder o rol das capas pode ser interesante por sí só ou mesmo pode ser un mécanismo para crear e mellorar modelos de A.P.. Así un tipo de C.N.N. que converteuse no éstandar dentro desta familia, o ResNet [12] dota pola construcción do modelo un rol a cada capa. Así, como este rol resultou ser útil, xeral é doado de adestrar a ResNet chegou a ter moito éxito. En xeral unha rama da A.P. chamada Aprendizaxe Desenrolada (A.D.) estuda a construcción de redes nas que o rol de cada capa é complexo e predefinido, constando duns parámetros aprendibles que o traveso do adestramento determinarán o comportamento final das Redes. As Redes desenvoltas neste traballo adscríbense a este marco.

1.3.5 A Atención

1.3.6 Discusión

[NOTA: —]

1.3.7 ISTA

[NOTA: ser é correcto o que digo pero paréme irrelevante. o que é relevante do ISTA é dicir que é unha implementación de aprendizaxe de diccionarios, que parécese a un MLP e que funciona baixo o principio de Unroll learning. todo isto é interesante dicilo poruque logo o ISTA vai ser o MLP de crate.]

Un algoritmo clásico do A.A. é a Regresión Lineal, co que Carl F. Gauss empezou a teorizar e ofrecer garantías sobre o seu modelo

$$X\beta = Y + \epsilon$$

onde $\epsilon \sim \mathcal{N}(\mu, \sigma^2)$ nos albores do século XIX, chegando á coñecida forma cerrada

$$\hat{\beta} = (X^{'}X)^{-1}X^{'}Y.$$

A primeira regularización do modelo para facelo máis robusto chegou con ideas orixais no campo de resolución de problemas mal planteados, Andrey Tikhonov introduce a penaliza-

ción segundo a norma $\mathcal{L}_2$ dos parámetros β, o cal é equivalente a asumir unha distribución Gausiana en β. O estimador ten a forma cerrada

$$\hat{\beta} = (X^{'}X + \lambda I)^{-1}X^{'}Y,$$

onde λ controla a estructura do conxunto de funcións [13]. Se ben esta regularización segue a usarse hoxe en día porque devandita asunción pode ser moi natural, dende o 1996 considérase o Lasso [14], que penaliza a norma $\mathcal{L}_1$ (equivalente a asumir unha distribución Laplaciana nos parámetros) e sen ter forma cerrada ofrece un estimador con ceros, é dicir o proceso de optimización de Lasso supón unha selección de características. En particular, o problema a resolver adoita ser:

$$\min_{\beta} ||X\beta - Y||_2^2 + ||\beta||_1. \tag{1}$$

Como en moitos problemas de optimización de interese científico e comercial a resolución deste problema convexo por medio de métodos de punto interior pode ser infactible [15], o algoritmo Ista atopa unha solución ó Lasso a través da iteración de descenso do gradiente da parte da esquerda da expresión 1 e proxección á bola $\mathcal{L}_1$ (ver Figura 1.6) para levar a cabo a penalización da parte dereita, en concreto:

$$\beta_{t+1} = \sigma_\epsilon(\beta_t - \lambda X^{'}(X\beta - Y)),$$

onde λ é un hiperparámatro que controla o axuste e σ_ϵ é a función de umbral suave (ver figura 1.7). É esta función, en compañía do termo illado de β_t os que levan a cabo a proxección á bola $\mathcal{L}_1$.

1.3.8 ViT

A arquitectura ViT (do inglés *Vision in Transformer*)[16] é unha instanciación do xa coñecido Transformer [17] aplicado á vision. No seu dominio orixinal, o procesamento da linguaxe natural, o Transformer demostrou moi bo rendemento, xogando un papel moi importante na burbulla económica da IA que estamos a vivir. En particular o ViT demostrou que a convolución, a compoñente fundamental das C.N.N. xa non era necesaria[1] marcando así un hito na historia do A.P.. Na Figura 1.8 ilústrase a arquitectura a nivel conceptual para un problema de clasificación.

1.3.9 Aprendizaxe desenrolado

[NOTA: recurso : [19], acronimo: Aprendizaxe Desenrolada (A.D.). esencialmente: cada capa modela Z^l co seu modelo correspondente (conxunto de bases).

[1] Cando menos para clasificación de imaxe de dominio xeral[18]

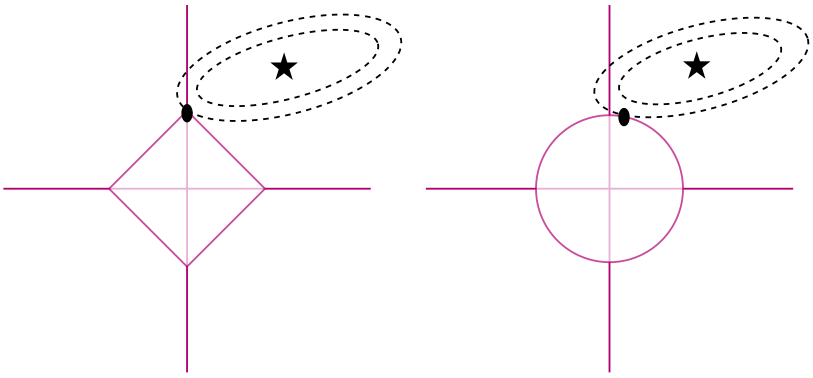

Figura 1.6: Proxeción ás bolas a) $\mathcal{L}_1$ correspondente ca penalización Lasso, e b) $\mathcal{L}_2$ correspondente ca penalización Tikhonov. As curvas de nivel denotan a función de error (cuadrática) de mínimos cuadrados, onde $\star$ denota o mínimo error e $\bullet$ a proxección deste na respectiva bola. Nótese que tanto neste caso dibuxado artificialmente como na práctica, observase unha tendencia a que a proxección coincida nun ou varios eixos, isto é, que $\beta_i = 0$ para algúns i. Figura de autoría propia.

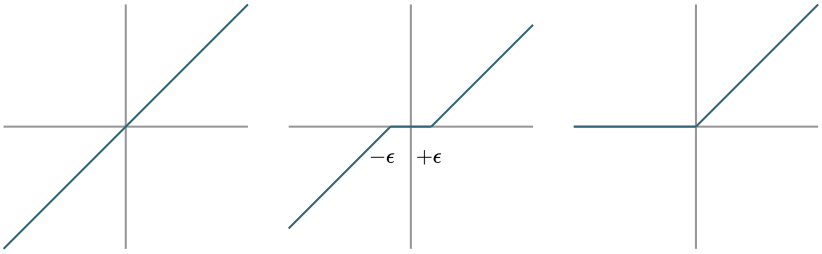

Figura 1.7: Funcións de activación usadas no traballo. (*esquerda*) Función identidade (*centro*) Función de umbral suave $\sigma_\epsilon(\cdot)$, parametrizada por ϵ (*dereita*) Función ReLU, nótese que a función $\sigma_\epsilon(x)$ é indentica (no dominio $\mathbb{R}^+$) a ReLU$(x - \epsilon)$. Figura de autoría propia.

conseguindo, a través delas o obxectivo global. esta seccion é para introducir o crate, cousas que saianse deso sobran]

1.4 Representacións

1.4.1 Aprendizaxe de diccionarios

O aprendizaxe de diccionarios é o problema de representar o vector $X \in \mathbb{R}^n$, como unha combinación $\beta \in \mathbb{R}^d$ de *palabras dun diccionario* $D \in \mathbb{R}^{n,d}$ de forma que preténdese minimizar

$$\|X - D\beta\|_p$$

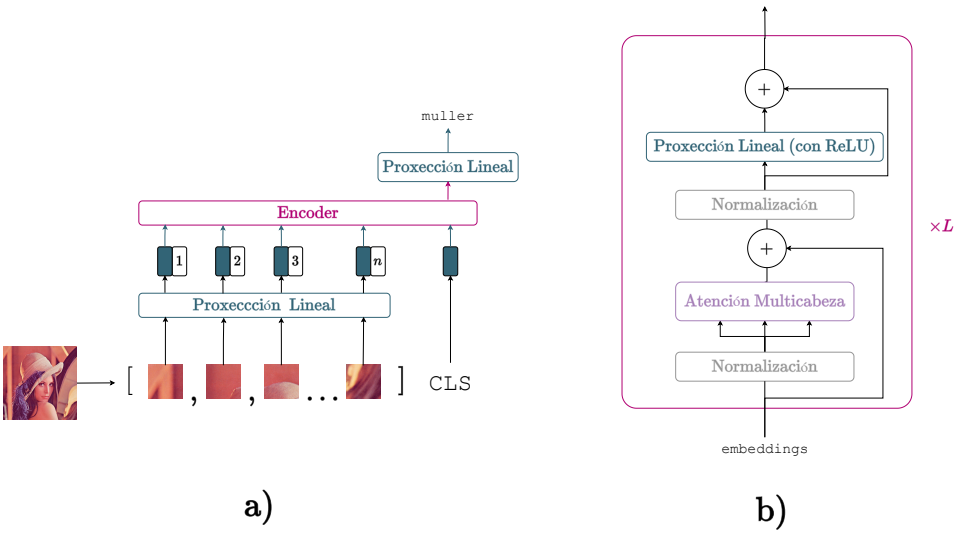

Figura 1.8: Arquitectura do ViT [16]. a) Para ser procesadas, as imaxes son recortadas en parches. Estes son proxectados ó espacio de `embeddings` e concatenados cun vector posicional (representado na Figura como un núnmero) antes de entrar no Encoder. Xunto cos parches tamén é entrada do Encoder un vector aprendible asociado á `clase`. b) O encoder consta de dos grandes bloques residuais precedidos de normalización, o primeiro é a Atención Multicabeza [17] e o segundo un M.L.P.. Figura de autoría propia.

para algún p. Este problema correspóndese cun cambio de base (e.g. Transformada de Fourier, PCA ...) no que pasamos da representación orixinal (valores RGB dos píxeles no caso das imaxes) a unha máis interesante ou representativa. Sobre este problema adoitanse engadir restriccións adicionais, por exemplo que as columnas de D sexan ortonormais, isto é $D^{'}D = I$, e ten a implicación de que as *palabras* do *diccionario* sexan incoherentes entre sí (pola natureza dos respectivos problemas, tanto a Transformada de Fourier como PCA teñen esta propiedade). Outra restricción é penalizar o número de *palabras* cas que un pode expresarse é dicir $\|\beta\|_0$, de xeito que este novo problema sería:

$$\min \|X - D\beta\|_p + \|\beta\|_0$$

para algún p. A esta formulación coñécese como Aprendizaxe de Diccionarios Dispersa, e ten moitas propiedades interesantes [10], por exemplo a *decorrupción* de imaxes (ver Figura 1.9).

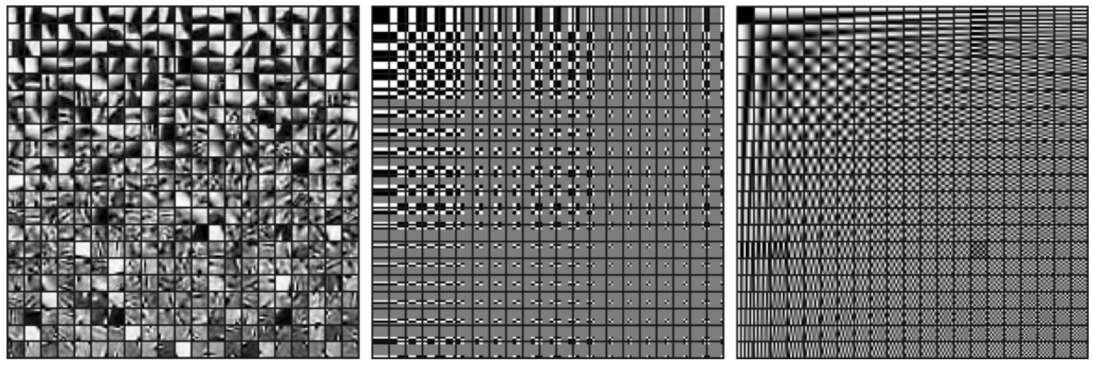

(a)

(b)

Figura 1.9: Exemplo de *decorrupción* con Aprendizaxe de Diccionarios. (a) Móstranse tres dicionarios, o primeiro adestrado segundo o algoritmo KSV e un conxunto de datos de caras, o segundo e o terceiro son bases de Haar e da Transformada de coseno discreta, respectivamente. (b) Unha imaxe con ruído, e o resultado de reexpresar devandita imaxe como unha combinación de palabras dos tres anteriores dicionarios. Obsérvase que o mellor resultado acádase co diccionario aprendido. Figuras extraídas de [9].

1.4.2 MCR^2

1.5 Redes Caixa Branca

1.5.1 Motivación

1.5.2 MCR^2 e ReduNet - Redes Caixa Blanca

[NOTA: darlle unha volta a esta sección, o tema e presentar o obxectivo MCR^2 disperso para motivar a crate e as nosas derivacións e xa]

[NOTA: referenciar á Figura 1.10]

Na primeira metade da pasada década viuse o esplendor dun tipo de R.N.A. nas que o operador principal é a convolución dun filtro ou *kernel* aprendible coa imaxe (ou ca saída doutra convolución), estas Redes chámanse Rede de Neuronas Artificiais Convolucionais (*Convolutional Neural Network*) (C.N.N.). Se ben son algo explicables [20, 21], a pregunta 'Que esta a facer esta compoñente da C.N.N.?' en xeral só pode responderse *a posteriori*. Isto motivou ó grupo do profesor Yi Ma o desenvolvemento dunha C.N.N. como instancia do MCR^2 [22], creando así unha Rede Caixa Blanca **[NOTA: acronimo? mellor en inglés?]**.

A Maximal Coding Rate Reduction (MCR^2) Dispersa é unha función obxectivo de A.R. que intenta cumplir cos seguintes obxectivos na representación no espacio de características:

[NOTA: estas tres características sacoas de o artigo de CRATE pero quito a de 'consistent' porque penso que non ven ó caso, no libro de 2022 fala doutras tres características, pero estas parécenme máis entendibles]

- *Comprimidas:* sendo uniformemente distribuídas segundo algunhas estruturas de baixa dimensión[2] estándar que se axustan á baixa dimensionalidade intrínseca dos datos, co fin de asegurar unha codificación compacta dos datos.
- *Lineais:* as estruturas de baixa dimensión teñen unha xeometría (a anacos) lineal, co fin de facilitar a interpolación e a extrapolación no espazo de representación.
- *Dispersas:* as estruturas de baixa dimensión correspondentes a diferentes partes da distribución dos datos son estatísticamente incoherentes ou xeometricamente ortogonais, e tamén aliñadas cos eixes, co fin de asegurar unha codificación máis compacta e facilitar o procesamento posterior.

Formalmente defínese como a maximización da seguinte función:

$$\Delta R(Z|U_{[K]}) = R(Z) - R^c(Z|U_{[K]})$$

[2] Como unhas gausianas

onde

$$R(Z) \doteq \frac{1}{2}\text{logdet}(I + \beta Z^{'} Z)$$

e

$$R^{c}(Z|U) \doteq \sum_{k} R(U_{k}^{'} Z)$$

(aquí β é unha constante cuxa presencia é necesaria para o desenvolvemento do traballo, pero unha xustificación da mesma esta, non obstante fora de lugar.)

[NOTA: —]

en [23] dicen que as redes (Transformadores) caixas brancas son as que diséñanse '*con a estuctura dos datos de entrada en mente, representando un maridaxe entre a aproximación clásica a A.R. e o novo A.P.*'

1.6 CRATE

Unha alternativa a ViT onde cada capa é interpretable, é dicir compréndense de anteman que ocurre tanto na *Atención Multicabeza* como na *Proxeción Lineal* (ver Sección 1.3.8). Para presentar axeitadamente o modelo CRATE, a exposición terá en conta dous puntos de vista de interese cuxa equivalencia non é trivial: os cambios que CRATE supón frente ó Vit a nivel arquitectural, na Sección 1.6.1 e os principios teóricos que levaron á súa concepción, na Sección 1.6.2.

1.6.1 Diferenzas arquitecturais entre CRATE e ViT

Segundo a arquitectura do ViT exposta esquemáticamente na Figura 1.8, a concepción global do mesmo dispoñible na subfigura (a) é idéntica. Os cambios residen nos compoñentes de *Atención Multicabeza* e *Proxeción Lineal*, visibles na subfigura (b). En particular as diferencias son:

- **Atención Multicabeza:** a nivel conceptual diféréncianse en que en CRATE cada cabeza ten un espacio vectorial asociado sobre o cal proxecta, mentres que o ViT leva a cabo a Atención a traveso de multiples espacios. É dicir, mentras que no ViT a Atención **dunha** cabeza (da capa ℓ) sobre a entrada Z^{ℓ} é:

  $$\text{Atención}_{\texttt{ViT}}(Z^{\ell}|U_Q, U_K, U_V) = \text{Softmax}((U_Q^{'} Z^{\ell})(U_K^{'} Z^{\ell})^{'}/\sqrt{d})U_V^{'} Z^{\ell},$$

  onde d é a dimensión das cabezas, mentras que no modelo CRATE é:

  $$\text{Atención}_{\texttt{Crate}}(Z^{\ell}|U) = \text{Softmax}((U^{'} Z^{\ell})(U^{'} Z^{\ell})^{'}/\sqrt{d})U^{'} Z^{\ell}.$$

En ambos casos as atencións das distintas cabezas amalgámanse do mesmo xeito:

$$\text{Atención Multicabeza}(Z^\ell|U_{[K]}) = [\text{Atención}_1(Z^\ell)|U_1]), \ldots, \text{Atención}_K(Z^\ell)|U_k])W,$$

onde U_i é a parametrización correspondente á cabeza i e W un novo tensor adicado á mistura de cabezas.

- **Proxección Lineal:** se ben ambos teñen proxeccións lineais sucedidas dunha función de activación non lineal σ (ReLU, polo xeral, ver Figura 1.7), que no caso do ViT lévase a cabo por un M.L.P. de dúas capas e no caso do CRATE por unha iteración de ISTA (ver Sección 1.3.7), a diferencia filosófica é profunda. O ViT espera que o M.L.P. unha vez adestrado 'filtre' do fluxo da Rede o que non vale, ou reorganize a entrada doblando o espazo dun xeito máis ou menos simple [24, 25], o ISTA ten un comportamento predefinido, coñecido e esperable, en particular: "transformar Z^ℓ para que sea unha codificación dispersa de $Z^{\ell+1}$" (ver siguiente Sección para máis detalles). En particular as opcións son:

$$\text{Proxección Lineal}_{\texttt{ViT}}(Z^\ell|D_1, D_2) = \sigma(D_2\sigma(D_1 Z^\ell))$$

e

$$\text{Proxección Lineal}_{\texttt{Crate}}(Z^\ell|D) = \sigma(Z^\ell - \eta D^{'}(DZ - Z) - \eta\lambda\mathbf{1})$$

onde η e λ son hiperparámatros (ver [26] para máis detalles) e $\mathbf{1}$ é unha matriz de todo unos (o lector atento recoñecerá $\sigma(\cdot - \lambda\mathbf{1})$ como $\sigma_\lambda(\cdot)$, ver Figura 1.7). **[NOTA: o lector debería entender esta sección con axuda da sección en ISTA]**

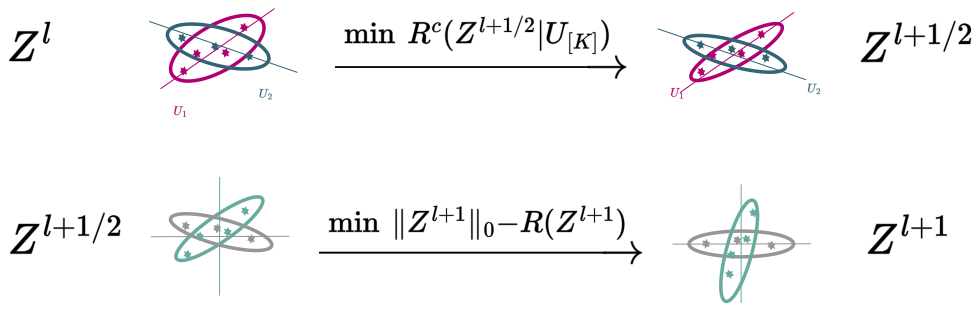

Figura 1.10: Iteración dos pasos do MCR^2. O primeiro paso *comprime* o espacio segundo modelos locais de gausiana parametrizados por $U_i \in U_{[K]}$. Isto é: asigna cada token a un espacio (En realidade a asignación é suave no sentido de que cada token exprésase como $z_i = \alpha_i U_{[K]}$, onde $\alpha_{i,j}$ é a influencia do espazo U_j no token z_i.) e reduce o volumen que ocupan os tokens de cada espacio. O segundo paso realiza dúas accións simultaneamente: expande o volumen que ocupan todos os tokens (de todos os espacios) e rota os exes de xeito que coincidan cas coordenadas, facendo así unha representación dispersa. Figura de autoría propia.

1.6.2 Principios teóricos [NOTA: ou 'Relación con conceptos da teoría']

O deseño de CRATE, non obstante, preséntase con moita xustificación, é dicir, as súas diferencias co ViT teñen unha razón de ser; e se experimentalmente outros autores chegaron a ViTs con semellanzas a CRATE, este avala ca teoría as decisións. Todo comeza co obxectivo de estructurar "ben" os datos, para así poder realizar con facilidade tarefas diversas de A.A.. Ese "ben" e segundo os obxectivos definidos na Sección 1.5.2 que instancianse na formulación mátematica do Maximal Coding Rate Reduction (MCR^2) Disperso. E dicir, segundo os autores, se os datos siguen unha estructura que respete esas funcións obxectivo, todo será doado.

Logo, Cómo unha R.N.A. pode acadar tal cousa? A resposta é sinxela: capa a capa. É dicir, conseguirase o obxectivo de MCR^2 Disperso a traveso dunha secuencia (finita) de pasos, cada un deles será unha capa da Rede. Estamos polo tanto a falar dun caso de Aprendizaxe Desenrolada (A.D.) no que (neste caso como queremos construir un Transformer) os to-

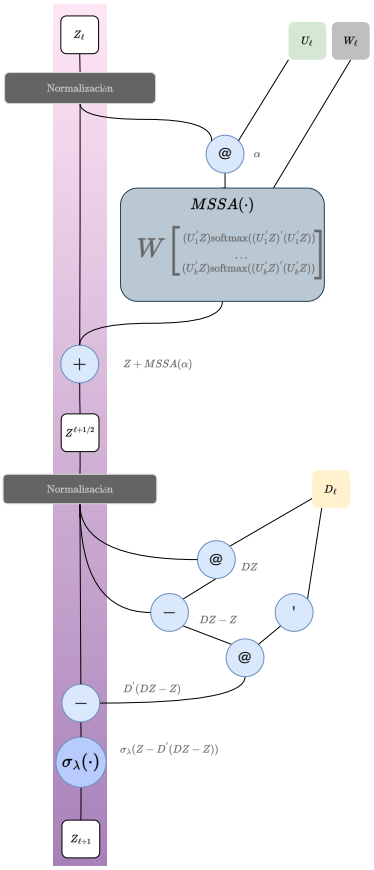

Figura 1.11: Esquema da arquitectura de CRATE. Figura de autoría propia.

kens Z^ℓ arrexúntanse cara os K espacios condicionados por $U_{[K]}$ para dar $Z^{\ell+1/2}$ e estos a súa vez expándense e aliñanse cos eixos para finalmente dar $Z^{\ell+1}$. E así transfórmanse os tokens de entrada nos de saída. A sucesión de dous pasos (de ℓ a $\ell+1/2$ a $\ell+1$, en cal de ℓ a $\ell+1$) fundaméntase no seguinte: como temos dous desexos (a saber: Reducir o Coding Rate e Maximizar a Dispersión), será mellor (máis fácil de deseñar, implementar e interpretar) se temos unha capa para cada cousa en cal de unha capa que leve a cabo dúas tarefas.

En particular a instanción en operadores das subtarefas (visibles na Figura 1.10) resulta en:

- Para Reducir o Coding Rate, ou *arrexuntar os tokens entre sí se son do mesmo espazo e separalos no caso contrario* optouse polo operador MSSA [26], semellante á Atención Multicabeza dos ViT [16] pero só usando un espazo vectorial por cabeza (cada cabeza está subordinada a un concepto).

- Para Maximizar a Dispersión, ou *expandir os tokens e aliñalos cos eixos*, optouse polo operador ISTA, que vai levar a cabo unha optimización de Aprendizaxe de Diccionarios a traveso da Rede, onde cada iteración é unha capa [15, 26, 27] (ver Sección 1.3.7).

Finalmente a Rede resultante pódese apreciar no diagrama de fluxo da Figura 1.11 onde obsérvase unha Multiatención que reutiliza o espacio e un M.L.P. que implementa o ISTA. Esta Rede, aunque moi semellante ós ViT xa que no plano de condicións e técnicas de adestramento e igual (*backpropagation* con *Cross Entropy*) as pequenas e xustificadas diferencias arquitecturais presentan boas propiedades. Como as Cabezas fan uso dun único espazo, que son ortogonais entre sí (ver [26]) e a representación Z^ℓ fórzase a ser máis dispersa cas capas, temos unha Rede que nas capas finais acadou unha calidade de representación dos tokens tan xeitosa que como consecuencia natural do deseño, os Mapas de Atención (ver Sección 3.3) posúen segmentación emergente. Isto é, as cabezas asignaranse a elas mesmas "conceptos" independientes para a discriminación de clase.

[NOTA: explicar máis, pero só o necesario.]

[NOTA: polo menos hai que facela conexión entre o obxectivo de maximización e a arquitectura. tamen hai que facer paralelismo co vit clásico (o mssa é o mhsa, o ista é o mlp . . .). tamén tense que presentar as formulas que logo vanse usar na seccion 3.2.1. quizais algún diagrama? igual cun recorte do diagrama 3.1 e engadirlle o mlp/ista chega?. falando do MCR2 e Sparsity hai que dicir, "como verase na seccion 3.3, istos principios suporan propiedades emerxentes como a asignación sematica ás cabezas de atencion". ainda que xa faramos dos vit hai que facer explicito o uso to token cls no crate porque logo vaise usar enton non pode aparecer da nada, ou que o lector teña que deducir que simplemente iportase do vit.]

1.7 Obxectivos e contribucións

1.7.1 Elementos diferenciais

Os modelos de tipo C.N.N. ou ViT son hoxe a base da visión por computadora pero a súa explicabilidade adoita ser *a posteriori*, como os métodos de visualización CAM (ver Sección 1.2) ou necesitar un proceso de adestramento sofisticado e non plenamente xustificado como DINO [28]. Nese senso, CRATE [26] é distinto, grazas a que cada compoñente derívase dun obxectivo teórico (o MCR^2 disperso) é inherentemente interpretable e además o deseño deriva en propiedades de explicabilidade naturais como as visualizacións de mapas de atención semánticas. Pola contra, devaditas propiedades evidenciáronse para contextos xerais como as imaxes naturais de Imagenet. Baixo o noso coñecemento, CRATE non se aplicou a imaxe de retina en particular ou imaxen médica en xeral.

1.7.2 Oportunidades

A imaxe médica é un ámbito onde as saídas do modelo precisan de xustificación, ben sexa para a confianza do profesional, que ten que entender que o modelo tomou unha decisión ou ben pola obriga legal de transparencia sobre sistemas críticos que establece a normativa europea do AI ACT [3]. Unha arquitectura interpretable e explicable por construcción ofrece unha vía distinta ás explicacións a posteriori. Logo, a oportunidade é estudar se na tarefa de diagnose de patoloxías sobre imaxes de fondo de retina as propiedades de CRATE mantéñense e poden convertirse en explicacións útiles; en particular na toma de decisións (con mapas de atención) ou nas representacións internas (cas 'palabras' do diccionario).

1.7.3 Contribucións

O obxectivo xeral deste traballo é estudar e ampliar a interpretabilidade e explicabilidade de CRATE, e avaliala sobre imaxe médica. En concreto, as achegas son:

- Unha variante de segundo orde da atención de CRATE, derivada dunha aproximación máis fina dun termo do seu deseño (Sección 3.2).
- O cruce de arquitecturas: adestrar cunha ordenación e inferir coa outra. Probouse que non funciona, e ese resultado negativo axuda a entender o papel das cabezas (Sección 3.2.3).
- Variantes que comparten U e D, motivadas polo principio de A.D., e as súas combinacións ca variante de segundo orde. (Sección 3.5)

- Extensións das técnicas de explicabilidade: visualización de mapas de atención (incluíndo a de segundo orde e a resolución por píxel) e recuperación de parches representativos para interpretar as dimensións.
- Un estudo experimental en ImageNet, DRIVE e RFMiD, que inclúe, baixo o noso coñecemento, a primeira aplicación de CRATE a imaxe de fondo de retina. Co fin doble de avaliar as nosas achegas fronte ó modelo orixinal e avaliar ambos no contexto clínico.

1.8 Organización da memoria

O resto da memoria organízase como segue. O Capítulo 2 describe a metodoloxía e os recursos; o Capítulo 3 presenta as propostas teóricas e as preguntas que guían o estudo; o Capítulo 4 recolle a experimentación; e o Capítulo 5 responde ás preguntas e discute as limitacións e o traballo futuro. Adicionalmente o Apéndice A repasa brevemente conceptos básicos de optimización.

Capítulo 2

Metodoloxía e planificación

O que queira peixes que molle o cu [29]

Neste capítulo descríbese cómo se traballou así como os recursos involucrados e a planificación do traballo.

2.1 Método de traballo

Dada a natureza exploratoria do proxecto, adoptouse un modelo de desenvolvemento iterativo e incremental. Este enfoque permite introducir novos avances de xeito progresivo en cada iteración, mediante o desenvolvemento e avaliación das achegas de cada incremento para o avance do proxecto. Isto permite reaccionar axiña mediante a planificación progresiva de novas funcionalidades e experimentacións adicionais, axustadas a cada estadio no desenvolvemento e resultados da investigación.

Os primeiros esforzos adicaronse á compresión do material. Unha vez a compresión foi sufiente para empezar as iteracións semanais, estas avanzaron de xeito controlado a traveso de reunións. Estas seguen o esquema representado na Figura 2.1, de xeito que en función dos resultados parciais priorízase o foco do seguinte incremento. O traballo individual do alumno ó longo das semanas comprendía:

- **Programación:** de experimentos (isto é: adestramento de R.N.A.) e de visualizacións para poder analizar distintos aspectos das Redes adestradas.
- **Análise de resultados:** para interpretar as visualizacións e formular afirmacións ou preguntas dependendo do entendemento. En ambos casos era moi útil porque se formulaba unha afirmación, ó presentarlla ós titores ou ben comprendía porque tiña razón ou porque non a tiña; e se formulaba unha pregunta aprendía da súa resposta.
- **Lectura bibliográfica:** de temas que non plantexáronse ó principio pero foron importantes para respostar ás preguntas que xurdían e en xeral comprender profundamente

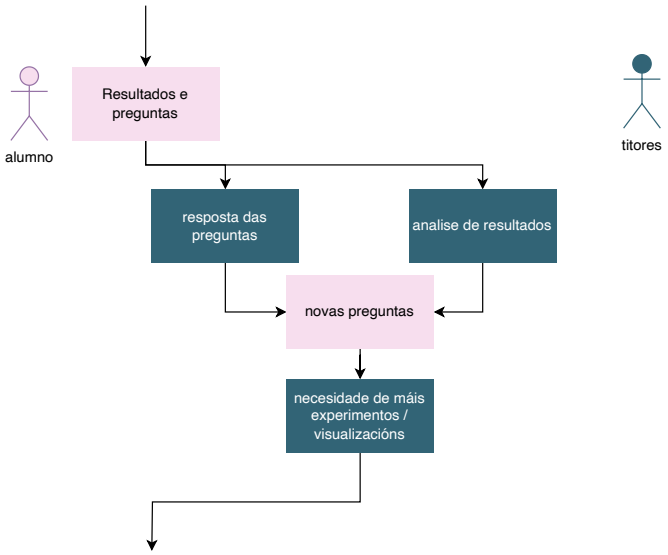

Figura 2.1: Esquema do contido das reunións semanais entre o alumno e os titores. Figura de autoría propia.

o tema a tratar, segundo íase presentando de forma distinta ó longo das semanas.

2.2 Recursos

2.2.1 Humanos

Este traballo foi supervisado por tres tutores [1] que tiveron o rol directivo en canto ás ideas, respostaron a pregunta 'Qué se fai?' e en canto o método, 'Cómo se fai?'. O alumno tivo de entrada un natural papel subordinado é dicir, leu e programou o que se lle mandou. Co paso das semanas, o coñecemento e intuición que desenvolveu o alumno sobre o tema permitiulle do mesmo modo propoñer ideas e métodos, dotando ós tutores dun rol máis alto nivel.

A primeira achega dos tutores foi o punteiro á bibliografía e código necesarios para a compresión do tema. Devandita tarefa mantivo ocupado ó alumno en soidade os primeiros meses e cando este acadou un nivel de compresión sufiente comenzaron as reunións semanais.

2.2.2 De *Software*

A continuación listanse os recursos *Software* empregados no traballo con importancia descendente. Nótese que todo o *Software* é código aberto e nalgúns casos código libre.

- **Python:** [2] a linguaxe por defecto para escribir os programas do traballo. Funcional-

[1] Un dos cales mudou de universidade durante o traballo e por tanto non figura na portada.
[2] Licenza da "Python Software Foundation", Versión 2 (PSF-2.0)

mente é conector das librerías mencionadas xa que se ben por si só Python non é tan útil para a práctica de A.P., funciona como un fabuloso pegamento.

- **PyTorch:** [3] a libraría por defecto de A.P. hoxe en día que permitiunos facer modificacións, inspeccións e adestramentos sobre a R.N.A., o cal corresponde co *grosso* do traballo.
- **einops:** [4] é un paquete adicado á manipulación axil a nivel de código de tensores. Como a disciplina de A.P. esencialmente baséase neso, o paquete axilizou o desenvolvemento á vez que fixo o código máis lexible é fácil de manter ou asegurar a súa correctitude.
- **draw.io (diagrams.net):** [5] a éxpresión gráfica é moi importante á hora de comunicar conceptos complexos, polo que nos informes semanais e no presente documento os esquemas e diagramas realizáronse con este conveniente programa de escritorio.
- **Matplotlib:** [6] a libraría por defecto para as gráficas e figuras xeradas de xeito programático con Python.
- **NumPy:** [3] é a libraría que da soporte ós tipos de dato de Matplotlib polo que fai de punto en común entre o código experimental desenvolto en PyTorch / einops e o código de figuras desenvolto en Matplotlib.
- **Scikit-Learn:** [3] é unha libraría que da soporte a algoritmos de A.A. e funcións de avaliación.
- **Bash:** [7] cando o programa (ou *script*) ía ser sufientemente pequeno, o alumno considerou á linguaxe Bash moito máis elegante e apropiada. Notar que estrictamente estrictamente non fixo falta sair de Python e por tanto a decisión ten unha compoñente de gusto persoal.
- **rsync:** [7] para ambos sentidos da sincronización retratada na Figura 2.4 foi de gran utilidade este programa GNU.
- **Vim:** [8] para a edición de arquivos de texto. En particular, a codificación de programas, a escritura da memoria ou a esporádica modificación dalgún arquivo de configuración.

[3] Licenza BSD 3-Clause
[4] Licenza MIT
[5] Licenza Apache 2.0
[6] Licenza Matplotlib (licenza similar á BSD baseada na PSF)
[7] GNU General Public License Versión 3 (GPL-3.0-or-later)
[8] Licenza Vim

- **tmux:** [9] é un multiplexor de terminais, é dicir permite acceder a múltiples sesións de terminal simultaneamente nunha única xanela. É útil para executar máis dun programa de liña de comandos ó mesmo, en particular, Vim para a edición de aquivos e Python para a execución dos mesmos.
- **latexmk:** [10] para a compilación da memoria, segundo as recomendacións do equipo de desenvolvemento da plantilla da memoria da FIC [30].

Merécese unha mención o mapa de cor `pink` (ver Figura 2.2) do paquete Matplotlib que foi usado nas visualizacións de atención (ver Sección 3.3) polo seu gran rango de luminosidade (L^*) [31] e o seu parecido co rosa institucional da UDC.

Figura 2.2: Mapa de cor Pink. Figura extraída de [31].

2.2.3 De *Datos*

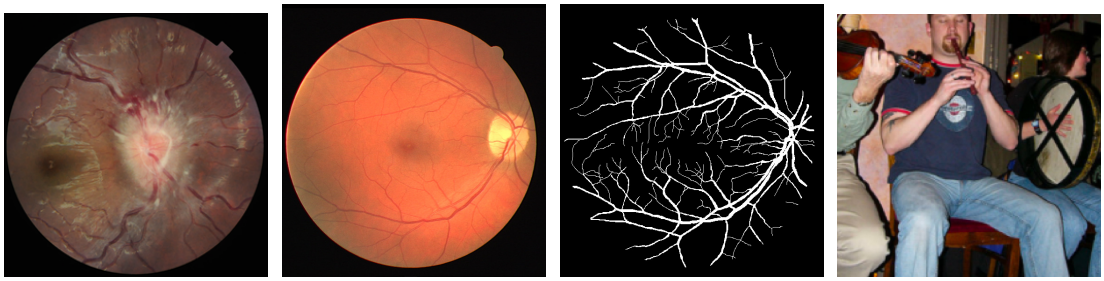

(a) (b) (c) (d)

Figura 2.3: Mostras dos conxuntos de datos. (a) Imaxe de fondo de retina con edema de disco óptico, pertencente ó conxunto de datos RFMiD. (b-c) Imaxe de fondo de retina e a súa correspondente máscara binaria anotada, pertencentes ó conxunto de datos DRIVE (d) Imaxe de mostra do conxunto de datos ImageNet

- **RFMiD 2.0 (2023).** [32] Recolle mostras de enfermidades raras con imaxes de alta resolución. Además de a etiqueta 'san', inclue 48 condicións entre as que se atopan as patoloxías vasculares (e.g. oclusións de veas e arterias, retinopatía hipertensiva, retinopatía hemorráxica, vasos tortuosos ...), diabéticas (e.g. retinopatía diabética, edema macular, manchas algodonosas, microaneurismas ...), dexenerativas ou relacionadas ca

[9] Licenza ISC
[10] GNU General Public License Versión 2 ou posterior (GPL-2.0-or-later)

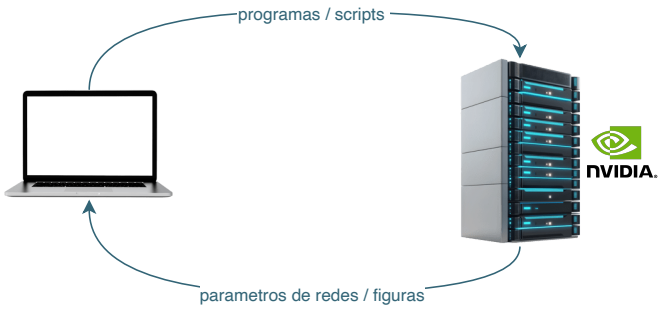

Figura 2.4: As comunicacións entre o portatil do alumno e o servidor seguen un bucle de sicronización. Figura de autoría propia.

idade (e.g. dexeneración macular asociada ca idade, drusas, retinite pigmentaria, miopía ...), trastornos do nervio óptico (e.g. escavación do nervio óptico, edema do disco óptico, palidez do disco óptico, hialose asteroide ...), alteracións estructurais da retina (e.g. desprazamento da retina, burato retiniano, rotura retiniana ...), congénitas (e.g. coloboma, pregamentos coroideos, hipertensión intracranial idiopática ...) ...Polo que é de gran utilidade para o diagnóstico e caracterización destas patoloxías dado o seu nivel de precisión cas etiquetas.

- **DRIVE (2004).** [33] Deseñado para segmentación de vasos sanguíneos, inclue 40 imaxes cas súas máscaras binarias anotadas manualmente por expertos (ver Figura 2.3 (b-c)).

- **ImageNet (2009).** [34] Nace ante a necesidade dun gran conxunto de datos de imaxe natural e foi plantexado como unha xerarquía de xeito que o concepto de *clase* é multinivel, porque se ben hai animais e artefactos, ambos divídense en subcategorías recursivamente ate chegar ó nivel do individuo. É dicir, preséntase o 'labrador alemán' non como un elemento illado pero como parte dos 'cans' e estes á súa vez de 'carnívoros', 'placentarios'... Polo seu gran tamaño é variedade tivo un impacto notable no desenvolvemento do A.P. es as R.N.A..

2.2.4 De *Hardware*

Fíxose uso do portatil do alumno para o desenvolvemento do código así como dun servidor cedido polo Grupo VARPA que conta cunha gráfica NVIDIA RTX A6000 ó que o alumno podía conectarse de xeito remoto. Ó desenvolver os programas no seu portatil, o alumno debía sincronizarse co servidor para que o segundo tivese o código do primeiro, e o primeiro os artefactos do segundo (ver Figura 2.4).

2.3 Distribución temporal do traballo

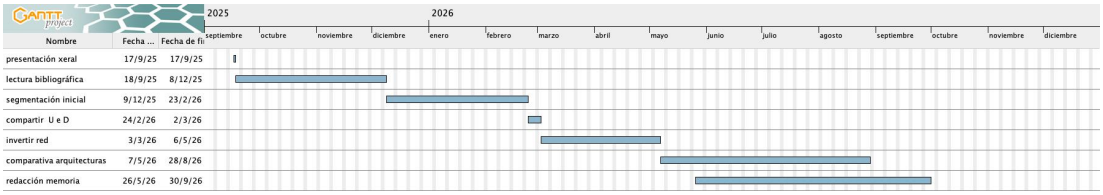

Figura 2.5: Diagrama de Gantt ilustrando as tarefas do traballo. Figura de autoría propia.

As fases do traballo, segundo pódense ver no Diagrama de Gantt da Figura 2.5, foron:

- Presentación, por parte dos titores, do marco xeral do traballo así como punteiros a recursos bibliográficos e de código. (2h)
- Lectura bibliográfica e comprensión do código de referencia. (20h)
- Comezo das interacións segundo o esquema da Figura 2.1.
- Nova tarefa: segmentar con venas usando CRATE e máis o conxunto de datos DRIVE (ver 2.3). Ali consideramos o sistema de supervisión (convolucionar a imaxe con gaussianas con desviacións típicas $\sigma_i = 2^i \times 0.5 \qquad \forall i \in \{0 \dots n\}$ pero finalmente usamos a version naive). (30h)
- Proposición do segundo orden, motivada teoricamente e a nivel experimental **[NOTA: en retrospectiva ambas motivacións orixinais eran cuestionables]**. A cal, pola sua parte motivou tanto o cambio de tarefa (predicción de ollo san - non san no conxunto de datos RFMiD) como a consideración de uso de Linformer **[NOTA: que quedou en nada]**. Ademáis considerouse o cruce (adestrar cun orde e facer inferencia con outro), que cualitativa e cuantitativamente demostrou non funcionar para Imagenet. (30h)
- Proposición de compartir U e D. (10h)
- Investigación dos parches da capa lineal de entrada ó transformer, co obxectivo de invertila red **[NOTA: non fun capaz de invertila, principalmente por descoñecemento e complexidade]**. Probouse a adestrar primeiro esa capa, a regulalizala con distintas penalizacións e varias (bastantes) combinacións (primeiro adestrar so a primeira capa con e sin regularizacions e logo conxelala, adestrar con regularizacions . . .). (20h)
- Comparativa en Imagenet, DRIVE e RFMiD das proposicións ca de referencia. (30h)

- Estas tarefas víronse asociadas á programación de *scripts* de visualización e redación de memorias semanais, de xeito totalmente paralelo.
- Redacción da memoria. (50h)

2.4 Estimación de custos

Neste traballo só supuxeron un custo os recursos Humanos, posto que os recursos de *Software* e Datos eran ou libres ou abertos, en definitiva, de balde e os recursos de *Hardware* considéranse amortizados por proxectos pasados. Así os custos humanos poden desglosarse á súa vez entre os do alumno e os titores. O primeiro adicou aproximadamente 190h e podríamos considerar un custo de 15 euros a hora. Pola súa parte, os titores traballaron aproximadamente 50h, cun soldo estimable de 30 euros a hora. Por tanto, sendo 2 titores, a conta resulta en $190 \times 15 + 50 \times 30 \times 2 = 5850$ euros.

Capítulo 3

Traballo proposto

O que non podo crear, non o podo entender [35]

O presente traballo é de carácter teórico e experimental. Neste capítulo presentaranse as propostas téoricas así como as posibilidades de comparación e análise dos experimentos que expondranse no próximo capítulo. Deste xeito a práctica experimental, ver o Capítulo 4 (e as consecuentes conclusións, ver Capítulo 5) baséase nas achegas teóricas a continuación presentadas.

3.1 Introdución

Este capítulo expón o que se propón neste traballo a partir de CRATE, e faino en dous niveis. O primeiro é o das *arquitecturas*: dúas vias de modificacións do modelo, unha aproveitando a natureza do paradigma A.D. no que se deseñou e outra facendo uso da derivación de expresións obxectivo a implementación . O segundo é o das *ferramentas para mirar dentro* da Rede, é dicir, os procedementos de explicabilidade co que se estudan esas modificacións e, en xeral, o comportamento do modelo.

De feito, as modificacións nacen da propia interpretabilidade da Rede, como pode entenderse, pódense facer preguntas concretas sobre as compoñentes.

- **Segundo orde.** A atención (ver Sección 1.6) require unha inversa que os autores aproximan de forma sinxela. Que Rede resultaría de aproximala máis finamente? (Sección 3.2). Como se verá a Rede resultante ten exactamente os mesmos parámetros ca orixinal, do que nace outra pregunta: Pode adestrarse unha Rede e facer inferencia ca outra aproximación? (Sección 3.5)

- **Compartir U e D.** A capa ℓ implementa unha iteración do algoritmo que busca optimizar Z a traveso de dous operadores, definidos por U_ℓ e D_ℓ. Así todas as capas fan o

mesmo pero con tensores distintos. Que pasa se compartense entre capas? Nótese que esta pregunta abre a posibilidade de compartir ambos ou un só (Sección 3.5).

Como estas propostas son ortogonais entre si, poden combinarse (Sección 3.6); a combinación é a proposta que no resto do traballo chamamos *combo*.

Para estudar as variantes empréganse dúas técnicas de explicabilidade. A primeira son os *mapas de atención* (Sección 3.3), que amosan qué rexións da imaxe pesan máis na decisión da Rede. A segunda é a *recuperación de parches representativos* (Sección 3.4.1), que dá unha idea visual do que significa cada "palabra" do dicionario definido por D. Serven para dous fins distintos: comprobar en que medida unha variante é explicable e sacar conclusións sobre como funciona a Rede en xeral.

Por último, o capítulo describe o marco no que se compararán as propostas: as métricas (Sección 3.7) e as tarefas de adestramento sobre cada conxunto de datos (Sección 3.8). Remata coas preguntas concretas ás que o Capítulo 4 tratará de dar resposta (Sección 3.9).

3.2 Segundo orden

Segundo a presentación do modelo CRATE (ver Sección 1.6), considérase agora a derivación de outro modelo estilo ViT (ver Sección 1.3.8) a partires da mesma premisa de maximizar o *Sparse Coding Rate*. Así, como verase nas vindeiras Seccións 3.2.1 e 3.2.2 o modelo derivado a continuación é, no respecto á teoría unha variante natural na liña de desenvolvemento do CRATE, sendo isto posible grazas ó marco de interpretabilidade no que encádrase o mesmo. Con respecto o rendemento do novo modelo na práctica, o Capítulo 4 adicarase en gran medida a avaliar o mesmo e comparalo co modelo CRATE de referencia.

3.2.1 Aproximación da inversa mediante suma de matrices

O operador MSSA do CRATE é unha implementación de un ascenso de gradiente sobre $R^c(Z|U_{[K]})$, é dicir queremos:

$$\nabla R^c(Z|U_{[K]}) = \beta \sum_k U_k(U_k^{'}Z)(I + \beta(U_k^{'}Z)^{'}(U_k^{'}Z))^{-1}$$

(ver Sección 1.6). Se Z son os tokens que estanse a procesar, esta operación intuitivamente corresponde con movelos (é dicir, cambiar a súa representación) cara un espazo onde os tokens máis parecidos[1] segundo un criterio k o sexan máis, simultaneamente para os K criterios. Devandita operación conlevaría K inversas o cal é computacionalmente complexo. Eiquí

[1]Neste caso o criterio de similaridade k-ésimo é o producto interno usual no espazo definido pola transformación liñeal U_k. É dicir, $\text{sim}_k(z_i, z_j) = (U_k z_i)'(U_k z_j)$

nace un dilema: Computar o que dí o principio, obtendo os resultados que tense en mente ou pola contra aproximar para facer a tarefa factible? Os autores optaron por aproximar as inversas segundo a expansión de primer orden das series de Neumann [26], o cal resultaría no exposto CRATE 1.6. En particular a expresión quedaría

$$\nabla R^c(Z|U_{[K]}) \approx \beta \sum_k U_k(U_k^{'}Z)(I - \beta(U_k^{'}Z)^{'}(U_k^{'}Z)) \tag{1}$$

Neste traballo preguntámonos: Qué pasaría se a aproximación fora máis precisa? Se a aproximación orixinal derivou nunha R.N.A., Qué R.N.A. resultaría de ter aproximado máis fino? A continuación presentamos a nosa derivación. Collendo adicionalmente o segundo termo da expansión de Neumann, quedaría o seguinte operador que asemella unha versión *de segundo orde* [36, 37] :

$$\nabla R^c(Z|U_{[K]}) \approx \beta \sum_k U_k(U_k^{'}Z)(I - \beta(U_k^{'}Z)^{'}(U_k^{'}Z) + \beta^2((U_k^{'}Z)^{'}(U_k^{'}Z))^2) \tag{2}$$

[NOTA: engadir un pouco de explicación para que se entenda como se pasa de unha cousa á seguinte. OU NON?]

3.2.2 Nova arquitectura

Para mostrar o paso da expresión 2 á nosa nova arquitectura, sera ilustrativo facelo parello a como os autores pasaron da equidade 1 á súa MultiAtención (ver Sección 1.6). Unha reorganización de 1 da:

$$R^c(Z|U_{[K]}) \approx \beta(\sum_k U_k U_k^{'})Z - \beta^2 \sum_k U_k(U_k^{'}Z)(U_k^{'}Z)^{'}(U_k^{'}Z), \tag{3.a}$$

onde se asumimos ortogonalidade nas filas de U, e queremos estimar o residuo da proxeción de $U_k z_i$ co resto de $U_k z_j$ para i e j no mesmo grupo (ver Figura 1.10), nos quedaría:

$$R^c(Z|U_{[K]}) \approx \beta Z - \beta^2 \sum_k U_k(U_k^{'}Z)\text{Softmax}((U_k^{'}Z)^{'}(U_k^{'}Z)). \tag{4.a}$$

Posto que o obxectivo inicialmente era reducir o Coding Rate co paso das capas (ver Sección 1.5.2 e 1.6):

$$Z^{\ell+1/2} \approx Z^{\ell} - R^c(Z|U_{[K]}),$$

o modelo CRATE podría quedar entón:

$$Z^{\ell+1/2} \approx (1-\beta)Z^{\ell} + \beta^2 \sum_k U_k(U_k^{'}Z)\text{Softmax}((U_k^{'}Z)^{'}(U_k Z)), \tag{5.a}$$

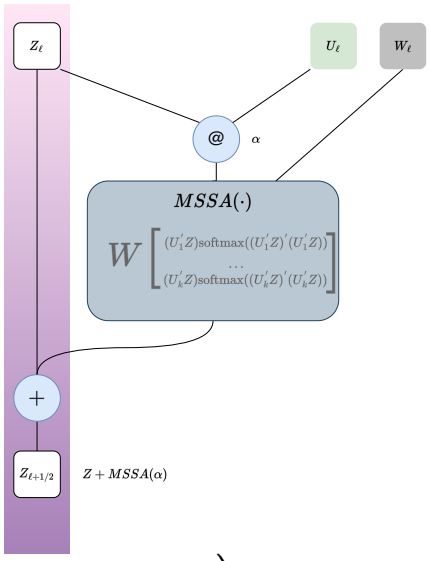

a)

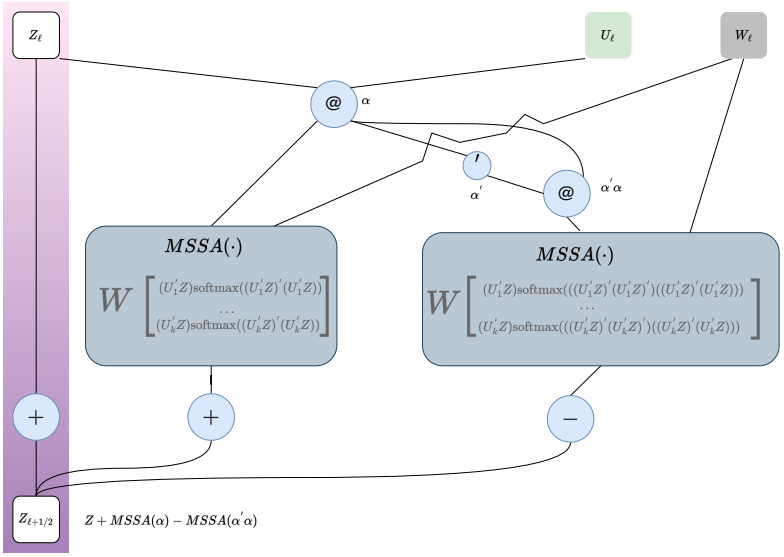

b)

Figura 3.1: a) A atención multicabeza do CRATE orixinal. Mostráse o fluxo residual da atención en púrpura [12, 17]. O símbolos @ e + denotan multiplicación e suma matricial respectivamente. b) A atención multicabeza proposta. O símbolos $'$ e − denotan trasposta e resta respectivamente o. **[NOTA: Explicar máis supoño pero non sei o que]**. Pódese apreciar que aínda que a arquitectura proposta realiza máis computo, non está máis parametrizada. Para máis detalles sobre a arquitectura orixinal e a súa derivación consultar [26]. Figura de autoría propia.

pero na súa experimentación (a traveso da substitución $W \doteq U_{[K]}$) quedáronse con:

$$Z^{\ell+1/2} = \underbrace{Z^{\ell}}_{\text{Conexión residual}} + \underbrace{W[(U_1'Z)\text{Softmax}((U_1'Z)'(U_1'Z)), \ldots, (U_n'Z)\text{Softmax}((U_n'Z)'(U_n'Z))]}_{\text{Atención MultiCabeza}}. \tag{6.a}$$

Agora, replicando o proceso de derivación e manipulación de converteu a aproximación da inversa orixinal 1 na expresión 6.a pero ca nova aproximación 2, teríamos a secuencia:

$$\begin{aligned} R^c(Z|U_{[K]}) \approx \beta(\sum_k U_k U_k')Z - \beta^2 \sum_k U_k(U_k'Z)(U_k'Z)'(U_k'Z) \\ + \beta^3 \sum_k U_k(U_k'Z)((U_k'Z)'(U_k'Z))^2, \end{aligned} \tag{3.b}$$

e dado que $(U_k'Z)'(U_k'Z)$ é simétrico, temos que $((U_k'Z)'(U_k'Z))^2$ é $((U_k'Z)'(U_k'Z))'(U_k'Z)'(U_k'Z)$ e por tanto:

$$\begin{aligned} R^c(Z|U_{[K]}) \approx \beta Z - \beta^2 \sum_k U_k(U_k'Z)\text{Softmax}((U_k'Z)'(U_k'Z)) \\ + \beta^3 \sum_k U_k(U_k'Z)\text{Softmax}(((U_k'Z)'(U_k'Z))'((U_k'Z)'(U_k'Z))), \end{aligned} \tag{4.b}$$

$$\begin{aligned} Z^{\ell+1/2} \approx (1-\beta)Z^{\ell} + \beta^2 \sum_k U_k(U_k'Z)\text{Softmax}((U_k'Z)'(U_kZ)) \\ - \beta^3 \sum_k U_k'(U_k'Z)\text{Softmax}(((U_k'Z)'(U_k'Z))'((U_k'Z)'(U_k'Z))), \end{aligned} \tag{5.b}$$

que finalmente resultaría en:

$$\begin{aligned} Z^{\ell+1/2} = \underbrace{Z^{\ell}}_{\text{Conexión residual}} + \underbrace{W[(U_1'Z)\text{Softmax}((U_1'Z)'(U_1'Z)), \ldots, (U_n'Z)\text{Softmax}((U_n'Z)'(U_n'Z))]}_{\text{Primeira Atención MultiCabeza}} \\ - \underbrace{W[\ldots, (U_i'Z)\text{Softmax}(((U_i'Z)'(U_i'Z))'((U_i'Z)'(U_i'Z))), \ldots]}_{\text{Segunda Atención MultiCabeza}}. \end{aligned} \tag{6.b}$$

A expresión 6.b define a nova compoñente de Atención, pódese comparar ca expresión 6.a visualmente na Figura 3.1. Pódese apreciar que a aproximación proposta é unha reinterpretación do rol de cada parámetro da Rede, influindo así nas operacións nas que comprométese tanto na inferencia (fluxo de entrada á saída) como no adestramento (fluxo de saída a entrada). En particular cada parámetro realiza máis cómputo na inferencia e polo tanto recibe un gradiente máis "rico" no adestramento. Intuitivamente engadir a nova cabeza é equivalente a regularizar a función de perda, posto que estáselle exisindo máis a cada parámetro. Naturalmente isto conleva inmediatas dificultades técnicas, a saber: (i) a necesidade de máis memoria para gardar os gradientes (ii) adestramentos máis lentos, xa que máis memoria RAM para os

gradientes acaba significado menos memoria RAM para o tamaño do *batch*[2] e iso á sua vez significa ter que empregar máis *batches* **[NOTA: batch acrónimo?]** (iii) Do mesmo xeito que unha regularización pola norma dos parámetros pode chegar a mellores resultados pero tamén pode prohibir á Rede a chegar a ningún resultado, a regularización imposta pola nova cabeza ten a mesma propiedade. A pesar das evidentes dificultades técnicas, esta nova arquitectura xa que desenvolveuse grazas ó mesmo marco teórico que o modelo CRATE pero ca característica adicional de que leva a cabo unha aproximación máis fina, está suficientemente motivada a posibilidade de boas propiedades e interese de adestramento. De entrada esta variante é totalmente interpretable xa que todas as partes que comparte con CRATE o son e a nova compoñente de Atención MultiCabeza é tamén interpretable xa que deseñouse na busca de aproximar máis o obxectivo de MCR^2.

Leváronse a cabo experimentos probando devandita arquitectura con todolos conxuntos de datos expostos na Sección 2.2.3 e os seus resultados en canto a rendemento nas métricas de Precisión, AUC-ROC, Coding Rate e Dispersión exponse nas Seccións 4.2.1, 4.3.1 e 4.4.1. Tamén levaranse a cabo experimentos na busca de propiedades de explicabilidade nesta nova variante, en particular farase uso da técnica de Visualización dos Mapas de Atención (ver Sección 3.3) e probarase con imaxes naturais en Redes adestradas con ImageNet (que fora o conxunto de datos cos que os autores orixinais de CRATE probaron a súa Rede) na Sección 4.2.3.

3.2.3 Cruce

Polas deseables propiedades desta nova arquitectura e o feito de que use os mesmos parámetros que a orixinal, xurde de forma natural a pregunta: Como comportaríase a unha Rede adestrada nun réxime de primeiro orden de ser usada en inferencia como se fora de primeiro segundo orde? E viceversa?

Como a versión de segundo orden pódese interpretar como a rede orixinal (unha cabeza de atención por bloque) con unha correción explicita no obxectivo de MCR^2 Disperso (en forma de outra cabeza) podería ser o caso que adestrar en, digamos, modo primeiro orde e facer inferencia en modo segundo orde, obteñamos unha correción *gratis* sen precisar un adestramento máis custoso. Tamén podería ser o caso que de adestrar en segundo orden e facer inferencia como primeiro orden (pensemos nun contexto en tempo real no que a velocidade é crítica) obteñamos a velocidade do primeiro orden ca precisión da segunda.

Leváronse a cabo experimentos probando ambas combinacións de cruce co conxunto de datos ImageNet e exponse os seus resultados na Sección 4.2.2 e analízanse na Sección 5.2.2.

[2] O *batch* é unha escolma de mostras usadas para adestrar en conxuntos de datos masivos, así, en vez de adestrar cunha mostra á vez, adestrase en lotes.

3.3 Visualizacións dos mapas de atención

3.3.1 Motivación

Se ben todolos Transformadores (en xeral, e todolos ViT en particular) teñen relacións de *atención*, e pode dicirse que dous *tokens atendense moito ou pouco*. Polo xeral estas relacións non reflictense de forma intuitiva nas relacións que podemos facer os humanos, é decir, os humanos podemos relacionar a condición de hipertensión nun ollo con rexións de venas moi tortuosas ou podemos relacionar a raza dun can coa forma das súas orellas. Nesta "problemática" ou discrepancia entre a nosa intuición e as R.N.A. nace DINO [28], que a traveso dun réxime de adestramento sofisticado, non trivial e non totalmente comprensible (parcialmente arbitrario) consegue unhas relacións de atención que sí correspóndese coa intuición humana. En particular as relacións de atención das visualizacións do artigo realízanse entre cada token e o token `[CLS]`[3].

Resultado do diseño baseado no principio de MCR[2] disperso, o modelo CRATE (ver Sección 1.6) é quen de producir semellantes visualizacións as do DINO, quizáis un pouco peores [23], pero claramente superiores en ambos casos a un ViT convencional con adestramento convencional. A diferencia entre as solucións que ofrecen DINO e CRATE reside en que entre un ViT e DINO cambia totalmente o procedimento de adestramento e mesmo as funcións de pérdidas usadas, mentres que entre un ViT e CRATE cambia lixeiramente a arquitectura, pero conservando todas as compoñentes e o adestramento.

A continuación descríbese como poder *visualizar* estas relacións de atención, que teñen como fin demostrar ó lector que efectivamente o funcionamento interno de CRATE correspóndese polo menos parcialmente ca intuición humana, exemplos de devanditas visualizacións presentaranse e discutiranse nas Seccións 4.2.3, 4.3.2 e 4.4.2.

3.3.2 Procedemento

A visualización da Rede supón, para cabeza ver canto *atende* o token `[CLS]` ós tokens asociados cunha imaxe. Desta forma se nunha cabeza de atención dunha Rede adestrada a predecir presenza de patoloxía en imaxes de fondo de retina, hai moita relación entre os tokens correspondentes a unhas rexións da retina e o token `[CLS]`, entón probablemente exista unha relación entre esas rexións e o estado de saúde dese ollo.

Como a atención nos ViT é un fenómeno relativo, é decir, unha cabeza pode atender moito a case todos os tokens e outra case nada á maioria; para a correcta visualización deste fenómeno é preciso unha normalización. Como xa existe unha `softmax` na atención (que subordina o comportamento xa que influe no adestramento) parece natural expresar a "relación

[3] Segundo o artigo fundacional dos ViT [16] o token `[CLS]` identifica a clase, nos problemas de clasificación. En particular nun contexto de diagnóstico de patoloxías a patoloxía é a clase.

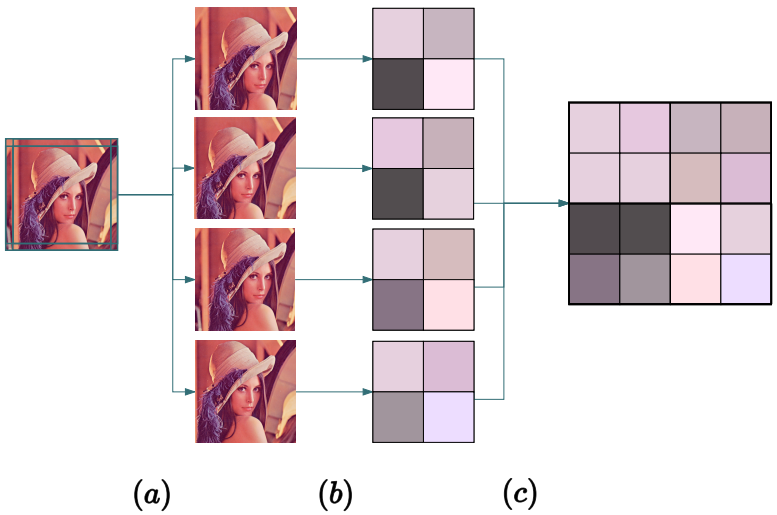

Figura 3.2: Pasos do procedemento de Mapas de Atención de alta resolución. a) Extración de recortes b) Obtención dos Mapas de Atención de cada recorte c) Amalgamación dos Mapas indiduais. Figura de autoría propia.

coa clase" no modelo CRATE do token z_i na capa ℓ na cabeza j (ver Figura 3.1) como a saída da `softmax` indexada no token `[CLS]`, é dicir sólo interésanos as relacións que ten un token co token `[CLS]` normalizado con canto relacionánse os demáis tokens co token `[CLS]`. Formalmente:

$$\texttt{relacion_clase}(z_i|U_j^\ell) = \frac{e^{\langle U_j^{\ell'} z_i, U_j^{\ell'} z_{[\text{CLS}]} \rangle}}{\sum_{i=1}^{N} e^{\langle U_j^{\ell'} z_i, U_j^{\ell'} z_{[\text{CLS}]} \rangle}}$$

Onde U_j^ℓ é a parametrización da j-ésima cabeza de atención da ℓ-ésima capa do Transformador. Así una vez calculados devanditos valores podemos simplemente asignar un cor a cada nivel de relación, onde (no caso dos diagramas deste traballo) máis relación é rosa mentras que menos é branco (para unha referencia no mapa de cor ver a Figura 2.2). Para máis detalles sobre este procedemento básico consultar [23, 26].

3.3.3 Extensión para resolución

A desvantaxe do método é que é moi *grano grueso* posto que só temos un valor por token. Para solventar eso lévase a cabo un proceso en tres pasos (ver Figura 3.2):

(a) Supoñendo que quérese aumentar a resolución n veces, tanto en horizontal como en vertical, será preciso facer n^2 recortes á imaxe. Na Figura 3.2 pásase dunha atención 2×2 a unha 4×4, é dicir $n = 2$ e por tanto foron precisos 4 recortes. En particular estos recortes obtensei da imaxe máis grande por deslizamento de un píxel dunha rexión

co tamaño deseado para ser entrada do modelo. Na Figura 3.2 pódense ver a modo de exemplo os catro cadrados que xerarían os correspondentes recortes.

(b) Extrénse os Mapas de Atención de cada recorte individualmente tal e como explicouse na Sección anterior.

(c) Xúntanse os Mapas de Atención, entrelazándose para xerar uno novo.

[NOTA: suficientemente ben explicado? dende logo para programar esto estaría ben falar en términos de índices pero tamén é certo que para facerse unha idea penso que co texto e a imaxe ben chega...]

3.3.4 Extensión ó segundo orde

Dado que neste traballo plantexamos unha nova arquitectura, significativamente distinta ó CRATE orixinal (ver Sección 3.2.2), é necesario presentar en que consitirán os Mapas de Atención desta nova arquitectura. Se ben é certo que a parte trocada é precisamente a Atención do modelo, como a saída da Atención de ambos (o modelo orixinal e o segundo orde) é un tensor de igual tamaño, ben poderíamos simplemente obviar as diferencias e usar as utilidades xa programadas para o modelo de primer orde co modelo de segundo orde. Non obstante, facendo tal cousa estaríamos obviando a complexidade interna da variante de segundo orde (ver Figura 3.1).

Aproveitando que na arquitectura segundo orde temos dos bloques de cabezas ligados estreitamente e que orixinalmente tiñamos un mapa de atención por cada cabeza, pensamos que o máis axeitado sería ter dous mapas de atención por cada cabeza. O primeiro sería o equivalente ó bloque (de cabezas) da esquerda da Figura 3.1 (que era o orixinal, presente no CRATE) e o segundo estaría asociado ó bloque da dereita de devandita Figura (que é o novo, vinculado ca correción da Equación 2). Deste xeito se antes para a cabeza i da capa j tiñamos un mapa de atención, agora temos dous.

Agora, Qué esperaríamos ver nestas cabezas? Plantéanse catro hipótesis sobre o posible comportamento da variante de segundo orde:

(a) Que a cabeza orixinal conserve un comportamento similar ó que os autores orixinais de CRATE reportan (ou equivalentemente, un comportamento similar ó que observemos nas nosas Redes CRATE que adestraremos neste traballo), e que a outra presente un comportamento novo.

(b) Que a nova cabeza sea a que ofrezca un comportamento semellante ó modelo CRATE orixinal e sexa a primeira a que se adapte e mostre un comportamento distinto.

(c) Que sexan moi parecidas entre sí e non se poda facílmente mendiante a observación sinalar ningunha diferencia consistente entre elas.

(d) Que por engadir a nova cabeza o modelo saíase do marco experimental dos autores o suficientemente como para convertirse nun modelo moi díficil de adestrar e por tanto ningunha amose nada relevante.

A evidencia sobre que hipótesis é correcta mostrarase no vindeiro capítulo na Sección 4.2.3 do Capítulo Resultados e analizarase na Sección 5.2.1 do Capítulo Conclusións. **[NOTA: falta por analizar]**

3.4 Recuperación de parches representativos

Xa que o MLP de CRATE implementa un aprendixaze de diccionarios (ver Seccións 1.3.7, 1.4.1 e 1.6) é de especial interese a visualización das *palabras* que compoñen o diccionario.

3.4.1 Procedemento

Para as visualizacións das palabras dunha Rede do vindeiro capítulo, neste traballo optamos polo seguinte procedemento en dous pasos:

1. Dada unha capa (normalmente a penúltima) collíase a salida intermedia do modelo de xeito que, para cada token obtíñase un vector (ver Figura 3.3). Esto facíase para todas as imaxes do conxunto de datos e para cada cabeza.

2. Unha vez temos para cada token de cada imaxe unha representación vectorial onde cada entrada deses vectores correspóndese cunha palabra, podemos preguntarnos: Cales son os parches que teñen a entrada i-ésima con máis valor absoluto? Eses seran os parches máis representativos de cada palabra e unha escolma deles dará dun vistazo unha idea do que supon esa palabra en términos visuais. Por tanto por cada entrada do vector calculamos mediante unha ordenación simple cales son os k vectores con devandita entrada de maior magnitude, para cada cabeza.

3. Finalmente, xa cos índices das imaxes (por exemplo: para a entrada corresponde ca decimoquinta palabra, os dous parches máis representativos son o segundo parche da quincuaxésima cuarta imaxe e o vixéximo parche da septuaxésima decimo terceira imaxe) escolmamos devanditos parches (os píxeles deles) e os arranxamos todos nun diagrama como o mosaico da Figura 4.5 onde cada gran columna é unha cabeza, dentro destas cada fila é unha palabra e dentro destas a columna i-ésima correspóndese co i-ésimo parche máis representativo. Unha vez este mosaico estaba preparado, procedíase a unha fase de inspeción manual para identificar palabras de interes.

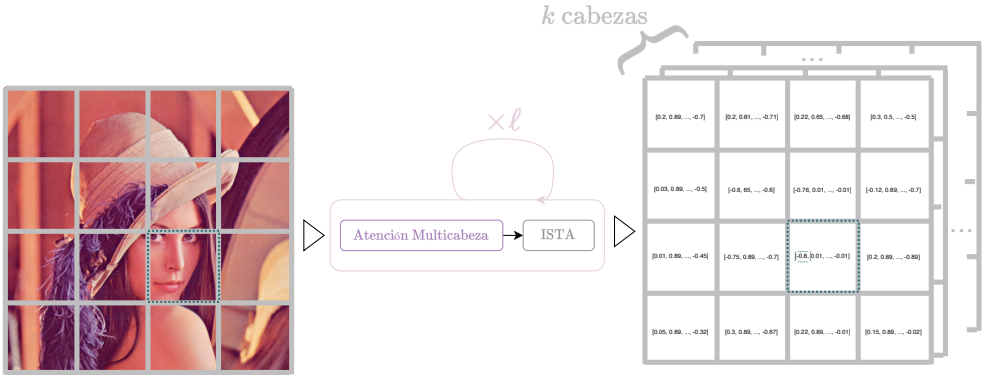

Figura 3.3: Representación intermedia que úsase para comparar os parches dos tokens. Na figura pódese observar que o parche correspondente á cara de Lenna é o que ten o valor absoluto máis grande na primeira entrada da primeira cabeza e por tanto neste caso poderíamos pensar que a primeira palabra desta cabeza ten o significado de "cara". En realidade as interprestacións semánticas das palabras dunha Rede adoitan ser menos evidentes, isto foi naturalmente un exemplo artificial. Figura de autoría propia.

En realidade, como o paso un podría tardar ate varias horas para o conxunto de datos completo de ImageNet, e xerar como resultado unha tremenda colección de tensores, neste traballo optouse pola realización simultanea dos pasos 1 e 2, é dicir, ir ordenando a medida que facíase a escolma.

3.5 Compartir U e D

Segundo as ideas do A.D. (ver Sección 1.3.9) nas que adscríbese o modelo CRATE, neste traballo preguntámonos: Se cada capa supón un proceso iterativo sobre o obxectivo MCR^2 disperso (ver Sección 1.5.2), Por que deben ser distintos os tensores U e D[4]? No modelo orixinal son distintos para cada capa ℓ, o que resulta en que a idea que os autores queren reflexar de "Optimizar os subespacios e o diccionarios o traveso das capas"[26] póñase en contradicción co mesmo deseño do modelo. Así, se compartísemos sendos tensores estaríamos comprobando realmente ate que punto ocurre o que os autores de CRATE pensan que ocurre.

Na Figura 3.4 pódese comparar a diferencia entre o modelo orixinal (á esquerda) e a versión na que comparténse ambos tensores, pódese apreciar que o segundo é un modelos máis lixeiro posto que conta con moitos menos parámetros. A lixereza pode ser unha vantaxe posto que as inferencias poden ser máis rápidas e de seguro o modelo ocupa menos en disco. Pola contra, no adestramento as derivadas da Propagación cara atrás [38] serían igualmente pesadas co

[4]Respectivamente, os subespacios ortogonais e os diccionarios.

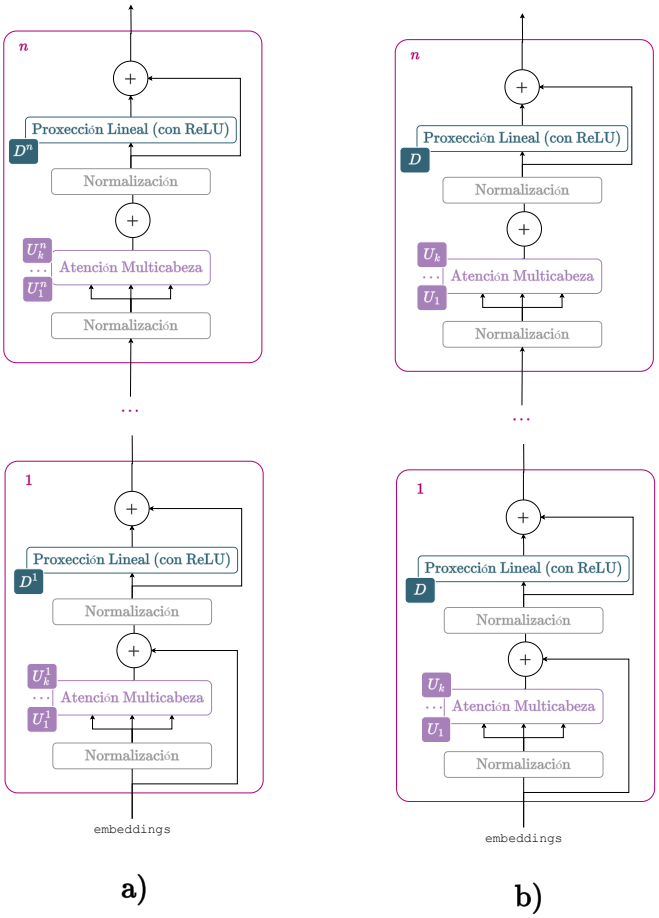

Figura 3.4: a) Rede orixinal onde cada capa ℓ ten os seús tensores U_ℓ e D_ℓ; para a atención multicabeza e o MLP, respectivamente. b) Proposta de compartir devanditos tensores ó traveso das capas. Figura de autoría propia.

respecto o modelo orixinal. Tamén existen beneficios no adestramento, no modelo orixinal a capa ℓ actualiza U_ℓ e D_ℓ cos seus correspondentes tensores $\frac{\partial \mathcal{L}}{\partial U_\ell}$ e $\frac{\partial \mathcal{L}}{\partial D_\ell}$, e así ocurre cas n capas; pola contra no modelo proposto a capa ℓ actualízase cos n tensores $\{\frac{\partial \mathcal{L}}{\partial U_i}\}^n$ e $\{\frac{\partial \mathcal{L}}{\partial D_i}\}^n$ polo que recibe máis información da supervisión. Esta información, no caso de non ser contradictoria[5], pódese esperar que axude á converxencia do adestramento.

Como temos intuición sobre o significado de tanto U coma D (ver Sección 1.6), punto intermedios moi interesante entre compartir ambos tensores ou non compartir ningún pode ser só compartir un deles:

- Só compartir U supondría optimizar ó traveso das capas uns espacios (que tenderan a ortogonais) que actuen sobre as mesmas rexións da imaxe, aínda que estas rexións podan rexpresarse.

- Só compartir D supondría manter fixas as palabras cas que pode representarse un token ó longo das capas, mentres que os tokens cos que se relacione ou agrupe sexan distintos.

[NOTA: dicir algo estilo que esta explicación non é moi boa pero porque todo esto é moi abstracto e é millor mirar os resultados]

Paga a pena notar, cara os resultados que exporanse no vindeiro Capítulo, que os modelos que compartan D, ó ter menos palabras en total, necesariamente evaluaranse como menos dispersos. É dicir, no modelo orixinal un token pode expresarse con d palabras na primeira capa, con outras d na segunda... e así cas n capas. O certo e que nos modelos de A.P. existe unha tendencia á abstracción cara as capas máis profundas[24], por tanto esperaríamos que: (i) as palabras das capas máis profundas sexan máis abstractas (ii) as palabras que reduzcan ó máximo o erro de representación nunha capa, dado un nivel de abstracción distinto, deben ser tamén distintas (iii) as palabras que permitan unha representación moi dispersa deben ser moi axeitadas, de non selo a representación preferirá usar máis palabras para reducir o erro de representación e por tanto reducindo tamén o nivel de dispersión. É por isto que dous modelos, un que comparta D e outro que non, van ter necesariamente niveis de dispersión distintos.

Por outra banda, esta propiedade do A.P. tamén ten o séu efecto no caso dos tensores $U^\ell_{[K]}$ relativos á MultiAtención. Nun réxime corriente, sen compartir, o tensor U^ℓ_i ten que facer algunha tarefa axeitada para a súa capa ℓ. Mentras, na variante que comparte o tensor U_i ten que ou ben facer algunha tarefa axeitada para as ℓ capas, ou só para algunhas a cambio de que outro tensor U_j "cubra" as outras capas. É dicir, ou fan unha tarefa xeralista ou son pouco útiles en certas capas. Isto conduce necesariamente a unha diferencia fundamental co modelo orixinal:

[5] Será permanentemente contradictoria no caso no que realmente precisese un modelo máis grande.

	$U_{\text{comp.}}$		Non $U_{\text{comp.}}$	
	$D_{\text{comp.}}$	Non $D_{\text{comp.}}$	$D_{\text{comp.}}$	Non $D_{\text{comp.}}$
1^{eiro} orde	derivada	derivada	derivada	orixinal
2^{ndo} orde	combo	derivada	derivada	derivada

Táboa 3.1: Combinacións das diferentes achegas. As filas indican se úsase a aproximación de segundo orde ou no seu defecto a variante orixinal de primeiro orde; as columnas falan de se as compoñentes U e D da Atención compártense ou non.

O modelo orixinal pode e beneficiase de adicar as K cabezas de atención da derradeira capa a que "atendan" a rexións fortemente vinculadas ca patoloxía, mentras que o modelo que comparte non pode posto que tamén ten que usar devanditas cabezas para as primeiras $\ell - 1$ capas.

Na Sección 4.4.2 verase como o modelo orixinal atende ó traveso das K cabezas da derradeira capa a esencialmente ó mesmo concepto mentres que a variante que comparte, se ben tamén sinala devandito concepto, "atende" a outros aspectos co resto de cabezas.

3.6 Combinación de achegas

Na Sección 3.2.2 expúsose unha nova arquitectura (a saber, a aproximación de segundo orde), e na Sección 3.5 outras tres (a saber, compartir U, compartir D e a combinación, é dicir compartir ambas). Naturalmente cabe preguntarse, Cómo resultarían as combinacións? A priori como cada unha das achegas por separado é fundamentada nos mesmos principios nos que derivouse o modelo CRATE orixinal (a saber o MCR^2 disperso), parece natural que todas as 2^3 posibles combinacións destes tres elementos respeten igualmente estos principios. Desta forma, como reflíctese na Táboa 3.1, neste traballo consideraremos a cobinación de todas as achegas por separado como a proposta combo, consideraremos nalgúns casos algunhas propostas derivadas e compararemolas co modelo orixinal.

3.7 Métricas

No presente traballo fase uso das seguintes métricas:

- **Precisión:** para reportar valores de problemas de clasificación. É intuitiva e ampliamente usada. No caso binario é

$$\frac{\text{\#mostras ben clasificadas}}{\text{\#mostras totais}}$$

e no multiclase é

$$\sum_i \frac{\#\text{mostras ben clasificadas da clase } i}{\#\text{mostras totais da clase } i}.$$

- **AUC-ROC:** para reportar valores de problemas de clasificación. Para contextos de desbalanceo de clases, pode dar unha mellor idea de que tan ben clasifica a Rede, considerando todos os umbrais de decisión posibles. Defínese como a area debaixo da curva ROC, que é unha gráfica que o eixo x ten a tasa de verdadeiros positivos e no y a tasa de falsos positivos, e os pares (x, y) que conforman a curva correspóndese con distintos valores do umbral de decisión. No traballo calculouse cunha función da libraría Scikit-Learn [39].

- **Dice:** para reportar valores de problemas de segmentación (ver Figura 4.9). Para o noso caso, como hai moitas máis mostras da clase negativa (ver, na Sección 3.8 o referido ó conxunto de datos DRIVE) resulta interesante porque se a Rede sempre di "clase negativa", tería unha relativamente boa métrica de Precisión pero sería, naturalmente un mal segmentador. Définese como

$$\frac{2\#\text{verdadeiros positivos}}{2\#\text{verdadeiros positivos} + \#\text{falsos positivos} + \#\text{falsos negativos}}.$$

3.8 Tarefas de adestramento

Sobre os conxuntos de datos expostos na Sección 2.2.3 realizáronse experimentos sobre as seguintes tarefas:

- Clasificación binaria sobre **DRIVE**, para a detección de vasos sanguíneos, ver Figura 3.5. A tarefa non elixiuse nin por complexa, ou interesante de ser resolta pero precisamente polo contrario, por ser simple, case trivial **[NOTA: se ben a tarefa si me parece trivial, o certo é que non acadamos resultados tan bos xd, a ver como digo isto mellor]**, as representacións internas deberían ser intuitivas.

- Clasificación binaria sobre **RFMiD** (ver Sección 2.2.3) onde todas as enfermidades aglutinábanse nunha única clase. Neste problema máis complexo esperaríamos que as representacións internas, e en xeral a explicabilidade asociada ás inferencias aporte luz sobre a condición do paciente. Neste caso o problema sí ten (ou pode ter) un interese real doble: por unha banda é interesante un modelo que axude ó ollo clínico do persoal sanitario tomando a decisión de enfermo ou non, pero además (e de xeito máis noble neste traballo **[NOTA: igual vou un pouco de flipao con isto que acabo de dicir?]**) habería unha xustificación a devandita decisión a traveso da técnica de explicabilidade de Visualización de Mapas de Atención, exposta na Sección 3.3.

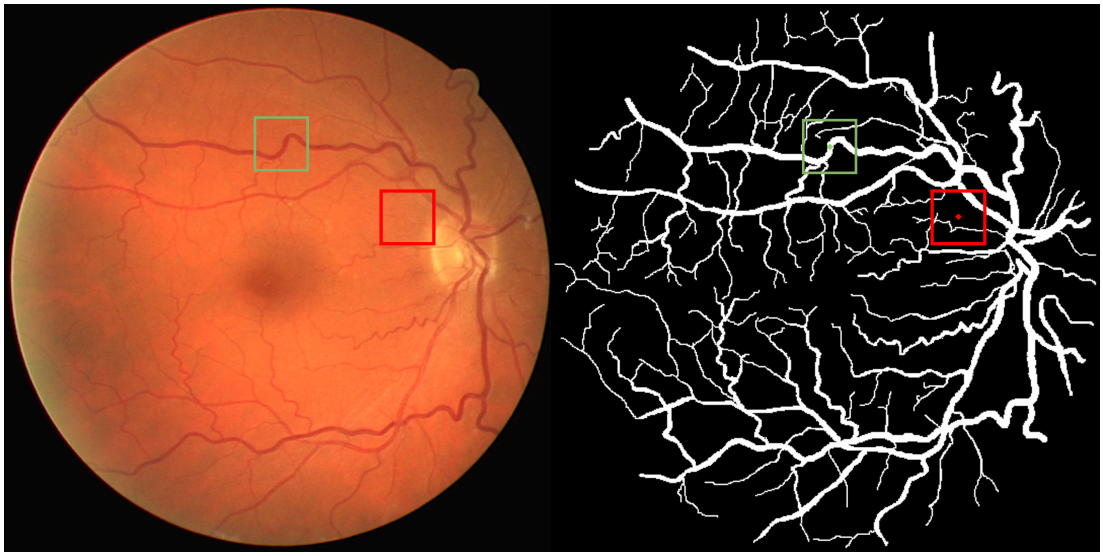

Figura 3.5: Mostras de supervision para o conxunto de datos DRIVE. As imaxes divídense en parches de 105 píxeles (a súa vez estos parches divídense en 7×7 tokens de 15 píxeles, ver Sección 1.3.8), cuxa etiqueta é 1 se o píxel central é vena e 0 se non o é. Devandita información extraese da máscara xa presente no conxunto de datos, ver a Sección2.2.3. Figura de autoría propia.

- Clasificación multiclase en **ImageNet** (ver Sección 2.2.3). Pola variabilidade das mostras neste conxunto e súa xeralidade, as representacións que se aprendan deberían ser suficientemente xerais como para poder ter algún tipo de interese para imaxes arbitrarias (sempre que non se afasten moito de as grandes categorías xerais de animais e artefactos humáns).

Sobre devanditas tarefas puideronse comparar distintas posibilidades de adestramento e estudalas traveso de técnicas de explicabilidade que descríbense nas seccións deseguido. Estas comparacións e ablacións recollense nos experimentos expostos no Capítulo 4

3.9 Preguntas

Con todo o exposto neste cápitulo, nacen as seguintes preguntas:

- Qué diferencias de rendemento poderanse observar ca nova variantes propostas da arquitectura CRATE?
- Como CRATE deseñouse co obxectivo de Dispersión e Minimización do Coding Rate (ver Sección 1.6), Qué suporá as novas variantes co respecto a este obxectivo? É dicir, Cómo rendiran nestras métricas?

- Cómo resultará o cruce de arquitecturas, segundo a definición da Sección 3.2.3, de primeiro orde a segundo? E de segundo a primeiro?
- Qué diferencias poderánse observar entre as visualizacións dos mapas de atención ó traveso dos ordes e dos modelos que comparten ou non U e D?
- Cal das hipótesis presentadas en 3.3.4 é certa?
- Qué información poden desvelar da diagnose de patoloxías relacionadas ca retina as visualizacións dos mapas de atención?
- Qué diferencias poderánse observar entre a recuperación de parches representativos ó traveso dos ordes e dos modelos que comparten ou non U e D?

No vindeiro cápitulo, a traveso da experimentación cas tarefas propostas na Sección 3.8 tratarase de dar resposta a estas preguntas.

Capítulo 4

Resultados

Neste capítulo realiazaranse experimentos para comprobar técnicas de interpretabilidade e explicabilidade así como as preguntas plantexadas na Sección 3.9 sobre os conxuntos de datos descritos na sección 2.2.3 e cas tarefas de adestramento expostas na Sección 3.8. Deste xeito na Seccións 4.2, 4.3 e 4.4 discutiremos os resultados sobre Imagenet, DRIVE e RFMiD respectivamente. A separación en conxuntos de datos da exposición dos resultados resulta en que cos distintos conxuntos de datos a Rede sométese a distintas tarefas, en distintas condicións con distintos hiperparámetros. Como un predicado sobre o rendemento dun modelo pode ser certo para unha tarefa e conxunto de datos determinado pero non para outro, o estudar os resultados por conxuntos-tarefas semellaba o máis correcto.

4.1 Introdución

	$U_{\text{comp.}}$		Non $U_{\text{comp.}}$	
	$D_{\text{comp.}}$	Non $D_{\text{comp.}}$	$D_{\text{comp.}}$	Non $D_{\text{comp.}}$
1^{eiro}	DRIVE RFMiD	DRIVE	DRIVE	INet DRIVE RFMiD
2^{ndo}	INet DRIVE RFMiD	DRIVE	DRIVE	INet DRIVE RFMiD

Táboa 4.1: Combinacións sometidas a experimentación. Cada celda representa unha arquitectura (ver Táboa 3.1).

Posto que os distintos conxuntos de datos ofrecen distintos problemas no adestramento, intentouse levar a cabo experimentos con varias das arquitecturas propostas para os tres conxuntos de datos expostos. Por cuestión de tempo non se puido facer unha busca exhaustiva para todos eles, só para o conxunto de datos DRIVE posto que tiña asociada unha tarefa máis

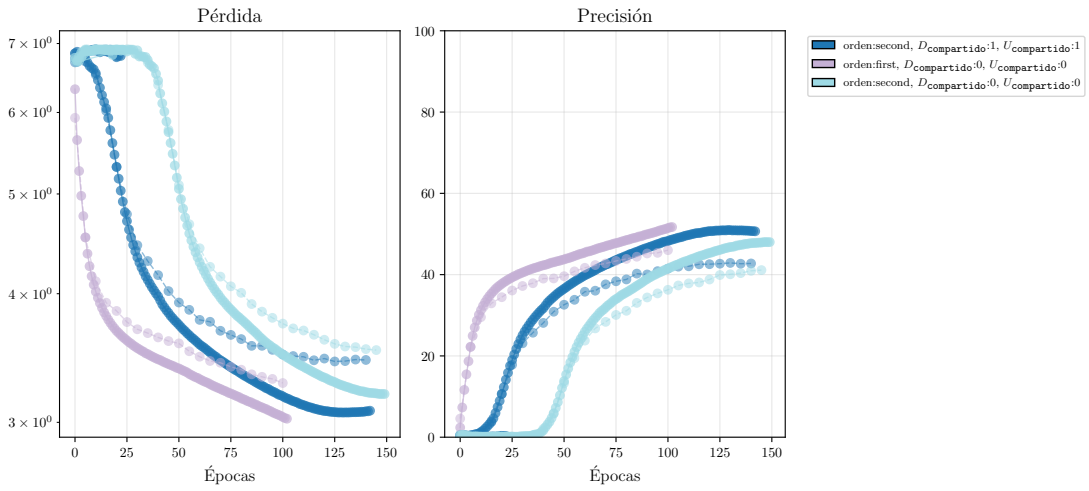

Figura 4.1: En liña continua os valores de Perda e Precisión respectivamente sobre o conxunto de adestramento o traveso das Épocas, en liña discontinua sobre o conxunto de validación. Pódese observar que a configuración base, é dicir, a rosa e a que acada mellores resultados aínda que ás outras dúas deuselles máis épocas. Figura de autoría propia.

sinxela ou *barata* (ver 3.8). A Táboa 4.1 mostra que conxuntos de datos experimentaron sobre as arquitecturas expostas nas seccións anteriores. Pódese ver que houbo un especial interese en comparar as arquitecturas máis distantes, a saber a orixinal e a "combo", que comparte U e D en cabezas de segundo orde.

4.2 Imagenet

Sobre o conxunto de datos Imagenet, por ser o máis custoso non se puido facer moita proba[1], non obstante fixemos tres adestramentos relativamente longos probando as variantes: (i) Modelo CRATE orixinal, (ii) Modelo CRATE segundo orde e (iii) Modelo CRATE segundo orde con U e D compartidos. **[NOTA: decir: O lector podería botar en falta a alternativa primeiro orde compartido U e D, pero non deu tempo?]**

Por ser Imagenet un conxunto de datos tan diverso, a explicabilidade e volvése tamén máis complexa. Se ben a variedade e cantidade de clases permitenos obter visualizacións dos mapas de atención máis ou menos interesantes de calqueira obxecto natural.

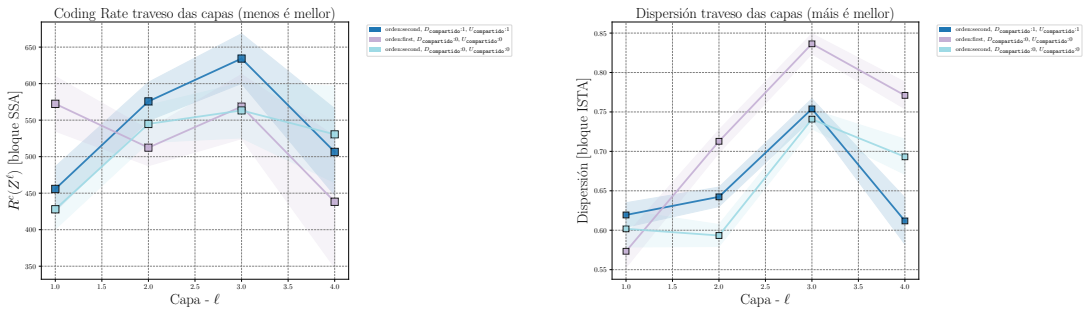

Figura 4.2: Métricas de MCR^2 e dispersión de diferentes arquitecturas sobre Imagenet. Apréciase que o modelo orixinal ofrece mellores resultados en ambas métricas e ademáis ten mellores métricas segundo o índice da capa é máis alto (salvo o último), o cal é unha propiedade desexada de CRATE, non obtida neste experimento nas variantes de segundo orde. Figura de autoría propia.

4.2.1 Busca de arquitecturas

En canto á metrica Precisión a que mellor resultou no noso experimento dende logo foi o modelo orixinal, como pódese ver na Figura 4.1, **[NOTA: é dicir, nestas condicións as nosas proposicións son peores]**. En canto a MCR^2 e Dispersión tamén é mellor o modelo orixinal, como pódese ver na Figura 4.2 pero eso é pouca sorpresa xa os mesmos autores de CRATE (ver Sección 1.6) observaron que ó traveso **das épocas e capas** mellorábanse ambas métricas, e aquí con "épocas" quérese dicir proximidade de converxencia ou definitiva cercanía de $\hat{\theta}$ a θ [13] (ver Sección A), e como nas variantes de segundo orde queda aínda moito (ou cando menos quédalles máis que ó modelo primeiro orde) é esperable que teñan peores valores en MCR^2 e Dispersión. Tamén é, por tanto, razonable a observación de que aparte de o modelo primeiro orde ten *menos* Coding Rate ca as outras variantes, tamén ten menos a traveso das capas (exceptuando a última), propiedade que sabemos por [26] que debería observarse nos modelos CRATE ben adestrados. O mesmo é certo para a Dispersión. Paga a pena notar os seguintes aspectos sobre o experimento:

- Os experimentos realiazáronse con exactamente os hiperparámetros especificados na publicación do modelo orixinal [26], é de esperar que as distintas variacións dun modelo precisen diferentes configuración para: (i) asegurar a converxencia a un mínimo suficientemente baixo (ii) unha converxencia con velocidade parecida; é dicir, se o noso modelo non converxera ou converxera moito máis lento **podería deberse exclusivamente á escolma de hiperparámetros** tales como a tasa de aprendizaxe, o tamaño de *batch*, o número de épocas, o momentum, o optimizador e a súa configuración ...

[1] Os autores do modelo orixinal no seu equipo contaban con 16 GPUs A100 de 40GB, o cal é un equipo 32 veces máis caro que o dispoñible para este traballo, unha GPU A6000 de tamén 48GB pero máis lenta. Ilustrativamente, a época a eles duraballe 240 segundos [26] mentras que a nos cerca das 3 horas.

adestrado (↓) / inferencia (→)	primeiro orde		segundo orde	
	acc@1	acc@5	acc@1	acc@5
primeiro orde	0.5260	0.7645	0.0010	0.0052
segundo orde	0.0010	0.0055	0.4721	0.7160

Táboa 4.2: Resultados do cruce de ordes mostrando o rendemento no conxunto de proba cas métricas Precisión a un e a cinco (ver Sección 3.7). Pódese apreciar que cambiar de orde ofrece uns resultados moi malos.

En definitiva, habería que realizar unha busqueda en cuadrícula ou aleatoria [40] antes de afirmar categoricamente nada. Tal busca non realiazouse por custe computacional e queda para traballo futuro.

- Obsérvase que as tres alternativas aprenden e continuan a facelo, de seguro continuarían algunhas épocas máis antes de converxer finalmente. Cantas épocas máis? Cal sería o estado final das alternativas unha vez que todas converxeron? Son preguntas importantes que precisan de máis exploración que, de novo, por custo computacional non puideron respostarse.
- **[NOTA: dicir algo estilo: os adestramentos cortaronse a man para ser relativamente comparables pero deberían adestrar moitas mais épocas]**

As redes usadas contaban con 6 cabezas ó traveso de 4 capas.

4.2.2 Cruce de arquitecturas

Logo de ter adestrado nas mesmas condicións, tanto a versión orixinal de CRATE (*primeiro orde*) como a versión *segundo orde*, presentánse agora os resultados do cruce (ver Sección 3.2.3) na Táboa 4.2 onde pódese ver que ningunha forma de cruce de orde trae resultados positivos, é máis, en ambos casos son cercanos a un predictor aleatorio. En conclusión, ambas hipóteses plantexadas resultan ser falsas.

4.2.3 Explicabilidade dos mapas de atención

Como o conxunto de datos Imagenet é tan variado, diverso e exhaustivo [34], para un analásise cualitativo non superficial **[NOTA: dicir que neste traballo non fíxose analásise cuantitativo dos mapas de atención pero en [23] explícase como podería facerse.]** é preciso acotar a variabilidade das imaxes co fin de poder encontrar os mesmos patróns nas distintas imaxes e analizar como de distintas son as respostas da Rede. No obstante as conclusións extraídas poderían estar sesgadas ás imaxes escolmadas e non ser xeneralizables.

(a) Imaxes orixinais

(b) Visualizacións da Atención do modelo CRATE.

(c) Visualizacións da Atención da versión do modelo CRATE segundo orde.

Figura 4.3: Explicabilidade das variantes aportación combo e modelo orixinal con Visualizacións dos Mapas de Atención con imaxes de Miss Vaca [41]. Móstranse as 6 cabezas da última capa. Figura de autoría propia.

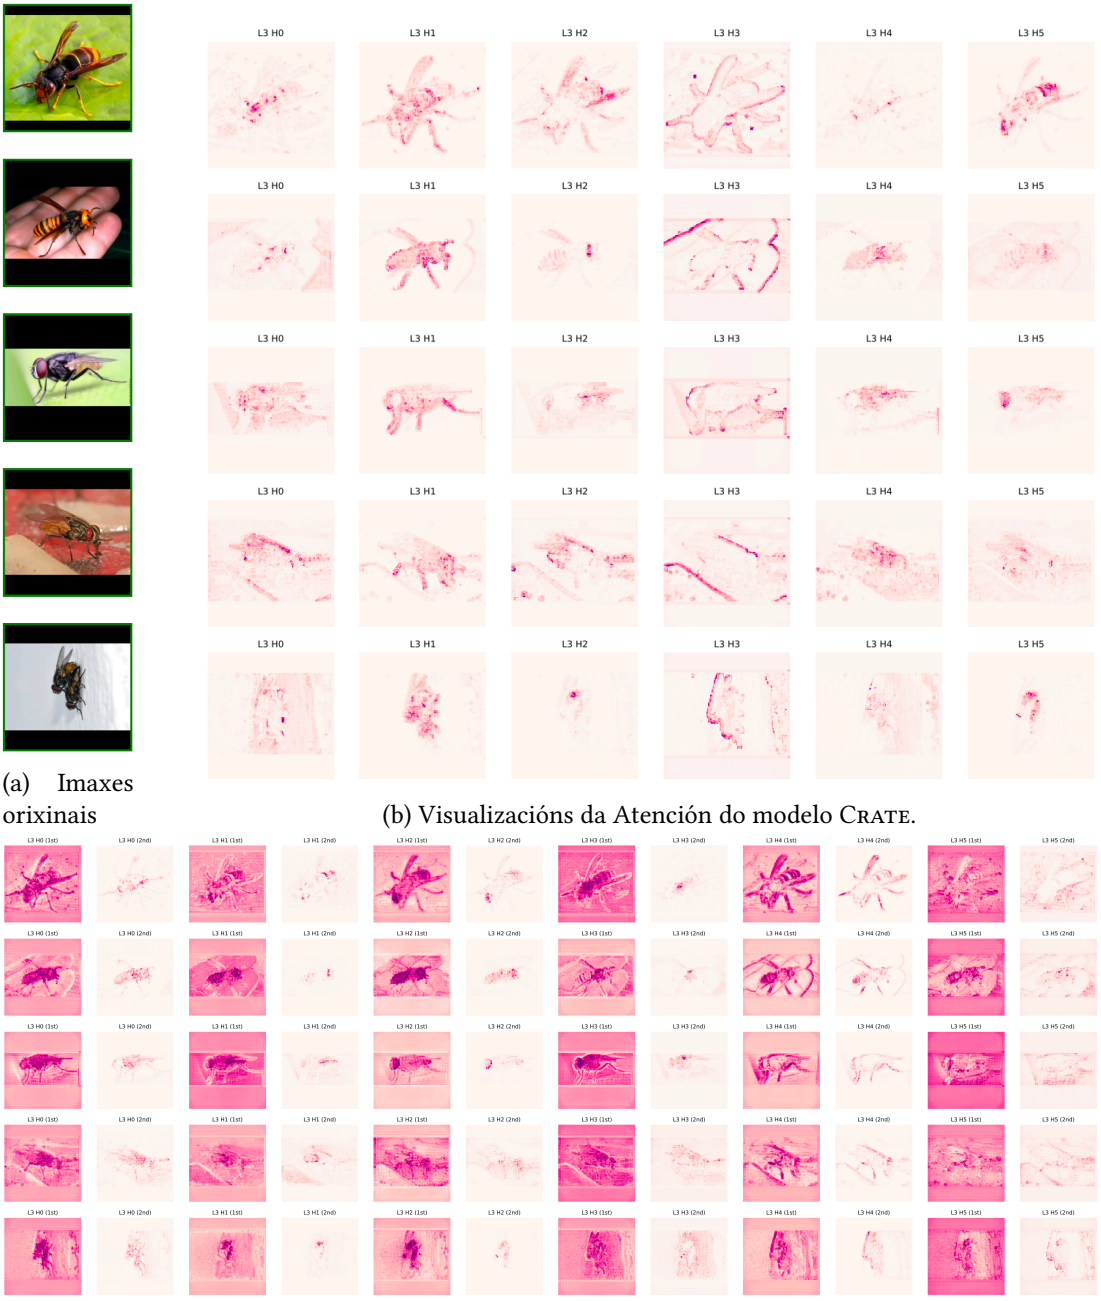

(a) Imaxes orixinais

(b) Visualizacións da Atención do modelo CRATE.

(c) Visualizacións da Atención da versión do modelo CRATE segundo orde.

Figura 4.4: Explicabilidade das variantes aportación combo e modelo orixinal con Visualizacións dos Mapas de Atención con imaxes de velutinas (as cales non estaban presentes no conxunto de datos de adestramento) e mosquitos. Móstranse as 6 cabezas da última capa. Figura de autoría propia.

Polo tanto neste traballa para analizar os mapas de atención dun xeito relativamente preciso pero non totalmente sesgado optouse por analizar sobre:

- Imaxes de vacas con humáns, extraídas do concurso Miss Vaca [41], presentes no problema de clasificación ca etiqueta `ox` no caso das vacas e baixo varias no caso dos humáns[2], dispoñibles na Figura 4.3.
- Imaxes de insectos entre os que atópanse mosquitos (presentes no problema de clasificación ó que foron adestradas as Redes baixo a etiqueta de `fly`) e velutinas (ausentes no conxunto de datos, pero que ofrecen a oportunidade de analizar a xeneralización da Rede sobre imaxes fóra do mesmo) dispoñibles na Figura 4.4.

Nas visualizacións apreciáse como as diferentes cabezas atenden a conceptos semánticamente distintos, propiedade resultado da ortogonalidade dos distintos espazos $U_{[K]}$, ver Sección 1.6. En particular obsérvanse os seguintes conceptos:

- **O fondo:** presente no modelo CRATE na cuarta cabeza (H3) e na variante de segundo orde na sexta cabeza (H5), tanto para imaxes de vacas como de insectos. Esta cabezas *atenden* ás rexións que non son parte do protagonista. Desta forma, caracterizando ó fondo como algo illado a Rede pode non ter problemas en identificar o obxecto independentemente do fondo. Pola contra se unha rexión de fondo e *atendida* por outras cabezas poderíamos identificar un caso de memorización (e.g. dí que é unha vaca porque está sobre a herba e as vacas adoitan estar sobre a herba, non porque identifique a vaca en sí mesma).
- **As cabezas:** presente no modelo CRATE na derradeira cabeza (H5) e na variante se segundo orde na terceira cabeza (H2), tanto para imaxes de vacas como para de insectos. Estas cabezas *atenden* ás cabezas en si mesmas e en menor medida a outras rexións de grande importancia como o cu ou a cola, pero non atenden en xeral ó corpo dos animais. Notar que en ambas Redes existe unha confusión ca derradeira imaxe de moscas (que aparecen dúas en realidade, unha sobre outra), xa que atendén só a cabeza dunha mosca; do mesmo xeito tamén existe confusión nas imaxes de vacas que teñen humáns xa que as Redes teñen dificultades para *atender* á vez a ambas cabezas.
- **O corpo:** presente no modelo CRATE na primeira e quinta cabezas (H0 e H4) para imaxes de vacas e na segunda, quinta e sextas (H1, H4 e H5) para imaxes de insectos. Na variante se segundo orde na segunda e cuarta cabezas (H1 e H3) para imaxes de vacas

[2]Se ben ningunha destas é clase, digamos, 'human', sí temos: '`ballplayer`', '`ballplayer, baseball player`', '`groom, bridegroom`', '`scuba diver`', '`academic gown, academic robe, judge's robe`' e '`military uniform`'... As cales van forzar á Rede a ter o concepto de humán.

e na primeira e cuarta (H0 e H3) para imaxes de insectos. Aquí son precisas dúas cabezas xa que (polo xeral) unha atende á xeralidade da superficie do corpo e a outra a matices (que normalmente a outra cabeza non atendeu) e complementan a descrición. É precisamente nestos casos das cabezas "que atenden a matices" onde observar á representación intermedia da variante de segundo orde (é dicir a cabeza á esquerda de cada dúas) é especialmente nutritivo para o análise xa que o seu suavizado (ver Sección 3.3.4) permite entender a relación global con devandita cabeza e o animal.

- **As pernas:** presente no modelo CRATE na terceira cabeza (H2) para imaxes de vacas e na segunda (H1) para imaxes de insectos. Na variante de segundo orde na quinta cabeza (H4) tanto para imaxes de vacas como de insectos. Aquí observarmos unha cousa moi interesante: por unha banda o modelo orixinal comparte cabeza (a H1) para dous conceptos separables (corpo e pernas), mentras que na variante de segundo orde a cabeza que *atende* ás pernas faino independentemente do animal, o cal correspóndense ca intuición e comunicación humana xa que usamos a palabras "pernas" ou "patas" para refererinos tanto ás das vacas como ás dos insectos. A priori semella máis interesante aglutinar conceptos relacionados abstractamente (pernas de vacas e insectos) que outros máis triviais (tratar ó corpo e ás pernas das vacas como unha soa cousa), perdendo expresividade.

4.2.4 Explicabilidade das dimensións

Como Imagenet é un conxunto de datos tan variado e diverso, as Redes que adestrénse con el teñen que estar preparadas para capturar ca súa representación todo tipo de imaxes naturais. Isto ten dúas implicacións importantes en canto á visualización de parches das dimensións (dispoñible na Figura 4.5):

- A Rede ten que ser quen de recoñecer todo tipo de texturas con todo tipo de cores. Isto implica que a Rede Deve levar a cabo moitas tarefas de P.S.D. e por tanto sería razonable que tivera dimensións asociada a conceptos tales como "segunda derivada orientada cara a dereita", "vermello", "primera derivada sobre fondo azul". É dicir, esperaríamos unha escolma de elementos de baixo nivel, de relativa fácil caracterización manual, necesarios para procesar calquera imaxe.

- As imaxes do conxunto de datos poden presentar o mesmo concepto a traveso de distintas aparencias. Poñamos por caso a clase "`rugby ball`", dependendo da escala da imaxe poderá ocupar maís ou menos tokens, que dende logo serán de cores variados, variada iluminación... en definitiva, se hai algunha dimensión asociada a devandita clase (sabemos que debe haber polo menos unha, pero probablemente sexan varias as

Figura 4.5: Mosaico con parches asociados a todas as dimensións de todas as cabezas dunha Rede adestrada en Imagenet. Neste caso as 6 grandes columnas correspóndense cas 6 cabezas de atención nos que divídese a representación de z_i^ℓ, dentro de cada columna, cada unha das 64 filas é unha dimensión. Así os 15 parches de cada dimensión son precisamente os 15 parches de todo o conxunto de datos Imagenet con maior valor absoluto nesa dimensión, por orde de esquerda a dereita. Figura de autoría propia.

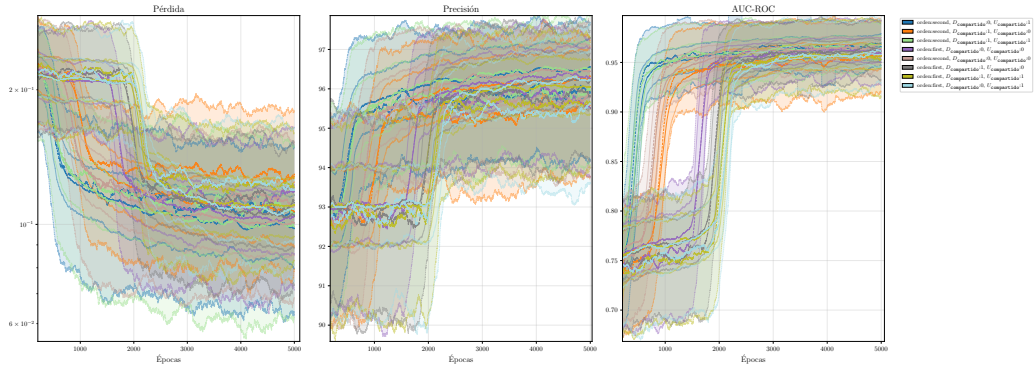

Figura 4.6: Comparativa entre as 2^3 combinacións dos atributos: segundo orde, compartir U e compartir D. Os valores foron suavizados cunha media deslizante e repórtase a desviación típica $\pm\sigma$. Obsérvase que se ben todas as variantes acadan valores similares de converxencia, a transición de fase ocurre a distintos tempos nas distintas arquitecturas, pero razonablemente pódense agrupar por grupos. O primeiro grupo (o da converxencia máis temprana) é o de segundo orde con U compartido, o segundo grupo é segundo orde sen compartir U e o derradeiro grupo é o das variantes de primeiro orde, encabezado polo baseline. Figura de autoría propia.

asociadas) dificilmente poderíamos esperar similitude visual entre os parches representativos desta dimensión.

[NOTA: incluir recortes do mosaico e falar en particular deles (ou non?). todo esto pódese facer sobre unha única rede e logo falar de si hai diferencias ou non entre as redes (eu non atopo)]

4.3 DRIVE

Por ser DRIVE o escenario de adestramento máis económico fíxose unha busca de arquitecturas exhaustiva probando todas as 2^3 ocións da Táboa 3.1, a cal examinaráse na Sección 4.3.1. Co respecto á explicabilidade, estudaranse os mapas de atención e as palabras do diccionario D nas Seccións 4.3.2 e 4.3.3 respectivamente.

4.3.1 Busca de arquitecturas

O resultado do adestramento das oito variantes pódese ver na Figura 4.6 onde vese que as distintas variantes, para esta tarefa e este conxunto de datos acadan (cas suficientes épocas, neste caso 5000) resultados semellantes [3]. En particular a comparativa un a un entre a pro-

[3]Paga a pena notar que, se nos quedaramos na época 1500 todas as variantes de segundo orde terían converxido mentres que as de primeiro orde non, e poderíamos sacar conclusións erroneas. Por tanto é importante

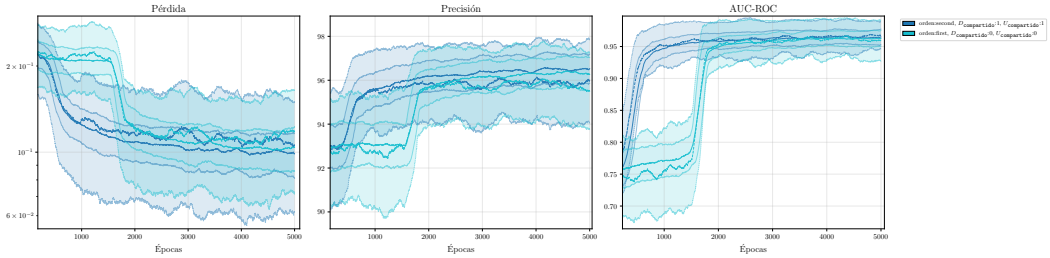

Figura 4.7: Comparativa entre a proposta combo e o CRATE orixinal. Malia a proposta comezar o réxime de converxencia final máis de 1000 épocas antes, eventualmente acadan resultados semellantes. Figura de autoría propia.

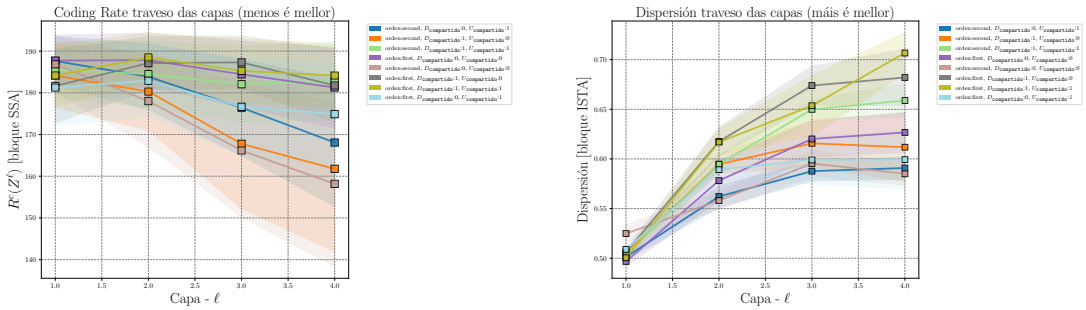

Figura 4.8: Comparativa dos obxectivos MCR^2 e Dispersión entre as variantes expostas na Táboa 3.1. Pódese observar que a variante combo é mellor que o modelo orixinal en ambas métricas. Pódese apreciar que as variantes con mellor Coding Rate (ambas segundo orde sen compartir U, sen compartir e compartindo D) teñen mala dispersión e viceversa. En xeral apréciase unha loita entre estas duas métricas onde as variantes que fano ben nunha fano mal na outra. Por outra banda sí observase en todas as variantes a propiedade de que ambas métricas son mellores ó traveso das capas, segundo o principio de A.D. apreciable na Figura 1.10. Figura de autoría propia.

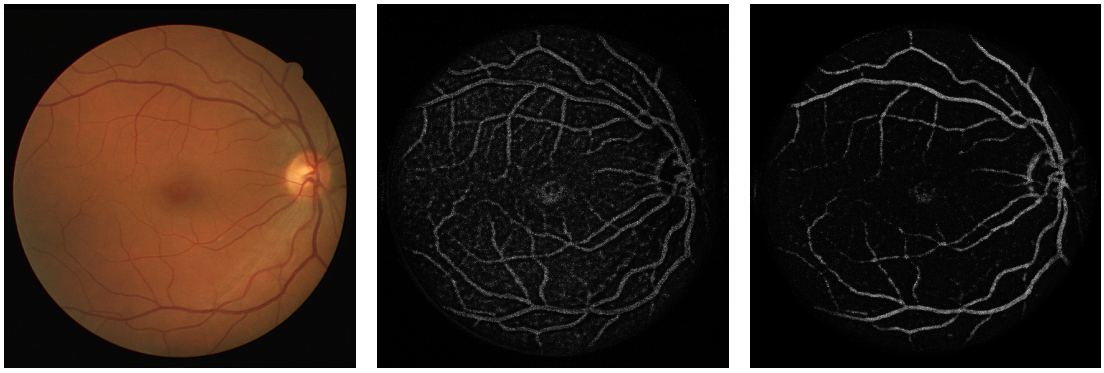

Figura 4.9: Comparativa da segmentación das variantes orixinal (centro, cun DICE de 0.23) e combo (dereita, cun DICE de 0.62) . A imaxe de entrada móstrase por referencia á esquerda. **[NOTA: decir que son unha merda. teño redes que segmentan mellor neste experimento e doutros: a que mellor segmenta deste experimento é primeiro orde que comparte U (a celeste nas gráficas) que ten malas metricas e é a última en converxer. podo pensar pq é esta a que mellor segmenta (actualmente non teño idea) ou calarme a boca]**. A métrica DICE descríbese na Sección 3.7. Figura de autoría propia.

posta combo e a orixinal pódese ver na Figura 4.7, onde apréciase que a proposta ten unha converxencia máis veloz.

Se ben todas estas propostas (incluído o modelo orixinal![26]) fixéronse tendo presentes os obxectivos de MCR^2 e Dispersión, unha pregunta natural é: Cómo reflictense as diferentes decisións arquitecturais nestos obxectivos? Como pódese ver na Figura 4.8, o certo é que (polo menos para as condicións deste experimento) non existen variantes que sexan as mellores en ambas métricas, posto que existe un balanceo entre ambos obxectivos e compiten entre eles [26]. Non obstante, sí é certo que a variante combo é mellor que a orixinal en ambas métricas. Cuantitativamente pódese apreciar que efectivamente a combo é mellor que a orixinal na segmentacións da Figura 4.9.

Todas as arquitecturas teñen catro capas e tres cabezas por capa.

4.3.2 Explicabilidade dos mapas de atención

Recordando a tarefa asociada con este conxunto de datos (ver Sección 3.8) e lembrando que o modelo CRATE segue os principios de separación por tokens do ViT (ver Sección 1.3.8) , un primeiro pensamento é que o modelo **atenderá** principalmente ó token central [4]. Por outra banda, segundo as ideas presentadas na Sección 1.1 tamén esperaríamos que as primeiras capas da Rede realice algunha tarefa de P.S.D. como deteción de bordes. Adicionalemente podería ser interesante atender ós tokens limítrofes de izquierda e dereita (posto que a maior

subliñar a importancia dos adestramentos longos para ofrecer conclusións asertivas, e por tanto as conclusións da Sección precedente son só preliminares.

[4]No caso de ter un numero de tokens $n = k^2$ onde k é impar, o cal foi o certo para o noso experimento.

parte de vasos son horizontais, na deteción de vaso no píxel central é máis interesante a esquerda e dereita que o arriba e abaixo) e finalmente unha comprensión global do parche. Pois todas estas cousas acharonse nos Mapas de Atención das Redes adestradas, por exemplo a da Figura 4.10 que en particular é o modelo orixinal de CRATE.

4.3.3 Explicabilidade das dimensións

Segundo a técnica desenvolvida na Sección 3.4.1 e como vese na Figura 4.11 a Rede aprende *palabras* útiles que permitiranlle sintetizar os elementos da imaxe dun xeito máis abastracto así como discriminar entre aquelas rexións que non teñen interese para a clasificación (pero si que teñen interese para a representación da Rede, porque só pode 'descartar' ou 'ignorar' aquelo que caracteriza).

4.4 RFMiD

O conxunto de datos RFMiD (ver Sección 2.2.3) e a súa tarefa asociada (ver Sección 3.8) supón moita complexidade para as Redes dun xeito moi distinto a Imagenet, aquí existe moita redundancia entre imaxes, o problema só ten dúas clases pero tamén o característico dun ollo patolóxico pode ser moito máis sutil. Aquí non vale inferencias basadas no cor xeral da imaxe ou na forma ou textura xeral, en RFMiD uns píxeles póden ser críticos. Además a motivación para adestrar Redes explicables e interpretables como as expostas neste traballo é de especial importancia neste conxunto de datos porque máis aló da etiqueta de "este fondo de retina posúe ou non unha patoloxía" as Redes **[NOTA: deberían]** brindar unha xustificación a devandita afirmación.

Levouse a cabo unha exploración dun subconxunto das arquitecturas da Taboa 3.1, en particular (i) Modelo CRATE orixinal (ii) Modelo CRATE compartindo U e D (iii) Modelo CRATE segundo orde (iv) Modelo CRATE segundo orde compartindo U e D (proposta combo). Durante o experimento observouse *tambaleos* na optimización das Redes de segundo orde (ver Sección A) e decidiuse repetir o adestramento destas dúas Redes con unha tasa de aprendizaxe máis baixa . Polo que ós mencionados engadeselles (v) Modelo CRATE segundo orde con tasa de aprendizaxe máis baixa.(vi) Modelo CRATE segundo orde compartindo U e D (proposta combo) con tasa de aprendizaxe máis baixa.

Co fin de que as Redes pouderan adestrar efectivamente usáronse Transformadores CRATE de 12 capas e 6 cabezas.

4.4.1 Busca de arquitecturas

O proceso de adestramento e converxencia das seis Redes pódese apreciar na Figura 4.12 onde están dispoñibles os valores de Perdida, Precisión e AUC para o conxunto de adestra-

	Primeiro Orde	Segundo Orde	
	$\eta = 5 \times 10^{-5}$	$\eta = 5 \times 10^{-5}$	$\eta = 1 \times 10^{-5}$
Sen compartir	**0.8776** (orixinal)	0.7431	0.7898
Compartindo	0.8768	0.7192	0.8055

Táboa 4.3: AUC no conxunto de proba para unha escolma de arquitecturas. Nótese que se ben para a mesma tasa de aprendizaxe η a variante de segundo orde ten moito peor rendemento, o feito de que con unha tasa de aprendizaxe máis pequena rinda mellor (acompañada do comportamento de adestramento inestable apreciable na Figura 4.12) suxire que con tasas de adestramento máis baixas podería rendir aínda mellor. Por outra banda ca evidencia presente non pódese inferir moito do impacto de compartir en canto a rendemento.

mento e validación, adicionalmente o AUC para o conxunto de proba está dispoñible na Táboa 4.3. As métricas de Coding Rate e Dispersión por capas pódense atopar na Figura 4.13. Con devandito material apréciase o seguinte:

- As variantes de primeiro orde posúen moitas máis facilidades de adestramento neste problema cos hiperparámetros probados. Pola contra non pode dicirse que acadaran un estado de converxencia posto que a Pérdida en adestramento seguía baixando con velocidade, polo que a comparativa entre elas (a saber, modelo orixinal e compartir U e D) aínda pode ser temprano para facela. Isto débese a que malia agora estar prácticamente empatadas nas métricas habituais, é certo que nos mapas de atención a variante que comparte é máis interpretable (ver Figura 4.14), pero tamén é certo que nas métricas especiais de Coding Rate e Dispersión, de momento a variante orixinal ten un mellor rendemento (ver Figura 4.13).

- As variantes de segundo orde se ben experimentan pouco aprendizaxe (ou un aprendizaxe marxinal), con unha tasa de aprendizaxe máis baixa sí poden aprender máis. O que resulta nas preguntas: Ata cando se pode baixar a tasa de aprendizaxe e seguir experimentando melloras no aprendizaxe? E, Nese punto, como rendirán as variantes de segundo orde? (ver Apéndice A)

- Se ben o modelo orixinal foi o que tivo o mellor rendimento, compartir U e D (o cal converteo nun modelo máis lixeiro xa que pasa de ocupar 30.7 MB con 8M parámetros a 25.1 MB con 6.5M de parámetros) empeora especialmente pouco o seu rendemento, a costa de volvelo moito máis interpretable, como sabemos por construcción e veremos na vindeira Sección na Figura 4.14.

4.4.2 Explicabilidade dos mapas de atención

Como os resultados da busca de arquitecturas exposta na Sección precedente deixaron de manifesto que as únicas variantes (que baixo as nosas condicións de adestramento) tiveron aprendido foron o modelo orixinal e a variante que comparte os tensores U e D procedemos á comparacion da explicabilidade de devanditas Redes á traveso da técnica exposta na Sección 3.3. A comparación levouse a cabo con catro imaxes do conxunto de proba que poden verse xunto cos mapas de atención asociados ás dúas últimas capas das dúas redes para cada unha das catro imaxes na Figura 4.14. Da observación dos mapas pódese extraer as seguintes conclusións:

- As diferentes cabezas exhiben maior diversidade de conceptos ós que atende no caso da Rede que comparte U e D. Esta ofrece unha separación semántica semellante a que pódese atopar en Imagenet (ver Figuras 4.3 e 4.4), que foi precisamente o dominio no que os autores da Rede CRATE demostraron súa propiedade de "separación semántica". Pola contra se ben é certo que as diferentes cabezas da Rede orixinal non atenden exactamente ó mesmo, todas parecen repetir o patrón que (segundo a Rede) ten que ver ca patoloxía da imaxe. Además pódese observar na Figura 4.12 que áinda que a Rede orixinal segue en réxime de aprendizaxe, pode decirse que está na fase de converxencia polo que esta diferencia observada é posible que mantéñase certa áinda con experimentos máis longos.

- A Rede que comparte por atender a cousas distintas non só acércase maís á alegación orixinal dos autores de que as cabezas supoñen unha separación semántica [26] se non que é máis comprensiva ca imaxe. Mentras a Rede orixinal mantén unha hipótese firme ó traveso das cabezas a variante que comparte considera moitos aspectos diferentes da imaxe polo que, de estar errada é máis probable que atenda (por casualidade) a cousas interesantes; no caso da Rede orixinal aférrase a un pensamento e, de estar errada non ten máis que ofrecer. Adicionalemente isto supón unha vantaxe para o adestramento (pódese ver na Figura 4.12 que a variante que comparte rinde lixeira pero constantemente mellor) posto que por atender a máis cousas, máis pode errarse ou acertar e por tanto ten unha sinal supervisoria máis rica. É dicir, como pódese ver na cuarta imaxe de fondo de retina da Figura 4.14 (e as correspondentes filas de mapas de atención) a Rede orixinal sí identificou o patrón relacionado ca patoloxía, non obstante, non di moito máis de esa imaxe. Pola contra, a variante que comparte además de indentificar devandito patrón atende a outras cousas que poden ter que ver ou non ca condición do paciente e que todas elas recibirán unha sinal supervisoria.

En conclusión, a Rede que comparte ofrece uns mapas de atención máis variados ca orixinal, o cal é positivo para a interpretabilidade (xa que a construcción da Rede que comparte

síguese do marco teórico dos autores orixinais [26] e leva consigo unha posta en alza das propiedades de separación semántica que eles afirmaron que a súa Rede tiña) e explicabilidade (posto que máis variedade nos mapas de atención supoñen unha explicación más rica e completa). **[NOTA: esta afirmación debe ir aquí?]**

4.4.3 Explicabilidade das dimensións

Posto que a variante con mellor rendemento no conxunto de proba foi o modelo orixinal, procedeuse á examinación manual das dimensións da mesma, que preséntanse na Figura 4.15. Malia só afondar nas palabras da Rede CRATE orixinal, o lector pode botar unha ollada ás demais na Figura 4.16, dispostas no mesmo orde que na Táboa 4.3, onde pode apreciarse que as Redes que todavía non adestraron ben (a saber, as de segundo orde), aínda non aprenderon tampouco palabras e os parches máis representativos da maioría das dimensións son parches negros (porque hai unha chea deles no conxunto de datos e están asociados a mostras positivas e negativas, non obstante non aportan demasiada información). De feito, este fenómeno (mal adestramento $\leftrightarrow$ palabras do diccionario "negras") pódese observar "en movemento": a Rede con peor rendemento (ver Táboa 4.3, centro abaixo) é a que máis parches negros ten na Figura 4.16, e pódese ver que, progresivamente según máis adestradas están, menos negro teñen. Despóis dos parches negros, o máis fácil de aprender son aqueles parches "raros" no conxunto de datos pero que poden asociarse cunha cor máis ou menos pura. Isto é porque antes de que a Rede aprenda que é o importante, será distraída con aqueles parches máis alexados do centro no espacio orixinal (é dicir, no valor dos píxeles en sí); por tanto nas Redes de segundo orde además de ver moitos parches negros vemos palabras asociadas co "verde" ou o "azul". Seguindo nesta liña, tamén pode dicirse que os parches de a variante orixinal (esquina superior izquierda no mosaico) son lixeiramente máis variados que os da variante que comparte, o cal sería un punto a favor da variante que comparte. En xeral para este problema convén que a Rede non se distraiga con particularidades da captura de imaxe ou parches "coloridos": para resolver o problema de discriminación entre retina patalóxica ou non a Rede ten que prestar moita atención a verdaderas sutilezas no espacio de píxeles, e para que iso sea posible ten que caracterizar de forma distinta moitos parches que semellen parecidos.

En calquera das dúas Redes de primeiro orde observábanse patróns complexos asociados a condicións particulares do fondo de retina baixo certas patoloxías así como patróns máis simples asociados a texturas. As diferencias máis salientables frente ós parches atopados no conxunto de datos DRIVE (ver Sección 4.3.3) son (i) a complexidade, posto que os atopados en RFMiD son moito máis complexos e variados e (ii) a coherencia ou similitude interdimensión, é dicir, canto parécense os parches entre sí; moito máis alta en DRIVE. Ambas diferencias xustificanse na natureza da tarea.

Paga a pena notar que se ben os Mapas de Atención para este conxunto de datos e pro-

blema asociado (ver Sección 3.8) expostos na Sección 4.4.2 sí teñen (ou poder chegar a ter en maior medida) utilidade clínica xa que además de dicirlle ó supuesto profesional da saúde se o paciente ten ou non unha patoloxía, indicanlle onde fixarse; as Palabras do Diccionario non teñen esta propiedade. Por exemplo, os parches con destellos das subfiguras 4.15a, 4.15b e 4.15d, poderían recoller drusas ou estrusados, pero probablemente recollan tamén artefactos producto da captura da imaxe, isto é, as palabras poden chegar a ter pouco ca patoloxía. Non obstante isto non é malo, xa que é preciso para a Rede capturar e recoñecer todas as variacións que ocurren no conxunto de datos para, eventualmente tomar unha decisión descartando aqueles elementos que tivera aprendido que son irrelevantes, como os artefactos de captura, e aqueles que sí teñen que ver ca condición do doente, como poden ser as drusas ou cruces arteriovenosos. Neste sentido a utilidade da visualización das Dimensións non reducese á inspección concreta que a Figura 4.15 fai dunhas poucas palabras; é tamén a visión xeral da Rede en términos de "Cantas palabras distintas de negro ten?" "Como de triviais son esas palabras?" "O concepto detrás da palabra ten relación en sí mesmo con síntomas de patoloxías?". Estas preguntas poden atopar resposta con visualizacións estilo a Figura 4.16.

4.5 Discusións

[NOTA: exactamente que diferencia hai entre esta sección e o capitulo conclusións? as conclusións do TFG sácanse todas de este capítulo.]

- Introdución: limitacións e oportunidades.
- Desenvolvemento
- Conclusións

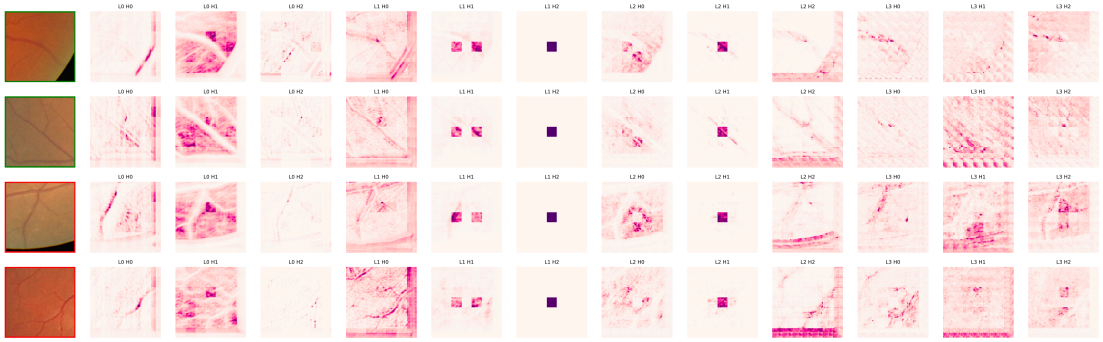

(a) Visualización das Atencións das tres cabezas (H$i, i \in \{0, 1, 2\}$) nas catro capas (L$i, i \in \{0, 1, 2, 3\}$) para catro parches, os dous de arriba de clase positiva e os dous de abaixo de clase negativa. Pódese ver que na primeira capa, a primeira e terceira cabezas (L0H0 e L0H2) implementan deteción de bordes ou alta resposta na primeira derivada da imaxe mentres que a segunda cabeza (L0H1) detecta os vasos en sí. Na segunda capa temos na primeira cabeza (L1H0) un detector de derivadas segundas estilo Laplaciano **[NOTA: Explicar na introdución os conceptos de derivada primeira e laplaciano?]** mentres que as outras dúas cabezas (L1H1 e L1H2) temos a atención adicada os tokens centrais, claves para esta tarefa en particular. Finalmente na derradeira capa, a que tomará a decisión final, obsérvase que en cada token **[NOTA: seguir falando]**.

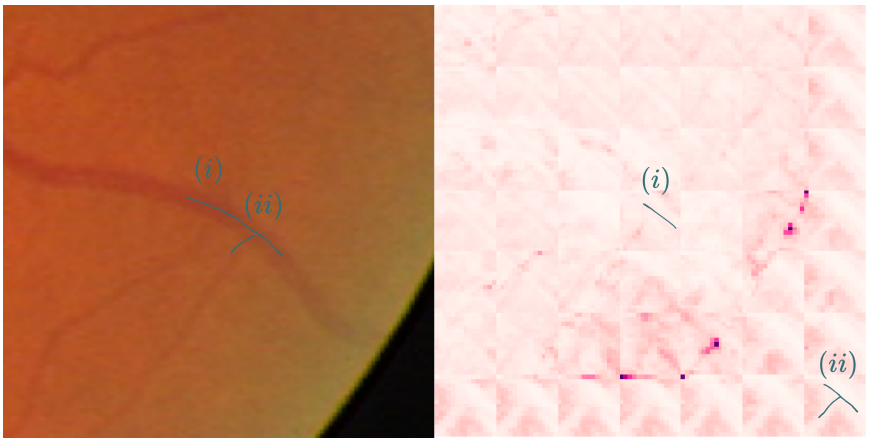

(b) **[NOTA: non estou moi seguro desta explicación]** Zoom dun parche e a atención da segunda cabeza na derradeira capa. Pódese ver como cada token reflicte en si mesmo toda a situación de interese para a inferencia, neste caso a presenza dun vaso no centro do parche. Tamén pódese ver como os distintos tokens supoñen unha pequena translación na zona de interese, polo que o token central captura a escea (i) e outro a (ii).

Figura 4.10: Visualizacións das Atencións, en (a) pódese ver todas as atencións de todas as capas e para imaxes de clase positiva e negativa e en (b) un zoom para apreciar en detalle a resolución da atención. Figura de autoría propia.

(a) Esta palabra recolle venas marrones orientadas aproximadamente horizontalmente de cor marrón sobre fondo alaranxado escuro.

(b) Esta palabra recolle venas marrones orientadas aproximadamente horizontalmente de cor vermello sobre fondo alaranxado vibrante.

(c) Esta palabra recolle porcións do borde superior esquerdo do ollo (ver Figura 2.3).

(d) Esta palabra recolle parches de cor vermello relativamente uniforme.

(e) Esta palabra recolle parches de cor amarelo relativamente uniforme. Correspóndense ca rexión do disco ótico (ver Figuras 2.3 e 3.5).

Figura 4.11: Escolma de parches representativos dalgunhas dimensions dunha Rede adestrada no conxunto de datos DRIVE ca tarefa especificada na Sección 3.8. As dimensións (a) e (b) recollen presenza de venas o cal é de moito interese para a tarefa de clasificación, a dimensión (c) recolle parches das rexións limítrofes co fondo da imaxe e as dimensións (d) e (e) recollen parches de cor 'lisos'. **[NOTA: falar máis ? mostrar un mosaico de todas as palabras como fixen con Imagenet?]**. Figura de autoría propia.

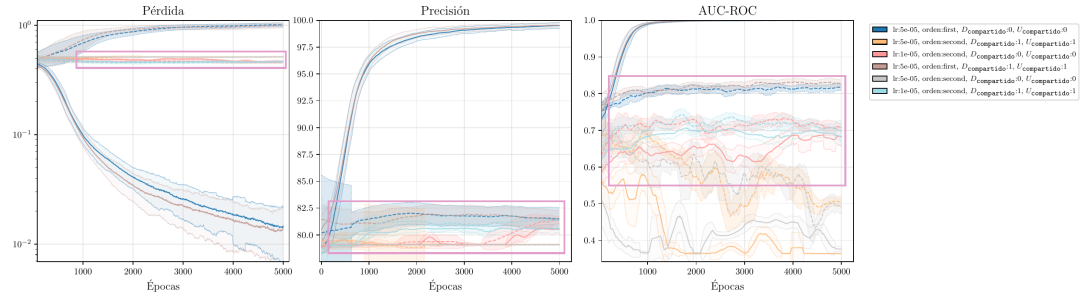

(a) Visión gobal do adestramento para RFMiD. Apréciase un veloz adestramento nas variantes orixinal e primeiro orde compartindo D e U. Non obstante sofren dun gran sobreaxuste, é dicir hai moita diferencia entre adestramento e validación (e os resultados de proba dispoñibles na Táboa 4.3). Pola contra contra todas as demáis variantes parecen ter un peor rendimento. Os rectángulos rosas sinalan a rexión ampliada na vindeira subfigura.

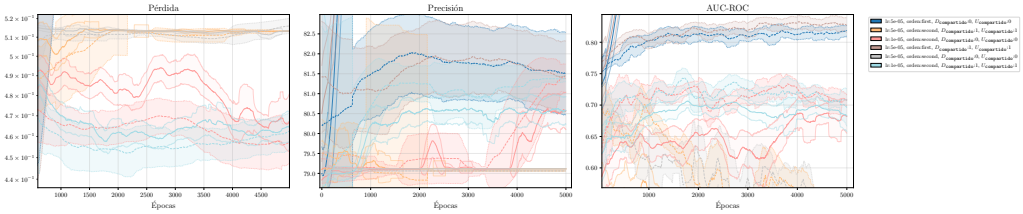

(b) Se ben as variantes segundo orde con tasa de aprendizaxe $\eta = 5 \times 10^{-5}$ ofrecen malos resultados dando moitos tumbos no proceso de aprendizaxe, as mesmas arquitecturas con unha tasa de aprendizaxe máis baixa, sí demostran aprender algo.

Figura 4.12: Comparativa do adestramento dalgunhas arquitecturas sobre RFMiD. Móstranse en liña continua os valores para o conxunto de adestramento e en liña discontinua para o conxunto de validación. Repórtanse valores para a Pérdida do modelo (esquerda), a Precisión (centro) e AUC (dereita). Figura de autoría propia.

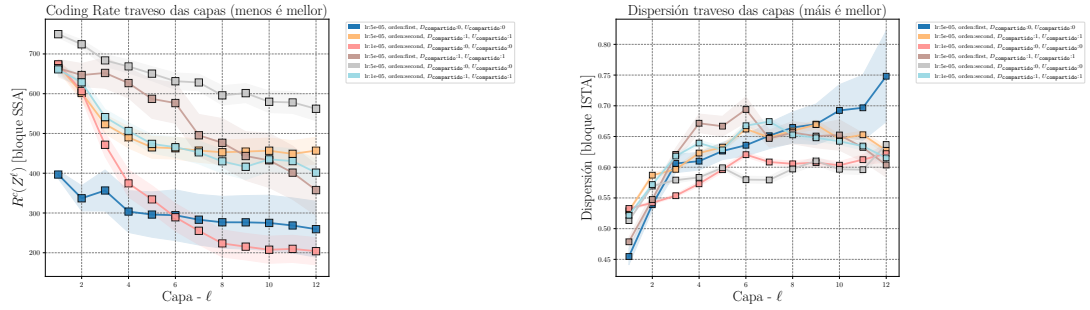

Figura 4.13: Métricas de MCR^2 e dispersión de diferentes arquitecturas sobre RFMiD. Figura de autoría propia.

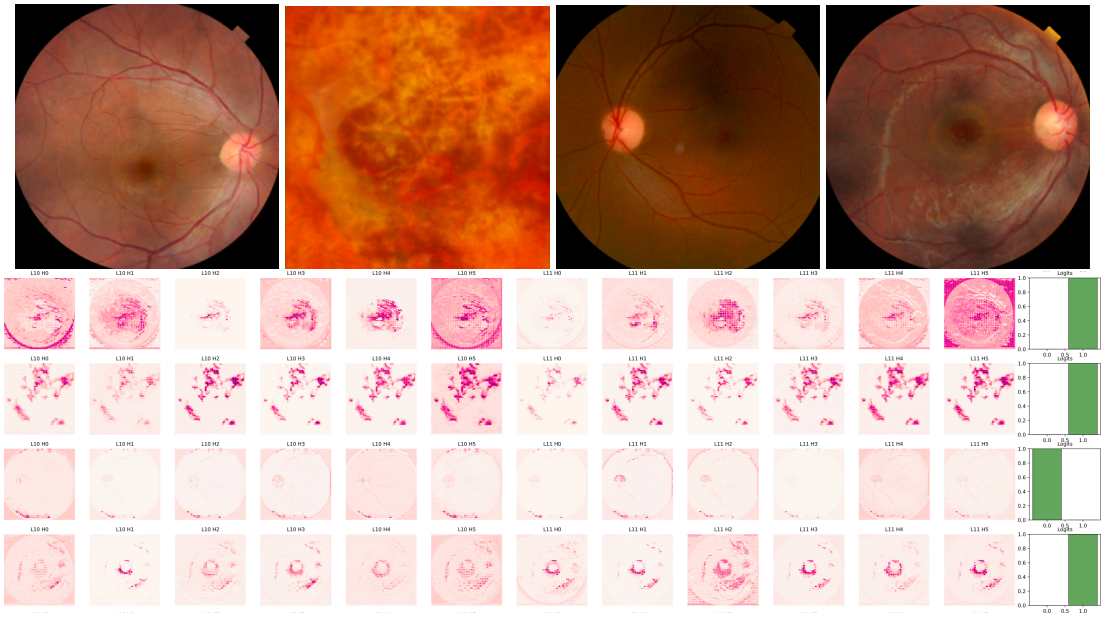

(a) Mapas de atención para as seis cabezas (H$i \in \{0, 1, 2, 3, 4, 5\}$) dúas últimas capas (L$i \in 10, 11$) do modelo CRATE orixinal. Obsérvase como a Rede ten unha *hipótese* de se a Rede ten patoloxía ou non e a manifesta matizando levemente algunhas rexións, pero as 12 cabezas mostradas veñen a atender relativamente ás mesmas rexións. O cal é relativamente bo se é o correcto pero no caso de non selo xa non aporta información real sobre o exemplo e só repetiría 12 veces o seu erro.

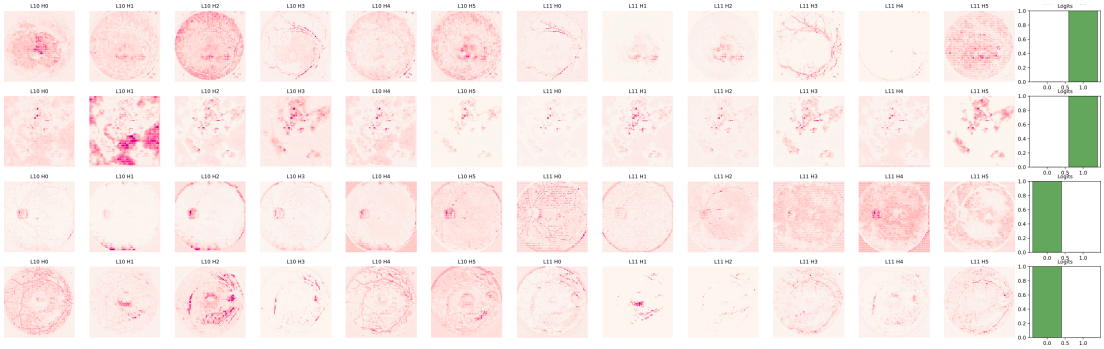

(b) Mapas de atención para as seis cabezas (H$i \in \{0, 1, 2, 3, 4, 5\}$) dúas últimas capas (L$i \in 10, 11$) do modelo CRATE con os tensores U e D compartidos a traveso das 12 capas. Apréciase duas cosas notables: (i) cada cabeza atende a cousas realmente distintas, pode ser que non todo teña que ver co que cree a Rede que é un sintóma patolóxico (non é malo) pero dende logo aténdese a todas as rexións cunha separación semántica semellante á atopada en Imagenet (ver Figura 4.3) (ii) unha cabeza dada ten unha relación coa mesma cabeza da seguinte capa, neste caso a cabeza L10Hj coa L11Hj. Esta relación se ben está claro que existe (o sabemos pola construcción da arquitectura) non é trivial e moitas veces incorpóranse rexións atendidas por outras cabezas.

Figura 4.14: Visualización dos mapas de atención sobre RFMiD. Arriba móstranse os catro ollos usados para realizar inferencia (os cales son patolóxicos todos) e en (a) e (b) compáranse os mapas de atención (para todas as cabezas das dúas últimas capas) da Red CRATE orixinal e a variante que comparte U e D respectivamente. Á dereita de cada fila móstrse a predicción de se é patolóxico (1) ou non (0). Malia neste exemplo acadar mellor resultado o modelo orixinal ($\frac{3}{4}$ contra $\frac{2}{4}$) as atencións do modelo que comparte tensores son máis variadas e suxerentes. Figura de autoría propia.

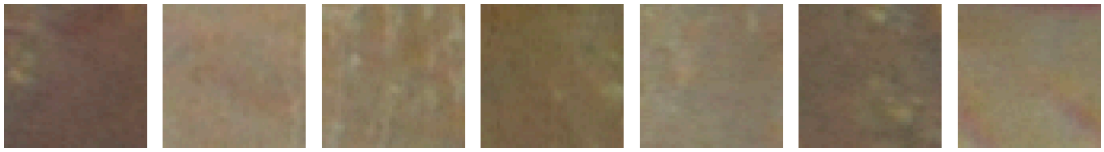

(a) Esta palabra recolle parches de fondo branco con destellos o salpicóns anómalos de pequeno tamaño e cor verde.

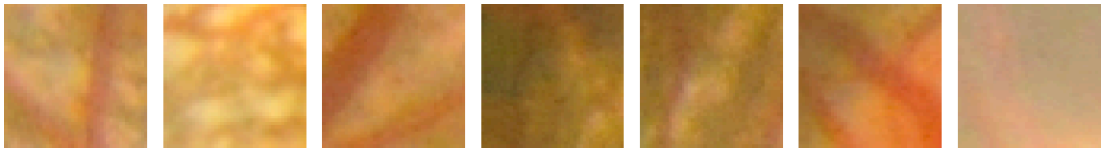

(b) Esta palabra recolle parches de fondo verduzco con destellos o salpicóns anómalos de tamaño medio e cor amarela.

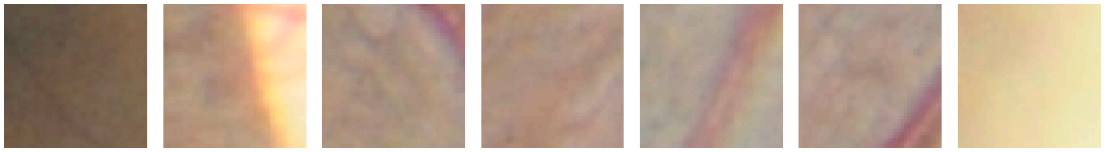

(c) Esta palabra recolle parches de fondo branco con vasos nítidos.

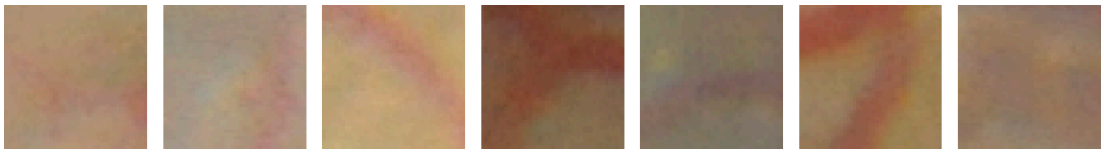

(d) Esta palabra recolle parches de fondo crema, con salpicóns verdes e vasos borrosos.

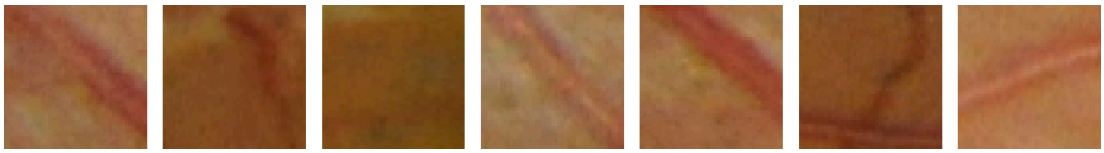

(e) Esta palabra recolle parches de venas normais aparentemente.

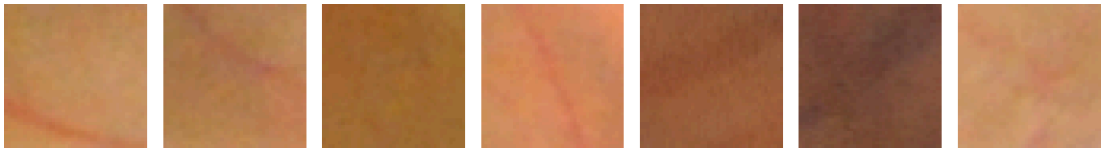

(f) Esta palabra recolle parches de capilares moi finos.

(g) Esta palabra recolle parches de cor vermello - amarelo.

Figura 4.15: Escolma de parches representativos dalgunhas dimensions dunha Rede adestrada no conxunto de datos RFMiD ca tarefa especificada na Sección 3.8. As dimensións (a)-(b) recollen mostras de destellos con o sin vasos, as dimensións (b)-(f) recollen parches de vasos de distintos tamaños e cores e na dimensión (g) recóllense patróns máis sinxelos estilo gradiente de cor. Figura de autoría propia.

Figura 4.16: Mosaico con parches asociados a todas as dimensións de todas as cabezas das seis Redes adestradas en RFMiD. A disposición e a mesma que a usada na Táboa 4.3. Notar que existe unha correlación total entre o adestrada que está unha Rede e os maduras que son as súas dimensións, é dicir: como de trivial é o concepto dunha dimensión está asociado a como de ben rinde unha Rede . Figura de autoría propia.

Capítulo 5

Conclusións

Neste capítulo pechase o traballo retomando as preguntas plantexadas na Sección 3.9 . Comeza cunha valoración do desenvolvemento do proxecto e da súa relación coas competencias da titulación; segue coas conclusións sobre cada unha das achegas: a variante de segundo orde, o cruce de ordes, a variante que comparte U e D, e a implicación do uso de CRATE no contexto de imaxe médica , graduando a firmeza de cada afirmación segundo a evidencia que a sustenta; e remata coas limitacións do estudo e as liñas de traballo futuro.

5.1 Valoración do TFG

O TFG plánteouse como unha oportunidade de coñecer e investigar métodos de interpretabilidade e explicabilidade na corrente actual da A.A., a A.P. grazas á arquitectura CRATE proposta polo profesor Yi Ma. Nese senso chegouse a unha gran satisfacción dos obxectivos posto que o alumno foi quen de derivar unha nova arquitectura interpretable e xunto cos titores deseñaronse e implementáronse métodos para examinarla e ofrecer explicabilidade ós resultados obtidos ca mesma.

Para isto foi necesaria a comprensión das asignaturas 'mátematicas' do Grao como 'Álxebra', 'Cálculo' e 'Optimización Matemática' e das asignaturas relativas ó A.A. como 'Fundamentos da Aprendizaxe Automática', e 'Modelos avanzados de Aprendizaxe Automática I e II' así como das asignaturas asociadas ó A.P. como 'Aprendizaxe Profunda' e 'Visión por Computadora Avanzada'. Además polo alcance do traballo presente foi preciso que o alumno afondara en temas máis avanzados relativos a estas asignaturas como, en xeral, toda a teoría do MCR^2 (que á súa vez precisaba a comprensión de temas tamén avanzados como o A.D., o deseño desenrolado de Redes e conceptos sobre dispersión).

En particular o traballo supuso moito aprendizaxe no relativo ó adestramento de Redes, posto que probáronse distintas Redes con distintos conxuntos de datos, as dinámicas do adestramento eran particulares para cada situación. Por iso a análise das curvas de Pérdida xunto

cos métodos de explicabilidade dotou o alumno de maior intuición sobre o adestramento de Redes.

5.2 Resultados

- **[NOTA: en canto a mapas de atención parece que en Imagenet a variante segundo orde aínda con peor rendemento ofrecía mellor separación semantica (falta probas cuantitativas). aunque esta afirmación é un pouco 'trust me bro']**
- **[NOTA: en canto a palabras do dicionario non teño conclusión ningunha. :/. que tipo de conclusións poderíanse ter?]**

5.2.1 Variante Segundo Orde

Sobre o comportamento do segundo bloque de Atención Multicabeza a evidencia (ver Sección 4.2.3) mostra que *probablemente* a hipótese correcta da Sección 3.3.4 sea a (b), é dicir:

A nova (segunda) cabeza ofrece un comportamento semellante á cabeza do CRATE *orixinal e a primeira adáptase e toma un novo rol.*

En particular semella que é así porque as saídas dos Mapas de Atención do modelo orixinal e da segunda cabeza do modelo segundo orden son moi parecidas en canto a que en casos atenden exactamente ó mesmo pero en xeral polo *espíritu*. Isto é, dívidense as rexións de maior relevancia en "conceptos" nos que cada cabeza asígnase un ou varios e estas resaltan exclusivamente ese concepto. Pola contra, a primeira cabeza no modelo de segundo orde parece ser en realidade unha versión suavizada da segunda. Isto ten unha xustificación teórica e un interese particular.

Xustificación teórica. A entrada da primeira cabeza é a representación dos tokens Z proxectada nun certo espazo U_k. Poderíamos pensar que para un certo token z_i esta proxección , $U_k^{'} z_i$ ten valores asociados a "conceptos abstractos" (e.g. o valor $[U_k^{'} z_i]_j$ indica a presencia de "orellas" nese token). Agora, no caso da segunda, as entradas desta son a similaridade con outros tokens, en particular para un certo token z_i esto sería $(U_k^{'} Z)^{'} U_k z_i$, onde o valor $[(U_k^{'} Z)^{'} U_k z_i]_j$ dí a similaridade global da representacións de z_i e z_j baixo a proxección do espazo U_k. Filosóficamente isto pódese resumir en: a primeira cabeza codifica os tokens nunha serie de conceptos ou incluso palabras dun dicionario, que definen que é o token "para caracterizar un token con unha orella deberá ter moito valor na entrada asociada a orella", mentras que a segunda codifica os tokens nunha serie de tokens, chamémoslles os seus veciños, que definen quen é o token "para caracterizar un token con unha orella deberá ser semellante a outros tokens de orellas".Pois ben, malia as dúas representacións parecer moi distintas, o comportamento de U_k define todo e poden chegar a ser equivaltes (que é de feito

o observado nas Figuras 4.3 e 4.4). Para que pase esto ocurra, a proxección en U_k debe ser menos discriminativa ou máis suave "suave", se non, ninguén tería moitos veciños.

Interese. Este novo rol das proxeccións U_k, máis suaves *poden chegar a ter* intere polos seguintes motivos[1]:

- A visualización do Mapa suavizado é unha nova achega en sí, ofrecendo novas posibilidades de explicabilidade ou servido como complemento ás visualizacións da outra cabeza.
- Por ver o comportamento das dúas cabezas e reflexionar porque compórtanse así, temos máis evidencia e coñecemento sobre cómo funciona o CRATE, é dicir este *probablemente* non precise outra cabeza. Todo isto contribue á interpretabilidade do modelo.

Se ben non é imposible que para un conxunto de datos, unha tarefa e uns hiperparámetros, acádese mellor resultado ca variante segundo orde que co modelo orixinal (recordemos que na tarefa asociada a DRIVE acadouse mellores resultados cas variantes de segundo orde, ver Sección 4.3.1), o destacable na nosa opinión é que o modelo orixinal non precise "aproximar ben a inversa" para problemas a gran escala. Non é casualidade que no único escenario no que a variante de segundo orde acadou mellores resultados fora o menos complexo e abstracto, en DRIVE ó ser unha tarefa simple (ver Sección 3.8) a restricción adicional que impoñía a segunda cabeza resultaba ventaxoso pero nas outras dúas tarefas, máis complexas, ter a segunda cabeza presente dificultou o adestramento (precisando tasas de apredizaxe máis baixas como pódese ver na Táboa 4.3), semellando a unha *regularización* do modelo. Finalmente, o achar que a variante de Segundo Orde non supera en rendemento á orixinal ten dúas implicacións positivas:

- Como esta variante pretendía correxir unha aproximación da variante de primeiro orde, agora sabemos que o modelo orixinal non se veia perxudicado por non ter aproximado mellor.
- Como o CRATE orixinal era tan parecido a un ViT (ver Sección 1.6), tanto que CRATE podía verse como unha *interpretación do rol dos compoñentes do ViT*, o achamento de que o CRATE non precisa de outra cabeza, non pon en perigo a visió de CRATE como unha interpretación do ViT (noutro caso, sería un ViT un pouco raro).

5.2.2 Cruce de ordes

A idea de adestrar dúas Redes con arquitecturas distintas e intercambiar os parámetros en inferencia, notivada na Sección 3.2.3 viuse desmantelada ca evidencia exposta na Sección

[1] Máis experimentación é necesaria para afirmar categóricamente.

4.2.2. Unha vez comprendido, na Sección anterior o rol das cabezas na variante de segundo Orde é doado entender o fracaso da idea inicial. A esperanza de éxito baseábase na premisa de que a primeira cabeza conservaba o seu rol mentres que a segunda correxía erros, pero visto que non é o caso, é razonable o fracaso do cruze. Este fracaso non obstante contribue á comprensión da Rede, contribuíndo así á súa interpretabilidade.

5.2.3 Variante que comparte

Segundo a motivación da Sección 3.5 e os resultados das búsquedas de arquitectura das Seccións 4.2.1, 4.3.1 e 4.4.1 e a comparativa das visualizacións dos mapas de atención co modelo orixinal no conxunto de datos RFMiD na Sección 4.4.2 pode afirmarse que, a variante que comparte sí presenta vantaxes tanto en rendemento absoluto como en materia de explicabilidade.

En particular no experimento con Imagenet da Sección 4.2.1, onde adestrouse a variante segundo orde con e sen compartir, ó longo de todo o adestramento a que comparte exhibía mellor rendemento nas métricas de Precisión e Auc Roc foi a que compartía. No experimento da Sección 4.3.1 ocurre unha peculiaridade, compartir (en particular U) beneficia ás Redes de segundo orde e perxudican ás de primeiro. En consecuencia a variante combo (é dicir, compartir e segundo orde) é mellor que o modelo orixinal. Finalmente no escenario de RFMiD pódese ver na Figura 4.12 que durante o adestramento, as 3 variantes sin compartir probadas: orixinal, segundo orde e segundo orde con menor tasa de apredizaxe eran superadas polas súas versións que sí compartían. Aínda que a mellora en rendemento absoluto sea moi pequena (tanto de feito que nas variantes orixinal / primeiro orde que comparte óbservase unha *lixeira* mellor xeneralización á que non comparte) sigue sendo meritoria de interese a variante que comparte xa que é máis interpretable (sigue os principios do A.D., ver Seccións 1.3.9 e 3.5), explicable (ver Seccións 3.5 e 4.4.2) e é unha rede máis pequena.

5.2.4 Crate en imaxen médica

Se ben métodos xa coñecidos como Dino [28] permitían obter mapas de atención para explicar as decisións dos ViT, o cal é moi importante pola natureza crítica da imaxe médica (ver Seccións 1.2 e 1.7.2), baixo o noso coñecemento non usaronse arquitecturas ViT interpretables como Crate neste ámbito. Dotando a este traballo dunha natureza inovadora, avanzado cara a interpretabilidade e explicabilidade conxunta nos modelos de A.P..

En particular os mapas de atención e as visualizacións das palabras de atención poden axudar ó profesional sanitario a entender porque o modelo tomou unha decisión e ó enxeñeiro que deseñe e adestre as Redes a entender como de ben está adestrada e como de limitada pode chegar a estar.

5.3 Limitacións

O presente traballo, por cuestións de tempo non puido cubrir aspectos que valoramos importantes. A saber:

- **Adestramentos máis largos.** Non consideramos a ningún dos adestramentos expostos neste traballo como 'concluso' no senso de que estamos seguros que, con máis épocas as Redes tiveran aprendido máis. É posible que por 'truncar' os adestramentos de xeito prematuro saquemos conclusións erroneas, Que pensaríamos dos resultados de Drive se tiveramos cortado os adestramentos ás 1500 épocas? Que as variantes de primeiro orden non eran quenes de aprender, ver Figura 4.6.
- **Maior busca de hiperparámetros.** Además da busca de hiperparámetros presentada para o conxunto de datos RFMiD, realizáronse pequenas e preliminares buscas de hiperparámetros, todas elas con insuficientes épocas. De novo, con outros hiperparámetros os nosos resultados poderían cambiar.
- **Máis adestramentos por variante.** O sólo ter un adestramento para cada par `(variante, conxunto_datos)` é posible que por 'sorte' os resultados dun adestramento non sexan representativos do que esa variante podería chegar a facer nese conxunto de datos.
- **Cobertura completa.** É decir, probaar as 8 variantes nos 3 conxuntos de datos.

Non obstante estas cuestións son 'só' realativas a tempo de cómputo, é decir, ainda que levalas a cabo teña un impacto científico, pola nosa parte só sería deixar un programa executándose no servidor. E posto que tiñamos resultados dabando decidiuse rematar o traballo nestas condicións.

5.4 Traballo futuro

Como o presente traballo abrangueu tantos eidos de investigación e implementación, deixáronse no tinteiro temas que con máis tempo sería moi interesante cubrir, enuméranse aquí algúns deles:

- Facer adestramentos máis longos e con todas as variantes para o conxunto de datos Imagenet, en particular sería moi interesante probar a variante que comparte de primeiro orde.
- Facer adestramentos máis longos e con todas as variantes para o conxunto de datos RFMiD, en particular sería moi interesante usar toda a supervisión do conxunto de datos,

é dicir distinguir entre as patoloxías en sí e non só entre patolóxico contra non patolóxico. Para isto último sería interesante usar a técnica de aprendizaxe multitarea Mao [**?**].

- Extender o principio de A.D. que levounos a compartir U e D máis alo, compartindo tamén as matrices W e os `bachnorm`. Dese xeito teríase unha Rede totalmente repetida que faría inferencias a traveso dun único operador reiterado. Sería posible chegar a resultados comparables ca Rede orixinal tal e como o observamos para o caso de compartir U e D? Seguir nesta liña permitiría avanzar na interpretabilidade da Rede entendendo os seus límites.

- Empregar os U e D adestrados compartidos como inicialización de devanditos tensores dunha Rede que non os comparte. Esta operativa podería chegar a conservar de xeito aproximado as bondades de compartir pero acadando mellor rendemento. Ou mesmo valdría para estudar se o estado dos tensores compartidos é 'inestable' e no caso de relaxarse a restricción de que ten que ser iguais o proceso de adestramento os faría moi distintos.

- Ademáis da avaliación cualitativa dos mapas de atención sería moi interesante incluir unha avaliación cuantitativa como fíxose en [23], para poder avaliar máis obxetivamente o impacto das distintas variantes na explicabilidade.

- Empregar a técnica de cruce para facer *finetuning*. Agora sabemos que simplemente intercambiar a arquitectura (de primeiro orde a segundo ou viceversa) cos mesmos pesos non resulta exitoso en sí, pero queda aberta a pregunta de: Que pasaría se unha vez intercambiados os pesos procedesare a un *finetuning*?

Apéndices

Apéndice A

Optimización non convexa sen restricciónes

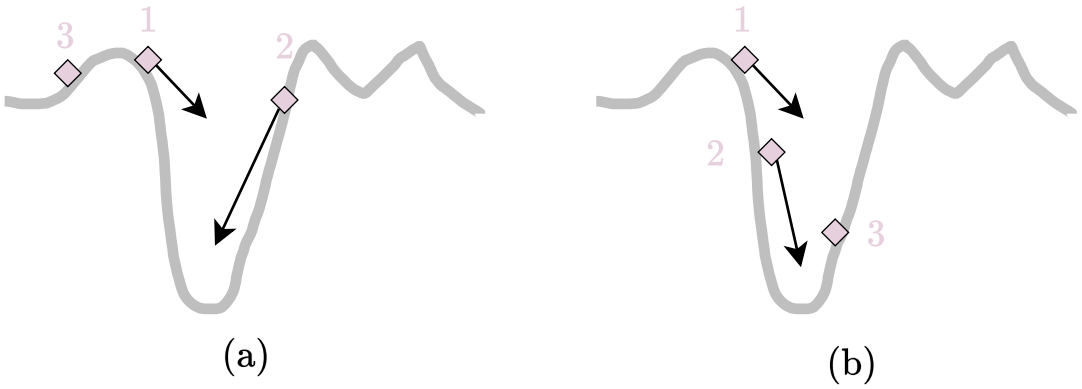

Figura A.1: Ilustración da influencia da eleción da tasa de aprendizaxe. Repórtase un un punto incicial (1) co seu gradiente negativo (dirección de máximo descenso), e as dúas iteracións seguintes. En (a) empregouse unha tasa de aprendizaxe grande que supón trucar de "parede" en cal de avanzar nunha dirección. En (b) utilizouse unha tasa de aprendizaxe máis baixa o que permite seguir na mesma rexión polo menos ata que se está suficientemente preto do mínimo. Figura de autoría propia.

A.1 Planteamento

O adestramento de Redes Neuronais é un problema de minimización non convexa sen restricciónes sobre os parámetros θ da mesma baixo unha función de perda $\mathcal{L}$ que intuitivamente indica o verosimil que lle resulta o conxunto de datos xunto cas súas etiquetas á Rede. É dicir, quérese:

$$\min_\theta \quad \mathcal{L}(\theta)$$

Polo descoñezemento obsuluto da forma ou propiedades da función $\mathcal{L}$, a optimización lévase a cabo via descenso de gradiente:

$$\theta_{t+1} = \theta_t - \eta \nabla \mathcal{L}(\theta_t), \tag{A.1}$$

onde η e a tasa de aprendizaxe. Pola non convexidade, non hai garantías de achar o mínimo e temos que conformarnos cun mínimo local suficientemente bo.

A.2 O efecto da tasa de aprendizaxe η

A eleción de η é moi importante posto que non só determina a velocidade á que pode chegarse a un mínimo local axeitado pero é quen de permitir quegar ou non. Isto é se un escolle unha tasa de aprendizaxe máis pequena do ideal vai ter que realizar máis iteracións da expresión (A.1), pero si un escolle unha tasa de aprendizaxe máis grande, cando se estea chegando ó mínimo, a optimización pode pasar de largo ou 'rebotar' nas paredes de $\mathcal{L}$, como pode verse na Figura A.1. Isto implacará oscilacións ou diverxencias nas Figuras de Perda contra número de épocas, pola contra se η é axeitada, a gráfica será suave.

A.3 Extensións sobre o descenso de gradiente

A idea da expresión (A.1) é de A. L. Cauchy no 1847, dende aquela e especialmente nos contextos de A.A. e A.P. desenvolvéronse extensions do algoritmo máis axeitadas para o adestramento de R.N.A.. En particular neste traballo fíxose uso de AdamW [42] que icorpora tasas adaptativas por parámetro e regularización sobre $||\theta||_2$, é dicir a norma dous dos parámetros, desacoplada da actualización do gradiente. A eleción deste optimizador débese a non variar a configuración dos autores orixinais.

Relación de Acrónimos

A.A. Aprendizaxe Automática. iv, 1–4, 6–8, 10, 18, 24, 69, 77

A.D. Aprendizaxe Desenrolada. iv, 10, 11, 18, 20, 29, 39, 56, 69, 72, 74

A.P. Aprendizaxe Profunda. iv, 1, 3–5, 8–11, 16, 24, 26, 41, 69, 72, 77

A.R. Aprendizaxe de Representacións. 15, 16

C.N.N. Rede de Neuronas Artificiais Convolucionais (*Convolutional Neural Network*). 7, 9–11, 15, 20

I.A.I Intelixencia Artificial Interpretable. 4, 5

I.A.X Intelixencia Artificial Explicable. 4, 5

M.L.P. Perceptrón Multicapa (Multi-Layer Percetron). 8, 10, 13, 17, 19

MCR^2 Maximal Coding Rate Reduction. iv, v, 15, 18, 20, 34, 35, 39, 42, 48, 56, 57, 65, 69

P.S.D. Procesamento de Señais Dixitais. 2, 3, 53, 57

R.N.A. Rede de Neuronas Artificiais. 2, 3, 7, 10, 15, 18, 22, 24, 26, 31, 35, 77

Glosario

explicabilidade Cualidade dun sistema de toma de decisións xunto con ferramentas auxiliares ou non de xustificar as súas decisións. Responde á pregunta: Porqué se tomou esta decisión?. iv, 1, 3–7, 20, 21, 29, 30, 34, 43, 44, 46, 47, 50, 51, 55, 60, 61, 69–72, 74

interpretabilidade Cualidade intrínsica dun sistema de toma de decisións que permite coñecelo, de xeito que os seus compoñentes están xustificados e enténdese o seu rol. 1, 3, 5, 20, 29, 30, 46, 60, 69, 71, 72, 74

píxel Elemento máis pequeno dunha imaxe, contén a información de cor (ou luminosidade) nunha localicación da mesma.. 3, 7, 13, 21, 36, 38, 44, 58, 61

tasa de aprendizaxe Hiperparámetro que determina o tamaño dos pasos cos que se actualizan os parámetros dun modelo durante o adestramento.. iii, v, vi, 48, 58, 59, 65, 76, 77

token Vector que apréndese que forma parte da entrada e fluxo interno de modelos Transformadores.. 18, 19, 30, 35, 36, 38, 39, 41, 44, 53, 57, 63, 70

Bibliografía

[1] G. E. P. Box and N. R. Draper, *Empirical Model-Building and Response Surfaces*. John Wiley & Sons, 1987.

[2] R. S. Zimmermann, T. Klein, and W. Brendel, "Scale alone does not improve mechanistic interpretability in vision models," in *Advances in Neural Information Processing Systems 36*, ser. NeurIPS 2023. Neural Information Processing Systems Foundation, Inc. (NeurIPS), 2023, p. 57876–57907. [En liña]. Dispoñible en: http://dx.doi.org/10.52202/075280-2523

[3] Parlamento Europeo e Consello da Unión Europea, "Regulamento (UE) 2024/1689 sobre intelixencia artificial," 2024. [En liña]. Dispoñible en: https://eur-lex.europa.eu/eli/reg/2024/1689/oj

[4] M. Garouani, J. Mothe, A. Barhrhouj, and J. Aligon, "Investigating the duality of interpretability and explainability in machine learning," 2025. [En liña]. Dispoñible en: https://arxiv.org/abs/2503.21356

[5] M. T. Ribeiro, S. Singh, and C. Guestrin, ""why should i trust you?": Explaining the predictions of any classifier," 2016. [En liña]. Dispoñible en: https://arxiv.org/abs/1602.04938

[6] S.-Y. Byun and W. Lee, "Vit-reciprocam: Gradient and attention-free visual explanations for vision transformer," 2023. [En liña]. Dispoñible en: https://arxiv.org/abs/2310.02588

[7] S. Verma, A. Lahiri, J. P. Dickerson, and S.-I. Lee, "Pitfalls of explainable ml: An industry perspective," 2021. [En liña]. Dispoñible en: https://arxiv.org/abs/2106.07758

[8] H. Barlow, "Single units and sensation: A neuron doctrine for perceptual psychology?" *Perception*, vol. 1, pp. 371–394, 12 1972.

[9] M. Aharon, M. Elad, and A. Bruckstein, "rmk-svd: An algorithm for designing overcomplete dictionaries for sparse representation," vol. 54, no. 11, p. 4311–4322, November 2006. [En liña]. Dispoñible en: http://dx.doi.org/10.1109/TSP.2006.881199

[10] J. Wright and Y. Ma, *High-Dimensional Data Analysis with Low-Dimensional Models: Principles, Computation, and Applications*. Cambridge University Press, January 2022. [En liña]. Dispoñible en: http://dx.doi.org/10.1017/9781108779302

[11] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, and R. Salakhutdinov, "Dropout: A simple way to prevent neural networks from overfitting," *Journal of Machine Learning Research*, vol. 15, no. 56, pp. 1929–1958, 2014. [En liña]. Dispoñible en: http://jmlr.org/papers/v15/srivastava14a.html

[12] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," 2015. [En liña]. Dispoñible en: https://arxiv.org/abs/1512.03385

[13] V. N. Vapnik, *The nature of statistical learning theory*. Springer-Verlag New York, Inc., 1995.

[14] R. Tibshirani, "Regression shrinkage and selection via the lasso," *Journal of the Royal Statistical Society: Series B (Methodological)*, vol. 58, no. 1, pp. 267–288, 01 1996. [En liña]. Dispoñible en: https://doi.org/10.1111/j.2517-6161.1996.tb02080.x

[15] A. Beck and M. Teboulle, "A fast iterative shrinkage-thresholding algorithm for linear inverse problems," *SIAM Journal on Imaging Sciences*, vol. 2, no. 1, pp. 183–202, 2009.

[16] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, and N. Houlsby, "An image is worth 16x16 words: Transformers for image recognition at scale," 2020. [En liña]. Dispoñible en: https://arxiv.org/abs/2010.11929

[17] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, "Attention is all you need," 2017. [En liña]. Dispoñible en: https://arxiv.org/abs/1706.03762

[18] X. Chen, C.-J. Hsieh, and B. Gong, "When vision transformers outperform resnets without pre-training or strong data augmentations," 2021. [En liña]. Dispoñible en: https://arxiv.org/abs/2106.01548

[19] V. Monga, Y. Li, and Y. C. Eldar, "Algorithm unrolling: Interpretable, efficient deep learning for signal and image processing," 2019. [En liña]. Dispoñible en: https://arxiv.org/abs/1912.10557

[20] M. D. Zeiler and R. Fergus, "Visualizing and understanding convolutional networks," 2013. [En liña]. Dispoñible en: https://arxiv.org/abs/1311.2901

[21] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra, "Grad-cam: Visual explanations from deep networks via gradient-based localization," 2016. [En liña]. Dispoñible en: https://arxiv.org/abs/1610.02391

[22] K. H. R. Chan, Y. Yu, C. You, H. Qi, J. Wright, and Y. Ma, "Redunet: A white-box deep network from the principle of maximizing rate reduction," 2021. [En liña]. Dispoñible en: https://arxiv.org/abs/2105.10446

[23] Y. Yu, T. Chu, S. Tong, Z. Wu, D. Pai, S. Buchanan, and Y. Ma, "Emergence of segmentation with minimalistic white-box transformers," 2023. [En liña]. Dispoñible en: https://arxiv.org/abs/2308.16271

[24] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. MIT Press, 2016, http://www.deeplearningbook.org.

[25] A. Géron, *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems*. O'Reilly Media, 2019. [En liña]. Dispoñible en: https://books.google.es/books?id=HHetDwAAQBAJ

[26] Y. Yu, S. Buchanan, D. Pai, T. Chu, Z. Wu, S. Tong, H. Bai, Y. Zhai, B. D. Haeffele, and Y. Ma, "White-box transformers via sparse rate reduction: Compression is all there is?" 2023. [En liña]. Dispoñible en: https://arxiv.org/abs/2311.13110

[27] I. Daubechies, M. Defrise, and C. De Mol, "An iterative thresholding algorithm for linear inverse problems with a sparsity constraint," 2003. [En liña]. Dispoñible en: https://arxiv.org/abs/math/0307152

[28] M. Caron, H. Touvron, I. Misra, H. Jégou, J. Mairal, P. Bojanowski, and A. Joulin, "Emerging properties in self-supervised vision transformers," 2021. [En liña]. Dispoñible en: https://arxiv.org/abs/2104.14294

[29] Instituto Cervantes. (2026) O que algo quere, algo lle custa. Centro Virtual Cervantes. [En liña]. Dispoñible en: https://cvc.cervantes.es/lengua/refranero/Ficha.aspx?Par=58652&Lng=2

[30] L. M. Castro, "modelo-tfg-fic: Modelo de memoria de tfg da facultade de informática (fic) da universidade da coruña," https://gitlab.com/lauramcastro/modelo-tfg-fic, 2020, gitLab repository, accessed 2026-06-14.

[31] Matplotlib Development Team, "Choosing colormaps in matplotlib," https://matplotlib.org/stable/users/explain/colors/colormaps.html, 2026, accessed: 2026-08-25.

[32] S. Panchal, A. Naik, M. Kokare, S. Pachade, R. Naigaonkar, P. Phadnis, and A. Bhange, "Retinal fundus multi-disease image dataset (rfmid) 2.0: A dataset of frequently and rarely identified diseases," *Data*, vol. 8, no. 2, 2023. [En liña]. Dispoñible en: https://www.mdpi.com/2306-5729/8/2/29

[33] J. Staal, M. Abramoff, M. Niemeijer, M. Viergever, and B. van Ginneken, "Ridge-based vessel segmentation in color images of the retina," *IEEE Transactions on Medical Imaging*, vol. 23, no. 4, pp. 501–509, 2004.

[34] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and L. Fei-Fei, "Imagenet: A large-scale hierarchical image database," in *2009 IEEE conference on computer vision and pattern recognition*. IEEE, 2009, pp. 248–255.

[35] R. P. Feynman, "O que non podo crear, non o podo comprender," Inscrición nun encerado, Caltech Images Collection, 1988, fotografado no momento do falecemento de Feynman. Arquivo e Coleccións Especiais de Caltech, identificador da imaxe 1.10-29.

[36] Wikipedia, "Neumann series," https://en.wikipedia.org/wiki/Neumann_series, 2026. [En liña]. Dispoñible en: https://en.wikipedia.org/wiki/Neumann_series

[37] J. Nocedal and S. Wright, *Numerical optimization*, 2nd ed., ser. Springer series in operations research and financial engineering. New York, NY: Springer, 2006. [En liña]. Dispoñible en: http://gso.gbv.de/DB=2.1/CMD?ACT=SRCHA&SRT=YOP&IKT=1016&TRM=ppn+502988711&sourceid=fbw_bibsonomy

[38] D. E. Rumelhart, G. E. Hinton, and R. J. Williams, "Learning representations by back-propagating errors," vol. 323, no. 6088, p. 533–536, October 1986. [En liña]. Dispoñible en: http://dx.doi.org/10.1038/323533a0

[39] S. learn developers, "roc_auc_score — scikit-learn documentation," 2026, accessed: 2026-09-02. [En liña]. Dispoñible en: https://scikit-learn.org/stable/modules/generated/sklearn.metrics.roc_auc_score.html

[40] J. Bergstra and Y. Bengio, "Random search for hyper-parameter optimization," *Journal of Machine Learning Research*, vol. 13, no. 10, pp. 281–305, 2012. [En liña]. Dispoñible en: http://jmlr.org/papers/v13/bergstra12a.html

[41] Wikipedia contributors, "Miss vaca," https://es.wikipedia.org/wiki/Miss_Vaca, 2026, Última edición: 30 de junio de 2026.

[42] I. Loshchilov and F. Hutter, "Decoupled weight decay regularization," 2017. [En liña]. Dispoñible en: https://arxiv.org/abs/1711.05101