

TRABALLO FIN DE GRAO
GRAO EN INTELIXENCIA ARTIFICIAL

**Interpretabilidade e explicabilidade
mediante técnicas de Aprendizaxe
Profundo de Caixa Blanca aplicadas ó
análise de imaxe**

Estudante: José Romero Conde

Dirección: José Rouco Maseda

Jorge Novo Buján

A Coruña, xuño de 2026.

Á miña avoa

Agradecimientos

Quero agradecer este trabalho a blablabla

Resumo

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

Abstract

Hello, here is some text without a meaning. This text should show what a printed text will look like at this place. If you read this text, you will get no information. Really? Is there no information? Is there a difference between this text and some nonsense like “Huardest gefburn”? Kjift – not at all! A blind text like this gives you information about the selected font, how the letters are written and an impression of the look. This text should contain all letters of the alphabet and it should be written in of the original language. There is no need for special content, but the length of words should match the language.

Palabras chave:

- First itemtext
- Second itemtext
- Last itemtext
- First itemtext
- Second itemtext
- Last itemtext
- First itemtext

Keywords:

- First itemtext
- Second itemtext
- Last itemtext
- First itemtext
- Second itemtext
- Last itemtext
- First itemtext

Índice Xeral

1	Introdución	1
1.1	Contexto xeral	1
1.2	Revisión pormenorizada SOTA e traballos relacionados	2
1.2.1	ISTA	2
1.2.2	Interpretabilidade no sota, <i>como?</i>	3
1.2.3	Explicabilidade no sota, <i>por que?</i>	4
1.2.4	MCR ² e ReduNet - Redes Caixa Blanca	5
1.2.5	ViT	7
1.2.6	Aprendizaxe de dicionarios	7
1.2.7	Aprendizaxe desenrolado	8
1.2.8	CRATE	8
1.2.9	Conxuntos de datos	8
1.3	Discusión	9
1.3.1	Elementos diferenciais	9
1.3.2	Oportunidades	9
1.3.3	Contribucións	9
2	Metodoloxía e planificación	10
2.1	Método de traballo	10
2.2	Recursos	10
2.2.1	Humanos	10
2.2.2	De <i>Software</i>	11
2.2.3	De <i>Hardware</i>	13
2.3	Planificación	13
3	Traballo proposto	15
3.1	Visualizacións dos mapas de atención	15
3.2	Recuperación de parches representativos	15

3.3	Segundo orden	15
3.4	Compartir U e D	15
4	Resultados	16
4.1	Resultado a - Interpretabilidade de segundo orden	16
4.2	Resultado b - Cruce de ordes	17
4.3	Resultado c	17
4.4	Discusións	17
5	Conclusións	18
5.1	TFG en sí	18
5.2	Resultados	18
5.3	Traballo futuro	18
A	Material adicional	20
	Relación de Acrónimos	22
	Glosario	23
	Bibliografía	24

Índice de Figuras

1.1	Diferenzas no procedemento enxeñeril entre o A.A. clásico e o A.P. cun exemplo de clasificación de imaxe. <i>a)</i> No enfoque clásico, a entrada (neste caso os <i>pixels</i> das imaxes) debía ser preprocesada con un ou máis métodos de P.S.D. co fin de extraer características (bordes, esquinas, patróns predefinidos ...) que logo o(s) algoritmo(s) de aprendizaxe usará(n) para predecir a saída. <i>b)</i> Na aproximación moderna, un modelo de A.P. é quen de extraer por si só as características que vai precisar para predecir a saída. Deste xeito o modelo de A.P. cumpre o rol de extracción de características e de discriminación sobre elas.	2
1.2	Funcións de activación usadas no traballo. (<i>esquerda</i>) Función identidade (<i>centro</i>) Función de umbral suave $\sigma_\epsilon(\cdot)$, parametrizada por ϵ (<i>dereita</i>) Función ReLU, nótese que a función $\sigma_\epsilon(x)$ é indentica (no dominio $\mathbb{R}^+$) a $\text{ReLU}(x - \epsilon)$.	3
1.3	Exemplos de algoritmos de explicabilidade	5
1.4	Iteración dos pasos do MCR ²	6
1.5	Arquitectura do ViT [19]. <i>a)</i> Para ser procesadas, as imaxes son recortadas en parches. Estes son proxectados ó espazo de <i>embeddings</i> e concatenados cun vector posicional (representado na Figura como un número) antes de entrar no Encoder. Xunto cos parches tamén é entrada do Encoder un vector aprendible asociado á clase. <i>b)</i> O encoder consta de dos grandes bloques residuais precedidos de normalización, o primeiro é a Atención Multicabeza [20] e o segundo un M.L.P.	7
1.6	Mostras dos conxuntos de datos. (a) Imaxe de fondo de retina con edema de disco óptico, pertencente ó conxunto de datos RFMiD. (b-c) Imaxe de fondo de retina e a súa correspondente máscara binaria anotada, pertencentes ó conxunto de datos DRIVE (d) Imaxe de mostra do conxunto de datos ImageNet	8
2.1	Esquema do contido das reunións semanais entre o alumno e os titores.	11

2.2	As comunicacións entre o portatil do alumno e o servidor seguen un bucle de sincronización.	13
4.1	blablabla	16

Índice de Táboas

Capítulo 1

Introdución

PRIMER capítulo da memoria

1.1 Contexto xeral

[NOTA: non darlle mais voltas a introdución de momento]

No contexto das sociedades da información que levamos vivindo como mínimo dende a revolución industrial, é cada vez máis evidente a importancia do [Aprendizaxe Automático \(A.A.\)](#). Esta disciplina trata de *aprender* funcións (de calquera propósito) en base a unha experiencia o un conxunto de datos (de calquera orixe). O [A.A.](#) gozou dun esplendor tanto no desenvolvemento teórico [1] como nas aplicacións (e.g. xogar as damas [2], recoñecer a fala [3] . . .) durante a segunda metade do pasado século.

Hoxe, na terceira década do século XXI atopamos que a natureza dos datos trocou, onde denantes unha representación natural dos datos era útil e con garantías de éxito, agora con datos multimodais, que xurden da interacción social é máis difícil. En particular os dominios das nosas funcións poden ser espazos moi complexos e os datos de entrada poden precisar un preprocesado particular. Se antes a disciplina de [Procesamento de Señais Dixitais \(P.S.D.\)](#) ofrecía unha serie de métodos de preprocesado (Filtrado de Kalman, Transformada de Ondas Discreta...), agora o [Aprendizaxe de Representacións \(A.R.\)](#) ofrece unha serie de métodos para *aprender* o preprocesado axeitado para a combinación de tarefa e conxunto de datos. É por isto que recentemente estase a ver un crecemento moi acelerado no [Aprendizaxe Profundo \(A.P.\)](#), unha subdisciplina do [A.A.](#) que ten como *slogan*: “Máis grande é mellor” [4, 5] e pretende solventar o problema do [A.R.](#) a través dunha sucesión de operadores non lineais coñecidos como [Rede de Neuronas Artificias \(R.N.A.\)](#), ver Figura 1.1 para máis detalles.

Pola súa banda as compoñentes das [R.N.A.](#) actuais non gozan da mesma xustificación teórica que acostumaban antaño outros algoritmos de [A.A.](#), como a Regresión Lineal ou as Máquinas de Soporte Vectorial [1]. Por tanto vivimos nun momento no que as [R.N.A.](#) reinan




Figura 1.1: Diferenzas no procedemento enxeñeril entre o A.A. clásico e o A.P. cun exemplo de clasificación de imaxe. *a)* No enfoque clásico, a entrada (neste caso os *píxels* das imaxes) debía ser preprocesada con un ou máis métodos de P.S.D. co fin de extraer características (bordes, esquinas, patróns predefinidos ...) que logo o(s) algoritmo(s) de aprendizaxe usará(n) para predecir a saída. *b)* Na aproximación moderna, un modelo de A.P. é quen de extraer por si só as características que vai precisar para predecir a saída. Deste xeito o modelo de A.P. cumpre o rol de extracción de características e de discriminación sobre elas.

o mundo das aplicacións pero sen que exista unha teoría conclusiva que as avale, ou cando menos de momento. Esta situación motivou o desenvolvemento dun marco para comprender as R.N.A., primeiro dende o punto de vista do algoritmo, é dicir *interpretabilidade* dos seus procesos de aprendizaxe e inferencia, para finalmente poder entender as decisións que toma de xeito individual e ofrecer unha xustificación a devandita resposta, é dicir, *explicabilidade* [6].

[NOTA: hai que motivar a necesidade de explicabilidade e interpretabilidade. e.g. confianza dos médicos, aiact. aquí hay motivos [7]]

1.2 Revisión pormenorizada SOTA e traballos relacionados

O traballo neste TFG móntase sobre a arquitectura CRATE (ver 1.2.8, páxina 8). Para poder exponer tanto a devandita arquitectura como as nosas aportacións, é necesaria a revisión duns conceptos previos.

1.2.1 ISTA

Un algoritmo clásico do A.A. é a Regresión Lineal, co que Carl F. Gauss empezou a teorizar e ofrecer garantías sobre o seu modelo

$$X\beta = Y + \epsilon$$

onde $\epsilon \sim \mathcal{N}(\mu, \sigma^2)$ nos albores do século XIX, chegando á coñecida forma cerrada

$$\hat{\beta} = (X'X)^{-1}X'Y.$$

A primeira regularización do modelo para facelo máis robusto chegou con ideas orixais no campo de resolución de problemas mal planteados, Andrey Tikhonov introduce a penalización segundo a norma $\mathcal{L}_2$ dos parámetros β , o cal é equivalente a asumir unha distribución Gausiana en β . O estimador ten a forma cerrada

$$\hat{\beta} = (X'X + \lambda I)^{-1} X'Y$$

onde λ controla a estrutura do conxunto de funcións [1]. Se ben esta regularización segue a usarse hoxe en día porque devandita asunción pode ser moi natural, dende o 1996 considérase o LASSO [8], que penaliza a norma $\mathcal{L}_1$ (equivalente a asumir unha distribución Laplaciana nos parámetros) e sen ter forma cerrada ofrece un estimador con ceros, é dicir o proceso de optimización de LASSO supón unha selección de características.

Como en moitos problemas de optimización de interese científico e comercial a resolución deste problema convexo por medio de métodos de punto interior pode ser infactible [9], o algoritmo ISTA atopa unha solución ó LASSO a través da iteración:

$$\beta_{t+1} = \sigma_{\epsilon}(\beta_t - \lambda X'(X\beta_t - Y))$$

onde σ_{ϵ} é a función de umbral suave (ver figura 1.2)




Figura 1.2: Funcións de activación usadas no traballo. (*esquerda*) Función identidade (*centro*) Función de umbral suave $\sigma_{\epsilon}(\cdot)$, parametrizada por ϵ (*dereita*) Función ReLU, nótase que a función $\sigma_{\epsilon}(x)$ é indentica (no dominio $\mathbb{R}^+$) a $\text{ReLU}(x - \epsilon)$.

1.2.2 Interpretabilidade no sota, como?

Un modelo de A.A. pode ofrecer claridade sobre o seu compartamento respondendo a dúas grandes preguntas: *Como* toma decisións? e *Porque* tomou unha decisión particular? Os campos de Interpretabilidade e Explicabilidade tratan de ou ben dar respostas a estas preguntas, respectivamente.

Pola súa banda, a Intelixencia Artificial Interpretable (I.A.I) crea modelos que responden á pregunta ‘*Como* toma decisións?’ de forma intrínseca. Consideremos Regresión Lineal, aínda que é un modelo ben Interpretable en xeral, se hai moitas variables regresoras, pode non

selo tanto. Nese caso podemos preferir un axuste os datos que asegure que moitos $\beta_i = 0$, desta forma á hora de interpretar o modelo podemos aforrarnos toda o análise relativo a esas variables. Esa foi a idea de LASSO [8], que instanciouse máis tarde como un operador iterativo (ver 1.2.1) e finalmente nunha R.N.A. [10, 11]. Neste caso cada capa da Rede lava a cabo unha iteración do algoritmo (ver 1.2.7).

A bondade da I.A.I recae en que aqueles (deseñadores, exeñeiros) que creen un modelo o entenden (ou poden chegar a entendelo), e por tanto o poden reparar se o considerasen. Desgraciadamente, tanto no caso da regresión lineal dispersa ou os árboles de decisión, buques insignia da I.A.I os modelos son simples. En xeral a búsqueda de interpretabilidade nun sistema conleva un decaemento no seu rendemento xeral [12]. Por outra banda, a interpretabilidade conleva unha natural explicabilidade.

[NOTA: motivar máis a necesidade de interpretabilidade zicais]

É por todo isto que estamos nun momento de necesidade de modelos de A.A. interpretables de alto rendemento, que permitan resolver as tarefas complexas.

[NOTA: falar (zicais despois) de que neste caso (crate) ‘symbolic knowledge injection and extraction’, hai extracción no sentido de que dicimos o semantica da cabeza pero non hai inxección]

1.2.3 Explicabilidade no sota, *por que?*

Intelixencia Artificial Explicable (I.A.X)

falar da fidelidad ‘the fidelity of an explanation determines the precision with which the model behavior is elucidated’

[NOTA: temos como recurso [12]]

gustárame falar mal de LIME [13] por ser unha falsedade e unha xustificación dun modelo ‘distinto’.

distinción entre local e global: explicar (modelo como un todo / modelo real VS decisións particulares modelo local), por exemplos e situar o noso traballo

tipos de aplicabilidade (o noso metodo realmente só vale para transformers) pero lime vale para todo

tipo: visualización VS feature attribution

problemas:

- Falta de métricas cuantitativas: como comparar variacións, no noso caso aplica
- escalabilidade: falar de local é caro, global as veces precisa moitos locais. no noso caso o caro é a resolución. ...desplegar
- vinculación da explicación ca acción

[NOTA: —]

A *Intelixencia Artificial Explicable (I.A.X)* ofrece mecanismos que incorporáanse sobre modelos (xa adestrados) para explicar o razoamento detrás das decisións do algoritmo. Estes poden clasificarse según locais ou globais segundo se para ofrecer a xustificación usa o modelo como un todo ou só unha parte del; e segundo se poden aplicarse a calqueira algoritmo ou precisa que este sexa parte dunha familia (e.g. sobre un modelo da familia ViT, ben poden usarse métodos de explicación xerais ou métodos exclusivos dos ViT).

Un exemplo de método explicable é LIME [13], que para ofrecer unha xustificación de porque un modelo deu unha saída cunha certa entrada, fai inferencias con entradas similares e aproxima localmente a función de decisión. Pode ofrecer explicacións relativamente útiles (ver Figura 1.3a) pero fundamentase na localidade, e usa un modelo auxiliar.

[NOTA: falar de gradcam e reciprocam [14] (teño imaxe en imaxes), dicir que no molan pq son complexos e específicos relativamente.]

Por tanto, precisamos algoritmos de explicabilidade que sexan de aplicación ou ben xeral ou cara os modelos usados agora (e.g. C.N.N., ViT ...)





Figura 1.3: Exemplos de algoritmos de explicabilidade

1.2.4 MCR² e ReduNet - Redes Caixa Blanca

Na primeira metade da pasada década viuse o esplendor dun tipo de *R.N.A.* nas que o operador principal é a convolución dun filtro ou *kernel* aprendible coa imaxe (ou ca saída doutra convolución), estas Redes chámanse *Rede de Neuronas Artificias Convolucionais (Convolutional Neural Network)* (C.N.N.). Se ben son algo explicables [15, 16], a pregunta ‘Que esta a facer esta compoñente da C.N.N.?’ en xeral só pode responderse *a posteriori*. Isto motivou ó grupo do profesor Yi Ma o desenvolvemento dunha C.N.N. como instancia do MCR² [17],

Figura 1.4: Iteración dos pasos do MCR^2

creando así unha Rede Caixa Blanca [NOTA: acronimo? mellor en inglés?].

A Maximal Coding Rate Reduction (MCR^2) é unha función obxectivo de A.R. que intenta cumprir cos seguintes obxectivos na representación no espazo de características:

[NOTA: estas tres características sacos de o artigo de CRATE pero quito a de ‘consistent’ porque penso que non ven ó caso, no libro de 2022 fala doutras tres características, pero estas parécenme máis entendibles]

- *Comprimidas*: sendo uniformemente distribuídas segundo algunhas estruturas de baixa dimensión¹ estándar que se axustan á baixa dimensionalidade intrínseca dos datos, co fin de asegurar unha codificación compacta dos datos.
- *Lineais*: as estruturas de baixa dimensión teñen unha xeometría (a anacos) lineal, co fin de facilitar a interpolación e a extrapolación no espazo de representación.
- *Dispersas*: as estruturas de baixa dimensión correspondentes a diferentes partes da distribución dos datos son estatisticamente incoherentes ou xeometricamente ortogonais, e tamén aliñadas cos eixes, co fin de asegurar unha codificación máis compacta e facilitar o procesamento posterior.

Formalmente defínese como a maximización da seguinte función:

$$\Delta R(Z|\Pi_{[K]}) = R(Z) - R^c(Z|\Pi_{[K]})$$

en [18] dicen que as redes (Transformadores) caixas brancas son as que diséñanse ‘con a estrutura dos datos de entrada en mente, representando un maridaxe entre a aproximación clásica a A.R. e o novo A.P.’

¹Como unhas gaussianas




Figura 1.5: Arquitectura do ViT [19]. a) Para ser procesadas, as imaxes son recortadas en parches. Estes son proxectados ó espazo de embeddings e concatenados cun vector posicional (representado na Figura como un número) antes de entrar no Encoder. Xunto cos parches tamén é entrada do Encoder un vector aprendible asociado á clase. b) O encoder consta de dos grandes bloques residuais precedidos de normalización, o primeiro é a Atención Multicabeza [20] e o segundo un M.L.P.

1.2.5 ViT

A arquitectura ViT (do inglés *Vision in Transformer*) [19] é unha instancia do xa coñecido Transformer [20] aplicado á vision. No seu dominio orixinal, o procesamento da linguaxe natural, o Transformer demostrou moi bo rendemento, xogando un papel moi importante na burbulla económica da IA que estamos a vivir. En particular o ViT demostrou que a convolución, a compoñente fundamental das C.N.N. xa non era necesaria² marcando así un hito na historia do A.P.. Na Figura 1.5 ilústrase a arquitectura a nivel conceptual para un problema de clasificación.

1.2.6 Aprendizaxe de dicionarios

O aprendizaxe de dicionarios é o problema de representar o vector $X \in \mathbb{R}^n$, como unha combinación $\beta \in \mathbb{R}^d$ de palabras dun dicionario $D \in \mathbb{R}^{n,d}$ de forma que preténdese minimizar

$$\|X - D\beta\|_p$$

para algún p . Este problema correspóndese cun cambio de base (e.g. Transformada de Fourier, PCA ...) no que pasamos da representación orixinal (valores RGB dos píxeles) a unha máis

²Cando menos para clasificación de imaxe de dominio xeral [21]

interesante ou representativa. Sobre este problema adoitanse engadir restriccións adicionais, por exemplo que as columnas de D sexan ortonormais, isto é $D'D = I$, e ten a implicación de que as *palabras* do *diccionario* sexan incoherentes entre sí (pola natureza dos respectivos problemas, tanto a Transformada de Fourier como PCA teñen esta propiedade). Outra restricción é penalizar o número de *palabras* cas que un pode expresarse é dicir $\|\beta\|_0$, de xeito que este novo problema sería:

$$\min \|X - D\beta\|_p + \|\beta\|_0$$

para algún p . A esta formulación coñécese como **Aprendizaxe de Dicionarios Dispersa**, e ten moitas propiedades interesantes [6] por exemplo a *decorrución* de imaxes. **[NOTA: exemplo cunha figura?]**

1.2.7 Aprendizaxe desenrolado

recurso : [22]

cada capa modela Z^l co seu modelo correspondente (conxunto de bases). conseguindo, a través delas o obxectivo global

1.2.8 CRATE

Unha alternativa a ViT onde cada capa é interpretable

1.2.9 Conxuntos de datos




Figura 1.6: Mostras dos conxuntos de datos. (a) Imaxe de fondo de retina con edema de disco óptico, pertencente ó conxunto de datos RFMiD. (b-c) Imaxe de fondo de retina e a súa correspondente máscara binaria anotada, pertencentes ó conxunto de datos DRIVE (d) Imaxe de mostra do conxunto de datos ImageNet

- **RFMiD 2.0 (2023).** [23] Recolle mostras de enfermidades raras con imaxes de alta resolución. Ademais de a etiqueta ‘san’, inclúe 48 condicións entre as que se atopan as

patoloxías vasculares (e.g. oclusións de veas e arterias, retinopatía hipertensiva, retinopatía hemorráxica, vasos tortuosos ...), diabéticas (e.g. retinopatía diabética, edema macular, manchas algodinosas, microaneurismas ...), dexenerativas ou relacionadas ca idade (e.g. dexeneración macular asociada ca idade, drusas, retinite pigmentaria, miopía ...), trastornos do nervio óptico (e.g. escavación do nervio óptico, edema do disco óptico, palidez do disco óptico, hialose asteroide ...), alteracións estruturais da retina (e.g. desprazamento da retina, burato retiniano, rotura retiniana ...), congénitas (e.g. coloboma, pregamentos corioideos, hipertensión intracranial idiopática ...) ... Polo que é de gran utilidade para o diagnóstico e caracterización destas patoloxías dado o seu nivel de precisión nas etiquetas.

- **DRIVE (2004).** [24] Diseñado para segmentación de vasos sanguíneos, inclúe 40 imaxes das súas máscaras binarias anotadas manualmente por expertos (ver Figura 1.6 (b-c)).
- **ImageNet (2009).** [25] Nace ante a necesidade dun gran conxunto de datos de imaxe natural e foi plantexado como unha xerarquía de xeito que o concepto de *clase* é multinivel, porque se ben hai animais e artefactos, ambos divídense en subcategorías recursivamente até chegar ó nivel do individuo. É dicir, preséntase o ‘labrador alemán’ non como un elemento illado pero como parte dos ‘cans’ e estes á súa vez de ‘carnívoros’, ‘placentarios’... Polo seu gran tamaño é variedade tivo un impacto notable no desenvolvemento do [A.P.](#) e as [R.N.A.](#).

1.3 **Discusión**

1.3.1 **Elementos diferenciais**

1.3.2 **Oportunidades**

1.3.3 **Contribucións**

Metodoloxía e planificación

O que queira peixes que molle o cu [26]

NESTE capítulo descríbese cómo se traballou así como os recursos involucrados e a planificación do traballo.

2.1 Método de traballo

Os primeiros esforzos adicaronse á comprensión do material. Unha vez a comprensión foi suficiente para empezar as iteracións semanais, estas consistían en sucesións de reunión (ver 2.1) e traballo individual. O traballo individual do alumno ó longo das semanas comprendía:

- **Programación:** de experimentos (isto é: adestramento de [R.N.A.](#)) e de visualizacións para poder analizar distintos aspectos das Redes adestradas.
- **Análise de resultados:** para interpretar as visualizacións e formular afirmacións ou preguntas dependendo do entendemento. En ambos casos era moi útil porque se formulaba unha afirmación, ó presentarlle ós titores ou ben comprendía porque tiña razón ou porque non a tiña; e se formulaba unha pregunta aprendía da súa resposta.
- **Lectura bibliográfica:** de temas que non plantexáronse ó principio pero foron importantes para responder ás preguntas que xurdían e en xeral comprender profundamente o tema a tratar, segundo íase presentando de forma distinta ó longo das semanas.

2.2 Recursos

2.2.1 Humanos

Este traballo foi supervisado por tres tutores ¹ que tiveron o rol directivo en canto ás ideas, responderon a pregunta ‘Qué se fai?’ e en canto o método, ‘Cómo se fai?’. O alumno tivo de

¹Un dos cales mudou de universidade durante o traballo e por tanto non figura na portada.




Figura 2.1: Esquema do contido das reunións semanais entre o alumno e os tutores.

entrada un natural papel subordinado é dicir, leu e programou o que se lle mandou. Co paso das semanas, o coñecemento e intuición que desenvolveu o alumno sobre o tema permitiulle do mesmo modo propoñer ideas e métodos, dotando ós tutores dun rol máis alto nivel.

A primeira achega dos tutores foi o punteiro á bibliografía e código necesarios para a comprensión do tema. Devandita tarefa mantivo ocupado ó alumno en soidade os primeiros meses e cando este acadou un nivel de comprensión suficiente comenzaron as reunións semanais. Estas seguían o esquema da Figura 2.1

2.2.2 De Software

A continuación listanse os recursos *Software* empregados no traballo con importancia descendente. Nótese que todo o *Software* é código aberto e nalgúns casos código libre.

- **Python:** ² a linguaxe por defecto para escribir os programas do traballo. Funcionalmente é conector das librerías mencionadas xa que se ben por si só Python non é tan útil para a práctica de *A.P.*, funciona como un fabuloso pegamento.
- **PyTorch:** ³ a librería por defecto de *A.P.* hoxe en día que permitiunos facer modificacións, inspeccións e adestramentos sobre a *R.N.A.*, o cal corresponde co *grosso* do traballo.

²Python Software Foundation License Version 2 (PSF-2.0)

³BSD 3-Clause License

- **einops:** ⁴ é un paquete adicado á manipulación axil a nivel de código de tensores. Como a disciplina de A.P. esencialmente baséase neso, o paquete axilizou o desenvolvemento á vez que fixo o código máis lexible é fácil de manter ou asegurar a súa correctitude.
- **draw.io (diagrams.net):** ⁵ a expresión gráfica é moi importante á hora de comunicar conceptos complexos, polo que nos informes semanais e no presente documento os esquemas e diagramas realizáronse con este conveniente programa de escritorio.
- **Matplotlib:** ⁶ a librería por defecto para as gráficas e figuras xeradas de xeito programático con Python.
- **NumPy:** ⁷ é a librería que da soporte ós tipos de dato de Matplotlib polo que fai de punto en común entre o código experimental desenvolto en PyTorch / einops e o código de figuras desenvolto en Matplotlib.
- **Bash:** ⁸ cando o programa (ou *script*) ía ser suficientemente pequeno, o alumno considerou á linguaxe Bash moito máis elegante e apropiada. Notar que estrictamente estrictamente non fixo falta sair de Python e por tanto a decisión ten unha compoñente de gusto persoal.
- **rsync:** ⁸ para ambos sentidos da sincronización retratada na Figura 2.2 foi de gran utilidade este programa GNU.
- **Vim:** ⁹ para a edición de arquivos de texto. En particular, a codificación de programas, a escritura da memoria ou a esporádica modificación dalgún arquivo de configuración.
- **tmux:** ¹⁰ é un multiplexor de terminais, é dicir permite acceder a múltiples sesións de terminal simultaneamente nunha única xanela. É útil para executar máis dun programa de liña de comandos ó mesmo, en particular, Vim para a edición de arquivos e Python para a execución dos mesmos.
- **latexmk:** ¹¹ para a compilación da memoria, segundo as recomendacións do equipo de desenvolvemento da plantilla da memoria da FIC [27].




Figura 2.2: As comunicacións entre o portátil do alumno e o servidor seguen un bucle de sincronización.

2.2.3 De Hardware

Fíxose uso do portátil do alumno para o desenvolvemento do código así como dun servidor cedido polo Grupo VARPA que conta cunha gráfica NVIDIA RTX A6000 ó que o alumno podía conectarse de xeito remoto. Ó desenvolver os programas no seu portátil, o alumno debía sincronizarse co servidor para que o segundo tivese o código do primeiro, e o primeiro os artefactos do segundo (ver Figura 2.2).

2.3 Planificación

As fases do traballo foron:

- Presentación, por parte dos titores, do marco xeral do traballo así como punteiros a recursos bibliográficos e de código.
- Lectura bibliográfica e comprensión do código de referencia.
- Comezo das interaccións segundo o esquema da Figura 2.1.
- Nova tarefa: segmentar con venas usando CRATE e máis o conxunto de datos DRIVE (ver 1.6). Ali consideramos o sistema de supervisión (convolucionar a imaxe con gaussianas con desviacións típicas $\sigma_i = 2^i \times 0.5 \quad \forall i \in \{0 \dots n\}$ pero finalmente usamos a version naive)

⁴MIT License

⁵Apache License 2.0

⁶Matplotlib License (BSD-style license based on the PSF License)

⁷BSD 3-Clause License

⁸GNU General Public License Version 3 (GPL-3.0-or-later)

⁹Vim License

¹⁰ISC License

¹¹GNU General Public License Version 2 or later (GPL-2.0-or-later)

- Proposición do segundo orden, motivada teoricamente e a nivel experimental **[NOTA: en retrospectiva ambas motivacións orixinais eran cuestionables]**. A cal, pola sua parte motivou tanto o cambio de tarefa (predicción de ollo san - non san no conxunto de datos RFMiD) como a consideración de uso de Linformer **[NOTA: que quedou en nada]**. Ademais considerouse o cruce (adestrar cun orde e facer inferencia con outro), que cualitativa e cuantitativamente demostrou non funcionar para Imagenet.
- Proposición de compartir U e D .
- Investigación dos parches da capa lineal de entrada ó transformer, co obxectivo de invertirla red **[NOTA: non fun capaz de invertirla, principalmente por descoñecemento e complexidade]**. Probouse a adestrar primeiro esa capa, a regularizala con distintas penalizacións e varias (bastantes) combinacións (primeiro adestrar so a primeira capa con e sin regularizacions e logo conxelala, adestrar con regularizacions . . .)
- Comparativa en Imagenet da nosa red (ambas proposicións) ca de referencia
- Estas tarefas víronse asociadas á programación de *scripts* de visualización e redación de memorias semanais, de xeito totalmente paralelo.
- Redacción da memoria.

Traballo proposto

O^{LA}

3.1 Visualizacións dos mapas de atención

[NOTA: decir que foi posible non grazas a un proceso complexo como DINO [28] se non grazas a natureza interpretable caixa branca de CRATE]

3.2 Recuperación de parches representativos

3.3 Segundo orden

3.4 Compartir U e D

O^{LA}

4.1 Resultado a - Interpretabilidad de segundo orden




Figura 4.1: blablabla

adestrado / inferencia	primeiro orden		segundo orden	
	acc@1	acc@5	acc@1	acc@5
primeiro orden	0.5260	0.7645	0.0010	0.0052
segundo orden	0.0010	0.0055	0.4721	0.7160

4.2 Resultado b - Cruce de ordes

4.3 Resultado c

4.4 Discusións

- Introducción: limitacións e oportunidades.
- Desenvolvemento
- Conclusións

Conclusións

DERRADEIRO capítulo da memoria, onde se presentará a situación final do traballo, as conclusións aprendidas, a relación coas competencias da titulación en xeral e a mención en particular, posibles liñas futuras,...

5.1 TFG en sí

Teño que dala sensación de que traballei dabondo

5.2 Resultados

5.3 Traballo futuro

Apéndices

Material adicional

EXEMPLO de capítulo con formato de apéndice, onde se pode incluír material adicional que non teña cabida no corpo principal do documento, suxeito á limitación de 80 páxinas establecida no regulamento de TFGs.

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique

neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

Relación de Acrónimos

A.A. Aprendizaxe Automático. 1, 2

A.P. Aprendizaxe Profundo. 1, 5

A.R. Aprendizaxe de Representacións. 1

C.N.N. Rede de Neuronas Artificias Convolucionais (*Convolutional Neural Network*). 3

MCR² Maximal Coding Rate Reduction. 3

P.S.D. Procesamento de Señais Dixitais. 1

R.N.A. Rede de Neuronas Artificias. 1–3, 5

Glosario

explicabilidade Cualidade dun sistema de toma de decisións xunto con ferramentas auxiliares ou non de xustificar as súas decisións. Responde á pregunta: Porqué se tomou esta decisión?. [2](#)

interpretabilidade Cualidade intrínseca dun sistema de toma de decisións que permite coñecer, de xeito que os seus compoñentes están xustificadas e enténdese o seu rol. [2](#)

Bibliografía

- [1] V. N. Vapnik, *The nature of statistical learning theory*. Springer-Verlag New York, Inc., 1995.
- [2] A. L. Samuel, “Some studies in machine learning using the game of checkers,” *IBM Journal of Research and Development*, vol. 3, no. 3, pp. 210–229, July 1959.
- [3] L. R. Rabiner, “A tutorial on hidden markov models and selected applications in speech recognition,” *Proceedings of the IEEE*, vol. 77, no. 2, pp. 257–286, 1989.
- [4] A. Krizhevsky, I. Sutskever, and G. E. Hinton, “Imagenet classification with deep convolutional neural networks,” vol. 60, no. 6, p. 84–90, May 2017. [En línea]. Disponible en: <http://dx.doi.org/10.1145/3065386>
- [5] K. Simonyan and A. Zisserman, “Very deep convolutional networks for large-scale image recognition,” in *International Conference on Learning Representations*, 2015.
- [6] J. Wright and Y. Ma, *High-Dimensional Data Analysis with Low-Dimensional Models: Principles, Computation, and Applications*. Cambridge University Press, January 2022. [En línea]. Disponible en: <http://dx.doi.org/10.1017/9781108779302>
- [7] S. Verma, A. Lahiri, J. P. Dickerson, and S.-I. Lee, “Pitfalls of explainable ml: An industry perspective,” 2021. [En línea]. Disponible en: <https://arxiv.org/abs/2106.07758>
- [8] R. Tibshirani, “Regression shrinkage and selection via the lasso,” *Journal of the Royal Statistical Society: Series B (Methodological)*, vol. 58, no. 1, pp. 267–288, 01 1996. [En línea]. Disponible en: <https://doi.org/10.1111/j.2517-6161.1996.tb02080.x>
- [9] A. Beck and M. Teboulle, “A fast iterative shrinkage-thresholding algorithm for linear inverse problems,” *SIAM Journal on Imaging Sciences*, vol. 2, no. 1, pp. 183–202, 2009.
- [10] K. Gregor and Y. LeCun, “Learning fast approximations of sparse coding,” in *Proceedings of the 27th International Conference on International Conference on Machine Learning*, ser. ICML’10. Madison, WI, USA: Omnipress, 2010, p. 399–406.

- [11] A. Szlam, K. Gregor, and Y. LeCun, “Fast approximations to structured sparse coding and applications to object classification,” 2012. [En línea]. Disponible en: <https://arxiv.org/abs/1202.6384>
- [12] M. Garouani, J. Mothe, A. Barhrhouj, and J. Aligon, “Investigating the duality of interpretability and explainability in machine learning,” 2025. [En línea]. Disponible en: <https://arxiv.org/abs/2503.21356>
- [13] M. T. Ribeiro, S. Singh, and C. Guestrin, “”why should i trust you?”: Explaining the predictions of any classifier,” 2016. [En línea]. Disponible en: <https://arxiv.org/abs/1602.04938>
- [14] S.-Y. Byun and W. Lee, “Vit-reciprocam: Gradient and attention-free visual explanations for vision transformer,” 2023. [En línea]. Disponible en: <https://arxiv.org/abs/2310.02588>
- [15] M. D. Zeiler and R. Fergus, “Visualizing and understanding convolutional networks,” 2013. [En línea]. Disponible en: <https://arxiv.org/abs/1311.2901>
- [16] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra, “Grad-cam: Visual explanations from deep networks via gradient-based localization,” 2016. [En línea]. Disponible en: <https://arxiv.org/abs/1610.02391>
- [17] K. H. R. Chan, Y. Yu, C. You, H. Qi, J. Wright, and Y. Ma, “Redunet: A white-box deep network from the principle of maximizing rate reduction,” 2021. [En línea]. Disponible en: <https://arxiv.org/abs/2105.10446>
- [18] Y. Yu, T. Chu, S. Tong, Z. Wu, D. Pai, S. Buchanan, and Y. Ma, “Emergence of segmentation with minimalistic white-box transformers,” 2023. [En línea]. Disponible en: <https://arxiv.org/abs/2308.16271>
- [19] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, and N. Houlsby, “An image is worth 16x16 words: Transformers for image recognition at scale,” 2020. [En línea]. Disponible en: <https://arxiv.org/abs/2010.11929>
- [20] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, “Attention is all you need,” 2017. [En línea]. Disponible en: <https://arxiv.org/abs/1706.03762>
- [21] X. Chen, C.-J. Hsieh, and B. Gong, “When vision transformers outperform resnets without pre-training or strong data augmentations,” 2021. [En línea]. Disponible en: <https://arxiv.org/abs/2106.01548>

- [22] V. Monga, Y. Li, and Y. C. Eldar, “Algorithm unrolling: Interpretable, efficient deep learning for signal and image processing,” 2019. [En línea]. Disponible en: <https://arxiv.org/abs/1912.10557>
- [23] S. Panchal, A. Naik, M. Kokare, S. Pachade, R. Naigaonkar, P. Phadnis, and A. Bhange, “Retinal fundus multi-disease image dataset (rfmid) 2.0: A dataset of frequently and rarely identified diseases,” *Data*, vol. 8, no. 2, 2023. [En línea]. Disponible en: <https://www.mdpi.com/2306-5729/8/2/29>
- [24] J. Staal, M. Abramoff, M. Niemeijer, M. Viergever, and B. van Ginneken, “Ridge-based vessel segmentation in color images of the retina,” *IEEE Transactions on Medical Imaging*, vol. 23, no. 4, pp. 501–509, 2004.
- [25] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and L. Fei-Fei, “Imagenet: A large-scale hierarchical image database,” in *2009 IEEE conference on computer vision and pattern recognition*. IEEE, 2009, pp. 248–255.
- [26] Instituto Cervantes. (2026) O que algo quere, algo lle custa. Centro Virtual Cervantes. [En línea]. Disponible en: <https://cvc.cervantes.es/lengua/refranero/Ficha.aspx?Par=58652&Lng=2>
- [27] L. M. Castro, “modelo-tfg-fic: Modelo de memoria de tfg da facultade de informática (fic) da universidade da coruña,” <https://gitlab.com/lauramcastro/modelo-tfg-fic>, 2020, gitLab repository, accessed 2026-06-14.
- [28] M. Caron, H. Touvron, I. Misra, H. Jégou, J. Mairal, P. Bojanowski, and A. Joulin, “Emerging properties in self-supervised vision transformers,” 2021. [En línea]. Disponible en: <https://arxiv.org/abs/2104.14294>